游戏中的 Elo 与匹配机制

胜率能否计算、“Elo 感”从何而来、与模型训练的关系

研究报告

研究一：文献、厂商披露与专利　研究二：胜率的计算

研究三：连败与“Elo 感”　研究四：训练视角

2026 年 10 月

推导与模拟代码见仓库 `code/`，原始研究笔记与核查记录见 `research_notes/`，
待核对来源见 `docs/TO_VERIFY.md`。

摘要

玩家口中的“ELO 机制”混合了两件事：系统怎样估计实力（评分），以及系统怎样安排对局（匹配）；不少玩家怀疑匹配在“控胜率”。本文分四项研究回答：评分与匹配有哪些研究、厂商披露和专利；不干涉匹配时胜率能否计算、与什么有关；诚实的系统会不会制造连败与“连胜后连败”的“Elo 感”；从训练模型的角度看，目标是胜率还是实力。方法上，本文通读评分与匹配的学术文献、十余家厂商的开发者文章与白皮书、24 件美国授权专利的权利要求和两起诉讼的材料，为每条陈述标注证据性质；在 1v1、团队和 8 人自由混战下推导闭式公式，并用固定随机种子的模拟验证。

研究一。评分的统计基础已经成熟（Elo 即对数似然上的在线随机梯度），但完整公开评分模型的只有微软系游戏。厂商普遍采用“隐藏分负责匹配、可见段位另算”，承认延迟、新手、组排、补位等非实力规则，否认按连胜连败安排对局。EA 的专利权利要求和 EOMM、EnMatch 等论文表明，以留存为目标的匹配被研究过并部署于未具名游戏，报告的效应不大（如 EOMM 每轮留存约 +0.7%）；主流排位是否使用，没有公开证据。

研究二。胜率能算，但它是实力相对实际对手的位置。随机匹配下 $W = \Phi\big((s-\mu)/\sqrt{\sigma_d^2+\tau^2}\big)$，$\tau = 200$ 时最强、最弱 10% 的长期胜率约为 83% 和 17%；按分匹配下，恒等式“胜率 = 平均预测胜率 + 评分净变化 /($K\times$ 局数)”把实力兑换成评分，十分位胜率被压到 42%–58% ($\sigma_q = 100$)。“每局五五开”指系统预测胜率而非真实实力相等：$K = 16$ 时 90% 的这类对局真实胜率在 38%–62% 之间。团队把个人优势稀释约 $1/\sqrt{n}$ 到 $1/n$；8 人局的基准取决于“胜”的定义；分辨 52% 与 50% 约需 4,900 局。

研究三。纯随机已足以产生“Elo 感”：胜率五成的玩家打 100 局，81% 会遇到 5 连败，31% 会遇到“4 连胜紧接 4 连败”。诚实 Elo 只带来很小的均值回归（1v1、$K = 32$ 时 5 连胜后约低 3 个百分点），单人要 5 万局以上才能察觉；连败触发的“上头”可使“5 连胜紧接 5 连败”约翻倍。操纵若存在，可靠的指纹在匹配输入（连胜后对手评分偏高），而不在胜负序列。

研究四。评分系统的标签是胜负、输出是胜率、潜参数是实力，Elo 的 K 就是学习率。收敛后胜负仍不断产生，对匹配模型而言接近抛硬币，但五五开的对局信息量最大；检验应以冻结的收敛模型为零假设看残差。对酒馆战棋 AI，宜用名次似然训练、用冻结参照池评估。

局限。部分来源只读到摘要或转述，已逐条标注待核对；全部模拟数字来自理想化模型，量级随参数而变。本文能说明这些现象“无需操纵即可解释”，不能证明没有操纵。

关键词： Elo；匹配机制；胜率；连败；实力波动；参与度优化匹配；酒馆战棋

目录

摘要 **1**

引言 **7**

第一章 研究一：评分与匹配机制的文献、厂商披露与专利 **12**

1.1 评分与匹配是两个问题 13

1.1.1 所有模型共用一个潜变量框架 13

1.2 评分模型的谱系：从成对比较到贝叶斯滤波 15

1.2.1 成对比较：Thurstone、Zermelo、Bradley–Terry 与 Luce 15

1.2.2 Elo：把成对比较变成在线记分 16

1.2.3 Glicko 与 Glicko-2：给评分加上误差棒 17

1.2.4 TrueSkill：因子图上的团队、多人与平局 18

1.2.5 全历史方法与解析近似：TTT、WHR 与 Weng–Lin 19

1.2.6 TrueSkill 2：先找出假设错在哪，再改模型 19

1.2.7 多人名次与非传递性 20

1.2.8 Elo 的统计行为：近十年的理论结果 21

1.3 匹配机制本身的研究 23

1.3.1 公平与信息量：同一个目标 23

1.3.2 等多久：等待时间与匹配质量的在线权衡 23

1.3.3 组队：把一维评分分成两队 24

1.3.4 以参与度为目标的匹配 24

1.3.5 动态难度调整：单人游戏里的先例 26

1.3.6 连胜、连败与流失：实证证据 26

1.4 各游戏的专门研究 27

1.4.1 《光环》与《战争机器》 28

1.4.2 CS:GO：研究的是职业比赛，不是官方匹配 28

1.4.3 PUBG 与大逃杀：评估指标与团队聚合 29

1.4.4 英雄联盟、Dota 2 与同类 MOBA 29

1.4.5 王者荣耀 29

1.4.6 国际象棋：最透明的数据 30
1.4.7 星际争霸 II 30
1.4.8 炉石传说与酒馆战棋：几乎没有学术研究 30
1.5 中文学术文献 31
1.6 学术研究小结：什么已经清楚，什么有争议，什么还没人做 32
1.7 厂商披露：逐家阅读原文 33
1.7.1 Riot Games：《英雄联盟》《英雄联盟手游》与 VALORANT . . . 33
1.7.2 Valve：Dota 2 与 CS:GO / CS2 34
1.7.3 Blizzard：《守望先锋 2》、炉石传说与酒馆战棋、《星际争霸 II》 35
1.7.4 Activision：《使命召唤》的匹配博客与三份白皮书 36
1.7.5 大逃杀与其他射击游戏：Respawn、Epic、KRAFTON、Embark 38
1.7.6 公开了模型的系统：微软 TrueSkill、《光环：无限》与国际象棋平台 39
1.7.7 腾讯：《王者荣耀》 40
1.7.8 网易及其他厂商 40
1.7.9 横向比较：官方承认了什么、否认了什么 41
1.8 “每局双方约五五开”到底是什么意思 42
1.9 专利：权利要求实际保护了什么 44
1.9.1 Activision：按“诱导购买”匹配，以及多因素打分 45
1.9.2 EA：以留存为目标的匹配、以“对局质量”为目标的匹配，以及动态难度 45
1.9.3 微软：TrueSkill 与“按等待时间调阈值” 46
1.9.4 Riot：按行为数据和游戏时段组队 47
1.9.5 中国公司 47
1.10 诉讼与监管 49
1.10.1 Zajonc 诉 EA：动态难度集体诉讼（2020—2021） 49
1.10.2 孙千和诉腾讯：“中国游戏算法诉讼第一案”（2024—2026） . . . 49
1.10.3 监管：算法推荐规定与游戏规章 51
1.11 证据强度小结：哪些已证实，哪些被否认，哪些仍未知 51
1.12 本章小结：两条线索合起来看 53

第二章 研究二：不干涉匹配时胜率能否计算 55
2.1 实力、评分与胜率是三个不同的量 55
2.1.1 实力是只在比较中才有意义的潜变量 55
2.1.2 胜率是实力对对手分布的平均 56
2.1.3 评分是带噪声、带滞后、带刻度的估计 56
2.2 “每局五五开”是预测胜率五五开，不是实力五五开 58

2.2.1 匹配器拉平的是估计实力，等价于预测胜率 50% 58
2.2.2 真实胜率围绕 50% 分布，宽度由评分误差决定 58
2.2.3 团队游戏：总和相等，个人可以很悬殊 58
2.2.4 这不是关于长期胜率的陈述 59
2.3 1v1 随机匹配：胜率由实力百分位和运气比例决定 59
2.4 1v1 按分匹配：实力被兑换成评分 61
2.4.1 一条恒等式说明实力优势去了哪里 61
2.4.2 评分的稳态误差约为 $9.3\sqrt{K}$，衰减需要 30–65 局 62
2.4.3 匹配窗口决定天梯两端偏离 50% 多少 63
2.4.4 新号与回流：强玩家从 1500 起步要几十局才能追回 64
2.4.5 严格按分匹配会拉伸评分刻度（理想模型的性质） 65
2.4.6 可见段位与隐藏分 67
2.5 每局人数：团队稀释个人优势，多人局改变“胜”的基准 67
2.5.1 团队游戏：加和模型约按 $1/\sqrt{n}$ 稀释，均值模型约按 $1/n$ 67
2.5.2 多人自由混战：Plackett–Luce 给出名次概率 69
2.6 实力有波动时，期望胜率仍可计算，误差更大 70
2.6.1 独立的单局波动：曲线变平，评分刻度同比例压缩 70
2.6.2 自相关的状态：评分只吸收一部分，窗口胜率成段波动 70
2.6.3 长期进步：评分滞后，胜率高出期望得分约 $\lambda v/K$ 71
2.7 统计不确定性：分辨 52% 和 50% 需要约 4,900 局 73
2.8 小结：胜率能不能算、和什么有关 74

第三章 研究三：诚实系统会不会制造“Elo 感” 77
3.1 玩家说的“Elo”是什么：三种假说和它们各自的预测 77
3.2 纯随机下的连败与“连胜后连败” 78
3.2.1 最长连败有精确分布 79
3.2.2 Schilling 近似：最长连败约为 $\log_{1/q}(np)$ 80
3.2.3 “连胜后连败”的精确计数 81
3.2.4 不必连续：滑动窗口里的低谷 81
3.2.5 Miller–Sanjurjo 偏差：自查战绩时的陷阱 81
3.2.6 构成效应：全服合并统计为什么也会骗人 83
3.3 诚实 Elo 的均值回归：有，但很小 83
3.3.1 机制：连胜后评分过冲 83
3.3.2 线性高斯近似：连胜 k 局后的胜率 83
3.3.3 它让长连败更少，“连胜后连败”几乎不变 84
3.3.4 效应大小对排队窗口敏感，但定性结论不变 85
3.3.5 单个玩家几乎察觉不到 86

3.4 实力波动模型：上头、状态与疲劳 86
3.4.1 (a) 逐局独立噪声：没有记忆就没有连串 86
3.4.2 (b) AR(1) 状态：评分会吸收大部分慢变化 88
3.4.3 (c) 两状态隐马尔可夫：状态好与状态差 89
3.4.4 (d) 上头：连败触发的自激 89
3.4.5 (e) 局内疲劳与休息 90
3.4.6 五种形式的比较 91
3.4.7 一个玩家要打多少局才能看出来 92
3.4.8 怎样用一个玩家的历史拟合这些模型 94
3.5 认知偏差：为什么正常的随机看起来像被安排 95
3.6 操纵会留下什么指纹 96
3.7 8 人名次游戏：酒馆战棋里的“Elo 感” 98
3.8 小结 99

第四章 研究四：训练视角——目标是胜率还是实力 100
4.1 同一个“胜率”在训练里有三种角色 100
4.2 Elo 就是在线逻辑回归 101
4.2.1 一次 Elo 更新是一步随机梯度下降 101
4.2.2 TrueSkill：学习率随不确定度自动变化 102
4.2.3 固定 K 的代价：噪声球与跟踪滞后 102
4.3 实力不可辨识，所以只能在数据空间评估 104
4.4 收敛之后：胜负照样产生，只是像抛硬币 104
4.4.1 完美模型在五五开对局上的三个下限 104
4.4.2 最难预测的对局，恰恰最有信息 105
4.4.3 能不能直接用胜负说明问题：把收敛模型当零假设 106
4.5 匹配让胜负难预测，但外部模型仍能预测 109
4.6 自博弈：胜率是目标，进步要对固定参照来量 110
4.6.1 和自己打永远五五开 110
4.6.2 AlphaStar 的联赛：把胜率当成课程的控制变量 112
4.6.3 非传递性：一个标量 Elo 不够用 112
4.7 同一结构在大模型训练里再次出现 113
4.8 当目标换成留存：胜负数据混入系统意图 114
4.9 对酒馆战棋 AI 的含义 114
4.10 小结 116

结论与展望 118

参考文献 121

附录 A 推导与模拟细节 140
A.1 第一章学术部分的推导与公式 140
A.2 厂商披露与专利部分的检索方法与核算 143
A.3 第二章的推导与模拟参数 144
A.4 第三章的推导与模拟参数 149
A.5 第四章的推导 154

引言

几乎每一款有排位的对战游戏里，都流传着“ELO 机制”的说法：连赢几把就会被塞进“坑队友”的队伍，系统要把每个人的胜率拉回五成，低分段的人“出不去”。这些说法把两件不同的事混在一起：系统怎样估计一个人有多强（评分），以及系统怎样安排谁和谁打（匹配）。本文把这个话题拆成四项研究，分别回答“有什么研究和披露”“胜率能不能算”“诚实的系统会不会让人有被操纵的感觉”“从训练模型的角度看，目标究竟是胜率还是实力”。

研究问题

用户提出的原始问题如下（原文照录）：

> 我想看看一项研究的情况：各种游戏中的 elo 机制。请分 4 个研究进行。
> 1. 首先是文献调研，通用的 elo 或者匹配机制有没有人研究？各个游戏专门的呢？游戏公司有披露的相关机制吗？有公司的专利或者论文吗？
> 2. 然后是对于一个游戏，假设结果只有输或者赢，在不干涉任何匹配的情况下，能数学计算出胜率吗？和什么有关呢？比如一把游戏的人数，匹配的时候的游戏段位或者分数，玩家实力（这个也很难说是什么，毕竟胜率，游戏分数都能体现一部分实力），如果实力有波动那胜率还能计算吗？
> 3. 在上面情况下，有没有可能造成会有 elo 的感觉？（什么是 elo？多次连败？连胜后连败？）
> 4. 脱离 elo 来讲这和训练模型或许有一定关系，target 究竟是胜率还是实力？训练到模型稳定后有没有胜负数据？或许可以直接来说明胜负情况。

用户随后追问：厂商常说“每局双方约五五开”，这指的是*实力*五五开，还是*胜率*五五开？此外，用户要求用实力波动模型展示“上头”，并在合适处说明结论对《炉石传说》酒馆战棋这类 8 人名次游戏意味着什么（用户在做酒馆战棋 AI）。

四项研究与章节的对应

- **研究一（第一章）**：文献与一手材料调研。前半部分综述评分模型、匹配机制和各游戏的学术研究；后半部分逐家阅读厂商的开发者文章和白皮书、24 件美国授权专利的权利要求、两起诉讼的案卷与报道，并按证据强度分级。

- **研究二（第二章）**：在“只有输赢、匹配不被操纵”的前提下推导胜率。按 1v1 随机匹配、1v1 按分匹配、团队、8 人自由混战和实力波动分节给出闭式公式，并用模拟验证。
- **研究三（第三章）**：把玩家口中的“Elo”形式化为可检验的假说，计算纯随机和诚实 Elo 下的连败与“连胜后连败”，用五种实力波动模型（含“上头”）看什么会放大它们，再给出操纵会留下的统计指纹。
- **研究四（第四章）**：从训练模型的角度重述评分系统：标签、输出与潜参数各是什么，收敛后的胜负数据还有多少信息，怎样用胜负数据做检验，以及自博弈和大模型评测中的同一结构。

最后的“结论与展望”把四项研究串成一条主线，并说明两项后续工作：收集社交平台上的“控胜率”说法并用第三章的模型检验，以及分析用户本人的对局数据。推导与模拟参数集中在附录（附录 A）。

问题速答

下表把用户的每个子问题对应到一句话回答和正文位置。带“延伸”字样的是正文顺带回答、用户未直接问到的问题。

问题速答：子问题、一句话回答与正文位置

问题	一句话回答	见
研究一：文献、披露与专利		
通用的 Elo 或匹配机制有人研究吗?	有，且成熟：Elo、Glicko、TrueSkill 等评分模型的统计性质已有严格结果；匹配研究覆盖公平与信息量、等待时间、分队和以留存为目标的匹配。	第 1.2 节与 1.3 节
各个游戏专门的呢?	有但不均衡：只有微软系游戏公开了完整评分模型，其余多为外部研究者在公开数据上的行为研究；酒馆战棋没有评分或匹配研究。	第 1.4 节
游戏公司有披露吗?	有：普遍是“隐藏分负责匹配、可见段位另算”，承认一组非实力规则（延迟、新手与回流、组排、补位、行为分、机器人），否认按连胜连败安排队友。	第 1.7 节
有公司的专利或论文吗?	有：EA 的留存匹配专利家族、Activision 的“诱导购买”匹配专利，以及 EOMM、EnMatch、CUPID 等论文；专利不证明部署，论文的部署游戏不具名。	第 1.9 节与第 1.3.4 节
研究二：不干涉匹配时的胜率		
只有输赢、不干涉匹配，能算出胜率吗?	能算期望：随机匹配下 $W=\Phi\big((s-\mu)/\sqrt{\sigma_d^2+\tau^2}\big)$；按分匹配下由恒等式“胜率 = 平均预测胜率 + 评分净变化 /($K\times$ 局数)”决定，长期趋于 50%。	第 2.3 节与第 2.4.1 节
和一局的人数有关吗?	有：团队中个人优势约按 $1/\sqrt{n}$（加和模型）到 $1/n$（均值模型）稀释；8 人局的基准率取决于“胜”的定义（第一名 12.5%，前四 50%）。	第 2.5.1 节与 2.5.2 节

问题	一句话回答（续）	见
和匹配时的段位或分数有关吗?	只通过对手分布起作用：评分落后于实力时胜率偏高（重置为 1500 的高手前 50 局约 77.5%），天梯两端因人少偏离 50%；可见段位叠加了保底和加分，不宜直接用来估计。	第 2.4.3 节、2.4.4 节与 2.4.6 节
“实力”是什么？胜率、分数各体现多少?	实力是只在比较中有意义的潜变量，可操作地定义为“对固定参照池的胜率”；胜率是实力相对实际对手的位置，评分是带噪声、滞后和刻度的估计。	第 2.1 节与 4.3 节
实力有波动，胜率还能算吗?	能算期望，但误差更大：独立波动让曲线变平；自相关的状态让百局胜率的方差变为二项分布的约 1.6–3.7 倍；持续进步让胜率高出预测约 $\lambda v/K$。	第 2.6 节
（延伸）多少局才能看出差别?	区分 52% 与 50% 约需 4,900 局（双侧 5%、功效 80%）；8 人局用完整名次比用前四率省样本。	第 2.7 节
追问：每局“五五开”		
每局双方约五五开，是实力五五开还是胜率五五开?	是系统预测的胜率五五开，即双方估计实力相等；真实实力并不相等（$K = 16$ 时 90% 的“五五开”对局真实胜率在 38%–62% 之间），长期胜率接近 50% 是收敛的结果，多家厂商明说不是目标。	第 1.8 节与 2.2 节
研究三：“Elo 感”		
上述情况下会有“Elo 的感觉”吗?	会，不需要操纵：胜率五成的玩家打 100 局，81% 会遇到 5 连败；诚实的按分匹配只带来很小的均值回归。	第 3.2 节与 3.3 节
什么是 Elo?	学术上是一套评分更新公式；玩家说的“ELO 机制”指被怀疑的操纵（强制五成、连胜惩罚、Elo 地狱），本文把它们写成可检验的假说。	第 1.2.2 节与第 3.1 节
多次连败?	很常见：100 局中最长连败的期望约 6 局，1000 局内出现 10 连败的概率约 39%；诚实 Elo 下连败使对手变弱，长连败反而略少。	第 3.2.1 节与第 3.3 节
连胜后连败?	纯随机下 100 局内出现“4 连胜紧接 4 连败”的概率为 31%；诚实 Elo 只让 5 连胜后下一局胜率低约 3 个百分点（1v1，$K = 32$）；真正放大它的是连败触发的“上头”（“5 连胜紧接 5 连败”约翻倍）。	第 3.2.3 节与 3.4.4 节
“上头”等实力波动怎样建模?	写成 $s_t = s + u_t$ 的五种形式（独立噪声、AR(1)、两状态、上头、疲劳）：慢变化大多被评分吸收，只有快速、由失败触发的上头显著增加长连败。	第 3.4 节
（延伸）若有操纵，会留下什么痕迹?	在匹配输入（连胜后对手评分显著偏高、在触发阈值处跳变）和系统自己的预测里，而不在胜负序列里；对称的“控五成”反而让长连败更少。	第 3.6 节
研究四：训练视角		
这和训练模型有关吗?	有：Elo 更新恰是对数损失上的一步随机梯度下降，K 是学习率；TrueSkill 是学习率随不确定度变化的贝叶斯版本。	第 4.2 节
target 是胜率还是实力?	评分系统里，标签是胜负，输出是胜率，被学到的潜参数是实力；只有在自博弈中，胜率本身才是优化目标。	第 4.1 节
训练稳定后还有胜负数据吗?	有，照样产生、照样推动评分；只是对负责匹配的模型而言每局接近抛硬币，而五五开的对局恰恰 Fisher 信息最大。	第 4.4 节
能直接用胜负说明胜负情况吗?	能，但要把冻结的收敛模型当零假设，检验“实际减预测”的残差；朴素的“连败后胜率”检验在诚实 Elo 下也会误报。	第 4.4.3 节
（延伸）对酒馆战棋 AI 意味着什么?	用名次似然训练，用冻结参照池评估；前四率提高 2 个百分点约需 4,900 局，平均名次改进 0.1 约需 4,100 局。	第 4.9 节

记号

全文统一使用下列记号；只在某一节使用的局部记号在首次出现处定义。

记号表

记号	含义
s_i	玩家 i 的真实实力（潜变量，Elo 刻度）
μ, τ	群体实力的均值、标准差（默认 $\tau = 200$）
R_i 或 $R_{i,t}$	系统对实力的估计（评分、隐藏分、MMR）
$F(x) = 1/(1 + 10^{-x/400})$	Elo 胜率曲线
$c = \ln 10/400$	Elo 曲线在 0 处的斜率常数，$F'(0) = c/4$
E	系统预测胜率 $F(R_i - R_j)$
p	真实单局胜率 $F(s_i - s_j)$
$y \in \{0, 1\}$	单局结果（Elo 文献中的 S）
K；T	K 因子；局数
n；N	每队人数；每局人数（自由混战）
σ_q	排队/匹配噪声（匹配窗口宽度）
σ_e	评分围绕实力的稳态误差标准差
λ	评分刻度相对实力刻度的伸缩系数
u_t	实力波动（状态），$s_{i,t} = s_i + u_t$
Φ	标准正态分布函数

两处局部记号需要提醒：AR(1) 状态的自回归系数在第二章记为 ϕ、在第三章记为 ρ（第三章的 ϕ 另指疲劳斜率）；第四章为避免与群体标准差混淆，把 TrueSkill 的不确定度写作 ς，第一章沿用原论文的 σ。

证据标签

每条事实性陈述后标注来源性质：

- 【文献】：同行评审论文或公司技术报告；
- 【官方】：开发商官方博客、白皮书、员工以官方身份的公开发言，以及法院案卷、法规文本；
- 【专利】：专利文献，只说明申请并获得过保护，不说明已部署；
- 【社区】：玩家、自媒体、第三方工具、百科，未经证实；
- 【本项目】：本项目自己的推导或模拟，正文或图注给出参数。

“无需操纵即可解释”不等于“已证明没有操纵”；全文的措辞都保持这个区分。

方法与局限

来源。 检索与阅读集中在 2026 年 10 月 18—19 日。核心来源读的是全文或原页面，包括 TrueSkill 与 TrueSkill 2、Glickman 的评分综述、Aldous 等 Elo 理论论文、EOMM、EnMatch、CUPID、QuickSkill、Kang 等的流失研究、Rosenthal、Sapienza、Chowdhary、Miller–Sanjurjo、AlphaGo Zero 与 AlphaStar 的作者稿、OpenAI Five、Chatbot Arena；Riot、Valve、Blizzard、Activision、Respawn、343、KRAFTON 的官方文章与白皮书；24 件美国授权专利的首页与独立权利要求（USPTO 全文图像，经 OCR）；Zajonc 诉 EA 的联邦法院案卷。只读到摘要、题录或二手转述的来源，正文在对应位置加了“待核对”脚注，并逐条列入仓库的 `docs/TO_VERIFY.md`（约 40 条），主要是：1960 年以前的经典论文（只核对了题录）、付费墙后的论文（如 Kou 等、Deng 等、Chen–Elmachtoub–Lei、几篇心理学论文）、知网上的中文学位论文、腾讯 2018 年官网原文（依据媒体摘录）、王者荣耀案判决书（未公开，依据多家媒体报道），以及中国专利的检索。

模型。 本文所有【本项目】数字都来自理想化模型：一维实力，逻辑斯蒂胜率曲线，正态分布的群体（$\tau = 200$），固定 K 的 Elo，按“评分加噪声排序后相邻配对”的简化匹配器；没有组排、位置、延迟、版本更新和玩家流失。“上头”“疲劳”等波动模型的参数是示意值，不是从真实数据估计的。因此具体数字会随参数变化，可靠的是公式给出的依赖关系与各机制之间的相对大小。代码与缓存在仓库的 `code/` 目录，每张图的图注写明了参数。

第一章　研究一：评分与匹配机制的文献、厂商披露与专利

直接回答

通用的 Elo 或匹配机制有人研究吗？有，而且相当成熟。评分一侧从 Thurstone、Bradley–Terry 的成对比较一路发展到 Elo、Glicko、TrueSkill 与 TrueSkill 2，近十年还有对 Elo 收敛性和误差的严格结果：Elo 是对数似然上的在线随机梯度，固定 K 只能在“追得快”与“抖得小”之间取舍（第 1.2 节）。匹配一侧研究公平与信息量、等待时间、分队，以及以留存为目标的匹配（第 1.3 节）。

各游戏专门的研究呢？有，但很不均衡。只有《光环》《战争机器》等微软系游戏由设计者完整公开了评分模型；腾讯、网易、EA 的论文只透露部分做法；外部研究者只能用公开数据研究玩家行为，看不到匹配器本身；酒馆战棋没有任何评分或匹配研究（第 1.4 节）。

游戏公司有披露吗？有。Riot、Valve、Blizzard、Activision、Respawn、343、腾讯、网易等都发布过开发者文章或白皮书，共同结构是“隐藏分负责匹配、可见段位负责成长感”。官方承认的非实力因素是一组固定类别（延迟与排队时间、新手与回流、组排聚合、补位、行为分、休闲模式机器人）；被明确否认的是“读取连胜连败安排队友”“强制 50% 胜率”“按消费匹配”（第 1.7 节）。各家所说的“每局五五开”指系统预测的胜率，不是真实实力相等（第 1.8 节）。

有公司的专利或论文吗？有。EA 两个专利家族的权利要求写明按“流失风险”“预测留存时长”组局，Activision 有按“诱导购买”匹配的专利；EOMM、EnMatch 等公司论文公开了以参与度为目标的匹配算法，报告的效应都不大（第 1.9 节与第 1.3.4 节）。专利不证明部署，论文中的部署游戏不具名；没有任何厂商公开过可供第三方复核的匹配日志，王者荣耀案的法院也只裁判了“能否要求公开”（第 1.10 节）。

本章分两部分。前半部分（第 1.1 节至第 1.6 节）综述学术研究：先区分“评分”与“匹配”，再依次讨论评分模型的谱系、匹配机制本身的研究、各游戏的专门研究和中文文献。后半部分（第 1.7 节至第 1.11 节）逐家阅读厂商的一手材料：开发者博客与白皮书、厂商对“五五开”的原话、美国授权专利的权利要求、诉讼与监管，最后按证

据强度把说法分成“已证实、被否认、未知”。两部分各有小结（第 1.6 节与 1.11 节）；本章末（第 1.12 节）把两条线索合起来，说明后三章为什么转向“诚实的系统会产生什么”。

1.1　评分与匹配是两个问题

中文玩家口中的“ELO 机制”通常同时指两件事：系统怎样给人打分，以及系统怎样安排对手和队友。学术文献把它们分开研究。**评分**（rating，又称技能评级 skill rating）回答“这个人有多强”：从一局局胜负里估计一个看不见的实力，属于统计推断。**匹配**（matchmaking）回答“让谁和谁打”：拿着评分、排队时间、网络延迟等信息决定一局的人选和分队，属于优化与机制设计。Elo、Glicko、TrueSkill 都是评分系统；“按分匹配”（skill-based matchmaking, SBMM）、“参与度优化匹配”（engagement-optimized matchmaking, EOMM）是匹配策略。玩家怀疑的“控胜率”如果存在，只能发生在匹配这一层，评分公式本身只做记账。

两者又互相缠绕：匹配器用的是评分 R_i 而不是真实实力 s_i，评分系统看到的对局又是匹配器挑出来的。TrueSkill 的作者把匹配称为一种“序贯实验设计”，并记录了排行榜的反作用：有人为保分停玩、挑对手甚至作弊[1]【文献】。本章前半部分依次介绍评分模型（第 1.2 节）、匹配机制本身的研究（第 1.3 节）、各游戏的专门研究（第 1.4 节）和中文文献（第 1.5 节），并小结学术研究（第 1.6 节）；厂商披露、专利与诉讼见后半部分（第 1.7 节起）。

1.1.1　所有模型共用一个潜变量框架

几乎所有评分模型都假设：玩家 i 有实力 s_i，每局发挥一个随机的“表现” p_i，表现高者获胜，

$$p_i = s_i + \varepsilon_i, \qquad \mathbb{P}(i \text{ 胜 } j) = \mathbb{P}(p_i > p_j) = G(s_i - s_j), \tag{1.1}$$

G 是噪声差 $\varepsilon_j - \varepsilon_i$ 的分布函数。噪声为正态 $\mathcal{N}(0, \beta^2)$ 时得到 Thurstone 的“比较判断律”第五种情形（Case V），

$$\mathbb{P}(i \text{ 胜 } j) = \Phi\!\left(\frac{s_i - s_j}{\sqrt{2}\,\beta}\right); \tag{1.2}$$

噪声为极值（Gumbel）分布时，两人之差服从逻辑斯蒂分布，得到 Bradley–Terry 模型。Glickman 的国际象棋评分综述正是这样向棋手解释两者的区别[2]【文献】。国际象棋惯用的 Elo 曲线是以 10 为底的逻辑斯蒂函数，

$$F(x) = \frac{1}{1 + 10^{-x/400}} = \frac{1}{1 + e^{-cx}}, \qquad c = \frac{\ln 10}{400} \approx 0.005756, \tag{1.3}$$

所以 400 分只是刻度：分差 400 意味着胜负赔率 $10:1$，期望得分 $F(400) \approx 0.909$；逻辑斯蒂的一个“标准单位”对应 $400/\ln 10 \approx 173.7$ 分，Glicko-2 的内部刻度用的正是 173.7178[3]【文献】。

正态与逻辑斯蒂在实践中几乎分不出来：Glickman 转述 Stern 的结论，分析成对比较数据时两种假设“几乎没有差别”，选逻辑斯蒂主要因为数学上好处理[2,4]【文献】。本项目逐格抄录了 FIDE 现行条例的“分数 ↔ 分差”换算表[5]，发现它与“每人单局表现标准差 200”的正态曲线最多相差 19 分，而与 Elo 逻辑斯蒂曲线在尾部相差可达 121 分（期望得分 0.99 处，表中分差 677，正态 658，逻辑斯蒂 798；图 1.1，换算见附录 A.1.1）【本项目】。可见 FIDE 至今保留着 Elo 原书的正态假设（Glickman 1995 年把 FIDE 归入 Bradley–Terry 一类，对其现行换算表并不准确）。三条曲线之差不足 1.5 个百分点，对游戏无关紧要；真正影响预测的是图中第四条曲线：评分本身不确定时，预测应向 50% 收缩（第 1.2.3 节）。

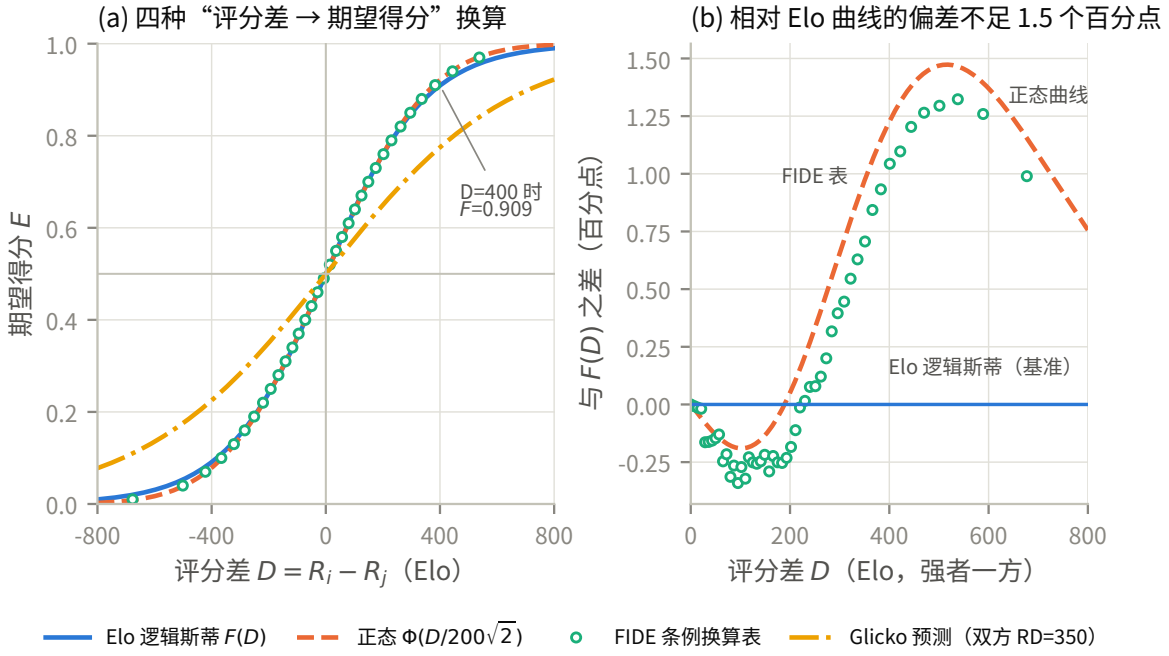


图 1.1： 四种“评分差 → 期望得分”换算。(a) Elo 逻辑斯蒂曲线、单人表现标准差 200 的正态曲线、FIDE 等级分条例（2024 年 3 月 1 日起施行）8.1.1 换算表，以及 Glicko 在双方评分偏差 RD= 350（未定级）时的预测式；(b) 正态曲线和 FIDE 表与逻辑斯蒂曲线之差。前三者相差不足 1.5 个百分点，FIDE 表贴近正态曲线；评分不确定时，Glicko 把预测明显拉向 50%。纯解析计算。

式 （1.1）有三处简化，后来的评分研究基本就是逐条放松它们：只有两人、只有输赢（团队、多人名次、平局怎么办）；s_i 固定且已知（估计有多不确定、实力怎样随时间变）；一个标量概括实力（有“石头剪刀布”式克制怎么办）。匹配研究则多出第四个问题：只知道 R_i 时应该优化什么。

要点

- 评分是推断（估计 s_i），匹配是决策（选对手、分队）；“控胜率”若存在，只能在匹配层。
- 主流模型都基于“实力 + 随机表现”框架；正态与逻辑斯蒂曲线相差不足 1.5

个百分点，分差 400 对应约 90.9% 的期望得分。

1.2　评分模型的谱系：从成对比较到贝叶斯滤波

图 1.2 把本章引用的主要文献按年份排开。主线很清楚：1920—1950 年代的心理测量学提供了成对比较模型；Elo 在 1950 年代末把它变成国际象棋的在线记分规则；1990 年代末起 Glickman 和微软研究院先后引入不确定性、团队与多人名次；2010 年代后期起，一方面把更多行为数据放进模型（TrueSkill 2），另一方面回头严格分析 Elo 的统计性质和一维评分的边界。

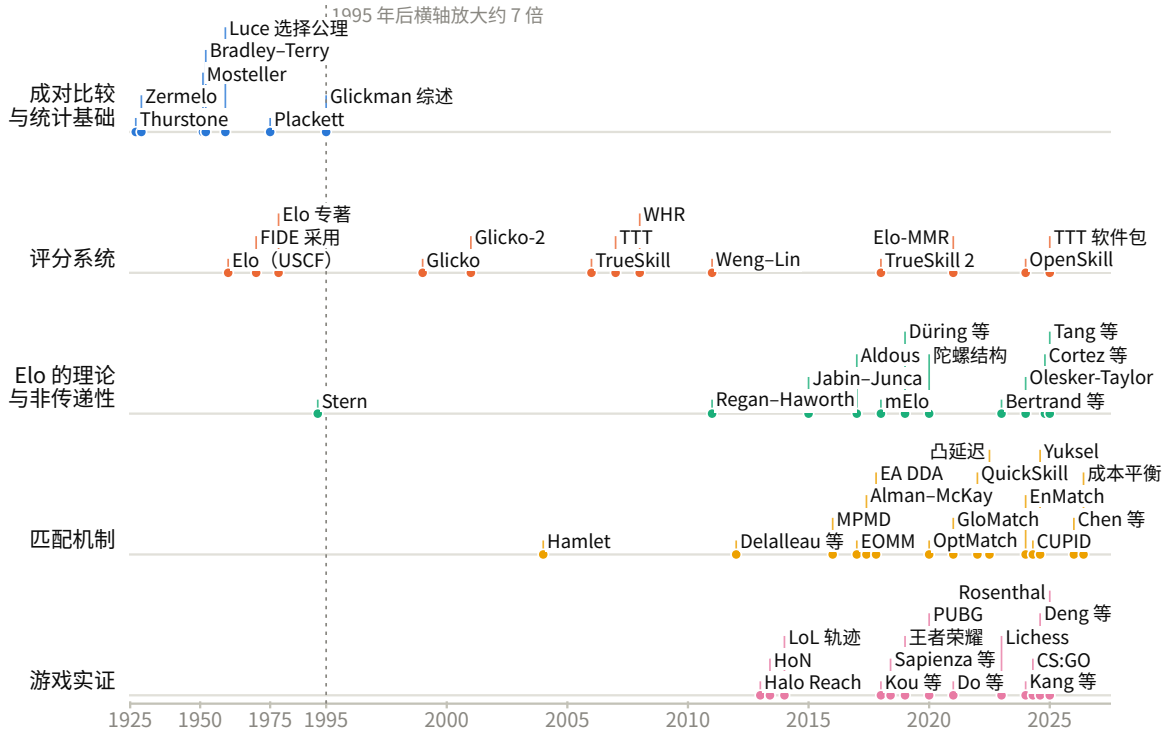


图 1.2： 评分模型与匹配机制研究的时间线。每个点是本章引用的一篇文献或一个标志性事件，年份取正式发表年（预印本取首次公开年）。1995 年后横轴放大约 7 倍：近十年的论文集中在匹配机制、Elo 理论和游戏实证三条线上。

1.2.1　成对比较：Thurstone、Zermelo、Bradley–Terry 与 Luce

Thurstone 1927 年提出“比较判断律”：被试对刺激的感受是正态随机量，比较时取较大者；各刺激方差相同、彼此不相关时即式 (1.2)[6]【文献】。Mosteller 1951 年给出该情形下刻度值的最小二乘解[7]【文献】，后人合称 Thurstone–Mosteller 模型。逻辑斯蒂一支更早出现在棋类中：Zermelo 1929 年的论文题目就是“把锦标赛成绩的计算写成概率论中的极大值问题”，他用今天称为 Bradley–Terry 的模型从循环赛结果推算

棋手实力[8]【文献】[1]。Bradley 与 Terry 1952 年独立提出[9]【文献】

$$\mathbb{P}(i \text{ 胜 } j) = \frac{\pi_i}{\pi_i + \pi_j} = \frac{1}{1 + e^{-(\theta_i - \theta_j)}}, \qquad \theta_i = \ln \pi_i. \tag{1.4}$$

Luce 1959 年的选择公理把它推广到从集合 S 中选一项，$\mathbb{P}(i \mid S) = w_i / \sum_{j \in S} w_j$，即“选 i 不选 j 的相对几率与集合里还有谁无关”[10]【文献】。Plackett 1975 年把逐个挑出第一名、第二名……的过程连乘，得到整个名次排列 π 的概率

$$\mathbb{P}(\pi) = \prod_{k=1}^{N} \frac{w_{\pi(k)}}{\sum_{m=k}^{N} w_{\pi(m)}}, \tag{1.5}$$

即 Plackett–Luce 模型[11]【文献】。它是 8 人名次类游戏（自由混战、大逃杀、自走棋）最自然的模型：一局 8 人的名次相当于连续 7 次“从剩下的人里选出最强者”。这些模型都是静态的；游戏需要每局更新、允许实力变化的在线版本，Elo 是第一个。

1.2.2　Elo：把成对比较变成在线记分

据 Glickman 的综述，第一个数值化的国际象棋评分是 Anton Hoesslinger 1948 年在德国提出的 Ingo 系统；1950 年代美国棋联（USCF）用过 Ken Harkness 的系统，它缺乏统计基础，甚至允许一个人全输却涨分。USCF 1960 年改用 Arpad Elo 的系统，FIDE 1970 年采用[2]【文献】，Elo 1978 年出版专著[12]【文献】。Elo 用当前评分算出期望得分 $E_{ij} = F(R_i - R_j)$，赛后按“实际减期望”修正：

$$R_i \leftarrow R_i + K\Big(S_i - \sum_{j} E_{ij}\Big), \tag{1.6}$$

S_i 是一个周期（如一次锦标赛）内的总得分（胜 1、和 0.5、负 0）。双方 K 相同时一方涨多少、另一方就跌多少，整个分池总分守恒。

K 有两种直观读法。Glickman 的读法：式（1.6）近似于“赛前评分”与“本次表现分”的加权平均，对一次 4 轮比赛，$K = 32$ 相当于给旧评分 94.7%、本次表现 5.3% 的权重（$K = 24$ 为 96.2% 与 3.8%，$K = 16$ 为 97.5% 与 2.5%），所以 Elo 评分是历史表现的指数加权移动平均[2]【文献】。统计学习的读法：式（1.6）恰好是对 Bradley–Terry 对数似然做一步随机梯度上升（下框），K 是学习率乘常数 c；Szczecinski 与 Djebbi[13]、Olesker-Taylor 与 Zanetti[14]、Tang 等[15] 都以此为出发点【文献】，第四章从训练模型的角度详细讨论（第 4.2 节）。

Elo 更新即随机梯度上升

设 $y \in \{0, 1\}$ 表示 i 是否胜 j，$E = F(R_i - R_j)$，单局对数似然 $\ell = y \ln E + (1 - y) \ln(1 - E)$。由 $F'(x) = c\,F(x)\big(1 - F(x)\big)$ 得 $\partial \ell / \partial R_i = c\,(y - E)$。以步长 η 做一

[1] 待核对：本次未读到原文全文；本节经典文献（Thurstone、Mosteller、Zermelo、Bradley–Terry、Luce、Plackett）只核对了题录，模型形式依据 Glickman 1995、TrueSkill 论文与 Aldous 2017 的转述。

步梯度上升，$R_i \leftarrow R_i + \eta\, c\,(y - E)$；令 $K = \eta\, c$ 即得式 (1.6)。对 R_j 的梯度恰为相反数，所以更新零和。K 越大，跟踪实力变化越快，评分围绕实力的抖动也越大。【本项目】

FIDE 现行条例（2024 年 3 月 1 日起施行）的 K：新棋手前 30 局及 18 岁以下且低于 2300 分者为 40，低于 2400 分为 20，一旦达到 2400 则永久为 10；一个周期内 K 乘局数不超过 700[5]【官方】。TrueSkill 论文的对照实验所用高斯版 Elo 相当于 $K = 24$，作者称之为“良好而稳定的动态”[1]【文献】。

Elo 有三个被充分记录的问题。**其一，用估计值预测会过度自信。**式 (1.3) 描述的是真实实力之间的关系，系统手里只有带误差的评分。Glickman 分析 1991—1993 年 8300 多局 USCF 比赛，发现按公布评分算出的期望得分系统性地高估了高分一方：例如真实 1900 分的棋手遇到公布 1700、真实实力一半时间 1600 一半时间 1800 的对手，代入公式得 0.76，实际平均只有 $(0.64 + 0.85)/2 = 0.745$[2]【文献】。Szczecinski 2026 年把它写成定理：由于估计噪声，用于排名和用于预测的模型必须解耦，预测曲线要更平；他发现六年的 FIFA 男足排名中绝大多数国家队尚未收敛[16]【文献】。这正是第二章“系统预测胜率 E 与真实胜率 p 不同”的来源（第 2.2 节；训练视角下的“过度自信”见第 4.3 节）。**其二，封闭分池会通缩。**只要玩家平均实力随时间上升、系统又不凭空加分，实力不变的老玩家就会不断输分给进步中、评分偏低的新玩家；USCF 在 1970 年代中期就观察到平均评分下滑，后来改设“评分地板”[2]【文献】。FIDE 2023 年承认近十年的改动造成通缩，提出给 2000 分以下（约 85% 的注册棋手）一次性加 $0.4 \times (2000 - R)$ 分、把最低等级分从 1000 提到 1400[17]【官方】。游戏中的“赛季重置”“保底分”可以看作同一问题的工程补丁。**其三，高端是否通胀。**Regan 与 Haworth 用高深度引擎评估每步棋的质量拟合“内在评分”，发现同一等级分对应的走子质量不随年代变化，“几乎没有评分通胀”[18]【文献】。

1.2.3　Glicko 与 Glicko-2：给评分加上误差棒

Glickman 的例子：两名 1700 分棋手对局，一人刚结束多年休赛，另一人每周都下；USCF 的 Elo 下胜者涨 16 分、负者跌 16 分，但回归者的 1700 本来就不可信，他赢了应该涨得更多，常客则不该跌太多[19]【文献】。Glicko 因此给每人两个数：评分 r 和评分偏差（rating deviation, RD），即 r 的标准差，推导基于动态成对比较的状态空间模型[20]【文献】。计算上有三个要点（完整公式见附录 A.1.2）：未定级玩家取 $r = 1500$、RD$= 350$，不下棋时 RD 逐期增大（上限 350）；期望得分用 $g(\mathrm{RD}) = \left(1+3q^2\mathrm{RD}^2/\pi^2\right)^{-1/2}$（$q = \ln 10/400$）折减分差，对手越不确定、期望越接近 0.5，这正是对上述过度自信的修正（图 1.1(a) 的点划线）；更新步长随自己的 RD 增大，相当于自动调节的 K，且更新不再零和[19]【文献】。

Glicko-2 再加一个“波动率” σ 描述实力本身变化的剧烈程度：长期稳定后突然打出远超预期的成绩，σ 变大、RD 随之放大，评分就能更快追上[21]【文献】。Glickman

建议系统常数 τ 取 0.3—1.2，每个评分周期平均至少 10—15 局[3]【文献】。波动率可以看作对实力波动的粗糙建模，第三章的“上头”与状态起伏正属此类（第 3.4 节）。Lichess 使用 Glicko-2[22]【文献】；CS:GO 被认为使用一个未公开的 Glicko-2 变体，但这一说法来自社区资料[23]【社区】。

1.2.4　TrueSkill：因子图上的团队、多人与平局

TrueSkill 为团队与多人在线游戏设计，部署在 Xbox Live 上，作者称它是迄今最大规模的贝叶斯推断应用之一[1]【文献】。它要解决 Elo 和 Glicko 都不处理的两个问题：结果常常是团队的，而匹配需要个人评分；一局可能有两个以上的队伍，结果是名次排列而非一胜一负。

模型为：实力先验 $s_i \sim \mathcal{N}(\mu_i, \sigma_i^2)$，表现 $p_i \sim \mathcal{N}(s_i, \beta^2)$，队伍表现是成员表现之和 $t_j = \sum_{i \in A_j} p_i$，名次由 t_j 的大小决定；相邻名次之差在平局边际 ε 以内算平局，ε 由观测平局率按 $\mathbb{P}(\text{平局}) = 2\Phi\big(\varepsilon/(\sqrt{n_1+n_2}\,\beta)\big) - 1$ 反推（n_1, n_2 为两队人数）。推断在因子图上用期望传播（矩匹配）完成，每局后把后验近似为高斯作为下一局的先验，运行时间不超过简单 Elo 更新的两倍。两人（两队）一胜一负时后验有闭式（推导见附录 A.1.3）：记 $c^2 = 2\beta^2 + \sigma_{\mathrm{w}}^2 + \sigma_{\mathrm{l}}^2$，$t = (\mu_{\mathrm{w}} - \mu_{\mathrm{l}})/c$，$a = \varepsilon/c$，

$$
\begin{aligned}
&\mu_{\mathrm{w}} \leftarrow \mu_{\mathrm{w}} + \frac{\sigma_{\mathrm{w}}^2}{c}\, v(t,a), \qquad \mu_{\mathrm{l}} \leftarrow \mu_{\mathrm{l}} - \frac{\sigma_{\mathrm{l}}^2}{c}\, v(t,a),\\
&\sigma_k^2 \leftarrow \sigma_k^2\Big[1 - \frac{\sigma_k^2}{c^2}\, w(t,a)\Big], \qquad v(t,a) = \frac{\varphi(t-a)}{\Phi(t-a)}, \qquad w(t,a) = v(t,a)\big(v(t,a) + t - a\big),
\end{aligned}
\tag{1.7}
$$

w、l 表示胜方与负方，$k \in \{\mathrm{w}, \mathrm{l}\}$，$\varphi$ 为标准正态密度。爆冷时 t 为负、v 很大，更新幅度大；与 Glicko 一样，步长正比于自己的方差。

TrueSkill 用“平局概率”衡量一局是否势均力敌：两人的匹配质量是 $\varepsilon \to 0$ 时平局概率与其最大可能值之比（附录 A.1.4），

$$
q_{\text{draw}} = \sqrt{\frac{2\beta^2}{2\beta^2 + \sigma_i^2 + \sigma_j^2}}\, \exp\!\left(-\frac{(\mu_i - \mu_j)^2}{2\,(2\beta^2 + \sigma_i^2 + \sigma_j^2)}\right). \tag{1.8}
$$

作者指出，一局的质量由结果的不可预测性决定，所以“匹配的目标与寻找信息量最大的对局是一致的”。Xbox 360 Live 取 $\mu_0 = 25$、$\sigma_0 = 25/3$、$\beta = \sigma_0/2$，每局附加动态方差 $(\sigma_0/100)^2$；排行榜显示保守估计 $\mu - 3\sigma$；系统每天处理数十万局[1]【文献】。

作者用 Bungie 提供的《光环 2》公测数据比较 TrueSkill 与高斯版 Elo（表 1.1），并提醒有匹配器参与时最小可达错误率可能高达 50%，因此设计了“挑战集”：各系统挑出自认为最势均力敌的 20% 对局交给对方预测。挑战集上 TrueSkill 全面占优；但在 4 对 4 的 Small Teams 模式中，全集上 Elo 略好，按匹配质量排序时 TrueSkill 也不如 Elo，作者认为“可能是因为这一模式多为夺旗玩法，违反了团队表现可加的假设”[1]【文献】。这是 TrueSkill 作者自己承认“团队 = 成员之和”可能失效，比 TrueSkill 2

的车队数据（第 1.2.6 节）早 12 年。作者展示的两名高分玩家约 10 局收敛（信息论下限约 5 局），Elo 收敛缓慢，但这只是两个示例。论文还记录了新玩家起初连续输球、把整体评分分布压到先验之下的现象，与 Glickman 描述的通缩是同一回事。

表 1.1：《光环 2》公测数据上的预测错误率（%，越低越好）。挑战集为对方系统认为最势均力敌的 20% 对局。数据摘自 Herbrich 等[1]；Weng–Lin 一列摘自 Weng 与 Lin[24]（Bradley–Terry 全配对算法，同一数据、同一指标）。

模式	人数	Elo	TrueSkill	Weng–Lin	挑战集 Elo	挑战集 TrueSkill
Free for All	8 人混战	32.14	30.82	30.59	38.30	35.64
Small Teams	4 对 4	34.92	35.23	33.97	42.55	37.17
Head to Head	1 对 1	33.24	32.44	32.53	40.57	30.83
Large Teams	8 对 8	39.49	38.15	37.30	44.12	29.94

1.2.5　全历史方法与解析近似：TTT、WHR 与 Weng–Lin

Elo、Glicko、TrueSkill 都只向前传递信息。TrueSkill 2 的作者举例：6 名初始相同的玩家依次进行 A 胜 B、C 胜 D、E 胜 F、B 胜 C、D 胜 E，逐局更新会让 B 与 D、C 与 E 的评分完全相同，而五局合看，顺序显然是 A>B>C>D>E>F[25]【文献】。TrueSkill Through Time（TTT）把每人每年的实力用随机游走串起来，在整个时间序列上做平滑而非滤波；作者用 ChessBase 约 350 万局、跨 150 年的数据发现整体棋力在上升（这与 Regan 和 Haworth 的“无通胀”不矛盾：前者估计绝对水平，后者检验刻度是否漂移），并发现为每名棋手估计“逼和能力”能明显提高预测力[26]【文献】。2025 年 Landfried 与 Mocskos 发布了 TTT 的 Julia、Python 和 R 实现[27]【文献】。

Coulom 的全历史评分（WHR）基于动态 Bradley–Terry 模型和维纳过程，直接对整段评分历史求精确的最大后验估计[28]【文献】。在 KGS 围棋服务器 1080 万局的数据上（测试集 233 万局），预测正确率依次为 Elo 55.12%、Glicko 55.52%、TrueSkill 55.54%、Bayeselo 55.67%、衰减历史 55.70%、WHR 55.79%：WHR 最好，但各方法相差不到 0.7 个百分点，而 WHR 在训练集上耗时 252 秒，Elo 只要 0.4 秒。

Weng 与 Lin 用 Stein 恒等式推出团队、多队排名的解析更新式（附录 A.1.5），免去 TrueSkill 的迭代消息传递[24]【文献】：在同一份《光环 2》数据上错误率与 TrueSkill 相当（表 1.1），运行时间 1.2 秒对 13 秒，代码不到 100 行对 500 多行。实现这些算法的开源库 OpenSkill 在作者自报的一个 Overwatch 小数据集上准确率反而低于 TrueSkill（87.56% 对 92.44%），优势在速度[29]【文献】。

1.2.6　TrueSkill 2：先找出假设错在哪，再改模型

TrueSkill 2 是微软研究院与《战争机器》开发商 The Coalition 合作的技术报告（未经同行评审），也是公开文献中对一款商业射击游戏评分系统描述最完整的一份[25]

【文献】。工作室的要求包括：评分必须是单个数字以兼容现有匹配器；激励必须相容，不能让玩家为刷分而损害队友。方法上，每项修改都由一个“指标”驱动：把玩家按某个特征分组，比较实际胜率与模型预期胜率，出现系统性偏差才改模型。数据是 343 Industries 提供的《光环 5》自 2015 年发售以来的全部对局，用发售后 2300 万局训练、其后 300 万局测试。主要修改有：

1. **车队偏移**。按玩家所在车队（预先组队的朋友）人数分组，经典 TrueSkill 的预期胜率远低于实际：4 人车队实际 57%、预期 52%，8 人实际 68%、预期 49%，10 人以上实际 89%、预期 67%（图 1.3）。作者的结论是“关于车队的假设是错的：车队的实力应大于成员之和，且效应随车队规模增大”，并提到《光环 5》和《战争机器 4》的部分模式因此禁止大车队，另一些游戏强制车队只匹配车队，代价是缩小匹配池。修正是让表现服从 $\mathcal{N}\big(s_i + \text{squadOffset}(\text{车队人数}), \beta^2\big)$。
2. **经验效应**。新玩家实际胜率 45%、预期 49%：最初几局进步最快。修正是让实力的随机游走带随局数变化的正漂移，相当于“每局无论胜负都加一点分”。
3. **个人统计与其他**。上一局每分钟击杀数最低组实际胜率 43%、预期 48%，最高组实际 59%、预期 50%；TrueSkill 2 让击杀、死亡数依赖于表现变量并强制单调，以免玩家为凑数字改变打法。中途退出按投降处理；各模式评分（相关系数约 0.6）共享一个“基础实力”。

这些修改把测试集准确率从 52% 提到 68%（指预测获胜队伍或首名平局，可选项为队伍数加一，不是二选一）。模型还故意不用“几点上线”“和谁组队”等与实力相关的信息，因为“激励应当是把游戏打好，而不是挑特定时间、和特定队友排队”。《战争机器 4》自 2016 年发售起使用 TrueSkill 2：实时在线更新，每个排位赛季前用 TTT 对全部历史批量重算；社交与合作模式中的电脑机器人按难度各当作一名实力固定的“玩家”，为人类评分提供固定参照[25]【文献】。

1.2.7　多人名次与非传递性

8 人一局、只看名次的游戏有三种建模办法：Plackett–Luce（式 (1.5)），Weng–Lin 给出了它的在线更新；TrueSkill 把 N 名玩家按表现排序、只连接相邻名次，《光环 2》的 8 人自由混战即如此处理[1]【文献】；以及 Ebtekar 与 Liu 的 Elo-MMR[30]【文献】。Elo-MMR 每轮先根据名次和他人评分估计每人本轮的“表现”，再把表现当作观测更新信念；名字中的 MMR 指 Massive（计算量线性）、Monotonic（激励相容，想提高评分的人永远不会想故意表现差）、Robust（单轮变化有界）。作者证明了这些性质（并指出 TrueSkill 被认为满足前两条但未经证明，且不满足稳健性），处理 Codeforces 30 多万名有评分用户、1000 场比赛不到一分钟，比现行系统快一个数量级，预测精度相当或更好。这三种模型都可直接用于《炉石传说》酒馆战棋一类游戏，但公开文献中没有任何一篇用酒馆战棋数据检验过它们（第 1.4.8 节）；这类游戏的“胜率”定义也要另说（第 2.5.2 节）。

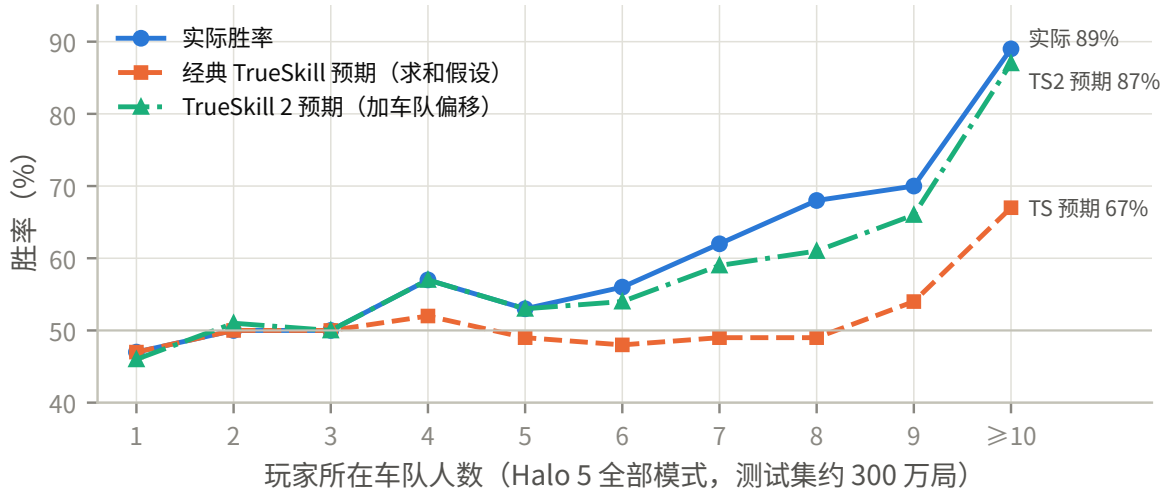


图 1.3: 《光环 5》测试集中车队人数与胜率。经典 TrueSkill 按“队伍实力 = 成员之和”给出的预期胜率在 4 人以上车队明显偏低；加入车队偏移后，TrueSkill 2 的预期接近实际。数据逐格抄自 Minka 等[25] 第 6 节两张表（原文第二张表中 6 人车队实际胜率印作 55，此处取第一张表的 56）。

式 (1.1) 还隐含了传递性。Balduzzi 等指出，Elo 在“石头剪刀布”式循环博弈中没有预测力，还可以被操纵：往数据里加入大量它能打赢的对手副本即可抬高其评分[31]【文献】。他们用组合 Hodge 分解把胜负矩阵分成传递与循环两部分，提出多维 Elo (mElo) $\hat{p}_{ij} = \sigma\big(r_i - r_j + \mathbf{c}_i^{\top} \Omega\, \mathbf{c}_j\big)$（$\mathbf{c}_i$ 为“克制向量”，Ω 反对称）；在 7 个 AlphaGo 变体加 Zen 的对战数据上，二维版本把与经验胜率矩阵之差的 Frobenius 范数从 0.85 降到 0.35。Czarnecki 等论证真实游戏的策略空间像“陀螺”，顶端接近传递、中段循环最多[32]【文献】；Bertrand 等证明 Elo 即使在简单的传递博弈中也可能提取不出正确的传递分量[33]【文献】。反方向的证据同样重要：Tang、Wang 与 Jin 发现多数真实对局数据集都显著偏离 Bradley–Terry 假设，但 Elo 的胜率预测仍常胜过 mElo 等复杂模型，原因是 Elo 作为在线梯度下降在设定错误时仍有“无悔”保证，而真实数据太稀疏[15]【文献】。对游戏而言，英雄、卡组造成的克制确实存在，单一 MMR 只是投影；但在每对玩家只交手几次的天梯数据上，一维评分仍是合理的折中。

1.2.8　Elo 的统计行为：近十年的理论结果

Aldous 2017 年称 Elo 是“应用概率中被忽视的课题”[34]【文献】。他证明随机配对下 Elo 评分过程有唯一平稳分布，再用模拟把误差分成“曲线选错”“滞后”“噪声”三部分（滞后随 K 减小而增大，噪声随 K 增大而增大），结论是：在合理的实力变化模型下，无论打多少局，预测胜率的典型误差都不会显著低于 10%（永远预测 50% 的误差为 15.9% 或 26.1%，视实力分散程度而定）；要把误差减半，实力需要约 150—200 局才发生显著变化。他追查网上广为复制的“约 30 场后评分就会收敛到真实实力”，没有找到任何来源或依据。

“动力学”模型把评分看作随时间演化的密度：据后续论文转述，Jabin 与 Junca

表 1.2: 主要评分模型一览（摘要表，公式与证据见正文）。

模型（年份）	胜负模型	相对前人修正了什么	已知局限或实证
Elo（1959/1978）	正态或逻辑斯蒂	成对比较变成在线更新	固定 K；预测过度自信；通缩
Glicko（1999）	逻辑斯蒂 + RD	不确定性，自动调步长	只处理两人；需评分周期
Glicko-2（2001）	同上 + 波动率	实力突变	同上；τ 需调
TrueSkill（2006）	正态，队伍 = 成员之和	团队、多队、平局、匹配质量	夺旗模式中可加假设失效
TTT（2007）/WHR（2008）	正态/动态 BT	全历史平滑	计算量大；KGS 上各法差 < 0.7 个百分点
Weng–Lin（2011）	BT、TM、PL	解析更新，快	精度与 TrueSkill 相当
TrueSkill 2（2018）	正态 + 个人统计	车队、经验、退出、跨模式	技术报告；准确率 52%→68%
Elo-MMR（2021）	逻辑斯蒂表现	大规模名次赛，激励相容	未在游戏天梯上检验
mElo（2018）等	BT + 循环分量	非传递性	稀疏数据上常不如 Elo

在一定假设下证明评分密度收敛到实力密度[35]【文献】[2]，Düring 等再加入学习效应和可变表现[36-37]【文献】。近三年的结果更为定量。Cortez 与 Tossounian 证明随机配对下 Elo 以指数速率（在 2-Wasserstein 距离下且几乎必然）收敛到唯一平稳分布，平稳分布在 $K \to 0$ 时以 $\sqrt{K}$ 的速率收敛到真实实力[38]【文献】。Olesker-Taylor 与 Zanetti 证明时间平均、设上下限的 Elo 学习 Bradley–Terry–Luce 参数的速率可与最好的离线算法相比，并把“如何安排对局让 Elo 收敛最快”转化为图上的“最快混合马尔可夫链”问题[14]【文献】。Szczecinski 给出 K 同时决定收敛时间（约与 K 成反比）和收敛后估计方差（约与 K 成正比）的闭式结果[16]【文献】；他与 Djebbi 此前指出，Elo 把平局记作半胜半负，隐含了一个特定的平局模型，并提出可调平局频率的 κ-Elo[13]【文献】。2026 年还有工作把每步棋的质量纳入 Elo 以更快跟踪实力[39]【文献】。这些结果说的是同一件事：固定 K 的 Elo 永远在“追得快”与“抖得小”之间取舍，第二章和第四章分别从胜率与训练角度给出具体数字（第 2.4.2 节与第 4.2.3 节）。

要点

- 评分模型的演化是逐条放松“两人、固定实力、一维”三个假设：Glicko 加不确定性，TrueSkill 加团队与多人，TTT/WHR 加全历史平滑，mElo 处理非传递性。
- 增益最大的往往是修正错误假设而非换公式：TrueSkill 2 靠车队、经验和个人统计把《光环 5》准确率从 52% 提到 68%；KGS 围棋上各主流系统相差不到 0.7 个百分点。
- 固定 K 的 Elo 收敛到围绕实力抖动的平稳分布；预测误差很难低于 10%，“30

[2]待核对：本次未读到原文全文；对其结论的描述来自 Aldous 与 Düring 等的转述。

场就收敛”查无出处。

1.3　匹配机制本身的研究

匹配研究问“给定一池排队的人，怎样配对、分队最好”。“最好”至少有四种含义：结果最难预测（公平）、对估计实力最有信息量、等待时间短、玩家留得住。前两者在 TrueSkill 框架下是同一个目标，后两者则与公平存在真实冲突。

1.3.1　公平与信息量：同一个目标

一局结果若能提前猜到，它对估计双方实力几乎没有帮助；胜率接近 50% 时结果的不确定性最大，单局 Fisher 信息 $c^2p(1-p)$ 也在 $p=1/2$ 时最大（式（4.4））。TrueSkill 的匹配质量式（1.8）把这一点做成了准则。Bober-Irizar 等把“选哪两队对局”当作主动学习中的“采集函数”，在 HLTV 收录的 9929 场职业与半职业 CS:GO 比赛上发现：挑选“最可能平局”或“交叉熵最大”的对局，比随机挑选的预测准确率高 1—1.5 个百分点，而直接用 TrueSkill 自带的匹配质量来挑反而不如随机[23]【文献】。Yuksel 的模拟则提醒，按分匹配并不总对估计有利：在他的设定中，Elo、Glicko、TrueSkill 估计群体评分的误差在随机配对下都更小，因为按分匹配让比较集中在相邻的人之间[40]【文献】。匹配还会反过来影响评估：有匹配器参与时最好的系统预测错误率也可能接近 50%，TrueSkill 2 因此改用“分组实际胜率 vs 预期胜率”作为主要诊断（第二章的出发点之一，第二章）。

1.3.2　等多久：等待时间与匹配质量的在线权衡

Emek、Kutten 与 Wattenhofer 以国际象棋、拼字游戏等在线对战平台为动机，提出带延迟的最小代价完美匹配（MPMD）：请求在连续时间里到达一个度量空间中的点（例如评分），算法可推迟配对，但总代价是

$$\operatorname{cost}(M)=\sum_{(u,v)\in M}\operatorname{dist}(u,v)+\sum_{u}\big(t_{\text{match}}(u)-t_{\text{arrive}}(u)\big),\tag{1.9}$$

即“配对双方的距离之和”加“等待时间之和”，且决策在线、不可撤销；他们给出竞争比 $O(\log^2 n+\log\Delta)$ 的随机算法[41]【文献】。Liu、Pan、Wang 与 Wattenhofer 针对“越等越不耐烦”的玩家改用凸等待代价[42]【文献】。2026 年 Liu、Zhang 与 Zhang 提出“成本平衡”规则：累计等待成本达到当前匹配成本的某个比例就匹配，最坏情况下代价不超过预知未来的最优策略的两倍[43]【文献】；在一个校准过的 1 对 1 模拟中，它比“搜索半径随等待时间线性扩大”的行业做法（气泡算法）总成本低 3.7%—8.2%。这些工作为“等得越久、允许的分差越大”提供了理论框架，但都没有用真实排队数据。

1.3.3　组队：把一维评分分成两队

团队游戏选出 $2k$ 人后还要分成两队；若队伍实力取成员之和，这就是 NP 难的“均衡数分割”问题[44]【文献】。Alman 与 McKay 用成员实力的 p-范数定义队伍实力，以两队之差（p-公平度）加整局实力的离散程度衡量不平衡[45]【文献】：

$$d_p(X,Y)=\Big|\Big(\sum_{x\in X}s_x^{p}\Big)^{1/p}-\Big(\sum_{y\in Y}s_y^{p}\Big)^{1/p}\Big|,\qquad f=\alpha\,d_p+\Big(\frac{1}{|Z|}\sum_{z\in Z}|s_z-\mu_Z|^{q}\Big)^{1/q}. \tag{1.10}$$

$p=1$ 时队伍实力就是成员之和，$p\to\infty$ 时只看队内最强者，正对应 Dehpanah 等发现预测最准的 MAX 聚合（第 1.4.3 节）。他们证明基本问题可用 $O(\log n)$ 时间的数据结构在线求解；允许玩家只选部分位置（“选位排队”）后，问题在 3SUM 猜想下计算上不可行，只能近似，作者以此解释英雄联盟 2015 年底改用选位排队后排队变长、平衡变差。

网易伏羲与腾讯在这条线上做了大量工程化工作。OptMatch 离线学习玩家表示和“组队效应”、在线规划以最大化满意度，在《潮人篮球》上做了线上实验[46]【文献】[3]；GloMatch 用自注意力和强化学习同时为多局做全局优化[47]【文献】[4]。腾讯的 QuickSkill 针对新手冷启动，用前几局的序列特征预测未来评分，在一款知名手机 MOBA 上称可消除新手阶段 20% 以上的一边倒对局[48]【文献】。同一团队的 CUPID 在常规匹配后加一道“重匹配”，重新分配队伍和位置[49]【文献】；论文顺带透露对照组是一款数千万玩家的手机 MOBA 排位模式中“基于 TrueSkill 的一步式 MMR 匹配”，其 MMR 预测胜负的准确率只有 52.83%。在 30 天、10% 对局进入实验组的 A/B 测试中，CUPID 使第 5 分钟的“碾压率”相对下降 10.54%（绝对数值因保密未公布）。

1.3.4　以参与度为目标的匹配

另一条研究线放弃“公平即最好”的前提，直接优化留存或参与度。它与玩家怀疑的“系统安排胜负”最接近，因此下面逐项说清设计、数据和效应量（汇总于表 1.3）。

Ubisoft，2012。　Delalleau、Bengio 等为《幽灵行动 Online》设计的匹配系统不只用技能值，而是用玩家历史统计训练神经网络，同时预测队伍平衡和玩家是否享受这局[50]【文献】。“享受”标签的来源说法不一：EOMM 论文描述为赛后询问玩家，检索到的摘要片段则称问卷数据当时不可得、改用针对该游戏的启发式[5]。

EA 的 EOMM，2017。　Chen 等（EA 与美国东北大学、UCLA 合作）明确以“整体参与度最大”取代“配对实力相近者”[51]【文献】。他们把每名排队玩家当作一个顶

[3]待核对：本次未读到原文全文；只读到摘要，线上效果未核对。
[4]待核对：本次未读到原文全文；只读到其他论文的描述。
[5]待核对：本次未读到原文全文；IEEE 全文无法访问，标签来源存在矛盾。

点，用两人配对后的预期流失概率之和

$$w_{ij} = c(s_i, s_j) + c(s_j, s_i) \approx \sum_{o \in \{\text{胜},\text{负},\text{平}\}} \mathbb{P}(o \mid \mu_i, \mu_j) \left[c(s_i, o) + c(s_j, \bar{o}) \right] \tag{1.11}$$

作为完全图的边权（此处 $c(\cdot)$ 是流失概率，不是 Elo 常数 c），再求最小权完美匹配[51]【文献】；s_i 是玩家状态（含最近 10 局胜负平等），μ_i 是技能评分，$\bar{o}$ 为对手视角的结果。他们证明：若流失只取决于本局结果且 $c(\text{胜}) + c(\text{负}) > 2c(\text{平})$，按分匹配最优；不等号反向时按分匹配最差；流失与结果无关时任何匹配都一样（附录 A.1.6；附录还说明，在没有平局的游戏里，只依赖结果的流失使匹配毫无作用，参与度优化必须依赖玩家状态【本项目】）。数据来自 EA 一款 1 对 1 游戏 2016 年上半年的 3690 万局：最近三局“负负负”的玩家 7 天内流失率 5.1%，“胜胜胜” 3.7%，“平负胜”等组合 2.6%—2.7%。实验是模拟：从真实玩家状态中抽样组成 100—500 人的等待池，用 Glicko 预测胜负、逻辑回归预测“8 小时内不再玩”，重复 1 万轮。相对按分匹配，EOMM 每轮多留住的玩家在等待池 200—500 人时为 0.3%—1.1%，平均 0.7%；常被引用的“留存提高 15%”是作者按“8 小时匹配 20 轮”做的复利外推（$1.007^{20} \approx 1.15$），不是测量值；等待池 100 人时 EOMM 不显著优于随机匹配。

Chen、Elmachtoub 与 Lei，2026。　这篇 *Management Science* 论文建立了包含技能差异和“厌恶输球”的动态模型，在两种技能水平、玩家只在连败后流失的特例下求出最优策略[52]【文献】；会议版的描述是尽可能把不会流失的低水平玩家配给“再输一局就会流失”的高水平玩家。论文还发现，多数玩家水平较低时“付费变强”反而可能提高整体参与度，优化匹配能减少所需的机器人。用 Lichess 数据（新闻稿称 540 万局）校准的案例中，最优策略比按分匹配提高参与度 4%—6%，或把机器人比例降低 3%[53]【官方】；这是模型中的反事实计算，不是部署结果[6]。

网易伏羲的 EnMatch，2024。　EnMatch 把参与度优化推广到 k 对 k，用神经组合优化（强化学习）求解非线性目标下的分队[44]【文献】。探索性分析用一款“没有成熟匹配系统”的 3 对 3 游戏：同段位组成的“公平队伍”与“一高两低”的“混合队伍”各 1 万场相比，混合队伍获胜时聊天多 19.2%、点赞多 15.8%、被队友点踩少 12.3%；“负负负”的主力玩家流失率 8.4%，高于辅助位置的 6.2%。在一款 3 对 3 篮球游戏和一款 15 对 15 对战游戏为期两周的线上 A/B 测试中，以同样流量下的总对局数衡量，EnMatch 比最好的基线分别多 1.64% 和 7.19%。

反方向：Yuksel 的目标胜率匹配，2024。　犹他大学与 Roblox 的 Yuksel 提出的匹配器有意参考近期战绩，目的却是抑制长连胜和长连败[40]【文献】：若玩家最近 n 局赢了 w 局，为使包含未来 $n+1$ 局的 $2n+1$ 局窗口期望胜率等于目标 λ（两人游戏取

[6] 待核对：本次未读到原文全文；只读到摘要与新闻稿。

表 1.3: 参与度导向匹配与相关研究的效应量。所有数字都由作者用自有数据或自建模拟报告，本次检索没有找到独立复现。

研究	场景与数据	证据类型与结果	注意
EOMM[51]	EA 1 对 1 游戏，3690 万局	模拟：每轮留存 +0.3%—1.1%（均值 0.7%）	“15%”是外推；小池无效
Chen 等[52]	理论模型 + Lichess 校准	模型反事实：参与度 +4%—6% 或机器人比例 −3%	非部署结果
EnMatch[44]	网易两款团队游戏	两周 A/B：总对局数 +1.64%、+7.19%	作者即运营方
CUPID[49]	腾讯手机 MOBA 排位	30 天 A/B：5 分钟碾压率相对 −10.54%	目标是公平与位置
EA DDA[54]	EA 三消游戏（单人）	A/B：日均局数 +4.4%—7.9%，时长最多 +9%	难度调整，非匹配
Yuksel[40]	合成数据	模拟：多数玩家胜率被拉到目标值	只有合成评估

1/2），下一局对手应使其胜率为

$$p = \frac{\lambda(2n+1) - w}{n+1}. \tag{1.12}$$

以论文实验的 $n = 5$ 为例，连赢 5 局后下一局按“自己只有 $1/12 \approx 8\%$ 胜率”挑对手，连输 5 局后按 $11/12 \approx 92\%$ 挑（附录 A.1.7）【本项目】。论文只用合成数据评估。它的意义在于：根据近期胜负调整对手强弱的匹配器不但可行，而且已被公开提出；在机制上它与玩家所说的“输家队列”（loser queue）难以区分，区别只在设计目标。

1.3.5　动态难度调整：单人游戏里的先例

“按玩家状态暗中调整难度”在单人游戏中早有研究，统称动态难度调整（DDA）。Hunicke 与 Chapman 在《半条命》引擎上实现的 Hamlet 系统借用库存理论，在玩家即将陷入困境时调整补给和敌人的射击频率与准确度[55]【文献】，Hunicke 2005 年的论文报告了相应用户研究[56]【文献】[7]。EA 的 Xue 等把关卡进度建模为概率图，选择每关难度以最大化玩家总局数[54]【文献】：一款三消游戏中同一关不同随机初始盘面的通关率从 0.15 到 0.75 不等，他们就用“发哪个盘面”作为难度杠杆；三期 A/B 测试中实验组日均局数高 4.4%—7.9%、日均时长高 4.4%—9.0%，对付费影响中性。这说明“按玩家状态调整胜负概率以提高参与度”至少在单人游戏中公开部署过，但不能说明任何对战游戏的排位匹配这样做了。

1.3.6　连胜、连败与流失：实证证据

参与度优化的前提是“近期胜负影响玩家是否离开”，这方面的证据比通常想象的弱。EOMM 和 EnMatch 报告的都是条件均值（“负负负”后流失率最高），没有控制玩家本身的差异：容易流失的人可能本来就更容易连败[44,51]【文献】。

[7]待核对：本次未读到原文全文；未读到全文，实验结果未核对。

控制了个体差异的研究只找到一项。Kang、Suh 与 Kim 使用网石（Netmarble）手游 Everybody's Marble（一款大富翁类对战游戏）的服务器日志：发行商提供 2018 年 11 月 24 日至 2019 年 1 月 20 日 110 万名用户的匿名对局记录，作者把“连续 14 天以上不玩”定义为流失，只保留观察期内流失且至少玩了两天的玩家，得到 26.27 万名玩家、约 600 万局、150 万个“玩家—日”观测（整个 42 天日志约 2700 万局）[57]【文献】。双向固定效应逻辑回归显示：当天遇到的平均技能差每增加 1 分，流失概率增加 0.13%，技能差的方差也显著增加流失；胜率每高 1 个百分点，流失概率降 0.31%；连胜对局占比每高 1 个百分点，流失概率降 0.86%；而**连败对局占比不显著**（$p = 0.773$）。加入“游戏阶段”交互项后，连败效应随阶段而异，低等级玩家在连败比例上升时反而更不容易离开。作者认为短连胜带来正面体验，而定性研究中玩家描述的往往是十局以上的极端连串。这款游戏允许用游戏内货币购买影响胜率的道具，结论能否推广到纯技巧对战游戏并不清楚。

定性与行为研究给出的是另一面。Kou 等分析英雄联盟论坛讨论，发现连胜和连败都损害体验，暂时脱离游戏是主要应对策略[58]【文献】[8]。Deng 等在英雄联盟顶尖玩家的 597680 场对局中发现，连胜与表现提升、连败与表现下降之间的相关显著但很小，连串后玩家会休息更久，这在输局后略微改善了下一局表现[59]【文献】[9]。Sapienza 等分析 16665 名活跃玩家约 24.2 万场单排对局，发现一次连续游戏内个人表现逐渐下降，经验能缓解这种下降，多数玩家长期并无显著进步[60]【文献】。这些是第三章“上头”与疲劳模型的经验依据（第 3.4.4 节与 3.4.5 节）。

要点

- 以留存为目标的匹配技术上可行，公开报告的效应都不大（EOMM 每轮 0.7%，EnMatch 两周 1.6%—7.2% 的对局数），全部来自作者自有数据，没有独立复现。
- “连败导致流失”的证据不一致：条件均值显示连败后流失率较高，控制个体差异后连败不显著，连胜则显著降低流失。
- 按近期战绩调整对手强弱的匹配器已被公开提出（Yuksel 2024，目的为抑制连串）；这说明机制可行，不等于任何游戏这样做了。

1.4　各游戏的专门研究

针对具体游戏的研究按数据来源分两类。第一类由游戏公司或其合作者完成，作者能看到真实日志，有时就是系统设计者：TrueSkill 与 TrueSkill 2（微软与 Bungie、343 Industries、The Coalition）、EOMM（EA）、EnMatch 与 OptMatch（网易）、QuickSkill 与 CUPID（腾讯）、王者荣耀团队构成研究（腾讯合著）、Everybody's Marble 流失研

[8] 待核对：本次未读到原文全文；只读到摘要。

[9] 待核对：本次未读到原文全文；只读到摘要。

表 1.4: 各游戏专门研究能回答与不能回答的问题（摘要）。“公司数据”指作者使用了运营方提供的日志。

游戏	主要研究（数据）	能说明	不能说明
光环/战争机器	TrueSkill 系列、Huang 等（公司数据）	评分模型、参数、车队偏差	匹配器的搜索规则
CS:GO	Skill Issues（职业比赛）、Dehpanah 等	通用模型在职业数据上的优劣	Valve 官方匹配
PUBG	Dehpanah 等（Kaggle 公开数据）	名次评估指标；MAX 聚合	PUBG 自己的系统
英雄联盟	Kou、Sapienza、Deng、Do 等（公开数据）	连串的感受与行为；赛前可预测性	匹配器是否参考近期战绩
Dota 2/HoN	选人预测；HoN 评分漏洞	阵容可预测性；MMR 可被操纵	当前匹配算法
王者荣耀	Cheng 等、QuickSkill、CUPID（公司数据）	段位差与胜负；新手定级；对照组为 TrueSkill 型 MMR	是否按连胜连败调整
国际象棋	Glickman、Regan、Chowdhary、Rosenthal 等	通缩、通胀、连串统计	（规则公开，无需反推）
星际争霸 II	Thompson 等、AlphaStar	评级作为技能测量	天梯算法细节
炉石/酒馆战棋	无评分或匹配研究	——	全部

究（网石数据）。第二类由外部研究者用公开 API、战绩网站或公开数据集完成，只能重跑通用模型或研究玩家行为，看不到实际使用的匹配器。下面说明每项研究能告诉我们什么、不能告诉我们什么（汇总于表 1.4）。

1.4.1　《光环》与《战争机器》

第 1.2.4 节与第 1.2.6 节介绍的微软系游戏，是唯一由系统设计者完整公开评分模型的案例[1,25] 【文献】。Huang 等与微软研究院、微软游戏工作室合作，用《光环：致远星》7 个月、300 多万名玩家的 TrueSkill 评分研究技能发展：早期对局中的评分变化能预测之后的技能，游戏强度能预测最终打多少局，长时间中断后评分下降但恢复训练后回升较快[61] 【文献】。这些研究给出了评分模型、参数和已知偏差，但不涉及匹配器怎样在评分、延迟和等待时间之间取舍，也不涉及后来的作品。

1.4.2　CS:GO：研究的是职业比赛，不是官方匹配

常被引为“CS:GO 评分系统分析”的 Skill Issues，数据是 HLTV 收录的 2017—2022 年 9929 场职业与半职业比赛，不是 Valve 官方匹配的对局[23] 【文献】。在这批数据上，以队伍为单位时 Glicko-2 略优于 Elo 和 TrueSkill，给 10 名选手各自评分的 TrueSkill 最好（平均准确率最高 64.1%），TrueSkill 默认参数已接近最优。关于 Valve

实际使用的系统，学术文献只引用社区说法；这些研究说明不了官方匹配是否公平，也说明不了它是否参考连胜连败。

1.4.3　PUBG 与大逃杀：评估指标与团队聚合

DePaul 大学的 Dehpanah 等用 Kaggle 公开的 PUBG 数据做了一组研究：在 10 万多场单人对局上比较 6 种评估指标，发现有的不区分名次差了几位、有的受新玩家影响过大，最终推荐归一化折损累计增益（NDCG）[62]【文献】，在 2.5 万多场双人组队对局上结论相同[63]【文献】。团队聚合研究在 PUBG、英雄联盟、CS:GO 三个公开数据集上比较 SUM、MAX、MIN，MAX（队伍实力 = 队内最强者）在 PUBG 和英雄联盟的所有设定中最好，在 CS:GO 上不稳定[64]【文献】；用行为特征构建的简单玩家模型，名次预测胜过三种主流评分系统[65]【文献】。这些结论对 8 人名次游戏（包括酒馆战棋）很有参考价值，但它们并不知道 PUBG 自己怎样评分和匹配。

1.4.4　英雄联盟、Dota 2 与同类 MOBA

英雄联盟是行为研究最多的游戏。除 Kou、Deng、Sapienza 等（第 1.3.6 节）外，Do 等用 Riot 公开 API 抓取的 5000 场排位对局，仅凭玩家对所选英雄的熟练度就在开局前以 75.1% 的准确率预测胜负，认为按分匹配后两队实力仍差异很大[66]【文献】；但样本较小，熟练度在抓取时读取、论文未说明是否严格限于赛前，可能高估可预测性【本项目】。Véron 等用一个服务器 2800 多万局的公开数据分析匹配服务的需求[67]【文献】[10]。Dota 2 的研究集中在胜负预测：Semenov 等发现仅凭阵容预测能力有限，且分段越高越难预测[68]【文献】[11]；Yang 等在 7.8 万场对局上比较赛前特征，只用英雄的逻辑回归为 60.07%，加入玩家历史与“玩家 × 英雄”特征后为 71.49%[69]【文献】（表 4.2）；另有混合段位预测[70]【文献】、选人推荐[71]【文献】和职业选手评分[72]【文献】等工作。与匹配直接相关的是 Caplar 等对《英雄纽斯》的分析：其 Elo 型匹配评分总体能反映技能，但存在有组织地故意压低 MMR 等漏洞，新玩家定位过慢，“小号”问题没有解决[73]【文献】。这些研究说明连串真实存在、开局前可预测性不低，但没有一项在隐藏 MMR 数据上检验过匹配器是否依赖近期战绩。

1.4.5　王者荣耀

Cheng 等（浙江大学、科罗拉多大学与腾讯合著）用《王者荣耀》9600 万局、1 亿名玩家的数据研究阵容构成，其中 5443 万局为排位赛[74]【文献】。与匹配有关的细节是：两队成员段位等级之和的差值，在超过 90% 的排位对局中在 ±5 级以内，但段位和较低的一方只赢下 28.7% 的对局。也就是说，匹配器在可见段位上留下的小差距仍

[10] 待核对：本次未读到原文全文；只读到摘要。

[11] 待核对：本次未读到原文全文；具体数值来自作者报告幻灯片的二手转述。

与胜负强烈相关；可能的原因是匹配依据隐藏分而非可见段位，论文没有讨论匹配机制本身。腾讯团队的 QuickSkill 和 CUPID 都以“一款知名手机 MOBA”为对象而不点名，CUPID 透露其对照组为基于 TrueSkill 的 MMR 匹配（第 1.3.3 节）[48-49]【文献】。这些论文说明腾讯在研究新手定级、分队与位置分配，但都不涉及按近期胜负调整对手；官方说明和诉讼见第 1.7.7 节与第 1.10 节。

1.4.6　国际象棋：最透明的数据

国际象棋规则完全公开、对局数据丰富，是检验理论的主要场地。除前述 Glickman、Regan 与 Haworth、TTT 外，Kaggle 2010 年竞赛的冠军 Elo++ 仍基于单一评分和逻辑斯蒂曲线，核心是防止过拟合的正则化[75]【文献】。Chowdhary 等分析 Lichess 上 98 万名玩家的 1.23 亿局，发现热、冷连串都比“打乱同一玩家对局顺序”的零模型更长[22]【文献】；但打乱顺序同时抹掉了心理惯性和实力的缓慢漂移，“比打乱后更长”不能区分两者【本项目】。Rosenthal 应 Chess.com 首席执行官之邀、用平台提供的数据检验 Kramnik 对中村光（Hikaru）长连胜的质疑：中村光在 Chess.com 下了 57421 局，一次 116 连胜期间他平均 3017 分、对手平均 1526 分；在合理的胜和概率模型下这些连胜“完全在统计预期范围内”，相邻对局的超额得分几乎不相关[76]【文献】。这也说明在线平台的顶端玩家常遇到弱得多的对手：分布尾部找不到实力相近的人。

1.4.7　星际争霸 II

星际争霸 II 的学术研究很少讨论天梯算法本身，而是把评级当作技能的测量值：Thompson 等用 3360 名玩家、7 个联赛等级（青铜到职业）的录像遥测数据研究复杂技能习得，发现不同水平下决定表现的变量并不相同[77]【文献】；DeepMind 的 AlphaStar 在 Battle.net 官方天梯上与人类匹配对战，按天梯 MMR 评估，三个种族均达到宗师级、高于 99.8% 的排名玩家[78]【文献】[12]。暴雪对天梯机制的官方说明见第 1.7.3 节。

1.4.8　炉石传说与酒馆战棋：几乎没有学术研究

炉石传说的学术研究集中在人工智能对弈与构筑，例如 Hearthstone-AI 竞赛框架[79]【文献】和用代理模型辅助 MAP-Elites 自动构筑卡组[80]【文献】；本次检索没有找到研究炉石天梯评分或匹配的同行评审论文。对酒馆战棋说得更直白：**没有找到任何关于其评分或匹配的学术研究**，只找到一份放在 ResearchGate 上、用蒙特卡洛树搜索辅助决策的学生报告，与评分无关。酒馆战棋评分的公开信息全部来自暴雪的开发者文章（第 1.7.3 节）。从学术角度能借用的只有通用工具：8 人名次可用 Plackett–Luce、TrueSkill 自由混战或 Elo-MMR 建模（第 1.2.7 节），名次预测宜用 NDCG 评估（第 1.4.3 节）。

[12]待核对：本次未读到原文全文；只读到摘要，“按天梯 MMR 评估”的细节未核对。

要点

- 只有微软系游戏由设计者完整公开了评分模型；腾讯、网易、EA 的论文只透露部分做法（如腾讯某 MOBA 的对照组是 TrueSkill 型 MMR）。
- 外部研究者只能在公开数据上重跑通用模型或研究玩家行为，无法判断任何游戏的匹配器是否参考近期胜负；酒馆战棋没有任何评分或匹配研究。

1.5　中文学术文献

本次从本环境直接检索中国知网、万方和百度学术均未成功（知网证书与主机不符被拒，百度学术返回 403，万方检索页需脚本渲染）。下面的中文文献经通用搜索引擎和第三方题录站间接找到，只读到题录或摘要，均标注待核对；结论只代表本次检索的覆盖范围。

学位论文。　间接找到三篇与游戏匹配直接相关的学位论文。安徽大学王瑞 2019 年的硕士论文《竞技游戏中的 ELO 算法与匹配算法研究》（导师吴建国）只找到题录[81]【文献】[13]。台湾交通大学陈韦成 2012 年的论文（指导教授孙春在）指出，现行配对系统多以 ELO 积分配对，但 ELO 需要足够场次才会收敛，配对系统又无法分辨积分是否已收敛，因此常产生不平衡的对局；作者估计玩家与团队的“影响力”来补足未收敛的积分[82]【文献】[14]。这是本次找到的唯一一篇直接讨论“评分未收敛导致团队对局失衡”的论文，与玩家所说的“Elo 地狱”最接近。同一实验室黄志宏 2010 年的论文用团体动力学，在玩家能力之外加入团体结构和沟通因素来改善团队配对[83]【文献】[15]。

中国机构的英文论文。　中国游戏公司最有分量的成果都以英文发表在国际会议上：网易伏羲的 OptMatch（KDD 2020）、GloMatch（KDD 2021）、EnMatch（AAAI 2024），腾讯的 QuickSkill（CIKM 2022）、CUPID（CSCW 2024），以及腾讯合著的王者荣耀团队构成研究（WWW 2019）[44,46-49,74]【文献】。作者即运营方，数据不公开，实验对象常不点名。

非学术资料与用语。　中文互联网上关于“ELO 机制”的大量文章来自技术博客和自媒体（如 GameRes 游资网的原理介绍、CSDN 上“按分数和等待时长扩大匹配范围”的实现教程），能反映从业者的通行做法，但不作为证据。中文语境里的“ELO 机制”已演变为“系统操控胜率”的代称，与学术用法不同（第 3.1 节）；腾讯官方 2018 年的说明本身也用了“ELO 等级分系统”一词（第 1.7.7 节）。

[13] 待核对：本次未读到原文全文；仅见第三方题录。
[14] 待核对：本次未读到原文全文；仅读到检索摘要。
[15] 待核对：本次未读到原文全文；仅读到检索摘要。

要点

- 间接找到的中文学位论文只读到题录或摘要；最接近“Elo 地狱”的是一篇 2012 年的台湾学位论文（评分未收敛时团队配对失衡）。
- 中国公司的匹配研究以英文发表在 KDD、AAAI、CIKM、CSCW、WWW 等会议，作者即运营方，数据不公开。

1.6　学术研究小结：什么已经清楚，什么有争议，什么还没人做

已经比较清楚的。　（1）评分的统计基础成熟：Elo 是 Bradley–Terry 模型上的在线随机梯度，K 在“追得快”与“抖得小”之间取舍，预测误差很难低于 10%。（2）用带误差的评分直接预测会过度自信，Glicko 的折减与“排名与预测解耦”是同一问题的两种修正。（3）封闭分池在玩家持续进步时会通缩，USCF 与 FIDE 都不得不人工干预。（4）“队伍实力 = 成员之和”在车队和部分团队模式中系统性失效。（5）公平的对局也是信息量最大的对局；有匹配器参与时，原始预测准确率接近 50% 并不说明评分系统差。

仍有争议的。　（1）以留存为目标的匹配是否值得做：效应正向但不大，且全部来自作者自有数据或模型计算。（2）连败是否导致流失：条件均值说是，控制个体差异后连败不显著、连胜显著降低流失，定性研究说两者都伤害体验。（3）一维评分是否足够：非传递性确实存在，但在稀疏的天梯数据上 Elo 常常预测得更好。（4）评分系统孰优孰劣取决于数据、指标和是否有匹配器参与。

还没有人做的。　（1）**没有任何同行评审研究在真实的隐藏 MMR 数据上检验过“输家队列”**，即匹配器是否在连胜后安排更强的对手或更弱的队友：外部研究者拿不到隐藏分和匹配日志，内部研究者发表的论文又不涉及这一环节。（2）**“Elo 地狱”几乎没有被正式研究**：除一篇 2012 年的台湾学位论文和 TrueSkill 2 的车队数据外，没有定量研究“个人对团队胜负影响小、评分收敛慢”是否会把玩家困在某个分段。（3）没有研究检验过酒馆战棋或其他自走棋的 8 人名次评分。（4）没有找到对参与度导向匹配的独立复现或伦理审查。

这些空白决定了后面三章的定位：既然无法从外部看到真实的匹配器，本研究就从另一端入手，先推导完全诚实的系统在数学上会产生怎样的胜率与连败（第二章与第三章），再从训练模型的角度说明胜负数据里有多少关于实力的信息（第四章）。这样得到的是“无需操纵即可解释”的基准，而不是“已证明没有操纵”的结论。

1.7　厂商披露：逐家阅读原文

本节逐家阅读开发商自己发布的开发者博客、白皮书、补丁说明，以及员工以官方身份做出的公开发言，时间跨度为 2013—2026 年，检索与阅读日期为 2026 年 10 月 18—19 日。引用时先给中文意译，必要处在括号里附英文原文短句。凡是只读到媒体转述、没读到原页面的，都在该处加了脚注。

阅读这些材料时有一个贯穿全节的区分：一套“匹配系统”其实由三层组成。第一层是**评分模型**，即怎样从胜负（有时还有个人表现）估计玩家实力，产物是隐藏的匹配分（matchmaking rating, MMR）R_i；第二层是**匹配器**（matchmaker），即拿着 R_i、延迟、排队时间等约束去组局和分队；第三层是**可见段位**，即展示给玩家看的段位、星数或分数。玩家关于“控胜率”的指控，大多是把这三层混为一谈：可见段位的升降规则（保底、加速、衰减）常被误认为匹配器在“安排”对局。下文对每家公司都尽量说明它披露的是哪一层。

1.7.1　Riot Games：《英雄联盟》《英雄联盟手游》与 VALORANT

英雄联盟 2018 年的匹配说明。　2018 年 2 月，Riot 在《/dev: Matchmaking Real Talk》中回答玩家的质疑[84]。文章把“一边倒”的对局归因于滚雪球式的局内优势、匹配本身的不确定性和玩家的感知偏差；在系统内部，“大多数队伍的预期胜率在 50%±1% 以内”（“*most teams have an expected win rate of 50 +/-1%*”）【官方】。对“连胜时是不是会被塞差队友”，设计师 Gortok 回答“这基本是都市传说，基本上”（“*This is pretty much an urban myth. Mostly.*”），并说“我们预期你打的每一局，你方摧毁水晶的机会都是 50%±1%”【官方】。文章同时承认模型看不见的东西：用不熟悉的位置或英雄、组排内部 MMR 差距大、小号尚未被准确定分，以及“睡眠不足”之类的个人状态【官方】——正是第二章中“估计误差”和“实力波动”两类偏差的来源（第 2.2 节与 2.6 节）。同系列的第三篇把匹配目标概括为公平对局、首选位置和短排队三者兼顾[85]【官方】。

《英雄联盟手游》2021 年的算法流程。　首席设计师 Josh Menke 2021 年 10 月的文章写出了匹配器的循环[86]：每秒取出等待最久的玩家或队伍，检查其平均 MMR 的“合法范围”内是否有足够玩家；若有，在平衡两队 MMR 总量与位置偏好的前提下组队，“每队的 MMR 被平衡到双方赢的机会相同（接近 50%）”（“*MMR per team is balanced to give each team the same chance at winning the match (close to 50%)*”），最后检查两队 MMR 差是否在限值内【官方】。合法范围每秒扩大，2 分钟后扩到最大并维持 18 分钟【官方】。对“输家队列”，他的回答是没有，“匹配器根本不知道你处在什么样的连胜或连败中”，也不使用胜率；但他承认旧版 MMR 系统“可能让玩家的 MMR 被短暂高估，从而多输几局”【官方】——这是少见的厂商自认的连败成因，它属于评分层而不是匹配器的安排。文中“完全公平时 100 局里出现 10 连败的概率接近 10%”一说，

按独立公平局计算对应的是 10 连胜或 10 连败任一种（约 8.7%），单看 10 连败约为 4.4%（附录 A.2.2）【本项目】。他对两层分数的概括值得记住："MMR 是我们对将会发生什么的最好估计，段位是对实际发生了什么的奖励"【官方】。

2024—2026 年的英雄联盟。 首席玩法设计师 Matt "Phroxzon" Leung-Harrison 2024 年 2 月 11 日发推："我们不会故意把差的玩家放进你的队伍让你多输。（即使假设有这种前提，难道我们不该给你好队友让你别再输吗?）排位只按你的评分匹配，仅此而已。"[87]【官方】。2025 年 7 月前后，他在 15.14 版本预告中列举了匹配器不使用的因素：荣誉等级、标记次数、符文、是否处于连败[88]【官方】[16]。官方开发日志披露了几项实际改动：2024 年 11 月称 6 个月以上未玩的回流玩家"回来后胜率在 30% 多到 40% 出头"，因此加大段位衰减，之后"前钻石在翡翠局平均胜率 48%、前大师在钻石局平均胜率 49%"[89]【官方】——Riot 在这里把胜率是否接近 50% 当作段位是否放对了位置的诊断指标，而不是匹配器要强制的目标。2025 年 12 月的《/dev: Ranked 2026》写明一条非 MMR 规则：补位玩家先尽量与对方同位置的补位玩家对位，否则让两队补位人数相等，"最坏情况下，补位人数多的一方会分到 MMR 稍高的队友"[90]【官方】。这说明匹配器平衡的不是 MMR 本身，而是计入补位劣势之后的预测胜率（第 1.8 节）。

VALORANT：隐藏 MMR、收敛与"方差"。 2021 年 3 月的《Ask VALORANT – Rank Rating Edition》写道："你永远看不到你的 MMR，它是我们用来创造公平对局的"；新赛季或新账号被放在系统估计区间的低端，再通过"赢得多、输得少"的排位分（RR）让可见段位"收敛"到 MMR[91]【官方】。文章特别写道："当你处在你的 MMR 上时，我们最常看到的是 50% 的胜率"（"*When you are at your MMR, we've most often seen you with a 50% win rate*"）；段位高于 MMR 时会"赢得少、输得多"【官方】。这里的 50% 是对收敛后长期胜率的观察。2022 年 7 月，竞技设计师 Jon "EvrMoar" Walker 在回应主播 Shroud 时写道："VALORANT 没有输家队列……我们不操纵队列"，并称"研究表明，留住玩家的是公平的匹配，而不是被操纵的匹配"[92]【官方】。他还解释了评分不确定度：表现符合预期时"方差"收缩、MMR 难动，超出预期时方差打开、MMR 快速移动，"这就是为什么连胜……真的能帮你上分"[93]【官方】。

Riot 三款游戏的口径因此一致：连胜/连败影响的是评分更新速度（方差、收敛乘数），匹配器不读取连胜状态；唯一明确承认的"非 MMR 补偿"是补位。

1.7.2　Valve：Dota 2 与 CS:GO / CS2

Dota 2。 Valve 在 2013 年 12 月推出天梯时写道："Dota 2 的匹配一直在计算 MMR 并用它组局；天梯只是把这个 MMR 显示出来"[94]【官方】[17]。评分更新"以胜负为主要依据，但在我们对你的 MMR 不确定度高时，个人表现也起作用"；匹配器的目标

[16] 待核对：本次未读到原文全文；只读到媒体转述，未读到 X 原帖。

[17] 待核对：本次未读到原文全文；Valve 原博客页已下线，依据 PCGamesN 的大段引文。

包括两队平衡（“每队有 50% 的机会获胜”）、全场强弱差距和经验差距最小、两边组排数量相近、语言相通、等待不过久，各项打分加权平均，超过阈值即开局【官方】。2017 年 4 月的《Matchmaking Update》在调整组排 MMR 时写下一句对第 1.8 节很关键的话：“仅仅在长期上有均等的获胜机会，并不必然意味着对局有竞争性”（“*Simply having an even chance to win over the long run does not necessarily correlate to having competitive matches*”）；改动后“两队在大样本上的获胜机会与之前相同，但单局的波动减小”[95]【官方】。同年 7 月，Valve 宣布新玩家会被匹配给“行为分一贯较高”的玩家[96]【官方】，这是官方承认的非实力匹配因素。2019 年 10 月的更新加入了组排硬约束（如含不朽段位玩家的组排按最高者计、五人组排只对五人组排），并重申“我们始终按 MMR 而不是奖章匹配”[97]【官方】。2024 年 3 月，Valve 在 Dota Plus 中试验“赛前匹配分析”，开局前向玩家展示该局的技能离散度和行为分估计，并允许重排[98]【官方】——这是本文所见唯一把单局匹配质量信息直接交给玩家的做法。

CS:GO 与 CS2。　Valve 从未正式公布 CS:GO 段位算法。常被引用的说法来自 2015 年一位 Valve 员工在 Reddit 的回复：段位计算“起初基于 Glicko-2 的思想”，之后针对玩家群体做了大量修改[99]【社区】[18]。CS2 于 2023 年推出 Premier 模式的“CS Rating”，官方只说它是“对你 Counter-Strike 表现的可见度量”，决定全球和地区排行榜位置[100]【官方】；此后的更新说明写道“对局将以更长的排队时间为代价，让两队的评分差更小”[101]【官方】。公式、输入变量和隐藏分是否存在，Valve 都没有说明。

1.7.3　Blizzard：《守望先锋 2》、炉石传说与酒馆战棋、《星际争霸 II》

《守望先锋 2》2022—2023 年的两篇深度说明。　第一篇（2022 年 12 月 20 日）明确：每个玩家都有内部 MMR，它是相对于全体玩家的数，“包括竞技模式在内的所有模式在组局时只看 MMR，我们从不用你对外显示的段位组局”[102]【官方】。这篇文章披露了两项针对新手的改动，恰好是“系统确实会改变某些玩家胜率”的官方实例：Blizzard 发现新手输得比应有的多，胜率分布不是以 50% 为中心的正态，于是先把新手初始 MMR 从略低于平均（约白银低段）下调到相当于青铜 5，并称“胜率低于 40% 的新手立刻大幅改善”；随后又加入一个“连胜修正器”（streak modifier），跟踪玩家胜率的移动平均，“胜率高于 50% 时让 MMR 涨得更快”，直到玩家进入胜率 50% 的公平对局为止【官方】。所以官方承认“胜率”会进入系统，但它进入的是*评分更新速度*，目的是让 MMR 更快追上实力，而不是在匹配时对连胜者施加惩罚。第二篇（2023 年 1 月 30 日）的问答部分是全行业最明确的否认之一：“守望先锋没有赢家队列或输家队列。你当前的 MMR 是匹配器组局时唯一考虑的东西。匹配器不会对任何人强制 50% 胜率，也不偏袒任何玩家”[103]【官方】。对长连胜/连败，它的解释是“往往说明内

[18] 待核对：本次未读到原文全文；Reddit 原帖未能打开，依据 PC Gamer 转述。

部评分没有校准好”，但“也有时候只是运气”【官方】；它还承认两队评分“从不完全相同”，总有一方略被看好【官方】。

酒馆战棋：八人对局的评分。　对本项目最直接相关的是《炉石传说》酒馆战棋（Battlegrounds）的两篇数据科学家署名文章。2019 年 11 月 27 日，高级数据科学家 Tian 解释：评分既代表实力，也用于“为你匹配七位实力相近的玩家”；系统希望评分分布呈正态；每个玩家还有一个不显示的“方差”，新手大、随场次下降，但出现意外结果时会回升[104]【官方】。每局赛后，系统要算出每位玩家对其余七人的胜率，“一共 56 次”；评分变化取决于自身评分、对手评分、名次、预测胜率、方差等【官方】。文章说 Elo 和 Glicko“主要为两人对局设计”，模拟显示自研算法运行最快、精度最高【官方】。它给出一组数字：假设对手与你同分，旧系统首局第一名约 +240、第 150 局以后约 +24；11 月 19 日改动后分别约为 +195 与 +98【官方】。它还加入了一个“很小的进度加成”：评分低于 6500 时，每局无论胜负都会加一点正分【官方】。2020 年 9 月 28 日的 18.4 版本把评分拆成两套[105]：外显评分每赛季清零，2000 以下不掉分，2000—6000 每 500 一道保底，单局最多加 300 分，低于 6500 时每局有正向进度分（文中例子：本应 ± 50，实得 $+53/-47$），内部评分高于外显评分时胜场加分乘以一个与差距成比例的“追赶倍率”；内部评分永不重置、没有保底和加成，必要时做“重新归一化”使其保持钟形分布【官方】。匹配“只按内部评分，尽量选出内部评分最接近的八个人”，外显评分“在匹配中不起任何作用”【官方】。

可见，外显分包含保底、进度分和追赶倍率，系统性地高于“纯实力”轨迹；八人对局里的“公平”指八人内部评分相近，对应的是预期名次 4.5、前四率约一半，而不是“胜率 50%”（第 1.8 节）。这两点对用天梯分评估酒馆战棋 AI 的具体含义见第 4.9 节。

炉石传说构筑模式与《星际争霸 II》。　炉石构筑天梯有保底和月初星级加成，社区维基称其匹配依据不随赛季重置的 MMR[106]【社区】[19]。《星际争霸 II》曾对长期不活跃的玩家下调隐藏分（“MMR 衰减”），2015 年 4 月因副作用移除[107]【官方】。

1.7.4　Activision：《使命召唤》的匹配博客与三份白皮书

Activision 是唯一一家公开了匹配 A/B 实验结果的大厂，因此这里展开得最细。

2024 年 1 月的博客。　《An Inside Look at Matchmaking》（2024 年 1 月 28 日发布，同年 4 月 4 日更新）列出多人模式匹配的因素及其优先级：连接质量“最关键、权重最大”（“Ping is King”），其次是匹配用时，然后是播放列表多样性、最近玩过的地图/模式、技能/表现、输入设备、平台、语音开关；文章强调技能是因素之一，“但不是主导变量”[108]【官方】。常见问题部分有几条明确否认：匹配“不考虑你玩得多频繁、玩了多久”；“花钱绝不以任何方式、任何形式影响匹配”；常规匹配不使用机器人；主

[19] 待核对：本次未读到原文全文；未找到 Blizzard 关于构筑匹配算法的官方说明。

播没有特殊待遇【官方】。关于测试，它写道曾多次测试去掉技能因素，并且“我们有意不公开这些测试何时进行，因为那可能影响反馈或测试期间的数据”【官方】——玩家在某些时段遇到的匹配可能来自未公开的实验配置。

白皮书一：延迟（2024-04-04）。 这份白皮书主要讲数据中心选择与延迟差，有两段与本研究直接相关[109]。一是人口学例子：100 万在线玩家中，同时在搜索的只有约 1.3 万人，分散到约 40 个数据中心和 40 个播放列表后，任意 15 秒内平均只有约 8 名相互兼容的玩家，凑不满一局 12 人【官方】——任何严格的实力约束都必须随等待放宽。二是关于留存的表述：团队关注的指标包括每用户游戏时长、对局退出率、玩家留存/流失和问卷，但“这些指标并不直接作为匹配选择算法的输入，而是告诉我们匹配方案是否奏效的可观测结果”【官方】。

白皮书二：技能的作用（2024-07-26）。 这是三份中最重要的一份[110]。技能的计算方式是：每局赛后计算每名玩家在某个表现指标上的成绩，全场玩家不分队伍两两比较，技能调整量“与该玩家取得这一结果的可能性成反比”；所用指标只涉及局内表现，“玩家的成长进度和总游戏时长不计入技能”【官方】。白皮书也承认连串是正常的：即使技能被完美追踪、每局对手都完全势均力敌，“任意连续五局中，约 3% 的玩家会经历五连败，约 3% 会经历五连胜”【官方】（即 $0.5^5 \approx 3.1\%$）。分队的目标是“让对局结果尽可能不可预测”【官方】；图 2 显示团队死斗中很小的队伍技能差就会显著改变胜率——12 名 50 分位玩家中若有一人换成 80 分位，其所在队伍胜率超过 70%；一支六人全为 60 分位的组排，强于约 80% 的随机六人队【官方】。

实验部分是全文核心。2024 年初，Activision 在《现代战争 III》北美服务器进行了“降低技能权重测试”（Deprioritize Skill Test）：用 A/B 框架把 50% 的玩家放进处理组，放宽（而非移除）技能约束，另一半保持标准配置；白皮书说这类测试“在过去五年里不同时间做过多次”【官方】。衡量“好玩”的数据包括继续游玩多久、对局退出率、问卷和对局结果【官方】。一个月后，按测试期间的平均技能把处理组分成十等份，与对照组比较：“14 天内回流的玩家比例对 90% 的玩家显著下降，技能最高的 10% 回来得更多，但总体上回来的玩家明显变少”；对局中途退出率在 80% 的玩家中显著上升，只有最高 10% 明显下降；团队死斗的碾压局（比分差超过 30）对所有分组都增加；每分钟击杀在底部 20%—30% 显著下降，最高 10% 显著上升【官方】。白皮书据此推论：长期下去低技能玩家流失，原来的前 10% 会逐渐变成前 20%、前 30%，最终也会流失【官方】。反方向的“收紧技能”测试结果相反——90% 的玩家退出率下降、低技能玩家的击杀和得分改善，但高技能玩家受损，因此没有推广；更早在《现代战争》（2019）中，“只保护底部 25%、其余 75% 放宽”的方案在两周内也导致玩家数下降和退出率上升【官方】。

白皮书最后写出了实现细节：匹配目标随搜索时间按“退避”（backoff）模式放宽，技能约束放宽得比延迟差更快；组局用技能百分位，分队用近似正态的“原始技能”；

组局阶段限制各组排平均技能之差和大厅内的强弱差距，分队阶段在 12v12 以内穷举所有分法、选两队技能总和差最小者；对实力悬殊的组排“取中间”匹配【官方】。

对“Activision 是否以留存为目标匹配”这个问题，原文支持的精确表述是：Activision 用留存和退出率来评估匹配配置（多大的技能约束），并通过 A/B 测试选择配置；延迟白皮书明说这些指标不是匹配选择算法的直接输入【官方】。这与 EOMM 一类“每次组局时预测流失并据此选人”的方案（第 1.3.4 节与第 1.9 节）是两回事：前者是对一条全局规则的离线调参，后者是逐局的目标函数。

白皮书三：排位模式（2024-12-23）。　排位白皮书把可见的技能分（SR）与内部“原始技能”分开，并说明原始技能“在业内俗称 MMR”[111]【官方】。每个玩家有一个由技能百分位换算的“目标 SR”和一个显示的“当前 SR”；所有人从青铜起步，胜场按与目标 SR 的距离和本局表现加分，“在超过目标 SR 之前，一场胜利的价值几乎总是大于一场失败”【官方】。顶尖玩家胜率常超过 80%，为防 SR 通胀，当前 SR 远超目标 SR 时胜场加分递减、败场扣分加大【官方】。排位匹配先尝试单一段位大厅，等待到点后最多放宽三次段位跨度，并限制组排的段位跨度【官方】。这份文件是“双轨制”（隐藏分负责公平、可见分负责成长感）的一个完整公开样本，与酒馆战棋 2020 年的设计同构。

2025 年的转向。　2025 年 10 月 9 日，Treyarch 在《黑色行动 7》Beta 结束时宣布：上线时“技能考量极小的开放式匹配”（Open Matchmaking）将成为多人模式默认，并引入持续大厅[112]【官方】。一年前的白皮书还在用 A/B 数据论证技能匹配的必要性，一年后默认配置就改为弱技能约束，这本身说明“技能约束有多紧”是厂商随产品目标和舆论调整的参数。

1.7.5　大逃杀与其他射击游戏：Respawn、Epic、KRAFTON、Embark

《Apex 英雄》（Respawn/EA）。　2023 年 1 月 17 日的匹配说明[113]写道，技能分“有意对玩家隐藏，以防被利用”；组排队伍按队内最高技能者计算有效技能（匹配与排位都如此），以防高手带新号“炸鱼”，但也承认这让新手很难与高手朋友一起玩【官方】。一局 60 人从相近技能的玩家中抽取；在普通模式里，系统把这些人分成平均技能尽量接近的队伍，而在排位里“我们更看重队友实力相当、少一些‘带飞’负担，而不是一局完美公平的比赛”【官方】——这是官方明确承认排位分队不以两队均衡为首要目标的少数例子。对连胜/连败，它写道：“我们不会因为你赢得多就故意给你更难的对局来拖慢你，也不会因为你连败就故意给你更容易的对局”；连胜使你的技能分上升、对手随之变强，这一过程“通常较慢”，并提醒“进了一局后，你落在本局技能下半区的机会是 50/50”【官方】。

《堡垒之夜》（Epic Games）与 PUBG（KRAFTON）。 2019 年 9 月，Epic 宣布在 10.40 版本为大逃杀核心模式引入按技能匹配，并在下赛季加入机器人：“机器人会与新的匹配系统配合工作，随着你的技能提高，你遇到的机器人会减少；竞技播放列表中没有机器人”[114]【官方】[20]。KRAFTON 2024 年 4 月 16 日的开发者信件说明 PUBG 普通模式按击杀、名次等计算内部 MMR，在玩家不足的时段“可能用机器人替补”[115]【官方】；组排 MMR 从取平均（早期）改为取最高（2022 年），再改为“加权平均”（2024 年），越强的队员权重越大【官方】。机器人数量随实力递减这一点，是厂商公开承认的、会系统性提高弱玩家胜率（或名次）的机制，但它只用于非竞技模式。

ARC Raiders（Embark Studios）。 在 2026 年 1 月报道的一次访谈中，Embark 首席执行官 Patrick Söderlund 确认这款撤离射击游戏“现在也按你倾向 PvP 还是 PvE 来匹配”[116]【社区】[21]。它是“按行为而非实力匹配”被公开承认的一个新近例子。

1.7.6　公开了模型的系统：微软 TrueSkill、《光环：无限》与国际象棋平台

微软研究院的 TrueSkill 项目页说明，TrueSkill 用于 Xbox Live 上从《光环 3》到《极限竞速 7》的许多游戏，TrueSkill 2 随《战争机器 4》上线，后用于《光环 5》《战争机器 5》《光环：无限》和《极限竞速》[117]【官方】。项目页对“匹配质量”的定义很特别：用两名玩家（假想的）打平概率衡量，“如果你很可能和另一名玩家打平，那他就是你的好对手”；这一量在 0 到 1 之间，并且“即使两人 μ 相同，只要任一方 σ 很大，匹配质量也明显小于 1”【官方】。项目页还举了一个例子：匹配时显示的是保守估计 $\mu - 3\sigma$，所以新玩家对已定级的 25 级玩家显示差 23 级、匹配质量却有 57.6%，新玩家对已定级的弱玩家显示只差 1 级、匹配质量却只有 5.7%【官方】——可见段位与匹配变量不一致导致的“看起来不公平”，在早期的 Xbox Live 上就已存在。TrueSkill 与 TrueSkill 2 的技术细节见[1,25]。

343 Industries 2022 年 3 月的《光环：无限》排位说明把这套关系写得最清楚[118]：MMR 由 TrueSkill 2 按播放列表计算，用于匹配；可见的竞技技能段位（CSR）“与 MMR 紧密相关，但不直接用于匹配”【官方】。CSR 赢了不降、输了不升，长期总是趋向 MMR，偏离大时每局变化达上限 ±15；定级赛的 CSR 有意略低于预期【官方】。文章随后给出全行业最精确的一句定义：“这里的‘公平对局’是指两队因实力均衡而各有 50/50 的获胜机会。持续把玩家放进这样的对局，我们预期会看到平均 50% 的胜率。注意那是我们预期看到的副作用，而不是目标——我们不会为了强制 50% 胜率而给你不公平的对局。”【官方】（原文见表 1.6）

国际象棋平台公开得最彻底。Lichess 使用 Glicko-2，新账号 1500 起，计算时对执

[20] 待核对：本次未读到原文全文；Epic 原公告页拒绝访问，依据 PC Gamer 当日引文。

[21] 待核对：本次未读到原文全文；依据 TechRadar 对 GamesBeat 访谈的转述。

黑的结果给更多分；它对评分系统用途的表述是“预测对局结果，以便进行均衡的配对”[119]【官方】。Chess.com 的帮助中心说明其使用含“评分偏差”（RD）的 Glicko 系统，长期不下棋 RD 会增大[120]【官方】。

1.7.7　腾讯：《王者荣耀》

中文语境里“ELO 机制”这个词，部分来自官方自己。2018 年，《王者荣耀》官网发布《狄仁杰答疑｜匹配算法全面解析》，否认“通过匹配算法刻意为连胜状态下的召唤师匹配‘坑队友’”，称匹配算法的目标是“尽可能将水平尽量相当的召唤师放入同一局比赛”，“基于长期的数据基础，评估出每位召唤师的综合能力”，并写道“我们没有任何动机去干预召唤师们的对局结果与胜率，这样做对《王者荣耀》毫无好处”；文中介绍“ELO 等级分系统”用于评估技术等级，并称 MOBA 需要“创造双方势均力敌的竞技环境”[121]【官方】[22]。这几句话与 Riot、Blizzard 的口径相同，但没有给出任何数字。

此后八年，腾讯的公开说明主要出现在诉讼答辩（第 1.10 节）和两次匹配改版中。2025 年 11 月起，官方对随机选取的高星玩家灰度测试新匹配算法[122]；12 月 30 日称新算法下“90% 以上的对局双方段位差控制在 2 星及以内”；2026 年 1 月 8 日上线的 S42 赛季宣布“以段位为主要依据进行匹配”，组队和加载界面显示队伍的平均加权段位，并新增“挑战强敌”机制——匹配时间过长时适当扩大段位范围，低段位赢下高段位可获额外积分[123]【官方】。一些自媒体给出“旧机制 70% 看隐藏分、新机制 60% 看段位 40% 看近期表现”等比例[124]【社区】，本文未找到这些数字的官方出处。2026 年 8 月，官方“对局环境优化专栏”首期称收集了 7000 多条反馈，排位匹配新增“负面信誉”判断维度，使信誉正常的玩家“不会连续被分配到负面信誉玩家所在队伍”，并邀请职业教练复盘大量连败对局；文中回顾此前的匹配优化把段位差 5 星以内的对局占比从 66.8% 提高到 99.6%，2 星以内从 36.1% 提高到 90.7%[125]【官方】[23]。

这两次改动有两层含义。第一，官方公布的质量指标从此变成了“可见段位差”，而不是预测胜率；可见段位通常比隐藏分更滞后于实力，按段位配平会让单局真实胜率离 50% 更远（第 2.4.6 节）。第二，“负面信誉”是官方承认的、依赖近期分队历史的非实力规则（“不再连续”同队），它的条件是违规行为而不是胜负，但它确实让分队与玩家最近几局的经历相关。

1.7.8　网易及其他厂商

2025 年 8 月，在玩家普遍怀疑《漫威争锋》（Marvel Rivals）使用“参与度优化匹配”（engagement optimized matchmaking, EOMM）时，官方账号发布声明：“我们想重申，《漫威争锋》不使用 EOMM”，并预告一周内发布匹配与排位说明视频[126]【官方】

[22]待核对：本次未读到原文全文；官网原文未能打开，依据 2025 年《每日经济新闻》报道中的摘录。

[23]待核对：本次未读到原文全文；依据快科技转述，未读到官方专栏原文。

。随后的视频由首席战斗设计师 Zhiyong 讲解，称系统按竞技分和阵容构成分配队伍，例外来自离群值和高水平玩家遇到新玩家等情况[127]【社区】[24]。值得并列的是，网易伏羲实验室 2024 年在 AAAI 发表的 EnMatch 明确批评“只在同一段位层内匹配”的公平匹配“并不总是对玩家参与度有利”，并报告了“在两款游戏中的线上部署”（未点名游戏）[44]【文献】。两者并不矛盾——一款游戏否认、另有两款未具名游戏部署——但它说明网易内部确实存在以参与度为目标的匹配实践。主要在腾讯完成的 CUPID（2024）则报告了部署于“一款热门手机 MOBA”（未点名）的“重匹配”系统，其目标是对局公平性和位置满意度[49]【文献】。这些公司论文的方法与结果见第 1.3.3 节与 1.3.4 节，这里只记录它们作为“厂商实践”证据的意义。

《永劫无间》《第五人格》（网易）、Supercell 旗下游戏和《火箭联盟》（Psyonix），本文都没有找到说明匹配算法的官方文档；社区流传的说法（如“火箭联盟用类 TrueSkill 算法”）没有官方出处。

1.7.9　横向比较：官方承认了什么、否认了什么

表 1.5把上面的披露压缩成一张表。规律有四条：（1）几乎所有厂商都把“隐藏分负责匹配、可见段位负责成长感”分开，并在可见层加入保底、加速、追赶倍率等非对称规则，它们让玩家看到“赢得多输得少”或反之，但不改变匹配器；（2）官方承认的非实力因素是一组固定类别——延迟与排队时间、新手初始分与回流衰减、组排有效技能的聚合方式、位置与补位、行为分或信誉、休闲模式的机器人；（3）被明确否认的是“读取连胜/连败安排队友”“按消费匹配”“强制 50% 胜率”；（4）没有一家公开过可供第三方复核的匹配日志或审计结果。

表 1.5：各厂商官方披露摘要（时间截至 2026-10；引文出处见正文）

厂商（游戏）	评分与可见层	官方承认的非实力或补偿规则	官方明确否认
Riot（LoL、手游、VALORANT）	隐藏 MMR；段位/RR 经“收敛”乘数追赶 MMR；不确定度（方差）随表现变化	位置偏好与补位（补位多的一方给略高 MMR 队友）；排队时间换 MMR 窗口；回流段位衰减	输家队列；读取连败；按荣誉、标记、符文匹配
Valve（Dota 2、CS2）	隐藏 MMR（Dota 天梯可见）；CS Rating 可见、公式未公开	新手配高行为分玩家；组排、语言、经验差；高段组排按最高者计；Dota Plus 显示行为分	（未见针对“控胜率”的正式否认文件）
Blizzard（OW2、酒馆战棋、SC2）	内部 MMR/内部评分只用于匹配；外显段位或外显评分另算（保底、进度分、追赶倍率）	新手初始 MMR 下调到青铜 5；按胜率移动平均加速 MMR；按位置配对；SC2 曾有不活跃衰减（2015 年移除）	赢家/输家队列；强制 50% 胜率；按外显段位匹配

[24]待核对：本次未读到原文全文；未观看原视频，依据媒体转述。

续表 1.5

厂商（游戏）	评分与可见层	官方承认的非实力或补偿规则	官方明确否认
Activision（CoD）	原始技能（MMR）与百分位；排位另有目标 SR/当前 SR	延迟优先、匹配用时次之；技能约束随等待放宽；组排“取中间”；未公开时段的 A/B 测试；2025 年默认弱技能匹配	按游戏时长、按消费匹配；常规匹配用机器人；主播特殊待遇
Respawn（Apex）	隐藏技能分	组排按最高者计；排位分队优先队友实力相当而非两队完美均衡	赢多了故意加难、连败故意放水
Epic、KRAFTON	内部 MMR，算法未公开	休闲模式机器人随实力递减或在人少时替补；组排 MMR 加权平均（PUBG）	—
微软 / 343（光环）	TrueSkill 2 计算 MMR；CSR 可见但不用于匹配	跨播放列表初始化；匹配参数随人口自动调整	为强制 50% 胜率而制造不公平对局
腾讯（王者荣耀）	2018 年称用 ELO 评估实力；2026 年起“以段位为主要依据”	挑战强敌（等待过长扩大段位范围）；负面信誉维度（不连续同队）	为连胜者匹配“坑队友”；干预胜率
网易（漫威争锋）	竞技分，细节未公开	阵容构成、离群值处理	使用 EOMM

1.8　“每局双方约五五开”到底是什么意思

用户的问题是：厂商说“每局双方约五五开”，指的是实力五五开，还是胜率五五开？把各家原话放在一起（表 1.6），答案相当确定：厂商让相等的是**系统对实力的估计**（MMR 或其团队聚合值），由此得到的是**系统预测的单局胜率**约为 50%。它既不是关于真实实力的断言（估计有误差），也不是关于长期胜率的承诺（长期胜率接近 50% 是收敛后的结果，多家明确说不是目标）。

表 1.6: 各厂商对“公平对局”的原话（英文为原文摘录）

来源	原话	被拉平的量
Riot，LoL 2018[84]	“*most teams have an expected win rate of 50 +/-1%*”；“*We expect every game you play to have a 50 +/-1% chance of your team destroying the Nexus.*”	系统的单局预期胜率（“from all the data we have, we think we’ve made a fair match”）
Riot，手游 2021[86]	“*MMR per team is balanced to give each team the same chance at winning the match (close to 50%).*”	两队 MMR 总量，目的是预测胜率相等
Riot，LoL 2025[90]	“*In the worst case, the team with more autofilled players will have slightly higher MMR players.*”	计入补位劣势后的预测胜率（MMR 本身有意不等）
Riot，VALORANT 2021[91]	“*When you are at your MMR, we’ve most often seen you with a 50% win rate.*”	观察到的收敛后长期胜率（不是匹配目标）

续表 1.6

来源	原话	被拉平的量
Valve，Dota 2 2013[94]	“*The teams are balanced. (Each team has a 50% chance to win.)*”	两队预测胜率，与其他多项质量分加权
Valve，Dota 2 2017[95]	“*Simply having an even chance to win over the long run does not necessarily correlate to having competitive matches.*”	区分“长期均等”与“单局有悬念”
Blizzard，OW2 2023[103]	“*…make each match as fair as possible, meaning your team has an equal chance of winning or losing each individual match.*”；“*two teams never have identical ratings*”	单局预测胜率；承认总有一方略被看好
Blizzard，OW2 2023[103]	“*The matchmaker doesn't force a 50% win rate on anyone.*”	否认长期胜率是约束
343，光环 2022[118]	“*a “fair match” is one where each team has a 50/50 chance at winning because the teams are evenly balanced … we expect to see an average 50% win rate. Note that that's a side effect we expect to see and not a goal*”	单局预测胜率；长期 50% 是副作用
微软，TrueSkill[117]	“*If you are likely to draw with another player then that player is a good match for you!*”	模型下的打平概率（同时惩罚 μ 差和不确定度 σ）
Activision，CoD 2024[110]	“*The goal is to make the outcome of a match as unpredictable as possible.*”	两队技能总和差最小（在延迟与等待约束之下）
Respawn，Apex 2023[113]	“*We try to put you into matches where you'll have a fair chance of winning*”；排位中 “*we value having teammates of equal skill … over a perfectly fair match*”	普通模式：两队平均技能；排位：队友相近优先
Blizzard，酒馆战棋 2020[105]	“*we will try to select eight players with the closest internal rating*”	八人内部评分相近（等价于预期名次相近）
腾讯，王者荣耀 2018[121]	“尽可能将水平尽量相当的召唤师放入同一局比赛”“创造双方势均力敌的竞技环境”	系统评估的“综合能力”；未给数字
腾讯，王者荣耀 2026[123]	“以段位为主要依据进行匹配”；“90% 以上的对局双方段位差控制在 2 星及以内”	可见段位差（与预测胜率不同的量）

三种读法。　“五五开”至少有三种读法：(a) 双方真实实力相等；(b) 系统预测的单局胜率为 50%；(c) 每个玩家的长期胜率为 50%。表中没有一家声称 (a)——厂商只看得到估计值，Riot 2018 年的原话就是“从我们所有的数据看，我们认为这是一场公平的对局”，紧接着列举了数据看不到的东西。(b) 是所有厂商的实际口径：Riot 的“50%±1%”、手游的“接近 50%”、Dota 2 的“每队 50% 的机会”、光环的“50/50”，说的都是模型给出的预测值。(c) 在两家的原文中被明确降级为结果而非目标：光环说它是“副作用”，守望先锋说匹配器“不对任何人强制 50% 胜率”；VALORANT 的“在你的 MMR 上时最常看到 50% 胜率”则是对收敛状态的观察。

预测胜率 50% 不等于真实胜率 50%。　匹配器拉平的是估计值 $R_i = s_i + e_i$，所以一局的真实胜率 $p = F\big((R_A - R_B) - (e_A - e_B)\big)$ 围绕 50% 分布，宽度由评分误差 σ_e 决定：对全体对局平均，p 以 1/2 为中心；对某一局，它可以明显偏离 1/2。第 2.2 节给出完整推导与数值：固定 $K = 16$ 的 Elo 稳态下 $\sigma_e \approx 38$ 分，90% 的“五五开”对局真实胜率落在 38%–62% 之间；5v5 中两队评分和相等时，随机“对位”的单挑胜率可以悬殊得多【本项目】。对某一个玩家，若他的估计系统性偏低（水平刚提高，或用新账号重新定级），他的多局 p 都高于 1/2，长期胜率会高于 50%，直到评分追上实力（第 2.4.4 节与 2.6.3 节）。团队对局中还要加上组排、位置、状态等模型外因素。

几条原话的细节。　有三处细节支持上面的读法。第一，Riot 2025 年的补位规则说，补位人数多的一方会拿到 MMR 稍高的队友[90]——如果匹配器的目标是“MMR 相等”，这条规则就无从解释；它只有在目标是“考虑补位劣势后的预测胜率相等”时才说得通。第二，TrueSkill 把匹配质量定义为打平概率，这个量同时随均值差 $|\mu_A - \mu_B|$ 和不确定度 σ 下降[117]；也就是说，即便两人的估计均值完全相同，系统也承认“它不确定这是不是五五开”。第三，守望先锋承认“两队评分从不完全相同”，用“被看好一方的获胜比例”（可预测性）衡量对局，并发现低分段可预测性更低、因而校准评分的信息更少[103]。Dota 2 2017 年那句“长期均等不等于有竞争性”则把（b）和（c）的区别说得最透[95]。

腾讯的口径与八人对局。　腾讯 2018 年的“水平尽量相当”“势均力敌”属于读法（b），但没有给出数字；2026 年 S42 改版后公布的指标是“段位差在 2 星以内的对局占比”，这衡量的是可见段位是否接近，是第四种量。在隐藏分与可见段位分离的系统里，段位接近并不意味着预测胜率接近，反之亦然（TrueSkill 的 57.6% 与 5.7% 例子就是反例）。对酒馆战棋这样的八人自由混战，“公平”的含义是八人内部评分相近；在这种对局里，若八人实力完全相同，每人的预期名次为 4.5、进前四的概率为 1/2、拿第一的概率为 1/8【本项目】，所以“五五开”在八人游戏里没有直接对应物，比较时应看前四率或平均名次（第 2.5.2 节）。

1.9　专利：权利要求实际保护了什么

怎样读专利。　专利说明书可以描述很多“实施方式”，但被授予的权利只由*权利要求*界定，其中独立权利要求划出最大范围，从属权利要求在其上加限定。同一申请可以通过“续案”（continuation）不断拿到新的授权，续案的独立权利要求常常比母案更宽或换一个角度。专利只证明公司研究过某个方案并获得了保护，不证明它已在任何产品中使用；公司也常为防御而申请专利。本节读了 24 件美国授权专利的首页著录项和全部独立权利要求（USPTO 全文图像，经 OCR 识别，方法见附录 A.2.1），表 1.7是摘要。下面的“通俗含义”都是对*权利要求*的转述，不是对说明书或媒体报道的转述。

1.9.1　Activision：按“诱导购买”匹配，以及多因素打分

US 9,789,406《在多人游戏中驱动微交易的系统和方法》于 2015 年 5 月 14 日提交（四件临时申请均为 2014 年 7 月 3 日），2017 年 10 月 17 日授权，发明人 Marr、Kaplan、Lewis[128]【专利】。三项独立权利要求（方法、系统、存储介质）内容相同：先识别第一名玩家可能感兴趣但尚未拥有的道具（依据其档案中的偏好，或该道具对某一关卡的效用），再找到拥有该道具的第二名玩家，以“第一人对道具的兴趣”和“第二人持有该道具”为依据把两人匹配进同一局，最后更新第一人的档案以记录购买与否【专利】。从属权利要求进一步写到：第一人购买后，把他匹配进“适合使用该道具”的后续对局（权利要求 2）；道具可以依据促销活动选定（权利要求 7）；第二人可以按与第一人的技能差选定（权利要求 8）【专利】。通俗地说，就是“把你想要的装备的拥有者安排到你身边，买了以后再给你安排能让它大显身手的局”。专利曝光后，Activision 发言人称这是“一个由独立于各游戏工作室的研发团队在 2015 年提交的探索性专利，没有在游戏中实施”，Bungie 社区总监 DeeJ 称“这些功能都不存在于《命运》中”[129]【官方】；2024 年的《使命召唤》匹配博客又写明花钱“绝不以任何方式”影响匹配[108]【官方】。

同一批申请里的另两件更“平常”。US 10,322,351（2019-06-18 授权）的独立权利要求是：用多项匹配变量乘以系数求和得到匹配分，系数从默认值调成“调优值”，再把匹配分与一个随该玩家等待时间调整的阈值比较，决定是否成局[130]【专利】——等待越久门槛越低，这与 2024 年白皮书公开的“退避”机制在形式上一致，但专利本身不能说明白皮书描述的系统就是它。US 10,376,792（2019-08-13 授权）保护的是“推荐小队构成”：以曾一起玩过的“基准小队”为参照、用与网络延迟有关的系数给候选小队打分，决定是否推荐[131]【专利】。

1.9.2　EA：以留存为目标的匹配、以“对局质量”为目标的匹配，以及动态难度

EA 名下至少有四个与匹配或难度相关的专利家族，发明人与 EOMM 论文[51]高度重合（Aghdaie、Kolen、Xue、Zaman、Chen）。

家族一：按预测留存替换人选。　US 9,993,735《多人游戏匹配优化》于 2016 年 3 月 8 日提交、2018 年 6 月 12 日授权[132]【专利】。独立权利要求：从排队玩家中选出一组人、分成两队形成“匹配方案”，用每人的交互数据算出该方案的参与度分；达到阈值就开局，达不到就从队列里换人（并保持某两人始终同局）【专利】。续案 US 10,610,786（2020-04-07）把“参与度分”写成“预测留存值”，并定义为“该方案中的玩家预计会继续玩这款游戏的时长”[133]【专利】；再续案 US 11,141,663（2021-10-12）把预组队的“用户组”也纳入预测[134]【专利】。

家族二：流失风险加权图。　US 10,286,327《多人游戏匹配系统和方法》于 2017 年 1 月 26 日提交（临时申请 2016-10-21）、2019 年 5 月 14 日授权，发明人 Xue、Zaman、Aghdaie、Kolen、Chen[135]【专利】。独立权利要求：把候选玩家建成连通图，每条边的权重由两端玩家各自的流失风险（由近期交互数据算出）决定，选出一组覆盖所有顶点的边，按选中的边配对开局【专利】。这就是 EOMM 的算法骨架。两件续案 US 10,751,629（2020-08-25）和 US 11,344,814（2022-05-31）把独立权利要求中的“流失风险”换成了更宽的“参数函数的输出”或“用户分”，再在从属权利要求中写明这个量可以是流失预测、留存预测或“完成本局的预测”，并把流失风险定义为“玩家在本局之后的某一时间段内不再玩这款游戏的可能性”[136-137]【专利】。US 10,751,629 的从属权利要求 8—10 还写明：先预测对局结果，再把预测结果作为参数函数的输入【专利】——也就是“预测谁会赢 → 预测谁会流失 → 据此配对”。续案越写越宽，说明 EA 在 2022 年仍在维护这个方向的保护范围。

家族三：对局质量因子。　US 11,071,909（2021-07-27 授权，2018-03-19 提交）及其续案 US 11,845,005（2023-12-19）保护“以对局质量为中心的匹配”：把玩家装入若干“虚拟对局”，每加入一名新玩家就重新计算一组对局质量因子（权利要求明确包括玩家之间网络速度的均衡），只有当质量因子改善（在 US 11,071,909 中要求“有的变好、没有变差”）时才保留这名玩家[138-139]【专利】。另一件 US 11,478,715（2022-10-25）按玩家自选的“控制选项”把玩家嵌入向量空间，距离小于阈值即匹配[140]【专利】。

动态难度（DDA）。　US 9,919,217《动态难度调整》与家族一的母案同日（2016-03-08）提交，发明人几乎相同（多一人），2018 年 3 月 20 日授权，公开号 US 2017/0259177 A1[141]【专利】。独立权利要求：用玩家交互数据和选定的预测模型算出该玩家的预测流失率，据此为游戏中的某个“旋钮”（改变游戏状态的变量）选定种子值，并据此修改游戏运行【专利】。续案 US 10,286,323（2019-05-14）把权利要求扩宽为“依据预测流失率修改游戏运行”，US 10,807,004（2020-10-20）则保护“按玩家通关成功率给关卡种子分难度等级”[142-143]【专利】。DDA 调的是游戏内容的难度，不是和谁对局；但它与家族一同日提交这一点说明，2016 年前后 EA 的同一个团队把“流失预测”同时用在了难度和匹配两个方向。下一节的诉讼针对的正是这件 DDA 专利。

1.9.3　微软：TrueSkill 与“按等待时间调阈值”

US 7,050,868《贝叶斯评分》（2005-01-24 提交，2006-05-23 授权，发明人 Graepel、Herbrich）是 TrueSkill 的原始专利[144]【专利】：独立权利要求包括按胜、负、平更新每名队员的均值和方差，以及由队员的均值、方差得到队伍的分布、按两队分数之差的期望来配对【专利】。续案 US 7,376,474（2008-05-20）把打平结果和“距上次游戏的时间”引起的实力变化写进权利要求，并规定配对阈值“取决于可供匹配的玩家数”[145]【专利】。US 8,538,910（2013-09-17）在因子图上用完赛名次和部分参与时长更新实力[146]【专

利】。US 8,672,764《游戏的自适应匹配》（2007-03-29 提交，2014-03-18 授权）把实力和连接质量合成一个数值，与匹配阈值比较；系统观察玩家实际等待时间，与“目标等待时间”相差超过一定幅度时，带阻尼地调整阈值[147]【专利】。这是“排队时间换匹配精度”最早的一手专利文献之一。与其他公司不同，TrueSkill 的部署有公开证据：微软研究院项目页列出了使用它的游戏[117]【官方】。Activision 的 US 9,789,406 首页引用文献中也列有这两件 TrueSkill 专利【专利】。

1.9.4　Riot：按行为数据和游戏时段组队

US 9,795,887（2012-07-17 提交，2017-10-24 授权，发明人 Jeffrey Lin、Paul Sottosanti）保护一套在线游戏系统：其他玩家的举报形成“骚扰分”，由仲裁者对举报做同行评议，匹配系统依据玩家档案中的行为数据配对[148]【专利】。续案 US 11,065,547（2021-07-20）的独立权利要求改为：其他玩家给出的“称赞”（commendation）按类型累计为分数，按阈值把玩家归入预设的“性格类别”，再依据双方的性格类别匹配（作为队友或对手均可）[149]【专利】。US 11,484,801（2021-03-23 提交，2022-11-01 授权）则在玩家发起组队请求时，按其常玩时段与其他账号的相似度排序，生成小队[150]【专利】。这三件都不涉及胜率。Riot 的荣誉系统确实存在，但 2025 年 Phroxzon 的公开说法是排位匹配不使用荣誉等级（第 1.7.1 节），这正是“有专利、但官方称不用于排位”的例子。

1.9.5　中国公司

本文能读到权利要求的中国公司专利，都是经 PCT 进入美国的同族。字节跳动的 US 12,533,594《游戏匹配的方法、装置、存储介质和电子设备》于 2023 年 5 月 25 日提交（中国优先权 202210583584.4，2022-05-25），2026 年 1 月 27 日授权[151]【专利】。独立权利要求：先取待匹配队伍的“队伍特征”，用预训练的聚类模型判定其所属簇——该模型训练时的约束是“不同簇的队伍游戏水平不同、不同房间类型下任意两簇的队伍数量差最小”——再按簇和房间类型把队伍分进匹配池（池内队伍水平差最小），在池内配对【专利】。它关注的是水平相近与匹配池规模均衡，不涉及留存或胜率调控。腾讯的 US 9,149,725（2015-10-06 授权，中国优先权 2013-06-03）保护按队伍人数分队列、拼成人数相等的两个阵营的组队方法[152]【专利】，同样与胜率无关。

中国国家知识产权局和 Google Patents 在本研究的网络环境中拒绝访问，腾讯、网易、字节跳动、米哈游名下以“对局匹配”“胜率”为题的中国专利只能经搜索引擎查找。出现过的条目（如 CN112221161B《对局参与方的匹配方法、装置、设备及可读存储介质》）本文未能核实申请人和权利要求[25]，因此既不列为任何公司的专利，也不据此断言“中国公司没有以胜率为目标的匹配专利”。就可核实的材料而言，中国公司“非纯实力匹配”的最有力证据是公司论文（EnMatch、CUPID），而不是专利。

[25] 待核对：本次未读到原文全文；中国专利检索系统与 Google Patents 不可访问。

表 1.7: 与匹配或难度相关的美国授权专利（按权利要求转述；“部署”一栏只记录公开证据）

专利号	权利人	提交	授权	独立权利要求的通俗含义	部署证据
9,789,406	Activision	2015-05	2017-10	按“对道具的兴趣＋对方持有该道具”匹配，记录购买与否	公司称未实施；2024 年称消费不影响匹配
10,322,351	Activision	2015-05	2019-06	多变量加权匹配分，阈值随等待时间放宽	无对应声明
10,376,792	Activision	2015-05	2019-08	参照“基准小队”推荐小队构成	无
9,993,735	EA	2016-03	2018-06	两队匹配方案的参与度分低于阈值则换人	无
10,610,786	EA	2018-05	2020-04	同上，指标为“预测会继续玩的时长”	无
11,141,663	EA	2020-03	2021-10	同上，把预组队纳入预测	无
10,286,327	EA	2017-01	2019-05	连通图边权＝两端玩家流失风险，选边配对（EOMM）	无；论文见[51]
10,751,629	EA	2019-03	2020-08	边权＝参数函数输出；从属项：先预测胜负再预测流失	无
11,344,814	EA	2020-08	2022-05	按用户分求组分选组；从属项：流失风险	无
11,071,909	EA	2018-03	2021-07	逐个加人，只在对局质量因子（含网速均衡）改善时保留	无
11,845,005	EA	2021-07	2023-12	同上（续案）	无
11,478,715	EA	2020-06	2022-10	按玩家“控制选项”嵌入向量空间，距离近则匹配	无
9,919,217	EA	2016-03	2018-03	预测流失率 → 调游戏“旋钮”（动态难度）	EA 称未用于 FIFA/Madden/NHL 及任何在线多人
10,286,323	EA	2018-02	2019-05	依据预测流失或留存修改游戏运行	同上
10,807,004	EA	2019-05	2020-10	按通关成功率给关卡种子分难度等级	同上
7,050,868	微软	2005-01	2006-05	高斯均值方差更新；按分差期望配对（TrueSkill）	公开部署（Xbox Live 等）
7,376,474	微软	2006-02	2008-05	加入打平与时间动态；阈值取决于可匹配人数	同上
8,538,910	微软	2007-01	2013-09	因子图更新，利用名次与部分参与时长	TrueSkill 系列
8,672,764	微软	2007-03	2014-03	实力＋连接质量合成值；按实际与目标等待时间带阻尼调阈值	无直接声明
9,795,887	Riot	2012-07	2017-10	举报形成骚扰分、同行仲裁，按行为数据匹配	2025 年称排位不按荣誉匹配
11,065,547	Riot	2017-09	2021-07	称赞 → 性格类别 → 按类别匹配	同上
11,484,801	Riot	2021-03	2022-11	按常玩时段相似度生成小队	无
12,533,594	字节跳动	2023-05	2026-01	聚类分匹配池（水平相近、池规模均衡），池内配对	无
9,149,725	腾讯	2014-05	2015-10	按队伍人数分队列，拼成人数相等的阵营	无

1.10　诉讼与监管

1.10.1　Zajonc 诉 EA：动态难度集体诉讼（2020—2021）

2020 年 11 月 9 日，Jason Zajonc、Danyael Williams、Pranko Lozano 三人代表全体同类玩家，在美国加州北区联邦地区法院起诉 EA（案号 3:20-cv-07871，法官 Alsup）[153-154]【官方】。起诉状称：EA 在 FIFA、Madden、NHL 的 Ultimate Team 模式中“未加披露地”使用其“已获专利的人工智能技术”——动态难度调整——并直接引用 DDA 专利申请的公开文本 US 2017/0259177 A1（即 US 9,919,217）中“依据历史用户活动生成游戏留存预测模型”和“对用户不可察觉的细粒度难度调整”等语句；起诉状还主张，即使不用 DDA，这些游戏也有其他“难度调整机制”，在与真人的在线对局中同样会让玩家“漏传、漏射、跑得更慢”【官方】。原告据此主张玩家花钱抽卡组建的球队并没有得到应有的价值。

诉讼没有进入实体审理。案卷显示：双方约定把 EA 答辩期限延至 2021 年 3 月 12 日；2021 年 2 月 11 日，原告依《联邦民事诉讼规则》第 41(a)(1) 条提交不损害再诉权（without prejudice）的自愿撤诉通知，此时 EA 尚未提交答辩或简易判决动议[154]【官方】。撤诉通知本身没有说明理由。理由只见于 EA 的公开声明：EA 向原告提供了“详细的技术信息并让他们与我们的工程师交谈，所有这些都（再次）确认 Ultimate Team 模式中没有 DDA 或脚本”；声明随后写道：“虽然 EA 确实拥有一项 DDA 技术专利，但这项技术从未用于 FIFA、Madden 或 NHL，将来也不会。我们不会在我们任何游戏的在线多人模式中使用 DDA 技术来给玩家优势或劣势”[155]【官方】。

这份声明的范围需要读准。它覆盖两件事：三款体育游戏中的 DDA，以及 EA 全部游戏在线多人模式中“用 DDA 给玩家优势或劣势”。它没有提到上一节的留存匹配专利家族（US 9,993,735、US 10,286,327 及其续案），也就是说，EA 对“按预测流失选人”既没有承认也没有否认。另外，撤诉不是法院的事实认定；它能说明的是，原告在拿到 EA 提供的材料后选择不再继续，这比单纯的公关声明多了一层经过对方律师检验的意味，但材料本身没有公开。

1.10.2　孙千和诉腾讯：“中国游戏算法诉讼第一案”（2024—2026）

起诉与庭审。　青岛执业律师孙千和于 2024 年 6 月向深圳市南山区人民法院提交起诉状，被告为深圳市腾讯计算机系统有限公司和腾讯科技（成都）有限公司；法院于 2025 年 2 月 18 日立案[156]【官方】。起诉状称，连胜几局后会匹配到“很菜的队友和很强的对手”，从而连输，“输输赢赢如此反复，直到胜率趋近于 50%”；诉讼请求是公开影响匹配队友和对手的具体因素，以及各因素在排位赛、巅峰赛、匹配赛、娱乐模式中的占比和权重[157]【官方】。2025 年 8 月 12 日开庭，庭审从下午两点半持续到晚上七点二十分左右，未当庭宣判[157]【官方】。腾讯提交了近 1000 页证据，主张匹配机制属于技术秘密；称“匹配机制并不完全等于游戏算法”，对局胜负受团队配合、阵容、

战术和玩家状态影响，“匹配机制无法决定游戏对局胜负”；并举例说某款游戏的玩家曾通过连续故意投降压低隐藏分、换取更弱的对手，以说明公开细节会被滥用[121]【官方】。腾讯还展示了随机抽取的玩家胜率：玩家 A 全部 752 场胜率 76.1%，玩家 B 全部 2398 场胜率 71%，玩家 C 当前赛年 472 场胜率 81.6%[121,157]【官方】。

这组样本只能反驳“每个玩家都被控制在 50%”这一强命题，不能证明不存在任何短期调节：样本是被告挑选的，“全部比赛”还可能混合了不同模式的 MMR 池。反过来看，在只按隐藏分匹配、隐藏分能追上实力的系统里，长期胜率应向 50% 收敛（第 2.4.1 节）；2398 场 71% 提示至少在部分模式或分段，强玩家并没有被迅速推到势均力敌的对手面前（例如受高分段人数或匹配范围上限约束）【本项目】。

案由变更与一审判决。 2026 年 1 月 22 日，法院依据当年 1 月 1 日施行的最高人民法院新增案由，把案由从“网络服务合同纠纷”变更为“数据纠纷”[156]【官方】。2026 年 4 月 7 日，原告在自媒体账号公开了一审判决[122]【官方】。判决书作出的确切日期未见报道。据报道，法院围绕四个争议焦点裁判[158]【官方】：

- 原告无权以消费者知情权要求公开算法：匹配算法不属于《消费者权益保护法》规定的知情权范畴，也不是游戏服务的基础性信息；运营方已通过多种渠道公开了匹配算法的类型、核心影响因素等核心逻辑，原告要求的具体技术细节超出知情权的合理范围；
- 判令公开不具有合理性：算法是运营方的商业秘密，运营方已采取合理保密措施，公开会泄露商业秘密、“禁锢算法的动态优化发展”，还可能被恶意玩家滥用、破坏游戏公平；
- 判决驳回原告全部诉讼请求。

判决书结尾写道：“对于本案《王者荣耀》游戏的玩家匹配算法及细节，虽不在行政监管的强制公示及备案之列”，但被告作为有较高影响力的游戏企业，“不能仅止步于被动接受行政监管”，可以“引入社会监督，设置人工干预及便捷的投诉、申诉渠道，为用户提供可选择的关闭算法推荐功能等措施，变被动合规为主动治理”[159]【官方】。腾讯相关人士表示判决“充分评估了匹配机制细节公开会给广大玩家带来的负面影响”[159]【官方】。

需要强调的是，这场诉讼的争点是能否要求公开，不是是否操纵胜率；法院没有就“胜率是否被控制”作出事实认定，判决既不能被读作“证明了没有操纵”，也不能被读作“默认了操纵”。

上诉情况。 判决公布当天，原告接受采访时称“目前尚未确定是否上诉”，并提到自开庭以来游戏陆续调整了匹配机制，如在对局界面显示双方段位[159]【官方】。4 月 9 日的一则 TapTap 用户帖称原告“已公开表示将提起上诉”[160]【社区】，本文未找到其他来源印证。截至 2026 年 10 月 19 日，本文未检索到上诉立案、二审开庭或二审判决

的报道[26]。

1.10.3　监管：算法推荐规定与游戏规章

与匹配透明度最相关的现行规范是国家互联网信息办公室等四部门 2021 年 12 月 31 日公布、2022 年 3 月 1 日施行的《互联网信息服务算法推荐管理规定》[161]【官方】。它所称“算法推荐技术”包括“生成合成类、个性化推送类、排序精选类、检索过滤类、调度决策类等”（第二条）；要求服务提供者“以适当方式公示算法推荐服务的基本原理、目的意图和主要运行机制”（第十六条），向用户提供“不针对其个人特征的选项”或“便捷的关闭算法推荐服务的选项”（第十七条），并鼓励提高排序、选择、推送规则的“透明度和可解释性”（第十二条）；需要向网信部门备案的只是“具有舆论属性或者社会动员能力”的服务提供者（第二十四条）【官方】。游戏匹配是否属于“调度决策类”算法推荐，规定没有明说；王者荣耀案的判决认定匹配算法“不在行政监管的强制公示及备案之列”，但判决建议中的“可选择的关闭算法推荐功能”显然借用了第十七条的思路。

游戏专门规章对随机性的监管远早于对匹配的监管。原文化部 2016 年的《关于规范网络游戏运营加强事中事后监管工作的通知》（文市发〔2016〕32 号，已失效）要求运营企业公示所有可抽取物品的信息和概率；国家新闻出版署 2023 年 12 月 22 日公开征求意见的《网络游戏管理办法（草案征求意见稿）》要求对随机抽取的次数和概率作出合理设置，并在第十七条规定不得设置强制对战[162]【官方】[27]。也就是说，中国的规章要求公开“抽卡概率”，却没有任何条文要求公开“匹配规则”。本文也没有检索到其他司法辖区对游戏匹配算法设定专门披露义务的规定。在这种格局下，匹配透明度目前只取决于厂商自愿披露的程度，而第 1.7 节显示这个程度差别很大：从 Activision 的三份白皮书到只有一句“以段位为主要依据”。

1.11　证据强度小结：哪些已证实，哪些被否认，哪些仍未知

把以上各节与本章前半部分的材料合在一起，关于“厂商是否在匹配中做了实力以外的事”，可以分成四档（表 1.8）。

已证实。　(1) 大厂研究过并申请保护了以留存或参与度为目标的匹配：EA 两个专利家族的权利要求明确写出“流失风险”“预测留存时长”【专利】，EOMM 与 EnMatch 公开发表了这类算法，EnMatch 还报告了在两款未具名游戏中的线上部署【文献】。(2) Activision 用 A/B 测试调整技能约束、以回流率和退出率评价，并有意不公开测试时

[26]待核对：本次未读到原文全文；需在中国裁判文书网或深圳市中级人民法院公开信息中核对。

[27]待核对：本次未读到原文全文；草案原文未读，依据律所解读；正式文本是否已施行未核实。

段【官方】。(3) 多家厂商承认了一组会改变部分玩家对局构成或胜率的非实力规则（新手、回流、机器人、行为与信誉、补位、组排聚合，见表 1.5），以及可见段位上的保底、进度分和追赶倍率【官方】。

被明确否认。　“读取连胜/连败安排队友”“输家队列”“强制 50% 胜率”“按消费匹配”“在线多人中用 DDA”“使用 EOMM”分别被相关厂商否认（表 1.8）【官方】。这些否认都是公司自述；只有 EA 的否认经过了诉讼程序的间接检验（原告获得技术材料后撤诉），但材料未公开。

仍然未知。　(1) 任何一款主流竞技游戏的排位模式是否在逐局组局时使用流失或参与度预测。公司论文说的是“两款游戏”“一款热门手机 MOBA”，没有点名，也没有说是否用于排位；专利不说明部署。(2) 未公开的 A/B 测试在某一时段把哪些玩家放进了哪种配置。(3)《王者荣耀》等未公开评分模型的游戏，其隐藏分与段位如何组合、“表现分”权重多大；法院没有就是否操纵作出认定。(4) 没有任何厂商发布过可由第三方复核的匹配日志或独立审计结果。

什么证据能够定论。　要区分“诚实的按分匹配”和“以留存为目标的匹配”，需要的不是更多的官方表态，而是可检验的数据：(1) *逐局的双方隐藏分和系统预测胜率*：在诚实的按分匹配中，控制了玩家自身评分之后，他近期的连胜或连败不应再能预测队友和对手的评分；如果能，就说明匹配器读取了战绩（检验思路见第 3.6 节与第 4.4.3 节）；(2) *独立审计或向监管部门备案的算法自评估报告*，《算法推荐管理规定》第二十四条已为“有舆论属性”的服务提供了备案框架，可以借鉴到游戏；(3) 像 *Dota Plus* *那样随局公开的匹配质量信息*，让玩家自己积累样本；(4) *诉讼中的证据开示*，如果未来有案件进入实体审理。在这些数据出现之前，本研究其余各章做的是另一件事：证明即使匹配器完全诚实，玩家也会看到连败、“连胜后连败”和长期 50% 胜率（第二章和第三章）——这说明那些体感*不需要*操纵就能出现，但正如上文所说，它不等于证明了没有操纵。

表 1.8: 关于厂商匹配实践的主要说法与证据强度

说法	证据	结论	标签
厂商研究并申请了以留存为目标的匹配	EA 两个专利家族的权利要求；EOMM、EnMatch 论文	已证实	【专利】【文献】
有公司把参与度匹配部署到线上	EnMatch：两款未具名游戏；CUPID：一款热门手机 MOBA（目标为公平与位置满意度）	已证实（游戏未知）	【文献】
厂商用 A/B 测试调整技能约束并以留存评估	Activision 白皮书二；测试时段不公开	已证实	【官方】
官方承认的非实力规则（新手、回流、机器人、行为、补位、组排）	守望先锋、英雄联盟、堡垒之夜、PUBG、Dota 2、王者荣耀、Apex 官方文本	已证实	【官方】

续表 1.8

说法	证据	结论	标签
可见段位与匹配分分离，可见层有保底和追赶	酒馆战棋、使命召唤、光环、VALORANT 官方文本	已证实	【官方】
按消费匹配	Activision 专利存在；公司 2017、2024 年否认	被否认	【专利】【官方】
EA 在体育游戏或在线多人中用 DDA	DDA 专利存在；诉讼撤诉；EA 声明	被否认（经诉讼间接检验）	【专利】【官方】
读取连胜/连败安排队友、输家队列、强制 50%	Riot、Blizzard、Respawn、腾讯、网易否认；无独立证据支持	被否认，未经独立检验	【官方】
主流排位模式逐局使用流失预测	无公开证据；专利与论文均未指明	未知	—
王者荣耀控制胜率	原告体感；腾讯否认；法院未作事实认定	未知	【社区】【官方】

1.12　本章小结：两条线索合起来看

学术文献和厂商材料描述的是同一套系统的不同侧面。把它们按“评分模型—匹配器—可见段位”三层对齐（表 1.9），可以看清哪里已经透明、哪里仍是黑箱。

表 1.9：三层结构上的学术证据、厂商披露与未知之处（详见第 1.6 节与 1.11 节）。

层	学术研究说明了什么	厂商披露了什么	仍然未知
评分模型（隐藏分 R_i）	统计性质清楚：稳态误差、滞后、用估计值预测会过度自信、封闭分池会通缩；“队伍实力 = 成员之和”在车队中失效	普遍使用隐藏 MMR；微软、国际象棋平台公开了模型，酒馆战棋公开了输入；多家承认按不确定度或近期胜率调节评分速度	王者荣耀、CS2 等的模型与“表现分”权重
匹配器	公平的对局信息量最大；等待与质量需要权衡；以留存为目标的匹配可行、报告的效应小、无独立复现	延迟优先，窗口随等待放宽，组排聚合、补位、行为分；否认读取连胜；Activision 用 A/B 测试以留存评估技能约束	主流排位是否逐局使用流失预测；未公开测试的时段与配置
可见段位	很少研究	保底、进度分、追赶倍率、目标 SR，与匹配分分离	各游戏的具体参数

两条线索在一个地方交汇。支持“匹配不只看实力”的最强证据来自公司自己：EA 的专利权利要求和 EOMM、EnMatch 论文说明这类方案被认真研究过，并在未具名的游戏中部署过；反对的最强证据也来自公司自己：多家厂商明确否认按连胜连败安排对局，但都没有可供复核的日志。外部研究者拿不到隐藏分和匹配记录，内部研究者发表的论文又不涉及排位匹配器这一环，所以这个问题无法仅靠文献和官方表态来判定。

因此后三章从另一端入手：假设匹配器完全诚实，推导它在数学上会产生怎样的胜率（第二章）、怎样的连败和“连胜后连败”（第三章），以及胜负数据里还剩多少关

于实力的信息（第四章）。这样得到的是“无需操纵即可解释”的基准；能把诚实系统和操纵区分开的检验，即“控制自身评分后，近期连胜连败能否预测对手和队友的评分”，在第 3.6 节与第 4.4.3 节给出。

第二章　研究二：不干涉匹配时胜率能否计算

直接回答

能算，但算出来的是期望胜率，而且它不是实力的单变量函数：胜率由自身实力、实际遇到的对手（和队友）分布、匹配规则、胜负的定义和游戏本身的随机性共同决定。随机匹配下有闭式公式 $W = \Phi\big((s-\mu)/\sqrt{\sigma_d^2+\tau^2}\big)$：群体实力标准差 $\tau = 200$ 时，最强 10% 的长期胜率约 83%，最弱 10% 约 17%。按分匹配下，固定 K 的 Elo 满足精确恒等式 “胜率 = 平均预测胜率 + 评分净变化 /($K\times$ 局数)”，于是实力被兑换成评分，各实力十分位的胜率被压到 42%–58%（匹配窗口较宽）或 49%–51%（很窄）。“每局五五开” 指系统预测的胜率为 50%，即双方估计实力相等；真实胜率围绕 50% 分布，$K = 16$ 时 90% 的 “五五开” 对局真实胜率落在 38%–62% 之间；团队游戏里两队评分和相等，个人对位可以相差很大。每队人数越多，个人优势被稀释得越厉害（约 $1/\sqrt{n}$ 到 $1/n$）；8 人局的基准率取决于 “胜” 的定义（第一名 12.5%，前四 50%）。实力有波动时期望胜率仍能计算：单局独立波动让胜率曲线变平，自相关的状态起伏让百局胜率的方差变成二项分布的 1.6–3.7 倍，持续进步让胜率比预测高出约 “评分上升速度 /K”。最后，要从数据上把 52% 和 50% 分开，大约需要 4,900 局。

本章所有数值都来自显式模型：玩家实力 $s \sim \mathcal{N}(\mu, \tau^2)$（$\mu = 1500$，$\tau = 200$），1v1 胜率 $p = F(s_i - s_j)$，评分为固定 K 的 Elo，匹配不使用任何隐藏变量。模拟参数在每张图的图注里给出，总表见附录 A.3.1；代码在 `code/ch2/`。模型外推到真实游戏时，具体数字会变，但公式给出的依赖关系不变。

2.1　实力、评分与胜率是三个不同的量

2.1.1　实力是只在比较中才有意义的潜变量

对抗比较模型把每名玩家的实力 s_i 当作看不见的参数：每局里玩家发挥出一个随机的 “表现”，表现高者胜，于是 i 胜 j 的概率只取决于实力差，$\mathbb{P}(i \text{ 胜} j) = G(s_i - s_j)$。表现噪声取正态时 $G(x) = \Phi\big(x/(\sqrt{2}\beta)\big)$，这是 Thurstone Case V 模型，也是 TrueSkill

的出发点；取逻辑斯蒂时 $G = F$，即 Bradley–Terry 模型和多数 Elo 变体[1,6,9,24][1]【文献】。Elo 原书把一名棋手单局表现的标准差定为 200 分，于是两人表现差的标准差为 $200\sqrt{2} \approx 282.84$[12]【文献】。逻辑斯蒂和正态几乎可以互换：$F(d) \approx \Phi(d/\sigma_d)$，$\sigma_d = 1.702/c \approx 295.7$，这个系数使两条曲线的最大偏差最小，约 0.95 个百分点[163]【文献】；我们在 $|d| \le 1500$ 上复核，最大偏差为 0.949 个百分点【本项目】。本章正文的闭式公式都用这一近似，数值表用精确的逻辑斯蒂积分。

这样定义的实力有三个先天限制：

1. **只有差值可识别**。所有人的 s 同加一个常数，任何对局概率都不变。Elo 在原书中写道："It is only differences on the scale that have real significance in terms of probabilities."[12]【文献】所以"实力 1800"只相对某个群体才有意义。暴雪在《守望先锋 2》的匹配说明里也承认，MMR 不是绝对值，个人实力不变时 MMR 也可能因为整体玩家变强或变弱而变化[102]【官方】。
2. **刻度由"运气有多大"决定**。Elo 规定 400 分差对应 10:1 的胜负比；TrueSkill 2 的表现噪声 β 被明确解释为"反映游戏随机性的参数"[25]【文献】。同样的实力差，在随机性大的游戏里换来的胜率更少。
3. **默认单维、可传递**。存在石头剪刀布式的克制时，单个评分没有预测力；Balduzzi 等人把胜率矩阵分解为可传递部分和循环部分，Elo 只能刻画前者[31]【文献】。卡组、英雄、阵容克制都属于后者。

2.1.2　胜率是实力对对手分布的平均

若玩家实际遇到的对手实力分布为 $\mathcal{G}$，其长期胜率为

$$W(s;\mathcal{G}) = \int F(s - t)\,\mathrm{d}\mathcal{G}(t). \tag{2.1}$$

$\mathcal{G}$ 由群体和匹配规则共同决定。同一个 s 换一个对手池，胜率就变：图 2.1(a) 中实力固定为 1756 的玩家，在随机匹配下的胜率随群体离散度从 80.0%（$\tau = 100$）降到 73.2%（$\tau = 300$）；单局随机性变大时降到 73.1%；换成按分匹配，胜率随匹配窗口收窄从 64.5% 一路降到 50.9%【本项目】。胜率因此不是实力本身，而是"实力相对你实际遇到的对手"。

2.1.3　评分是带噪声、带滞后、带刻度的估计

TrueSkill 2 的定义很清楚：评分是"根据以往对局结果，对玩家赢下一局能力的估计"，论文还特意区分"玩家的实际实力"和"系统给出的评分"[25]【文献】。把评分写成

$$R_{i,t} = a + \lambda\, s_{i,t} + e_{i,t}, \tag{2.2}$$

[1]待核对：本次未读到原文全文（Thurstone 1927 与 Bradley–Terry 1952 只核对了书目信息，模型形式依据 TrueSkill 论文和 Weng–Lin 的转述）。

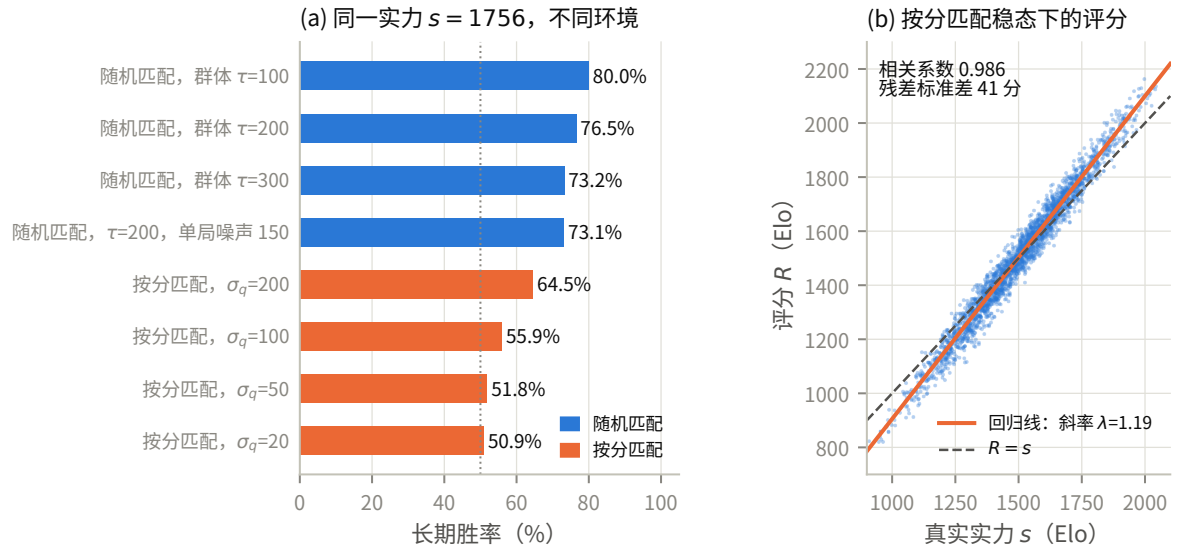


图 2.1： 同一实力在不同环境下的长期胜率不同；评分只是实力的带噪声、带刻度的估计。(a) 实力 $s = 1756$（$\tau = 200$ 群体的第 90 百分位，取实力在 ± 15 分内的玩家平均）在不同对手池和匹配规则下的胜率；(b) 按分匹配（$\sigma_q = 100$）第 3000 轮的评分与实力（随机抽 2,500 人作图）。参数：10,000 人，$s \sim \mathcal{N}(1500, \tau^2)$，$K = 16$，3000 轮，统计第 1001–3000 局。【本项目】

它与实力之间隔着四样东西：噪声 e（标准差 $\sigma_e \approx 9.3\sqrt{K}$，第 2.4.2 节）、滞后（误差衰减需要几十局）、刻度 λ 与截距 a（零和评分池的整体漂移，以及按分匹配下的刻度伸缩，第 2.4.5 节）。图 2.1(b) 是按分匹配稳态下的评分：与实力的相关系数 0.986，排序几乎正确，但斜率 $\lambda = 1.19$、残差 41 分【本项目】。

为什么胜率和分数都只体现一部分实力

- **胜率**衡量的是实力相对“实际对手”的位置。随机匹配下它随实力单调变化，但同时取决于群体离散度和游戏随机性；按分匹配会让对手随你的评分一起移动，胜率便趋于 50%，几乎不再反映实力（第 2.4 节）。
- **评分 / 段位分**衡量的是系统对实力的估计：有 $\pm\sigma_e$ 的噪声、几十局的滞后、随群体漂移的截距，在按分匹配下还可能有被拉伸的刻度；可靠的通常只有排序。可见段位往往还叠加了保底和加分（第 2.4.6 节）。
- **局内数据**（击杀、伤害、名次分）是另一种局部观测；TrueSkill 2 就把击杀数等作为额外证据[25]【文献】，但它们与胜负的关系依赖位置和打法。
- 可操作的定义：**实力是能预测“对任意对手胜率”的那个** s。一个可观测的替代量是“对固定参照池的胜率”，在正态群体中它与实力百分位一一对应（式 (2.5)）。在按分匹配的数据里，应当从评分和对手评分反推实力，而不是看胜率。

2.2　“每局五五开”是预测胜率五五开，不是实力五五开

2.2.1　匹配器拉平的是估计实力，等价于预测胜率 50%

匹配器看得到的只有评分。由于 $E = F(R_A - R_B)$ 是评分差的严格单调函数，“双方评分相等”与“系统预测胜率为 50%”是同一件事；团队游戏里，“两队评分之和（或均值）相等”等价于“团队预测胜率为 50%”。TrueSkill 用“平局概率”定义匹配质量，并指出“对局质量由结果的不可预测性决定”[1]【文献】。暴雪说明《守望先锋 2》组局时只看当前 MMR，并称匹配器不会强制任何人 50% 胜率[103]【官方】；同一系列的第一篇把“公平对局”直接对应到 50% 胜率[102]【官方】。所以“五五开”是关于系统所掌握的信息的陈述：在它知道的一切下，分不出谁更强。各厂商原话的逐条对照与“实力五五开、预测胜率五五开、长期胜率五五开”三种读法的辨析见第 1.8 节；本节给出这一读法的数学后果。

2.2.2　真实胜率围绕 50% 分布，宽度由评分误差决定

假设：评分处于稳态，$R = s + e$，$e \sim \mathcal{N}(0, \sigma_e^2)$ 与 s 独立；匹配器把评分恰好相等的两人配成一局。**推导**：给定 R，实力的条件分布是正态，方差 $v = \tau^2\sigma_e^2/(\tau^2 + \sigma_e^2)$，两人条件独立，均值相同，于是

$$s_A - s_B \mid R_A = R_B \;\sim\; \mathcal{N}\!\left(0,\, \frac{2\tau^2\sigma_e^2}{\tau^2 + \sigma_e^2}\right), \qquad p = F(s_A - s_B), \qquad f_p(x) = \frac{\phi\big(F^{-1}(x)/\sigma_\Delta\big)}{\sigma_\Delta\, c\, x(1-x)}, \tag{2.3}$$

其中 σ_Δ 是实力差的标准差（推导见附录 A.3.3）。**数值**：$K = 16$ 时 $\sigma_e = 37.7$，$\sigma_\Delta = 52.4$，90% 的“五五开”对局真实胜率在 37.8%–62.2% 之间，$|p - \frac{1}{2}|$ 平均 6.0 个百分点；$K = 32$ 时 $\sigma_\Delta = 73.7$，区间放宽到 33.2%–66.8%，平均偏离 8.3 个百分点【本项目】。从模拟的稳态评分表中把评分相邻的两人配对，得到的区间是 38.3%–62.1% 和 33.7%–66.0%（图 2.2(a)）【本项目】。

2.2.3　团队游戏：总和相等，个人可以很悬殊

团队匹配拉平的是两队评分的合计。加和模型下（第 2.5.1 节）团队实力差为 $(\sum s_A - \sum s_B)/\sqrt{n}$，给定两队评分和相等时它的方差同样是 $2v$，只是团队游戏中个人评分误差更大（$K = 16$、5v5 时约 58 分，第 2.5.1 节），于是 90% 的团队对局真实胜率落在 32%–68%（模拟 32.8%–66.9%）【本项目】。个人层面更悬殊：以 $\sigma_q = 100$ 组局时，一局内 10 人的评分标准差约 84 分，把双方队员随机两两“对位”，90% 的单挑真实胜率落在 22%–78%，约 26% 的对位偏离 50% 超过 20 个百分点（图 2.2(b)）【本项目】。暴雪描述过同一现象：整局是平衡的，但一方高分坦克对上另一方低分坦

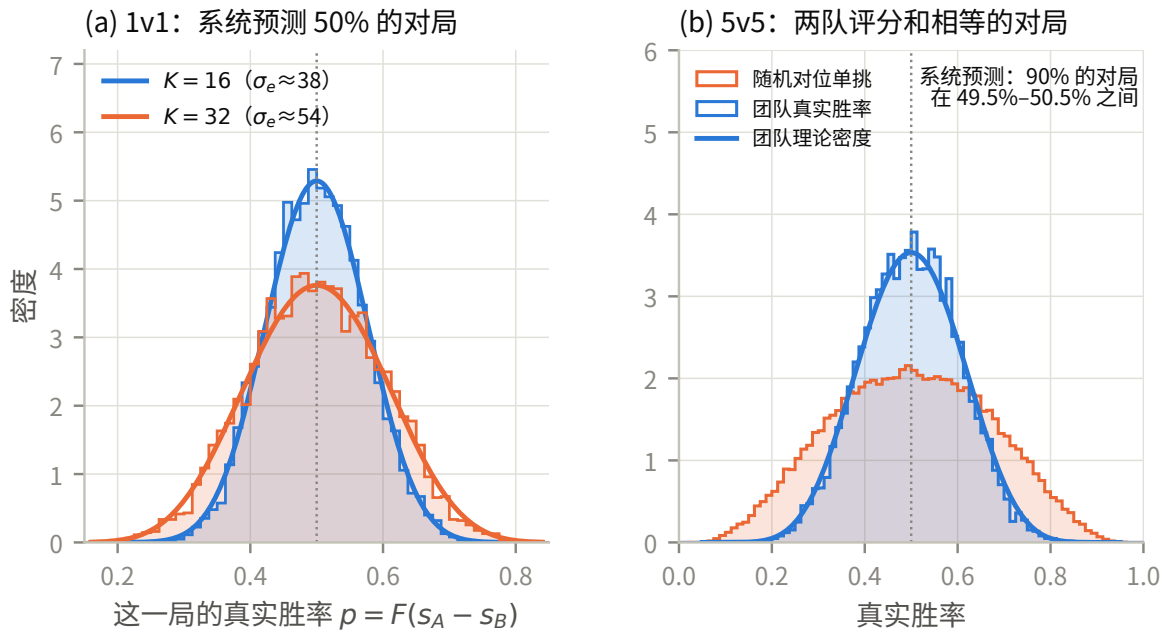


图 2.2: “五五开”的一局，真实胜率并不是 50%。(a) 1v1：把稳态评分表中评分相邻的两人配成一局，直方图为真实胜率 $p = F(s_A - s_B)$，曲线为式 (2.3)；(b) 5v5（加和模型，$K = 16$）：按 $R + \mathcal{N}(0, 100^2)$ 排序每 10 人一局，在 126 种分队中选评分和最接近的一种，比较团队真实胜率与随机分配位置后的“对位单挑”真实胜率。评分表取自随机匹配模拟第 3000 轮（10,000 人，$\tau = 200$）；(b) 重复组局 10 次，共 10,000 局。【本项目】

克，这条对位会“非常一边倒”[102]【官方】。

2.2.4　这不是关于长期胜率的陈述

“每局预测 50%”和“长期胜率 50%”是两件事。随机匹配下每局预测并不是 50%，长期胜率也不是；按分匹配下两者都接近 50%，但长期胜率趋于 50% 的原因是第 2.4.1 节的恒等式：实力优势被换成了更高的评分，而不是某种“拉回 50%”的干预。反过来，真实匹配器也做不到每局恰好 50%：排队时间要求放宽窗口，天梯两端人少，“没有同水平对手”时预测胜率就会偏离 50%（第 2.4.3 节）。

2.3　1v1 随机匹配：胜率由实力百分位和运气比例决定

假设：每局对手从全体中随机抽取，对手实力 $t \sim \mathcal{N}(\mu, \tau^2)$，胜率 $F(s - t)$。此时胜负与评分无关，K 只影响评分，不影响胜率。

随机匹配的闭式胜率

用 $F(d) \approx \Phi(d/\sigma_d)$，并利用恒等式 $\mathbb{E}\big[\Phi(a+bZ)\big] = \Phi\big(a/\sqrt{1+b^2}\big)$（$Z \sim \mathcal{N}(0,1)$；证明：$\Phi(a+bZ) = \mathbb{P}(Z' \le a+bZ \mid Z)$，而 $Z' - bZ \sim \mathcal{N}(0, 1+b^2)$）：

$$W(s) = \mathbb{E}_t\left[\Phi\left(\tfrac{s-t}{\sigma_d}\right)\right] = \Phi\left(\frac{s-\mu}{\sqrt{\sigma_d^2+\tau^2}}\right). \tag{2.4}$$

写成实力百分位 q（$s = \mu + \tau z_q$）：

$$W(q) = \Phi(\rho\, z_q), \qquad \rho = \frac{\tau}{\sqrt{\tau^2+\sigma_d^2}}. \tag{2.5}$$

ρ^2 是“两人表现差”的方差中由实力差解释的份额。单局另有独立噪声 $x \sim \mathcal{N}(0,\sigma_x^2)$ 时，把 σ_d 换成 $\sigma_d' = \sqrt{\sigma_d^2 + 2\sigma_x^2}$。

表 2.1 给出不同群体离散度下的数值。注意“前 10% 平均”要对组内每个人的胜率求平均，不能把组内平均 z 代入公式，后者因为 Φ 的凹性会偏高（$\tau = 200$ 时 83.7% 对 83.1%）。

表 2.1: 随机匹配 1v1 的长期胜率与群体实力离散度 τ（$\sigma_d = 295.7$）。百分位列用式 (2.5)；组平均列对组内每人的精确逻辑斯蒂胜率求平均。【本项目】

τ	ρ	ρ^2	第 75 百分位	第 90 百分位	前 10% 平均	前 1% 平均
100	0.320	0.10	58.6%	65.9%	71.7%	80.7%
150	0.452	0.20	62.0%	71.9%	78.5%	88.2%
200	0.560	0.31	64.7%	76.4%	83.1%	92.5%
300	0.712	0.51	68.5%	81.9%	88.2%	96.4%
400	0.804	0.65	70.6%	84.9%	90.8%	97.9%

模拟：10,000 人、$\tau = 200$、$K = 16$，每人统计 2,000 局，十分位平均胜率依次为 17.0、27.9、35.0、41.2、47.1、52.9、58.8、65.1、72.1、82.9%，精确积分值为 16.9…83.1%，差别不超过 0.2 个百分点；前 1% 为 92.7%（公式 92.5%），个人长期胜率的标准差为 19.6 个百分点【本项目】。$K = 32$ 的胜率与 $K = 16$ 完全相同，因为同一随机种子下配对和胜负都与评分无关【本项目】。

两个敏感性（图 2.3）：

- **群体离散度** τ：同一百分位，τ 越大（高手和新手差得越远）胜率越极端。TrueSkill 团队在 Xbox Live 上也观察到，运气型游戏（单局双陆棋、UNO）的实力分布窄，技巧型游戏（拟真赛车）的实力分布宽[1]【文献】——用本节的话说，就是 ρ 不同。群体整体变强（μ 上升）而你不变时，你的百分位下降，胜率也随之下降。
- **单局随机性** σ_x：$\sigma_x = 150$ 时 $\sigma_d' = 364$，曲线斜率变为原来的 0.81 倍，最强 10% 从 82.9% 降到 79.4%（模拟）【本项目】。Elo 会把预测胜率校准到观测胜率，所

以评分差也按同一比例压缩：模拟中评分对实力的斜率为 0.811（理论 0.813）【本项目】。评分度量的是“以胜率为单位的实力”。

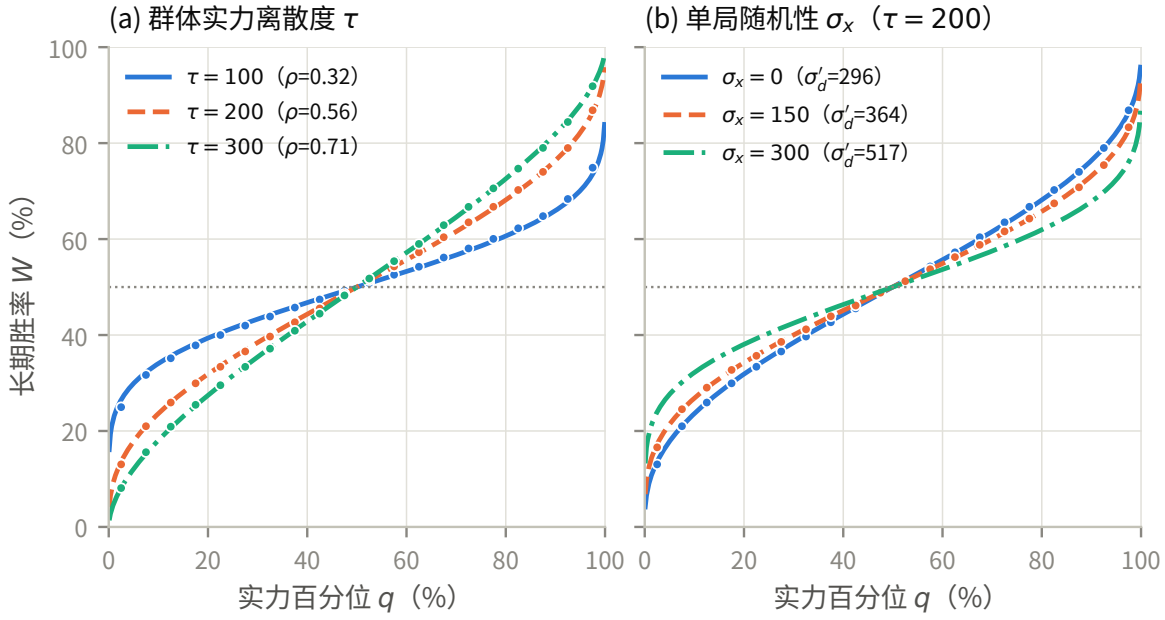


图 2.3: 随机匹配 1v1 的长期胜率随实力百分位变化。曲线为式 (2.5)，点为模拟（每 5% 百分位一组的平均胜率）。(a) 群体离散度 $\tau = 100/200/300$；(b) 单局独立噪声 $\sigma_x = 0/150/300$（$\tau = 200$；$\sigma_x = 300$ 只画公式）。参数：10,000 人，$K = 16$，随机配对，3000 轮，统计第 1001–3000 局。【本项目】

随机匹配下评分也能准确恢复实力：Aldous 证明随机配对的 Elo 过程有唯一平稳分布[34]【文献】，Cortez 与 Tossounian 进一步证明平稳分布以 $\sqrt{K}$ 的速度集中到真实实力[38]【文献】，Olesker-Taylor 与 Zanetti 证明时间平均后的评分以高概率逼近真实参数[14]【文献】。这些定理都假设“谁和谁对局”与当前评分无关；按分匹配不满足这一条件，Jabin 与 Junca 的连续模型显示，只与评分相近者对局时可能出现依赖初值的多个平衡态和很慢的收敛[35]【文献】。这正是下一节要处理的情形。

2.4　1v1 按分匹配：实力被兑换成评分

2.4.1　一条恒等式说明实力优势去了哪里

固定 K 的 Elo 每局评分变化为 $\Delta R_t = K(y_t - E_t)$。对 T 局求和，$R_T - R_0 = K\sum_t (y_t - E_t)$，两边除以 KT 并移项：

$$W_T \equiv \frac{1}{T}\sum_{t=1}^{T} y_t = \bar{E}_T + \frac{R_T - R_0}{K\,T}. \tag{2.6}$$

这是代数恒等式，对任何匹配方式都精确成立；在本章所有 1v1 和 5v5 模拟中，左右两边之差不超过 4×10^{-15}【本项目】。它说明长期胜率偏离 50% 只有两个来源：一是

匹配器系统性地给你更弱或更强的对手（$\bar{E} \neq \frac{1}{2}$）；二是你的评分还在单向移动（新号、正在进步、刻度在伸缩）。严格按分匹配让 $\bar{E} \approx \frac{1}{2}$，评分到达稳态后 $R_T - R_0$ 有界，于是 $W_T \to \frac{1}{2}$，偏差按 $1/T$ 衰减：实力强 ⇒ 评分高 ⇒ 对手强 ⇒ 单局胜率回到 50%。

可变步长时（Glicko 的评分偏差、TrueSkill 的不确定度 σ[1]、新号阶段放大的 K），恒等式变成加权形式 $\sum_t K_t(y_t - E_t) = R_T - R_0$；连胜加分、段位保底等不经过 $K(y-E)$ 的改动会直接打破它。《守望先锋 2》对新号和回流玩家使用的“连胜调节”（胜率高于 50% 时加快 MMR 上升）就是一种可变步长[102]【官方】。

2.4.2　评分的稳态误差约为 $9.3\sqrt{K}$，衰减需要 30–65 局

假设：对手评分与自己相近，各自误差独立同分布。**推导**：令 $e = R - s$，线性化 $F(s - s') \approx \frac{1}{2} + \frac{c}{4}(s - s')$，得 AR(1) 型递推

$$e_{t+1} = \Big(1 - \frac{Kc}{4}\Big)e_t + \frac{Kc}{4}e'_t + K\eta_t, \qquad \mathrm{Var}(\eta_t) \approx \tfrac{1}{4}, \tag{2.7}$$

平稳方差为

$$\sigma_e^2 = \frac{K}{2c\,(1 - Kc/4)} \approx \frac{200K}{\ln 10}, \qquad \sigma_e \approx 9.32\sqrt{K}, \tag{2.8}$$

误差的理想时间常数为 $4/(Kc) = 1600/(K \ln 10) \approx 695/K$ 局（推导见附录 A.3.4）。表 2.2 给出常用 K 的数值。

表 2.2: Elo 评分误差的线性化数值（$\lambda = 1$）。“修正”列含对手误差项；“实测”为模拟中误差自相关降到 $1/e$ 的局数。【本项目】

K	$\sqrt{200K/\ln 10}$	σ_e（修正）	理想时间常数 $4/(Kc)$	半衰期	实测衰减时间（按分 σ_q=100 / 200 / 随机）
10	29.5	29.7	69.5	48.2	—
16	37.3	37.7	43.4	30.1	55 / 59 / 66
20	41.7	42.3	34.7	24.1	—
32	52.7	54.0	21.7	15.1	34 / 30 / 34
40	58.9	60.7	17.4	12.0	—

模拟证实了 $\sqrt{K}$ 规律：随机匹配下 $K = 8, 16, 24, 32, 48, 64$ 的残差标准差为 26.5、37.8、46.7、54.5、67.9、79.9，公式为 26.5、37.7、46.5、54.0、66.9、78.2（图 2.4(a)）【本项目】。按分匹配下误差略大，因为刻度 $\lambda > 1$ 时 σ_e^2 按 λ 放大（附录 A.3.4）。

但 695/K 只是下限。它要求 $\lambda = 1$ 且每局 $P(1-P) = \frac{1}{4}$，这两条从不同时成立：随机匹配下对手常常差得远，$P(1-P) < \frac{1}{4}$；按分匹配下配到的对手评分会向均值回归，而且 $\lambda > 1$ 会削弱回复力。把这两项写进系数 $\kappa = 4\mathbb{E}[P(1-P)] \cdot (\lambda\tau^2 + \sigma_q^2)/(\sigma_R^2 + \sigma_q^2)$，时间常数为 $4/(Kc\kappa)$：$K = 16$ 时按分匹配为 56–58 局，随机匹配（各人恢复速度不同的混合）为 65 局，实测为 55、59、66 局；$K = 32$ 时公式 30–34 局，实测 30–34 局

（图 2.4(b)）【本项目】。所以现实的匹配条件下，$K=16$ 的评分误差约 55–65 局才衰减到 $1/e$，$K=32$ 约 30–34 局。这与 Aldous 的看法一致：Elo 在“滞后”和“噪声”之间取舍，K 小则噪声小、滞后大[34]【文献】。

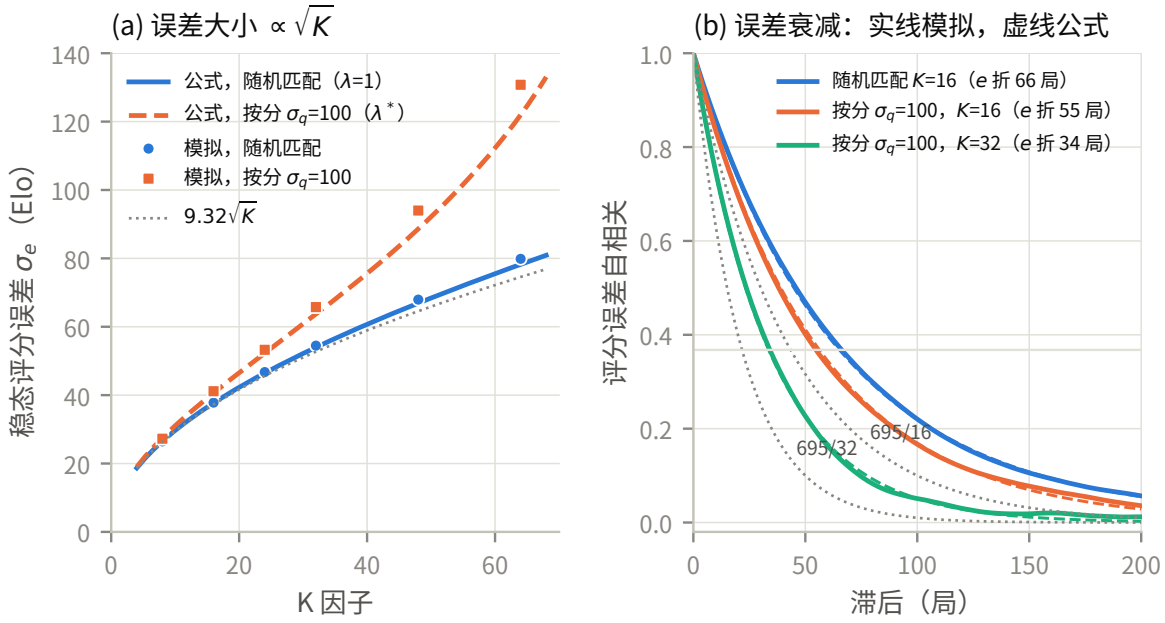


图 2.4: 评分误差的大小与衰减。(a) 稳态误差（相对评分–实力回归线的残差标准差）随 K 的变化，曲线为式 (2.8)（按分匹配取平稳刻度 λ^*），点为模拟（4,000 人，2,500 轮，预热 1,000 轮后每 50 轮取一次残差并平均）；(b) 评分误差的自相关：实线为模拟（10,000 人中前 2,000 人第 1001–1400 轮的逐轮评分），虚线为修正后的时间常数，灰色点线为理想值 $695/K$。【本项目】

2.4.3　匹配窗口决定天梯两端偏离 50% 多少

真实匹配器在一个窗口内找对手。我们用“按 $R+\xi$ 排序后相邻配对，$\xi\sim\mathcal{N}(0,\sigma_q^2)$”来模拟，$\sigma_q$ 越大窗口越宽。配到的两人评分差的标准差约为 $\sqrt{2g}\,\sigma_q$（g 见下式）：$\sigma_q=20$ 时约 28 分，系统预测胜率 90% 落在 43%–56%；$\sigma_q=100$ 时约 132 分，预测胜率 90% 落在 23%–78%，已是相当宽松的匹配【本项目】。

推导（附录 A.3.5）：设评分在群体中的标准差为 σ_R，排序键 $k=R+\xi$，相邻者的键几乎相同。给定自己的评分 R，对手评分 R' 服从

$$R-R'\sim\mathcal{N}\big((1-g)(R-\mu),\ g(1+g)\sigma_q^2\big),\qquad g=\frac{\sigma_R^2}{\sigma_R^2+\sigma_q^2},$$
$$W\approx\bar{E}\approx\Phi\left(\frac{(1-g)(R-\mu)}{\sqrt{\sigma_d^2+g(1+g)\sigma_q^2}}\right). \tag{2.9}$$

高分玩家平均遇到评分更低的对手，低分玩家相反。这不是操纵，而是“窗口对称、人口密度不对称”的结果，天梯顶端尤其明显；暴雪也提到最高分段“玩家少得多”，组局时更难避免分差[102]【官方】。

数值（图 2.5）：$K = 16$ 时最弱到最强十分位的胜率为：随机匹配 17.0%–82.9%，$\sigma_q = 200$ 时 30.9%–69.1%，$\sigma_q = 100$ 时 42.1%–58.0%，$\sigma_q = 50$ 时 47.6%–52.4%，$\sigma_q = 20$ 时 48.8%–51.2%【本项目】。$K = 32$ 的对应值为 31.6%–68.4%、43.5%–56.5%、48.3%–51.7%、48.9%–51.1%【本项目】。式 (2.9) 给出的最强十分位胜率为 57.8%（$K = 16$，$\sigma_q = 100$，模拟 58.0%）、69.3%（$\sigma_q = 200$，模拟 69.1%）、56.7%（$K = 32$，$\sigma_q = 100$，模拟 56.5%）【本项目】。

用式 (2.6) 分解：$\sigma_q = 100$ 时偏离 50% 的部分几乎全在 $\bar{E}$ 一项，评分项只有 ±0.05 个百分点；$\sigma_q = 20$ 时 $\bar{E}$ 只在 49.7%–50.3%，剩下的 ±0.9 个百分点来自评分项，即下文的刻度拉伸，它随时间减小【本项目】。

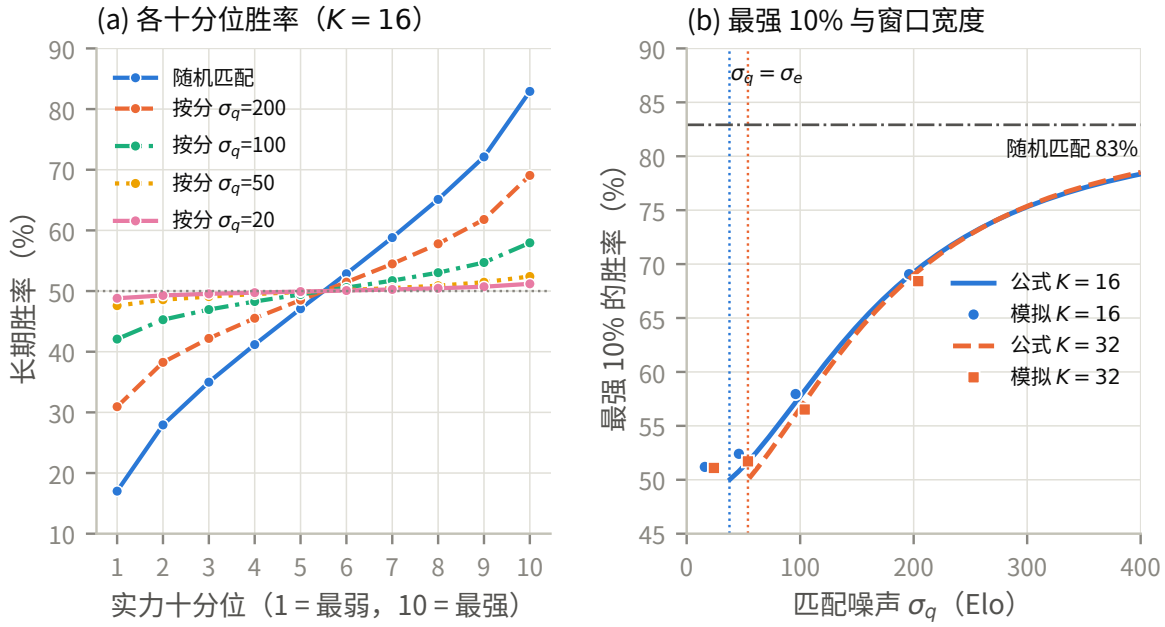


图 2.5: 按分匹配把各实力十分位的胜率压向 50%，压到什么程度由匹配窗口决定。(a) $K = 16$ 时各十分位的长期胜率；(b) 最强 10% 的胜率随匹配噪声 σ_q 的变化，曲线为式 (2.9)（只在 $\sigma_q > \sigma_e$、存在平稳刻度时画出），点为模拟（左右略错开以免重叠），点线标出 $\sigma_q = \sigma_e$。参数：10,000 人，$\tau = 200$，按 $R + \mathcal{N}(0, \sigma_q^2)$ 排序相邻配对，3000 轮，统计第 1001–3000 局。【本项目】

2.4.4　新号与回流：强玩家从 1500 起步要几十局才能追回

系统平稳后，从实力前 10% 中抽 500 人，把评分重置为 1500（相当于高手开新号），跟踪其后 400 局。差距用“实力 − 评分折算的实力”计量，折算用的回归线每轮在未重置玩家上重新拟合。结果（图 2.6）：初始差距约 350 实力分；按分匹配下追回一半需要 47 局（$K = 16$）或 30 局（$K = 32$），追回 90% 需要 150 局或 96 局；随机匹配下为 50/191 局和 26/101 局【本项目】。按分匹配的前 50 局胜率为 77.5%（$K = 16$）和 73.6%（$K = 32$），前 100 局为 72.9% 和 68.0%，第 301–400 局回落到 58.9% 和 57.1%，即前 10% 玩家在该窗口下的平稳胜率；随机匹配下胜率与评分无关，始终约 83%【本

项目】。

两点说明。第一，若把目标线固定在重置前一刻，追回 90% 看起来要 304 局（$K=16$）和 257 局（$K=32$）：在零和评分池里，把 500 人的评分从约 1920 拉到 1500 会让整个评分池下沉约 20 分，固定目标忽略了这一点【本项目】。第二，大差距时单局胜率接近饱和，每局最多涨 $K/2$，所以前期比线性理论慢。TrueSkill 在 Xbox Live 上观察到，新玩家若前几局持续输球，整体实力分布会落到先验以下；一次实力重置之后，在更严格的匹配下这一现象消失[1]【文献】；《守望先锋 2》则通过降低新号初始 MMR 并加快初期调整来处理新玩家胜率偏低的问题[102]【官方】。

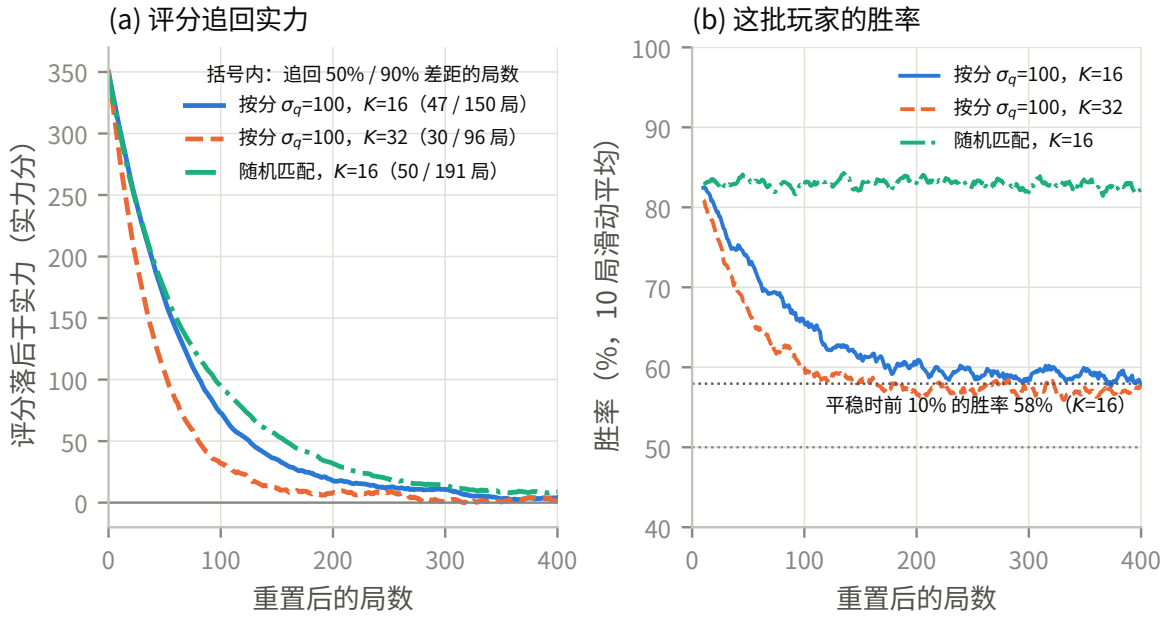


图 2.6: 强玩家评分被重置为 1500 后的追分过程。(a) 评分落后于实力的程度（实力分），括号内为追回 50% / 90% 差距所需局数；(b) 这批玩家的胜率（10 局滑动平均），点线为按分匹配平稳时前 10% 玩家的胜率。参数：10,000 人，$\tau=200$，系统运行 1000 轮后从实力前 10% 中随机重置 500 人，按分匹配 $\sigma_q=100$ 或随机匹配，$K=16/32$。【本项目】

2.4.5　严格按分匹配会拉伸评分刻度（理想模型的性质）

这一节讨论的是本项目在理想模型中推导并模拟出来的性质，**没有在真实数据中观测到**。

精确的出发点：两名评分完全相等的玩家对局，$E=\frac{1}{2}$，无论谁赢，两人评分都变成 $R\pm K/2$。于是每局使群体评分方差恰好增加 $K^2/4$。只要配对时对手的实力与自己“在给定评分下可交换”，就有 $\mathrm{Cov}(R,\,y-E)=0$，没有任何力量把这部分方差收回。模拟中以 $\sigma_q=0$ 确定性配对 3000 局，评分方差增加 191,792，理论值 $16^2\times 3000/4=192{,}000$【本项目】。方差增加而排序不变，表现为评分对实力的斜率 λ 增大，上包络为 $\lambda(t)^2\approx\lambda_0^2+K^2t/(4\tau^2)$。

一般窗口（附录 A.3.6）：用式 （2.2）的线性结构做平均场近似，

$$\frac{\mathrm{d}\lambda}{\mathrm{d}t} = \frac{Kc}{4} \cdot \frac{\sigma_e^2 + \sigma_q^2(1-\lambda)}{\lambda^2\tau^2 + \sigma_e^2 + \sigma_q^2}, \qquad \lambda^* = \frac{1}{1-\sigma_e^2/\sigma_q^2}. \tag{2.10}$$

分子第一项是“同分对局把评分拉开”，第二项是“窗口内遇到不同评分的对手把刻度拉回”。平稳刻度只在 $\sigma_q > \sigma_e$ 时存在，即配对评分差的标准差要大于约 $\sqrt{2}\sigma_e$（$K=16$ 时约 53 分，$K=32$ 时约 76 分）。$K=16$ 时 λ^* 在 $\sigma_q = 50, 100, 200$ 下为 2.32、1.17、1.04；$K=32$ 时 $\sigma_q = 100, 200$ 下为 1.41、1.08【本项目】。模拟（初始评分等于实力，$\lambda_0 = 1$）第 10,000 局的斜率为：$\sigma_q = 20$ 时 3.75（方程 3.77，上包络 4.12），$\sigma_q = 50$ 时 2.16 并仍在上升（方程 2.11），$\sigma_q = 100$ 时 1.20（1.17），$\sigma_q = 200$ 时 1.06（1.04）（图 2.7）【本项目】。

含义：刻度被拉伸时排序依然准确（相关系数 0.99），但评分差夸大了实力差，用评分差预测的胜率会过于自信；本章 $\sigma_q = 20$ 下各十分位的残余偏离（±0.9 个百分点）就是 λ 仍在增长带来的评分项。部署中的系统有很多这一模型没有的“锚”：新玩家以默认分进入、赛季软重置、长期不玩后的调整[102]【官方】、段位保底[105]【官方】、排队时间带来的窗口放宽，它们都可能限制拉伸。我们的判断是：无界的 $\sqrt{t}$ 增长在真实系统中不太可能出现，有界的轻度放大（λ^* 在 1.05–1.5 之间）是可能的，但未见实证。

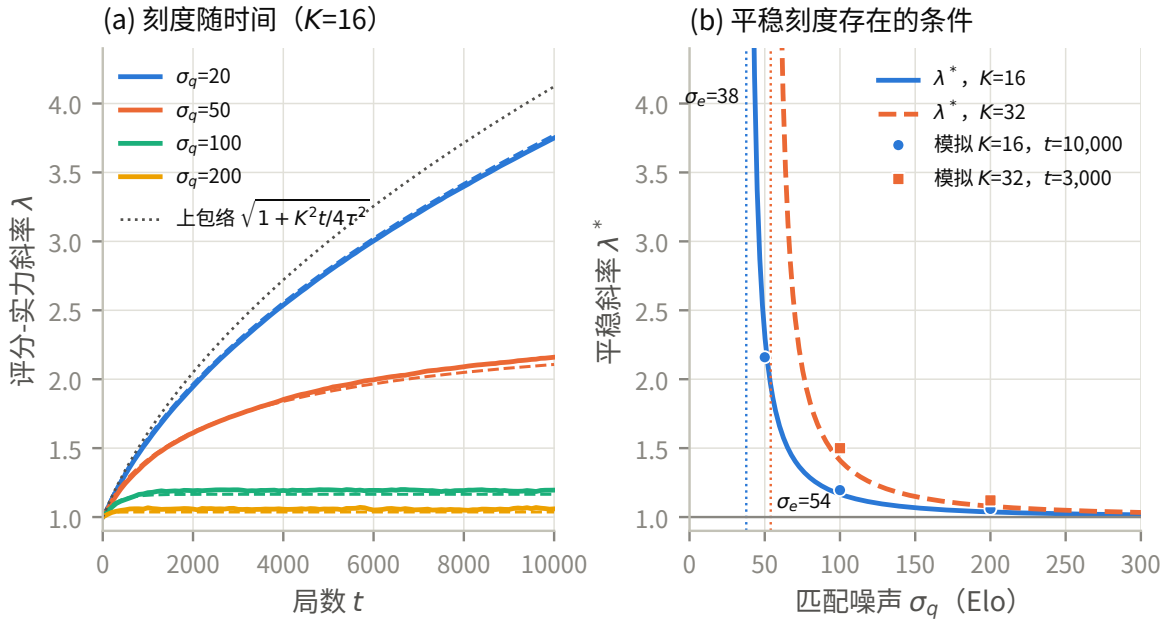


图 2.7： 严格按分匹配下评分刻度的拉伸（理想模型的性质，不是真实数据中的观测）。(a) 评分对实力的回归斜率 $\lambda(t)$：实线为模拟，同色虚线为式 （2.10）的平均场方程，灰色点线为配对评分完全相等时的上包络；(b) 平稳斜率 λ^* 与匹配噪声 σ_q，点线为 $\sigma_q = \sigma_e$。参数：(a) 2,000 人，$\tau = 200$，$K = 16$，初始评分 = 实力，10,000 轮；(b) 圆点取自 (a) 第 10,000 轮，方块取自 10,000 人、初始评分全为 1500、$K = 32$ 的模拟第 3,000 轮。【本项目】

2.4.6　可见段位与隐藏分

主流做法是用隐藏分（MMR）匹配，用可见段位提供进度感。暴雪说明《守望先锋 2》组局“从不使用”玩家看到的段位，只看 MMR[102]【官方】。《炉石传说》酒馆战棋 2020 年起也采用“双评分”：匹配只用内部评分，外显评分叠加保底和进度分[105]【官方】（各厂商的做法见第 1.7.3 节与表 1.5）。对本章的公式而言，这意味着：

- 匹配时“段位或分数”影响胜率，只是通过隐藏分决定对手分布 $\mathcal{G}$；式 （2.6）适用于隐藏分（若其步长固定）。
- 可见段位叠加了保底和加分，它的变化不再满足 $K(y-E)$，赛季内会系统性上漂，不宜直接用来估计实力或胜率。
- 同段位的两个人可能隐藏分相差很大，所以“我和对面段位一样却被碾压”并不与“预测胜率 50%”矛盾。

2.5　每局人数：团队稀释个人优势，多人局改变“胜”的基准

2.5.1　团队游戏：加和模型约按 $1/\sqrt{n}$ 稀释，均值模型约按 $1/n$

假设：焦点玩家比群体平均高 d 分，$n-1$ 名队友和 n 名对手都从 $\mathcal{N}(\mu,\tau^2)$ 随机抽取。两种团队模型：

- **加和模型**：每名队员有独立表现噪声，团队表现为队员表现之和（TrueSkill 的假设[1]【文献】），用逻辑斯蒂类比写成 $P=F\big((\sum s_A-\sum s_B)/\sqrt{n}\big)$；
- **均值模型**：随机性主要在团队层面（地图、阵容、配合），$P=F(\bar{s}_A-\bar{s}_B)$。

推导：加和模型下自变量 $X=(d+\sum_{n-1}t_i-\sum_n o_j)/\sqrt{n}\sim\mathcal{N}\big(d/\sqrt{n},\ (2n-1)\tau^2/n\big)$，均值模型下 $X\sim\mathcal{N}\big(d/n,\ (2n-1)\tau^2/n^2\big)$，再用式 （2.4）的高斯恒等式：

$$W_{\text{加和}}\approx\Phi\left(\frac{d/\sqrt{n}}{\sqrt{\sigma_d^2+(2n-1)\tau^2/n}}\right),\qquad W_{\text{均值}}\approx\Phi\left(\frac{d/n}{\sqrt{\sigma_d^2+(2n-1)\tau^2/n^2}}\right).\quad(2.11)$$

稀释有两层：个人优势在团队差中只占 $1/\sqrt{n}$ 或 $1/n$；队友和对手的实力离散 $(2n-1)\tau^2$ 又加了一层噪声。n 较大时，加和模型在 $d=0$ 处的斜率约为 $\phi(0)/\big(\sqrt{n}\sqrt{\sigma_d^2+2\tau^2}\big)\propto 1/\sqrt{n}$，均值模型约为 $\phi(0)/(n\sigma_d)\propto 1/n$。$n=5$ 时斜率分别是 1v1 的 0.40 和 0.23 倍（$1/\sqrt{5}=0.45$，$1/5=0.20$）【本项目】。

模拟（图 2.8）：随机分队的 5v5，加和模型十分位胜率为 34.8%–65.2%，前 1% 为 72.8%，个人长期胜率的标准差 8.8 个百分点（1v1 为 19.6）；均值模型为 41.0%–59.0%【本项目】。哪种模型更接近真实取决于随机性在哪里：TrueSkill 在 Halo 2 的 4v4 夺旗模式中没能胜过 Elo，作者认为可能是因为加和假设不成立[1]【文献】；TrueSkill 2 发现组队玩家的胜率高于“队员实力之和”所预测的值，于是加入组队偏移[25]【文献】。

表 2.3: 随机队友、随机对手时团队人数对个人胜率的稀释（$\tau = 200$，精确数值积分）。提升量按 $d = 0$ 附近的斜率计算；末列为队友与对手都和群体平均同水平时的加和模型。【本项目】

	最强 10% 的胜率		每 100 分优势的胜率提升（百分点）		
n	加和	均值	加和	均值	加和，同水平队友
1	83.1%	83.1%	11.4	11.4	14.4
2	73.9%	69.7%	7.4	6.0	10.2
3	69.6%	64.1%	5.9	4.1	8.3
5	65.2%	59.0%	4.5	2.6	6.4
6	63.9%	57.6%	4.1	2.2	5.9
8	62.1%	55.9%	3.5	1.7	5.1

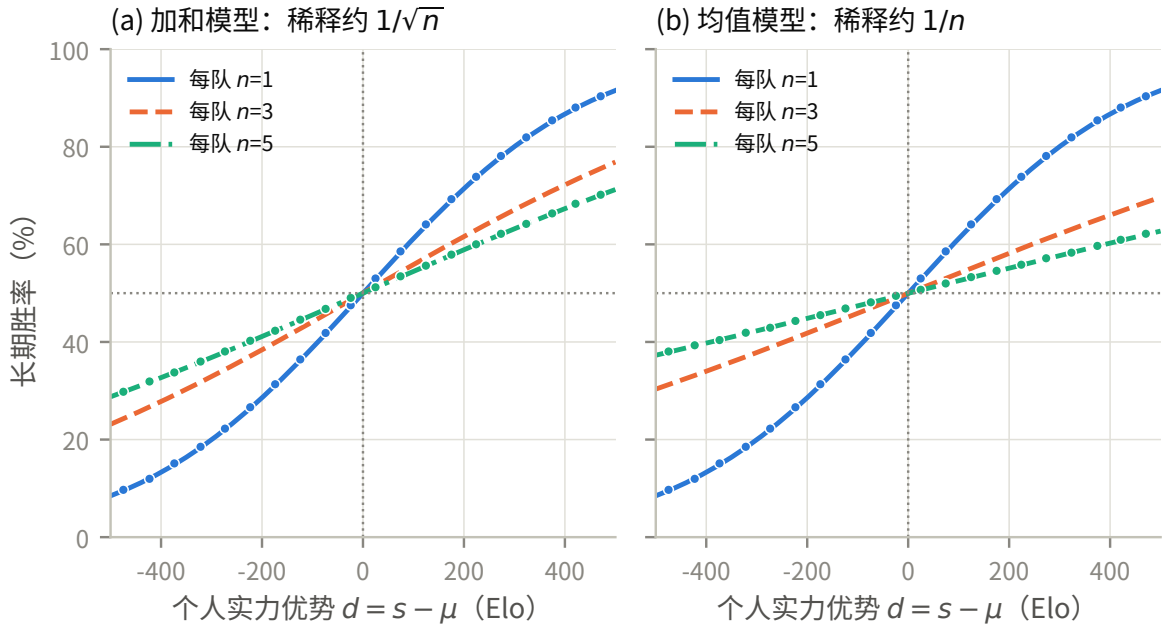


图 2.8: 团队游戏稀释个人实力优势。焦点玩家比群体平均高 d 分，队友和对手随机。曲线为式 (2.11) 对应的精确数值积分；蓝点为 1v1 随机匹配模拟，绿点为 5v5 随机分队模拟（按实力每 50 分一组的平均胜率）。参数：$\tau = 200$，10,000 人，$K = 16$，3000 轮，统计第 1001–3000 局。【本项目】

团队的按分匹配：按 $R+\mathcal{N}(0,\sigma_q^2)$ 排序每 10 人一组、组内蛇形分队，$\sigma_q=100$ 时加和模型十分位胜率为 46.6%–53.5%，均值模型 48.0%–52.0%；但 $\sigma_q=200$ 时为 41.7%–58.3%，而且 $\sigma_q=100$ 下刻度仍在拉伸（λ 从第 1000 局的 1.15 升到第 3000 局的 1.45），所以这些数字对窗口宽度和时间都很敏感【本项目】。团队中个人的评分误差也更大：加和模型的残差为 57.7 分（$K=16$），粗略公式 $\sqrt{K\sqrt{n}/\big(2c(1-\sqrt{n}Kc/4)\big)}$ 给出 57.2；均值模型为 84.4 分；1v1 为 37.8 分【本项目】。

2.5.2　多人自由混战：Plackett–Luce 给出名次概率

假设：N 人一局，表现为实力加 Gumbel 噪声（尺度 $400/\ln 10$）。这一设定下，任意两人的相对名次概率恰为 Elo 的 F，而完整名次服从 Plackett–Luce 模型：worth $w_i=10^{s_i/400}$，从剩余玩家中按 w 的比例依次抽出第一名、第二名……[24]【文献】（推导见附录 A.3.7）。**推导**：焦点玩家对其余 $N-1$ 名同水平对手的优势为 d，$w=10^{d/400}$，

$$\mathbb{P}(\text{第 }1)=\frac{w}{w+N-1},\qquad \mathbb{P}(\text{前}k)=1-\prod_{j=0}^{k-1}\frac{N-1-j}{w+N-1-j}. \tag{2.12}$$

后一式是“前 k 次抽取都没有抽中焦点玩家”的补概率。

表 2.4： 8 人自由混战（Plackett–Luce）中，对其余 7 名同水平对手的实力优势 d 与名次指标。【本项目】

d	w	1v1 胜率	第 1 名	前 4 名	平均名次
−200	0.32	24.0%	4.3%	20.8%	6.32
0	1.00	50.0%	12.5%	50.0%	4.50
+100	1.78	64.0%	20.3%	68.6%	3.52
+200	3.16	76.0%	31.1%	84.6%	2.68
+400	10.0	90.9%	58.8%	98.5%	1.64

“胜”的定义决定基准率。按分匹配把同一局 8 人的估计实力拉平，于是均衡时第一名率趋于 $1/N=12.5\%$，前四率趋于 50%，平均名次趋于 $(N+1)/2=4.5$。模拟（10,000 人，$K=16$，两两 Elo 更新每对步长 $K/7$）：随机组局时最强 10% 的第一名率 39.8%、前四率 93.1%、平均名次 2.20，最弱 10% 为 1.4%、10.7%、6.81；按分匹配（$\sigma_q=100$）时最强 10% 为 17.0%、61.3%、3.90，最弱 10% 为 8.9%、39.2%、5.10【本项目】。对酒馆战棋这类“前四加分”的游戏，按分匹配下前四率约 50% 并不说明水平一般；按“第一名”统计，基准是 12.5%。

多人局的评分误差更小。每局给出 $N-1$ 组两两比较，每组步长 $K/(N-1)$。同水平时名次均匀，单局评分变化的方差为 $K^2(N+1)/\big(12(N-1)\big)$，而 1v1 为 $K^2/4$；回复力相同，于是 $\sigma_{e,\mathrm{FFA}}=\sigma_e\sqrt{(N+1)/(3(N-1))}$，$N=8$、$K=16$ 时为 24.7 分，模拟为 24.7（按分匹配）和 22.6（随机组局），1v1 为 37.8【本项目】。酒馆战棋的评分更

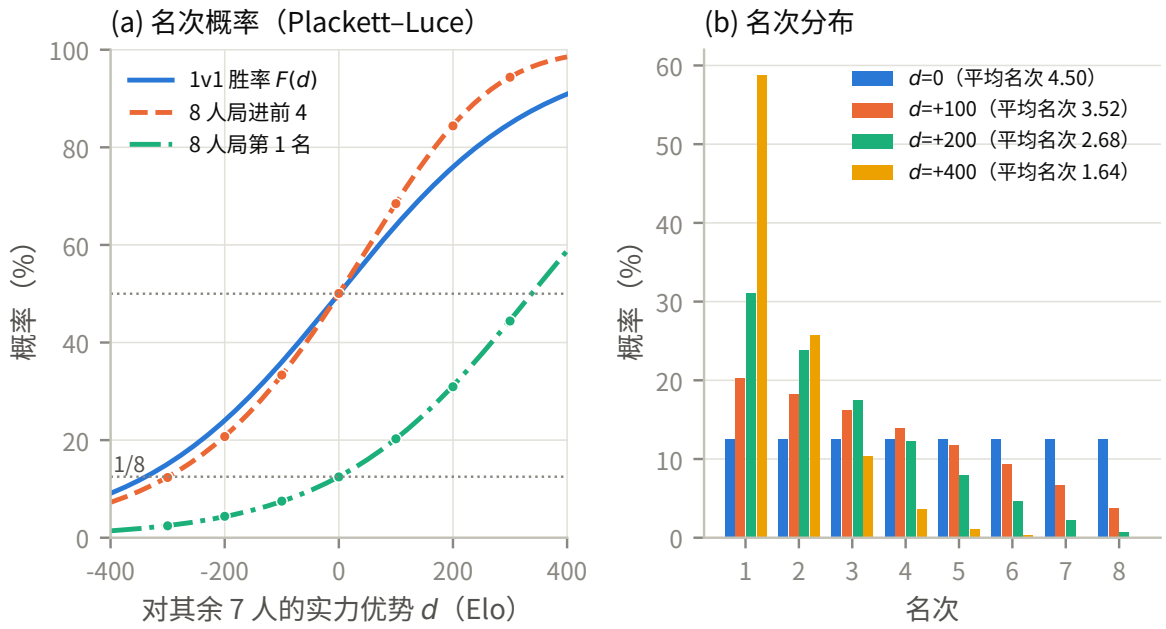


图 2.9: 8 人自由混战中实力优势如何换成名次。(a) 对其余 7 名同水平对手的优势为 d 时进前 4 名和拿第 1 名的概率（曲线为式 (2.12)，点为 Gumbel 表现的蒙特卡洛，每点 20 万局），蓝线为 1v1 胜率作对照；(b) $d = 0/+100/+200/+400$ 时的名次分布。【本项目】

新同样基于 8 人两两之间的 56 个预测胜率[104]【官方】（第 1.7.3 节），但具体公式没有公开，本节的两两 Elo 只是常见近似。

2.6　实力有波动时，期望胜率仍可计算，误差更大

把当局实力写成 $s_{i,t} = s_i + u_t$。三种波动的后果不同。本节只讨论胜率的水平与方差；“上头”这类由输赢反过来影响状态的反馈，以及它如何制造连败，见第三章。

2.6.1　独立的单局波动：曲线变平，评分刻度同比例压缩

u_t 每局独立、标准差 σ_x 时，$P = \mathbb{E}\,F(\Delta s + x_i - x_j) \approx \Phi\big(\Delta s/\sqrt{\sigma_d^2 + 2\sigma_x^2}\big)$，相当于游戏更随机（第 2.3 节）。Elo 把评分校准到“以胜率为单位的实力”，评分差压缩为实力差的 σ_d/σ_d' 倍：$\sigma_x = 150$ 时理论 0.813，模拟 0.811；随机匹配下十分位胜率 20.6%–79.4%，按分匹配（$\sigma_q = 100$）下 40.9%–59.1%【本项目】。

2.6.2　自相关的状态：评分只吸收一部分，窗口胜率成段波动

假设：状态服从 AR(1)，$u_{t+1} = \phi u_t + \sqrt{1-\phi^2}\,\sigma_u \varepsilon_t$；取 $\sigma_u = 100$，$\phi = 0.99$（相关时间约 100 局），作为“状态好坏、疲劳、时段”的示意。

评分是指数平滑器。在实力单位下，Elo 每局把评分朝当局实力移动一个比例 $\alpha =$

$1/\tau_R$，即 $\hat{s}_{t+1}=(1-\alpha)\hat{s}_t+\alpha(s+u_t)+$ 噪声。它对当前状态的回归系数（“被吸收的份额”）为

$$a=\frac{\mathrm{Cov}(\hat{s}_t,u_t)}{\sigma_u^2}=\frac{\alpha}{1-(1-\alpha)\phi}. \tag{2.13}$$

用理想值 $\alpha=Kc/4$ 得 $a=0.70$（$K=16$）和 0.83（$K=32$）；用修正后的时间常数（$\sigma_q=100$ 时 56 局和 34 局）得 0.64 和 0.75，模拟为 0.63 和 0.73【本项目】。没被吸收的 $(1-a)u_t$ 直接进入单局胜率，所以即使在按分匹配下，“手热”（$u>\sigma_u$）时也多赢：模拟胜率 58.9%，“手冷”（$u<-\sigma_u$）时 41.1%；近似公式 $F\big((1-a)\mathbb{E}[u\mid u>\sigma_u]\big)\approx F(0.36\times 152)\approx 57.8\%$【本项目】。

逐局几乎看不出，窗口胜率却明显更分散。按分匹配下逐局结果的自相关只有 0.016（滞后 1 局）、0.014（5 局）、0.008（20 局），很难从单局层面察觉；但 n 局窗口胜率的方差明显偏离二项分布。由式 (2.6)，窗口胜率的波动来自 $\bar{E}$ 的局间波动和窗口内评分的净变化，后者的方差由评分对 $s+u$ 的跟踪和评分噪声共同决定，得到（附录 A.3.8）

$$\begin{aligned}\frac{\mathrm{Var}(W_n)}{p(1-p)/n}&\approx 4\,\mathrm{Var}(E_t)+\frac{4}{K^2n}\,\mathrm{Var}(R_{t+n}-R_t),\\ \mathrm{Var}(R_{t+n}-R_t)&=2\big[\Gamma(0)-\Gamma(n)\big],\end{aligned} \tag{2.14}$$

其中 $\Gamma(k)=\lambda^2\gamma_{\hat{s}}(k)+\sigma_e^2(1-\alpha)^k$，$\gamma_{\hat{s}}$ 是指数平滑后状态的自协方差。100 局窗口的方差比（模拟/公式）为：随机匹配加状态 3.60/3.80，按分匹配加状态 1.61/1.64（$K=16$）和 1.07/1.01（$K=32$），按分匹配且实力固定 0.56/0.56（图 2.10）【本项目】。最后一项小于 1 值得注意：实力固定时按分匹配让胜率比独立抽样更稳定，因为评分上涨会立刻带来更强的对手；$n\gg\tau_R$ 时 $\mathrm{sd}(W_n)\approx\sqrt{2}\sigma_e/(Kn)$，按 $1/n$ 而不是 $1/\sqrt{n}$ 衰减。换成“百局胜率不低于 60% 的窗口占比”：二项分布 2.8%，按分匹配实力固定 5.4%，加状态 10.4%，严格按分匹配（$\sigma_q=20$）0.7%，随机匹配 33.9%（主要反映人与人的实力差）【本项目】。Aldous 在三种实力随时间变化的模型中模拟后认为，在他认为合理的参数下，Elo 预测胜率的典型误差不会明显低于 10%[34]【文献】；与此一致，状态起伏让“当前胜率”在相当长的窗口里都偏离长期值。

2.6.3　长期进步：评分滞后，胜率高出期望得分约 $\lambda v/K$

假设：玩家每局实力上升 v 分。**推导**（附录 A.3.9）：由式 (2.6)，$W-\bar{E}$ 精确等于评分上升速度除以 K。稳态下评分折算的实力与真实实力同速上升，评分以 λv 的速度上升，于是

$$W-\bar{E}\approx\frac{\lambda v}{K},\qquad \text{滞后（实力分）}\approx\frac{4\lambda v}{Kc}=\lambda v\cdot\frac{4}{Kc}. \tag{2.15}$$

模拟（图 2.11）：系统平稳后随机抽 2% 玩家每局进步 v，共进步 300 分。按分匹配（$\sigma_q=100$）下，$K=16$ 时 $v=0.25,0.5,1.0$ 的 $W-\bar{E}$ 为 1.79、3.54、6.67 个百分点，

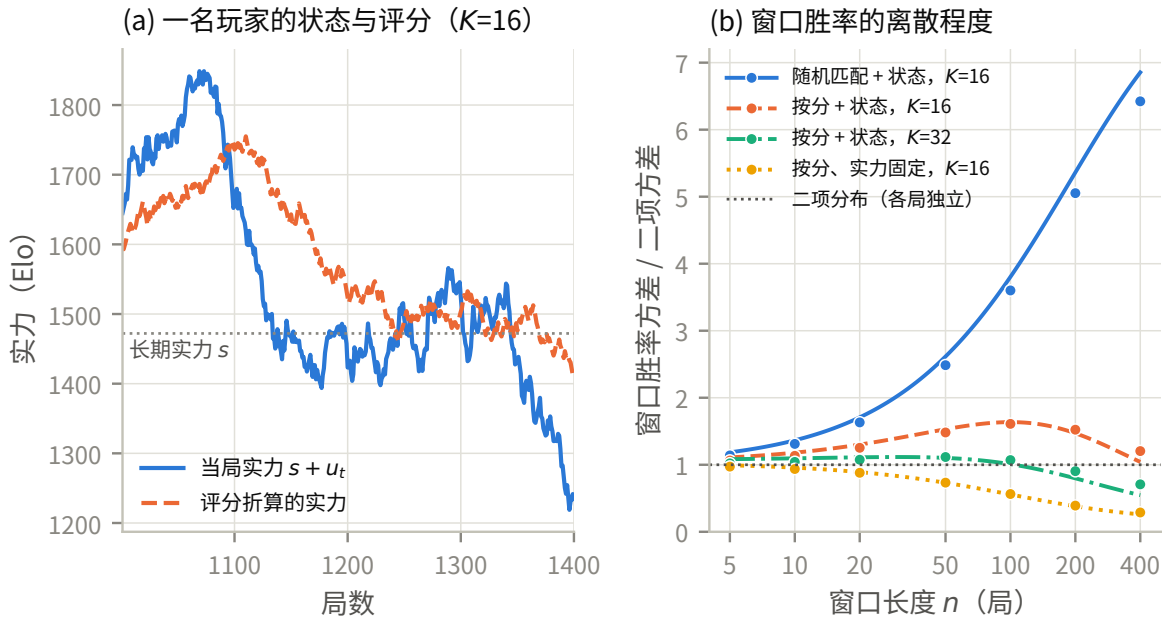


图 2.10： 自相关的状态起伏：评分只能部分追上，窗口胜率比二项分布更分散。(a) 按分匹配（$\sigma_q = 100$，$K = 16$）中一名实力接近中位数的玩家：当局实力 $s + u_t$ 与评分折算的实力；(b) n 局窗口胜率的人内方差除以二项方差 $\hat{p}(1-\hat{p})/n$，点为模拟（每人 2,000 局切成 $2000/n$ 个窗口），曲线为式 （2.14）及随机匹配下的对应公式。参数：10,000 人，$\tau = 200$，$\sigma_u = 100$，$\phi = 0.99$，3000 轮，统计第 1001–3000 局。【本项目】

公式（$\lambda^* = 1.17$）为 1.82、3.64、7.29；$K = 32$ 时为 1.11、2.19、4.40，公式为 1.10、2.20、4.41；$v = 0.5$ 的滞后为 28.9 分（$K = 16$，公式 25.3）和 15.0 分（$K = 32$，公式 15.3）【本项目】。$v = 1$、$K = 16$ 时偏低约 9%，可能的原因是进步者升到高分区后同分对手变少，评分上升受窗口边缘限制。若让 10% 的玩家同时进步（$v = 0.5$），测得的 $W - \bar{E}$ 会再低 11%–15%：进步者之间频繁对局，零和更新不给这一群体带来净分【本项目】。

真实数据里有对应的痕迹：TrueSkill 2 在 Halo 5 数据中发现，新玩家前 10 局的实际胜率（45%–47%）低于经典 TrueSkill 的预测（48%–49%），作者把它解释为实力随经验上升、而模型假设实力只做无偏随机游走，并据此加入经验偏移[25]【文献】。这正是式 （2.6）的另一面：胜率与预测胜率的差，衡量的是评分没跟上实力变化的部分。Düring 等人用动理学方程研究了带学习效应的 Elo 模型[36]【文献】。

小结：实力在变化时，期望胜率仍可写成 $W(t) \approx \bar{E}(t) + \lambda v(t)/K + \frac{c}{4}(1-a)u_t$：第一项由匹配决定，第二项来自长期进步，第三项来自没被评分吸收的状态。能算的是期望；不确定性要在二项误差之外乘以式 （2.14）的修正因子。

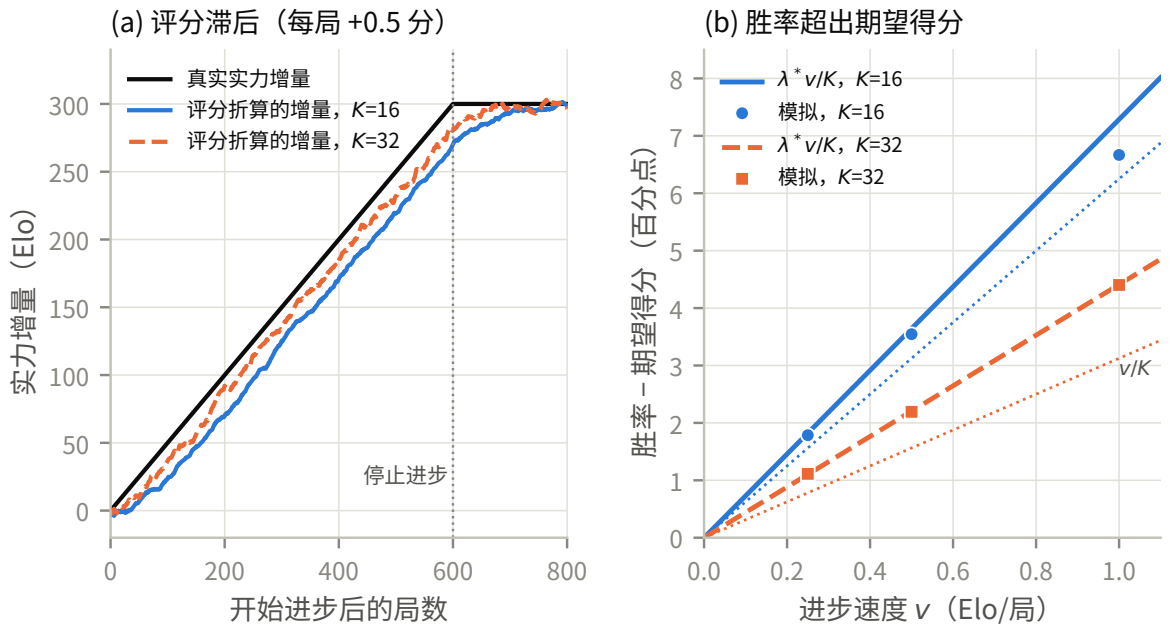


图 2.11: 长期进步：评分滞后，胜率高出期望得分。(a) 每局进步 0.5 分的玩家：真实实力增量与评分折算的实力增量；(b) 斜坡第 101 局至结束的 $W - \bar{E}$，点为模拟，实线为式 (2.15)（λ^* 取 $\sigma_q = 100$ 的平稳值），点线为 v/K。参数：10,000 人，$\tau = 200$，按分匹配 $\sigma_q = 100$，系统运行 1000 轮后随机抽 200 人每局进步 v、共 +300 分，之后再观察 200 局。【本项目】

2.7　统计不确定性：分辨 52% 和 50% 需要约 4,900 局

真实胜率为 p 时，n 局胜率的标准误为 $\sqrt{p(1-p)/n}$：$p = 0.5$ 时 20 局 ±11.18、100 局 ±5.00、500 局 ±2.24 个百分点（一倍标准误）【本项目】。小样本的区间应使用 Wilson 区间而不是 Wald 区间[164-165]²【文献】。

所需局数。检验 $H_0: p = p_0$ 对 $p = p_1$，双侧显著性 α、功效 $1 - \beta$ 所需局数为（正态近似，附录 A.3.10）

$$n = \left(\frac{z_{1-\alpha/2}\sqrt{p_0(1-p_0)} + z_{1-\beta}\sqrt{p_1(1-p_1)}}{p_1 - p_0} \right)^2 . \tag{2.16}$$

区分 52% 与 50%：$\alpha = 0.05$ 双侧、功效 80% 需要 4,903 局；单侧 3,862 局；功效 90% 需要 6,563 局。若观测胜率恰为 52%，要让 Wilson 95% 区间不含 50%，至少需要 2,401 局【本项目】。纯运气也会制造“高胜率”：真实 50% 时，100 局中胜率不低于 60% 的概率为 2.84%，20 局中至少 14 胜为 5.77%、至少 15 胜为 2.07%，500 局中不低于 55% 为 1.42%【本项目】。玩家基数一大，总有不少人只凭运气就有一段漂亮战绩。

相关性会改变误差（图 2.12(a)）：把式 (2.14) 的修正因子乘到二项方差上，100 局窗口的 95% 半宽在按分匹配、实力固定时约为 ±7.2 个百分点，在随机匹配加状态

[2]待核对：本次未读到原文全文（Wilson 1927 与 Brown–Cai–DasGupta 2001 只核对了书目信息）。

表 2.5: 观测胜率的不确定性（各局独立）。Wald 半宽按 $p = 0.5$ 计算；末列为观测胜率恰为 52% 时的 Wilson 95% 区间。【本项目】

局数 n	标准误	95% 半宽（Wald）	观测 52% 时的 Wilson 区间
20	11.18	±21.9	31.6%–71.7%
50	7.07	±13.9	38.5%–65.2%
100	5.00	±9.8	42.3%–61.5%
200	3.54	±6.9	45.1%–58.8%
500	2.24	±4.4	47.6%–56.3%
1,000	1.58	±3.1	48.9%–55.1%
2,000	1.12	±2.2	49.8%–54.2%
5,000	0.71	±1.4	50.6%–53.4%

起伏时约为 ±19.7 个百分点（相对长期均值），而二项分布为 ±9.8【本项目】。

8 人局（图 2.12(b)）：前四率是 $p_0 = 0.5$ 的二项比例，区分 52% 与 50% 同样要 4,903 局；第一名率要对 12.5% 检验，在 Plackett–Luce 下同等实力优势（前四率 52% 对应 $d \approx 11$ 分）的第一名率只有 13.2%，需要约 17,700 局；平均名次在同水平时的标准差为 $\sqrt{(N^2-1)/12} = 2.29$，检测平均名次移动 0.10（4.5→4.4）需要约 4,100 局，而前四率 52% 的玩家平均名次为 4.39，用平均名次检验只需约 3,400 局【本项目】。名次本身比“是否进前四”包含更多信息，估计 8 人局实力时应优先用完整名次。

2.8　小结：胜率能不能算、和什么有关

表 2.6 汇总本章结论。总的回答是：在“只有输赢、匹配不被操纵”的前提下，胜率可以算，但要先说清三件事——对手从哪里来（随机还是按分）、“胜”指什么（1v1、团队还是名次）、实力是固定还是在变。

三点值得带到后面两章。第一，按分匹配下长期胜率接近 50% 是式 (2.6) 的直接结果，不需要任何“控胜率”机制来解释；但“无需操纵即可解释”不等于“已证明没有操纵”，后者要看匹配输入（第三章）。第二，状态起伏让窗口胜率比二项分布更分散，这是第三章讨论连败与“上头”的起点。第三，从训练的角度看，胜负标签在系统稳定后仍然源源不断，但信息集中在偏离预测的部分 $(y - E)$，这与第四章讨论的“目标是胜率还是实力”直接相关。对酒馆战棋这类 8 人名次游戏，评估实力时应使用完整名次而不是前四率，并对固定参照池而不是天梯对手来测量。

表 2.6: 影响长期胜率的因素：方向与量级（模型参数见各节，$\tau = 200$，$K = 16$ 除非另注）。【本项目】

因素	方向	量级
自身实力（随机匹配）	实力百分位越高胜率越高，$W = \Phi(\rho z_q)$	最强/最弱 10%：83% / 17%
群体离散度 τ	越大胜率越极端	τ=100→300：前 10% 由 72% 到 88%
游戏随机性	越随机越接近 50%，评分差同比例压缩	单局噪声 150：斜率 ×0.81，前 10% 79%
匹配规则	按分匹配把胜率压向 50%，窗口越窄越接近	十分位范围：随机 17–83%，σ_q=100 时 42–58%，σ_q=20 时 49–51%
匹配时的评分/段位	只通过对手分布起作用；评分落后于实力时胜率偏高	重置的高手前 50 局 77.5%，约 47 局追回一半
K 因子	不改变随机匹配的胜率；决定评分噪声与滞后	$\sigma_e \approx 9.3\sqrt{K}$；误差衰减 55–65 局（$K$=16）、30–34 局（$K$=32）
每队人数 n	个人优势被稀释	n=5：斜率为 1v1 的 0.40（加和）或 0.23（均值）
每局人数 N 与“胜”的定义	基准率 $1/N$（第一名）或 50%（前一半）	8 人局按分匹配：第一名 12.5%，前四 50%，平均名次 4.5
独立的单局波动	等于游戏更随机	见“游戏随机性”
自相关的状态	长期胜率几乎不变，窗口胜率更分散	百局方差为二项的 1.6 倍（按分）至 3.6 倍（随机）
长期进步	胜率高于预测胜率	$W - \bar{E} \approx \lambda v/K$：$v$=0.5 时约 3.5 个百分点
样本量	决定能否分辨	52% 对 50%：4,903 局（80% 功效）

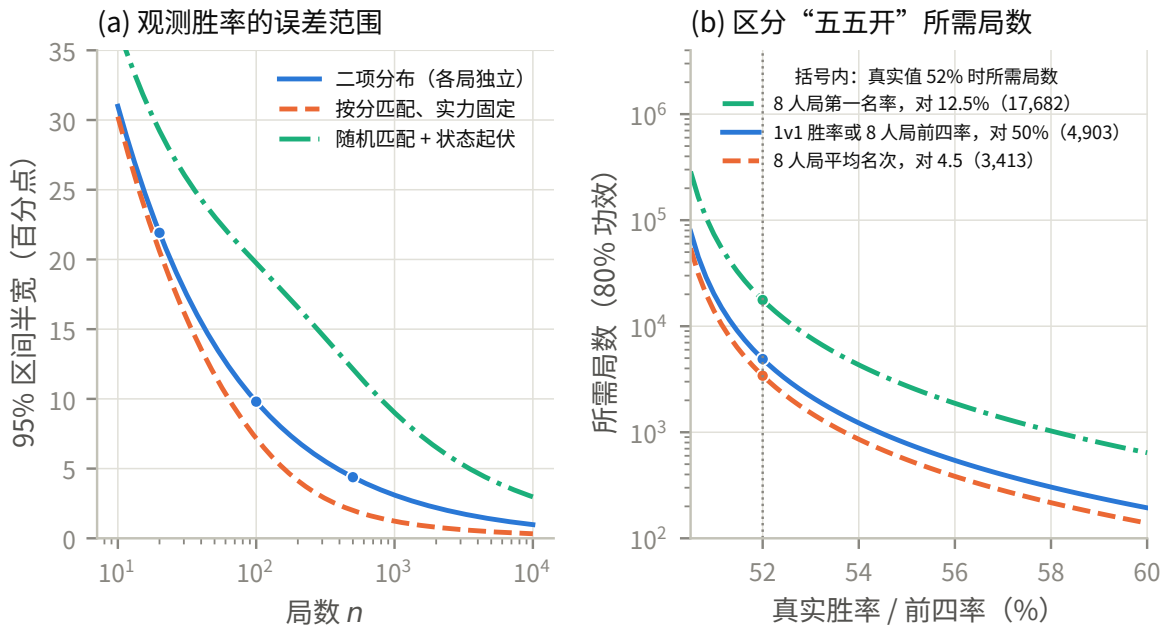


图 2.12: 胜率的统计不确定性。(a) 真实胜率 50% 时 n 局观测胜率的 95% 区间半宽：二项分布（三个点为 20、100、500 局），以及按式（2.14）修正后的按分匹配（实力固定，$\sigma_q = 100$，$K = 16$）和随机匹配加 AR(1) 状态（$\sigma_u = 100$，$\phi = 0.99$）；(b) 双侧 $\alpha = 0.05$、功效 80% 时区分“五五开”所需局数，8 人局的第一名率与平均名次按 Plackett–Luce 换算到相同的实力优势。【本项目】

第三章　研究三：诚实系统会不会制造“Elo 感”

直接回答

会，而且不需要任何操纵。玩家说的“ELO 机制”多指被怀疑的操纵：把胜率拉回五成、连胜后安排强敌或弱队友、低分段“出不去”。纯随机就足以产生大量这类体验：胜率五成的玩家打 100 局，81% 会遇到 5 连败，31% 会遇到“4 连胜紧接 4 连败”；打 1000 局，39% 会遇到 10 连败（第 3.2 节）。诚实的按分匹配只带来很小的均值回归：连胜 k 局后下一局胜率约低 $\kappa cKk/(16n)$，1v1、$K=32$ 时 5 连胜后约低 3 个百分点（5v5 约 0.5），并且让长连败变少，单人要 5 万局以上才能察觉（第 3.3 节）。诚实系统里真正能放大连败的是玩家自身的波动，尤其是连败触发的“上头”：每多输一局实力降 30 分（最多 90 分）时，“5 连胜紧接 5 连败”约翻一倍，千局内 10 连败的概率从约 40% 升到约 63%；慢变化的状态和疲劳大多被评分吸收（第 3.4 节）。统计陷阱和认知偏差把正常频率读成“被安排”（第 3.5 节）。操纵若存在，可靠的指纹在匹配输入（对手评分差）里，而不在胜负序列里；对称的“控五成”反而让长连败更少（第 3.6 节）。所以结论是“无需操纵即可解释”，不等于“已证明没有操纵”。

本章有两条线：一是数学，给定产生胜负的模型，长连败、“连胜后连败”和条件胜率的分布可以精确算出或写成近似式；二是模型比较，纯随机、诚实 Elo、五种实力波动和三种操纵规则各自留下什么统计痕迹，单个玩家要多少局才能分开它们。记号沿用全文约定；单局胜率记 p，$q=1-p$。标注【本项目】的数字都由 `code/ch3/` 的脚本算出，参数见图注、表注和附录 A.4.6。

3.1　玩家说的“Elo”是什么：三种假说和它们各自的预测

在学术文献里，Elo 指一套评分更新公式（第 1.2.2 节）；中文社区说的“ELO 机制”却指系统主动调控胜率。有自媒体文章称 ELO 机制“实际上在主动调控你的胜率，让你的对局结果趋向于 50%”，“连胜后你往往获得更弱的队友”[166]【社区】；另一篇的

标题就是“连胜之后必定连跪，王者 ELO 机制控制胜率”，描述的模式是“先给你来一波五连胜，再给你来一波六连跪”，手段是把正在连败、容易“摆烂”的玩家配给连胜者[167]【社区】；还有文章标题写着“官方解释”，正文却只是作者的说法：“如果你是高手，近期胜率 70%，那么队伍里必定有近期胜率 30% 的玩家”[168]【社区】。英文社区的“loser queue”指匹配系统人为制造连胜连败，让连败者和同样连败的人组队、对上正在连胜的人[169]【社区】。这些文章都没有数据来源。厂商的回应见第 1.7 节，例如 VALORANT 设计师称“There is no loser's queue in Valorant……We do not manipulate the queue”[92]【官方】，守望先锋 2 开发者博客说很长的连胜或连败往往说明内部评分还没有校准好[103]【官方】。

把这些说法形式化，得到三种操纵假说；再加上三种不需要操纵的解释，表 3.1 列出各自的预测，后面各节逐项检验。

表 3.1： “Elo 感”的六种解释及其可检验的预测。“条件胜率”指连胜（连败）k 局后下一局胜率相对该玩家自身平均的偏离；“对手评分差”指对手（或敌队均分）减我方评分。

解释	形式化	条件胜率	对手评分差、长连败
H1 强制五成	连胜 $\geq k_0$ 时配更强的对手，连败 $\geq k_0$ 时配更弱的（对称）	在阈值 k_0 处断崖式下降/上升	连胜后显著为正；长连败**少于**独立基线
H2 连胜惩罚 / loser queue	只惩罚连胜，或在分队时把连胜者配给弱队友	连胜一侧在阈值处下降	连胜后为正（团队游戏看敌我均分差）
H3 Elo 地狱	低分段队友差、个人影响被稀释，难以上分	无特定形状	长期期望上，强于当前分段者仍会上升（第 2.4.1 节与 2.4.4 节）
H0a 纯随机	单局独立、胜率恒定	0	0；长连败见第 3.2 节
H0b 诚实 Elo	按评分匹配，评分随结果更新	随 k 平滑、线性地小幅回归	约 0 或略负；长连败略少于基线
H0c 实力波动	实力 $s_t = s + u_t$ 随状态变化	视模型而定（上头：连败后更低）	约 0；长连败**多于**基线

H1 有一个常被误读的良性版本：按分匹配会让评分收敛到“每局约五成”的位置，长期胜率接近 50% 本身就是诚实系统的预测（第 2.4.1 节）。区别在手段：诚实系统改变你的评分，H1 改变某一局的对手。

3.2　纯随机下的连败与“连胜后连败”

本节假设每局独立、胜率恒为 p（H0a）。它若已能以玩家感受到的频率产生长连败和“连胜后连败”，“感觉”就不需要额外机制来解释。

3.2.1　最长连败有精确分布

记 L_n 为 n 局中的最长连败。把“当前尾部连败长度” $\ell \in \{0,\dots,r-1\}$ 当作马尔可夫链的状态：赢一局回到 0，输一局 $\ell \to \ell+1$，到达 r 就吸收。从 $\ell=0$ 出发走 n 步后未被吸收的概率就是 $\mathbb{P}(L_n < r)$，计算量为 $O(nr)$。等价地，按第一次获胜的位置分解得到递推

$$a_n = \sum_{j=0}^{r-1} q^j\, p\, a_{n-j-1} \quad (n \ge r), \qquad a_m = 1 \quad (0 \le m < r), \tag{3.1}$$

其中 $a_n = \mathbb{P}(L_n < r)$。表 3.2 给出精确值，图 3.1 画出 $\mathbb{P}(L_n \ge k)$ 随局数的变化【本项目】。

表 3.2: 独立对局中的最长连败（精确值，马尔可夫链动态规划；递推(3.1)与 Monte Carlo 校验一致）。“GSW 近似”为式(3.2)。

胜率	n	$\mathbb{E}L_n$	GSW 近似	标准差	95% 分位	$\mathbb{P}(L_n \ge 5)$	$\mathbb{P}(L_n \ge 7)$	$\mathbb{P}(L_n \ge 10)$
45%	100	6.85	6.83	2.06	11	0.920	0.497	0.101
45%	1000	10.69	10.68	2.15	15	1.000	0.999	0.682
50%	50	5.01	4.98	1.73	8	0.552	0.165	0.020
50%	100	5.99	5.98	1.79	9	0.810	0.318	0.044
50%	500	8.30	8.30	1.85	12	1.000	0.864	0.215
50%	1000	9.30	9.30	1.86	13	1.000	0.982	0.385
55%	1000	8.13	8.13	1.62	11	1.000	0.875	0.170

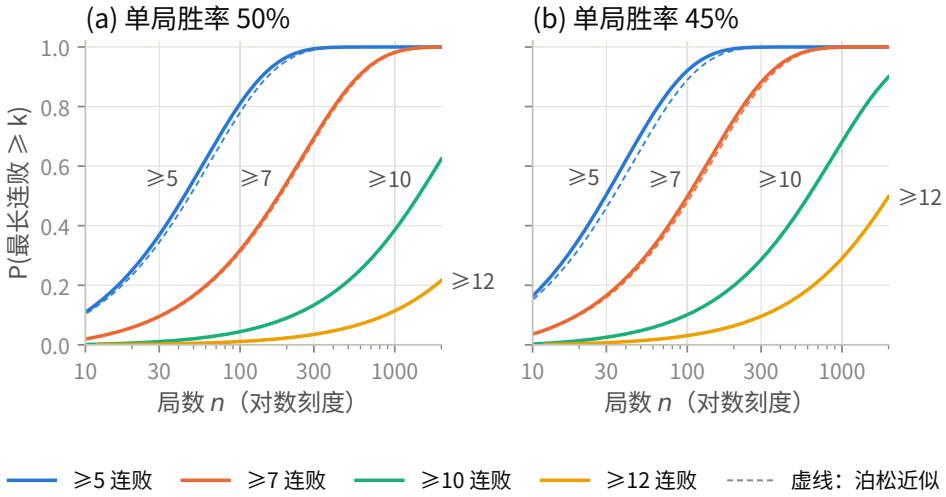


图 3.1: 独立对局中“至少出现一次 $\ge k$ 连败”的概率随局数 n 的变化。实线为精确值（马尔可夫链），虚线为泊松近似 $1-\exp(-q^k[1+(n-k)p])$。胜率五成时，100 局内出现 5 连败是常态（81%），1000 局内出现 10 连败也有 39%；胜率降到 45% 时，后者升到 68%。

规模效应把小概率变成大量真实经历：1000 万名胜率五成的玩家每人打 500 局，约 21%（两百多万人）会遇到 ≥ 10 连败；一晚打 20 局，出现 ≥ 4 连败的概率为 48% 【本项目】。

3.2.2 Schilling 近似：最长连败约为 $\log_{1/q}(np)$

下面的近似式可以心算。Gordon、Schilling 与 Waterman 证明，最长的“正面”游程近似等于 $n(1-p)$ 个独立指数随机变量最大值的取整，并给出均值和方差的展开[170] 【文献】（把“正面”换成“输”，即把其中的 p 换成 q）；Schilling 的普及文章给出了直观推导和体育应用[171-172] 【文献】[1]。

推导：最长连败的 Gumbel 近似

(1) 以第 i 局开始的一段 $\geq r$ 连败，要求第 $i-1$ 局赢（或 $i=1$）且第 $i,\dots,i+r-1$ 局全输，所以长度 $\geq r$ 的连败段的期望个数为

$$\mathbb{E}N_r = q^r\,[1+(n-r)p] \approx npq^r.$$

(2) r 较大时这样的连败段稀少且近似独立，N_r 近似服从泊松分布，于是 $\mathbb{P}(L_n < r) = \mathbb{P}(N_r = 0) \approx \exp(-npq^r)$。

(3) 令 $\lambda = \ln(1/q)$、$\mu = \log_{1/q}(np)$，则 $npq^r = e^{-\lambda(r-\mu)}$，

$$\mathbb{P}(L_n < r) \approx \exp\big(-e^{-\lambda(r-\mu)}\big),$$

这正是位置 μ、尺度 $1/\lambda$ 的 Gumbel 分布 G 在 r 处的分布函数。因为对整数 r 有 $\mathbb{P}(L_n < r) = \mathbb{P}(G < r)$，所以 $L_n \approx \lfloor G \rfloor$。

(4) Gumbel 分布的均值为 $\mu + \gamma/\lambda$（$\gamma \approx 0.5772$），方差为 $\pi^2/(6\lambda^2)$。取整使均值减少约 1/2、方差增加约 1/12（小数部分近似均匀分布）。合起来：

$$\mathbb{E}L_n \approx \log_{1/q}(np) + \frac{\gamma}{\ln(1/q)} - \frac{1}{2}, \qquad \operatorname{Var} L_n \approx \frac{\pi^2}{6\ln^2(1/q)} + \frac{1}{12}. \tag{3.2}$$

令 $N_r = 1$ 解出的 $r = \log_{1/q}(np)$ 是“典型的最长连败”，$p = 1/2$ 时为 $\log_2(n/2)$（100 局 5.6、1000 局 9.0），加上 $\gamma/\ln 2 - 1/2 \approx 0.33$ 后与精确均值几乎一致。在 $p \in \{0.45, 0.5, 0.55\}$、$n \in \{50, 100, 500, 1000\}$ 的 12 个组合中，式(3.2)的均值误差不超过 0.035 局【本项目】。方差与 n 无关（标准差约 1.9 局）：Schilling 指出，预测 100 次和 100 万次抛掷中的最长连串，精度一样[172] 【文献】。

[1] 待核对：本次未读到原文全文（Schilling 1990 只读到书目信息与二手介绍；1994 年短文已读全文）。

3.2.3　“连胜后连败”的精确计数

取最严格的定义：一段 $\geq k$ 连胜之后**紧接**一段 $\geq k$ 连败。它与子串 $\mathrm{W}^k\mathrm{L}^k$ 的出现一一对应（每次出现恰好跨过一个“左侧连胜 $\geq k$、右侧连败 $\geq k$”的交界，且该子串不会自重叠），由期望的线性性，

$$\mathbb{E}\big[\#\{\geq k \text{ 连胜紧接 } \geq k \text{ 连败}\}\big] = (n-2k+1)\,(pq)^k. \tag{3.3}$$

这是精确式【本项目】。$p=0.5$ 时，$k=4$ 每千局 3.88 次，$k=5$ 每千局 0.97 次。“至少出现一次”的概率用子串的 KMP 自动机做动态规划（附录 A.4.1，图 3.2(a)）：$k=4$ 时，100 局和 1000 局内分别为 31% 和 98%；$k=5$ 时为 8.6% 和 62%。

这些数字对定义敏感：要求“恰好 4 胜接恰好 4 负”时每千局只有 0.97 次；两种顺序都算时每千局 7.76 次，100 局内至少一次的概率约 50%【本项目】。主观上的“连胜后连败”往往不要求两段紧挨着，体感频率更高。

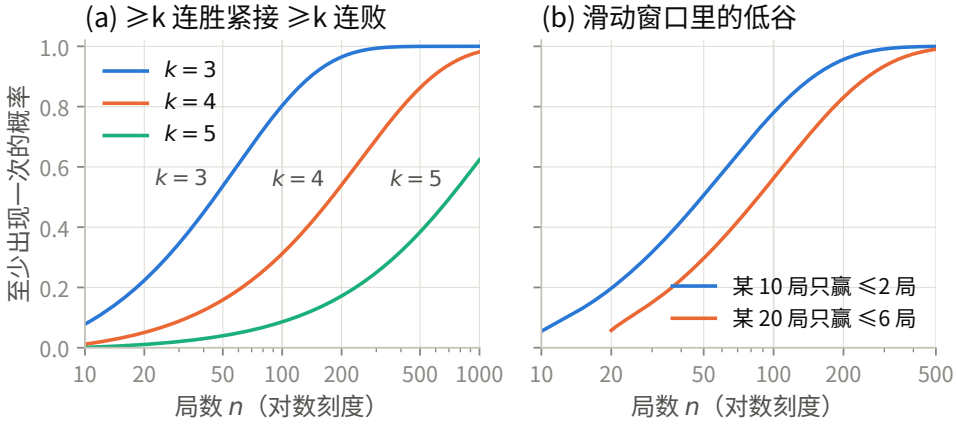


图 3.2: (a)“$\geq k$ 连胜紧接 $\geq k$ 连败”至少出现一次的概率（精确，KMP 自动机）。(b) 存在某个连续 10 局只赢 ≤ 2 局、或某个连续 20 局只赢 ≤ 6 局的概率（精确动态规划，状态为最近 $w-1$ 局）。单局胜率均为 50%。100 局中，前者为 78%，后者为 56%。

3.2.4　不必连续：滑动窗口里的低谷

“卡段位”“最近怎么都赢不了”并不需要严格连续地输。以最近 $w-1$ 局为状态做动态规划，可以精确算出“存在某个 w 局窗口只赢 $\leq x$ 局”的概率：胜率五成的人打 100 局，78% 会出现某 10 局只赢 ≤ 2 局，56% 会出现某 20 局只赢 ≤ 6 局；打 500 局，后者升到 99%，出现某 50 局胜率 $\leq 40\%$ 的概率约 96%（Monte Carlo）【本项目】。这种低谷在 100 局量级的历史里几乎必然出现。

3.2.5　Miller–Sanjurjo 偏差：自查战绩时的陷阱

玩家常用的“证据”是翻自己的战绩，数“连胜 3 局之后下一局赢的比例”。Miller 与 Sanjurjo 证明，在一段有限序列里计算这个比例，即使各局独立，它的期望也**低于**

真实胜率；偏差随序列变长而减小、随连串变长而增大[173]【文献】。

推导：$k=1$ 时的闭式解

设一段 n 局历史中赢了 n_1 局。在独立同分布下，给定 n_1 时每一种排列等可能。估计量 $\hat{P}_1 = \#\{\text{胜后胜}\}/\#\{\text{前}n-1\text{ 局中的胜}\}$。随机挑一个“有下一局的胜局”，它后面那一局来自其余 $n-1$ 局，其中只剩 n_1-1 场胜利，就像不放回抽样。Miller 与 Sanjurjo 的引理 1 给出

$$\mathbb{E}\big[\hat{P}_1 \mid N_1 = n_1,\ \hat{P}_1 \text{ 有定义}\big] = \frac{n_1 - 1}{n - 1} < \frac{n_1}{n}.$$

再对 n_1 的分布加权即得 $\mathbb{E}\hat{P}_1$；$n=100$、$p=0.5$ 时为 $49/99 \approx 0.495$。$k \geq 2$ 时没有简单闭式，本项目用状态为（截断到 k 的当前连胜、合格局数、其中胜局数）的动态规划精确计算（附录 A.4.2）。

胜率五成的玩家自查最近 100 局，“3 连胜后胜率”的期望只有 **46.0%**，4 连胜后 41.3%，5 连胜后 36.5%（图 3.3(a)）；“连败后胜率”对称地偏高【本项目】。这恰好像是“系统在惩罚连胜”的证据。Miller 与 Sanjurjo 用同一逻辑重新分析经典的“热手谬误”研究：每人 100 次投篮、命中率五成时，“3 中后命中率减 3 失后命中率”在独立投篮下的期望为 -8 个百分点，原研究观测到 $+4$；修正偏差后平均差值为 $+13$ 个百分点（$p < 0.01$），原结论反转[173]【文献】。

偏差取决于估计量：把所有人的历史合并计数，或每段连胜只取一次观测（如只看“恰好第 3 胜之后的那一局”，期望约 50.4%），偏差几乎消失【本项目】。检验时应当用合并计数、玩家内部置换检验，或直接扣除算出的偏差。

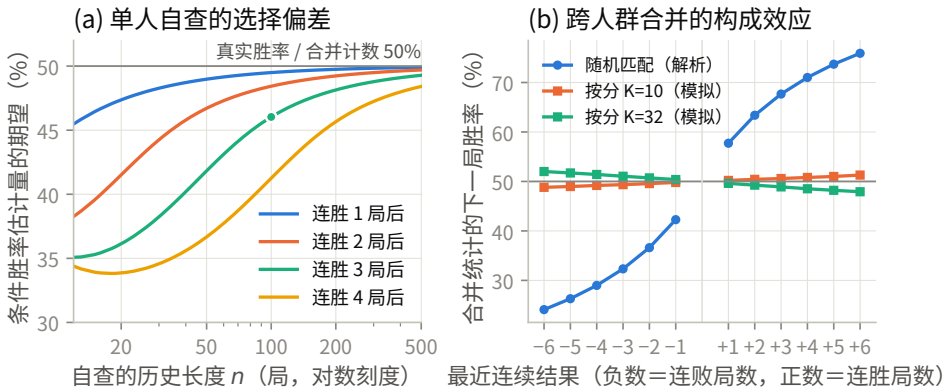


图 3.3: (a) 单局胜率 50% 的独立序列里，自查一段 n 局历史得到的“连胜 k 局后下一局胜率”的期望（精确动态规划，只取该比例有定义的历史；圆点为 $n=100$、$k=3$ 时的 46.0%）。(b) 跨人群合并统计的“最近连续 k 局全胜（正）/全负（负）后下一局胜率”。随机匹配为解析式 $\mathbb{E}[p^{k+1}]/\mathbb{E}[p^k]$，实力 $s \sim \mathcal{N}(0, 200^2)$；按分匹配为人群模拟（$N = 10{,}000$，$\sigma_q = 100$，记录 2000 局/人）。同一玩家内部，随机匹配下没有任何依赖，按分匹配下是小幅负向回归（第 3.3 节）。

3.2.6　构成效应：全服合并统计为什么也会骗人

另一类“证据”来自全服统计，如“5 连败后的下一局胜率只有三成”。设玩家 i 的单局胜率为 p_i、各局独立，合并所有玩家计数时，

$$\mathbb{P}(\text{胜} \mid \text{最近}k\text{ 局全胜}) = \frac{\mathbb{E}[p^{k+1}]}{\mathbb{E}[p^k]} \;\geq\; \mathbb{E}[p], \tag{3.4}$$

期望对玩家取；不等式由 $\mathbb{E}[p^{k+1}]\mathbb{E}[p^{k-1}] \geq \mathbb{E}[p^k]^2$ 得到，且比值随 k 增大：强者更常处于连胜中，弱者更常处于连败中。随机匹配、实力 $\mathcal{N}(0, 200^2)$ 时，合并后的“5 连胜后胜率”高达 73.7%，“5 连败后”只有 26.3%，而同一玩家内部没有任何变化【本项目】。按分匹配大幅削弱了构成效应，但 $K = 10$ 时合并统计的“5 连胜后胜率”仍为 51.0%，玩家内部其实是 -1.2 个百分点（图 3.3(b)）。社区分析也注意到这一点：约 10 万局英雄联盟数据中，刚 2 连败的玩家下一局胜率约 48.8%，作者指出这些玩家“统计上更可能本来就是较弱的玩家”[174]【社区】。跨玩家合并的条件胜率必须先控制构成效应。

3.3　诚实 Elo 的均值回归：有，但很小

不做任何操纵、只按评分匹配并按 Elo 更新时，系统本身会制造“连胜后略难、连败后略易”，但量很小，并且让长连败变少。

3.3.1　机制：连胜后评分过冲

连胜 k 局后评分上涨约 $kK/2$。这些胜利一部分说明你原本被低估，另一部分只是运气，所以连胜结束时评分平均**高于**真实实力；匹配器找来的对手评分和你相同，真实实力却比你高。图 3.4 展示了这个过冲：$K = 32$ 时，连胜开始前评分平均被低估约 40 分，连胜中每局涨约 16 分，结束时平均高估约 39 分，之后每局衰减约 4.6%。

3.3.2　线性高斯近似：连胜 k 局后的胜率

把评分误差 $e_t = R_t - s$ 的动态线性化，可以得到闭式近似。设每队 n 人，匹配器找评分相同的对手（系统预测 $E_t \approx 1/2$），真实胜率对自己评分误差的敏感度为 $\kappa c/(4n)$。

推导概要（详见附录 A.4.3）

线性化 $p_t \approx \frac{1}{2} - g\,e_t$，$g = \kappa c/(4n)$；Elo 更新给出 $e_{t+1} = (1-b)e_t + K\xi_t$，$b = gK$，$\xi_t = y_t - p_t$，稳态方差 $\sigma_e^2 = K^2/[4b(2-b)]$（$n = \kappa = 1$ 时 $\sigma_e \approx 9.3\sqrt{K}$，$K = 32$ 时 53 分）。“最近 k 局全胜”时评分涨了 $kK/2$；同时这 k 场胜利是对 e_{t-k} 的证据，

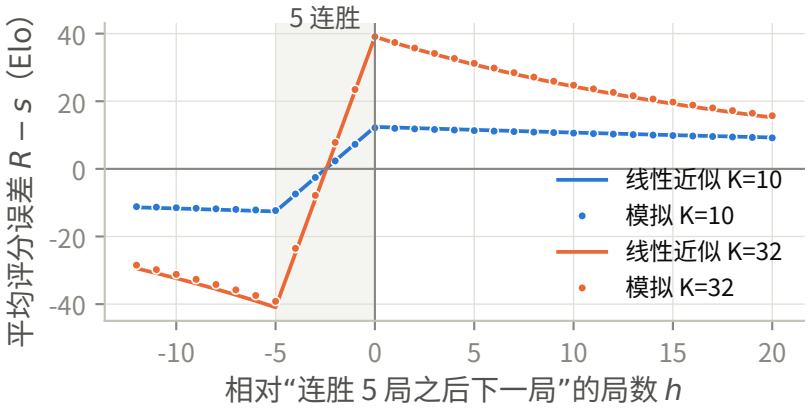


图 3.4: 诚实 Elo 的评分过冲。单个玩家对“校准良好的对手池”（对手真实实力 = 对手评分 = 我的评分 + $\mathcal{N}(0, 50^2)$ 排队噪声），以“最近 5 局全胜”的时刻为 $h = 0$，平均评分误差 $R - s$ 的前后走势。点为模拟（4×10^4 名玩家 × 400 局），线为第 3.3.2 节的线性高斯近似。

似然 $\propto \exp(-2gk\, e_{t-k})$ 把高斯先验的均值平移 $-2gk\sigma_e^2$。两者相减：

$$\begin{aligned} \mathbb{E}[e_t \mid \text{最近}k\text{ 局全胜}] &= \frac{kK}{2} - 2gk\sigma_e^2 = \frac{kK(1-b)}{2(2-b)} \approx \frac{kK}{4}, \\ \Delta_k &\approx -g \cdot \frac{kK}{4} = -\frac{\kappa\, c\, K\, k}{16\, n}. \end{aligned} \tag{3.5}$$

同理，滞后 1 自相关 $\rho_1 \approx -gK/(2-b) \approx -\kappa cK/(8n)$。

式(3.5)解释了模拟中的三个规律：效应随 k 线性增长、与 K 成正比、按队伍人数 n 稀释；过冲约为连胜期间涨分的一半。κ 衡量“评分误差有多少传到真实胜率上”：对手池校准时 $\kappa = 1$；闭合人群中评分刻度被拉伸 λ 倍且含噪声，κ 近似等于实力对评分的回归斜率 ρ_{Rs}^2/λ，本项目模拟中 1v1 $K = 10$、1v1 $K = 32$、5v5 $K = 32$ 分别为 0.88、0.64、0.57【本项目】。

图 3.5 对照近似与模拟。单人校准池中两者只差约 4%（$K = 32$、5 连胜后 −5.6 对 −5.4 个百分点）；闭合人群中近似高估 20%–35%（F 的非线性、对手评分误差的相关），但线性形状和比例关系都对。以模拟为准：5 连胜后下一局胜率比自身平均低约 1.2（1v1，$K = 10$）或 3.0 个百分点（1v1，$K = 32$），5v5 只低约 0.5 个百分点，连败一侧对称【本项目】。

3.3.3　它让长连败更少，“连胜后连败”几乎不变

连败时评分下降、对手随之变弱，连败更容易被打断。与“同一玩家结果随机打乱”的独立基线相比（表 3.3），1v1 $K = 32$ 时千局内 ≥ 10 连败的概率从 40.5% 降到 29.3%；“≥ 4 连胜紧接 ≥ 4 连败”只多约 2%，“≥ 5 接 ≥ 5”只多约 1%（不同设定下为 0–6%，见表 3.3与表 3.5）；5v5 几乎等于纯随机【本项目】。诚实 Elo 下 95% 以上

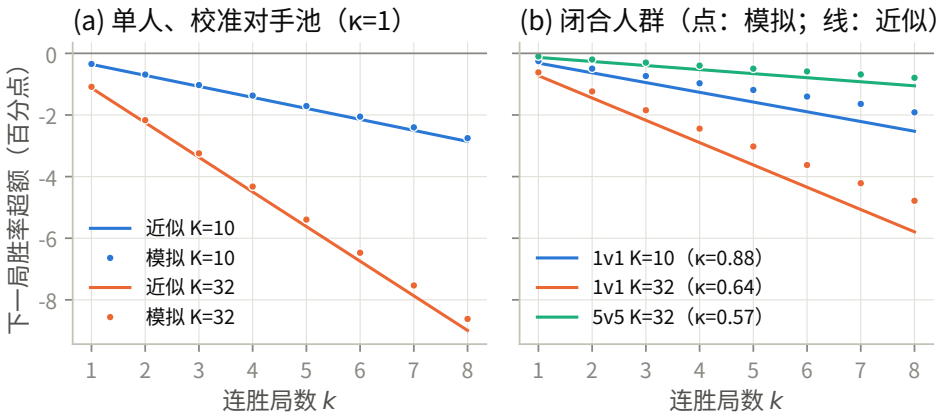


图 3.5: 诚实 Elo 下“连胜 k 局后下一局真实胜率”相对该玩家自身平均的超额。线为式(3.5)，点为模拟。(a) 单人、校准对手池（$\kappa = 1$，$\sigma_q = 50$，4×10^4 名玩家 × 1000 局）；(b) 闭合人群（$N = 10{,}000$，实力 $\mathcal{N}(0, 200^2)$，预热 1500 轮后记录 2000 局；1v1 $\sigma_q = 100$，5v5 每 10 人一房间、随机分队、$\sigma_q = 250$），κ 取模拟中实力对评分的回归斜率。

的“连胜后连败”在纯随机下同样会发生。

表 3.3: 诚实 Elo 的人群模拟（$N = 10{,}000$，实力 $\mathcal{N}(0, 200^2)$，评分从 0 起步，预热 1500 轮后每人记录 2000 局；连败统计按每人两个 1000 局半段平均）。W_5：5 连胜后下一局真实胜率的玩家内部超额（百分点）；“对手评分/实力”：5 连胜后对手（5v5 为敌队均分）减我方的玩家内部超额；ρ_1：扣除 $-1/T$ 偏差后的滞后 1 自相关；n^*：单人以双侧 5%、检验力 80% 检出 ρ_1 所需局数；λ：评分对实力的回归斜率（↑ 表示统计期内仍在增大）。

场景	λ	W_5	对手评分	对手实力	ρ_1	n^*	$\mathbb{P}(\geq 10)$ 实际/打乱	5 接 5
1v1，K=10，σ_q=100	1.11	−1.19	−2.1	+9.2	−0.0045	39.5 万	0.372 / 0.411	+2%
1v1，K=32，σ_q=100	1.50	−3.02	−3.7	+22.8	−0.0124	5.1 万	0.293 / 0.405	+1%
5v5，K=32，随机分队	1.38	−0.50	−4.3	+3.7	−0.0018	248 万	0.385 / 0.401	+2%
1v1，K=32，σ_q=25	4.37↑	−1.52	−0.1	+10.7	−0.0059	22.5 万	0.331 / 0.379	+3%
1v1，K=32，σ_q=50	3.40↑	−1.82	−0.4	+12.9	−0.0067	17.5 万	0.305 / 0.385	+3%
1v1，K=32，σ_q=200	1.13	−2.06	−16.1	+18.1	−0.0113	6.2 万	0.392 / 0.448	0%
1v1，K=32，σ_q=400	1.05	−0.72	−25.8	+7.1	−0.0049	32 万	0.450 / 0.472	+2%

3.3.4　效应大小对排队窗口敏感，但定性结论不变

表 3.3 下半部分改变排队噪声 σ_q（匹配窗口宽度）。$K = 32$ 时 5 连胜后的回归在 -0.7 到 -3.0 个百分点之间且不单调：窗口很宽时过冲几乎不改变对手（随机匹配时 $\kappa \to 0$）；窗口很窄时评分刻度不断拉伸，同样的 K 对应的实力误差变小。$\sigma_q = 100$ 接近最大值，“效应很小”的结论是保守的；所有设定下回归都是负向、小幅、随 k 线性，长连败都不多于基线。窗口变宽时“5 连胜后对手评分”明显为负（$\sigma_q = 400$ 时约 -26 分），因为高分区人少、带噪的排队键把高分玩家拉向人群中部，检验操纵时必须控制自身评分（第 3.6 节）【本项目】。

3.3.5　单个玩家几乎察觉不到

用滞后 1 自相关检验，单个玩家以双侧 5%、检验力 80% 检出 ρ_1 约需 $7.85/\rho_1^2$ 局：1v1 $K=32$ 约 5 万–6 万局（不同种子 5.1 万–5.7 万），$K=10$ 约 40 万局，5v5 约 150 万–250 万局【本项目】。玩家“感觉到的”连胜后连败，几乎全部来自随机性（第 3.2 节）和偏差（第 3.5 节）。

若把“连胜加分”写进**匹配用的**评分，过冲会被放大：从第 3 连胜起收益翻倍时，6 连胜后的回归约为 -4.0 个百分点（1v1 人群模拟、$K=32$ 的快照，评分刻度仍在拉伸）【本项目】。这是设计导致、没有恶意的“连胜后连败”；只作用于显示段位的加分不改变对局结果。

3.4　实力波动模型：上头、状态与疲劳

前两节假设玩家实力固定。本节放松这个假设：第 t 局的有效实力为

$$s_t = s + u_t, \tag{3.6}$$

u_t 是围绕长期实力 s 的波动，不同“形式”对应 u_t 的不同生成机制。我们关心三件事：能否产生更多长连败和“连胜后连败”；评分系统会吸收多少；单个玩家要多少局才能看出来。

统一设定。　本节用“单个玩家对校准对手池”的模型：对手真实实力 = 对手评分 = 我的评分 + $\mathcal{N}(0,50^2)$ 排队噪声。评分或者不动（$K=0$，对手始终与我的长期实力相当），或者按 Elo 更新（$K=20$）。单人模型的 $\kappa=1$，$K=20$ 时每局纠偏比例 $b=cK/4\approx 0.029$，与人群模拟中 1v1、$K=32$、$\sigma_q=100$（$\kappa\approx 0.64$）的有效强度相同，两者的诚实回归（5 连胜后 -3.4 对 -3.0 个百分点）和上头效应都很接近。评分不动时，除 AR(1) 外各模型都是“马尔可夫调制的伯努利序列”，条件胜率、自相关、最长连败分布和模式计数都能精确算出（附录 A.4.5）；其余情形用 2×10^4 名玩家 × 1000 局的模拟。参数都是示意值（表 3.4）。

图 3.6 是 (b)–(e) 的示例轨迹。它们的区别在时间尺度：AR(1) 与两状态的波动持续十几到几十局；上头只在连败期间存在，赢一局就消失；疲劳在每次游玩中累积、休息后清零。评分（橙线）跟得上慢变化，跟不上几局内的上头。

3.4.1　(a) 逐局独立噪声：没有记忆就没有连串

若 u_t 各局独立，y_t 也各局独立，单局胜率变成 $\mathbb{E}_u F(s-s_j+u_t)$；对手与自己长期实力相当时由对称性恰为 $1/2$，连败与条件胜率的分布与第 3.2 节完全相同。唯一后果是稀释实力差，用 probit 近似 $\mathbb{E}\,\sigma(a+bZ)\approx\sigma\!\left(a/\sqrt{1+\pi b^2/8}\right)$，

$$\mathbb{E}_u\,F(\Delta+u)\approx F\!\left(\Delta\Big/\sqrt{1+\pi c^2\sigma_u^2/8}\right). \tag{3.7}$$

表 3.4: 实力波动模型与示意参数。范围是本项目认为值得考察的量级，不是估计值。

模型	定义	本节取值	范围
(a) 逐局独立噪声	$u_t \sim \mathcal{N}(0, \sigma_u^2)$ 独立	$\sigma_u = 100$	0–150
(b) AR(1) 状态	$u_t = \rho u_{t-1} + \varepsilon_t$，$\mathrm{Var}\, u = \sigma_u^2$	$\rho = 0.9$，$\sigma_u = 60$	ρ 0.5–0.99，σ_u 20–100
(c) 两状态	正常 $u = 0$ / 状态差 $u = -\delta$，转移概率 α（正常 → 差）、β（差 → 正常）	$\delta = 120$，$\alpha = 0.02$，$\beta = 0.1$	δ 50–200，差状态平均 3–30 局
(d) 上头	$u_t = -\theta \min(L_{t-1}, m)$，$L$ 为当前连败，赢一局或休息后归零	$\theta = 30$，$m = 3$	θ 0–60，m 2–5
(e) 疲劳	$u_t = -\phi(j_t - 1)$，j_t 为本次游玩中的第几局，休息后归零	$\phi = 6$，每局后以 1/8 概率休息	ϕ 0–10，每次 3–15 局

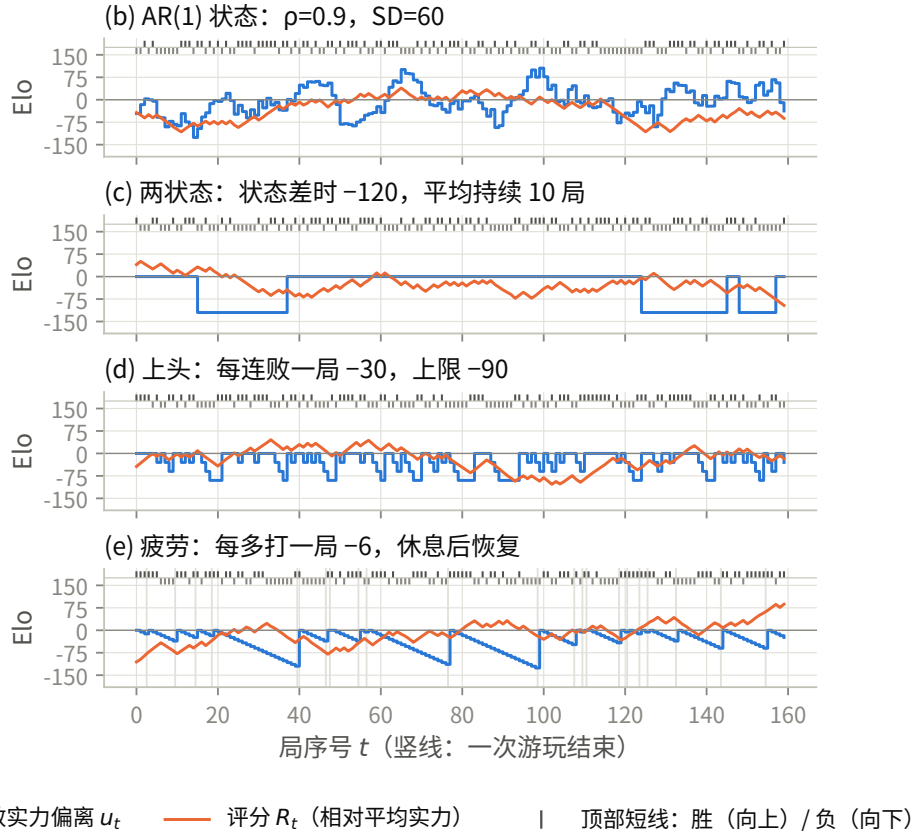


图 3.6: 四种实力波动模型的示例轨迹（单人、校准对手池、Elo $K = 20$，排队噪声 $\sigma_q = 50$；疲劳模型从一次游玩的开头截取）。蓝线为有效实力偏离 u_t，橙线为评分 R_t 相对长期实力的偏离，顶部短线为每局胜负。参数见表 3.4。

$\sigma_u = 100$ 时，200 分实力差的胜率从 76.0% 降到 74.5%（近似式 74.7%）【本项目】，与研究二中“胜率–实力关系变平”一致（第 2.3 节）。没有跨局记忆的“状态好坏”不会制造任何“Elo 感”；下面四种模型都有记忆。

3.4.2　(b) AR(1) 状态：评分会吸收大部分慢变化

设 $u_t = \rho u_{t-1} + \varepsilon_t$，平稳方差 σ_u^2。评分不动时 $p_t - \frac{1}{2} \approx \frac{c}{4} u_t$，于是

$$\mathrm{Corr}(y_t, y_{t+h}) \approx \frac{(F'(0))^2\,\sigma_u^2\,\rho^h}{p(1-p)} = \left(\frac{c}{4}\right)^2 \frac{\sigma_u^2 \rho^h}{p(1-p)}. \tag{3.8}$$

$\rho = 0.9$、$\sigma_u = 60$ 时 $\rho_1 \approx 0.027$；用实力差分布上 F' 的平均值代替 $F'(0)$ 后为 0.023，与模拟一致（图 3.7(b)）【本项目】。相关虽小，却能拉长连败：千局内 ≥ 10 连败的概率从 38% 升到 59%，连败 3 局后的胜率低 3.1 个百分点（表 3.5）。

评分会更新时，Elo 相当于对“当前有效实力”做指数平滑：线性化后 $x_{t+1} = (1-b)x_t + b\,u_t + K\xi_t$（$x_t = R_t - s$），真实胜率取决于评分没跟上的部分 $D_t = u_t - x_t$。

推导：评分吸收了多少 AR(1) 状态

只看由 u 驱动的部分，$x_t = b\sum_{j\geq 1}(1-b)^{j-1}u_{t-j}$。记 $a = 1-b$，由 AR(1) 的自协方差 $\sigma_u^2\rho^{|h|}$ 得

$$\mathrm{Cov}(u_t, x_t) = \frac{b\rho\,\sigma_u^2}{1-a\rho}, \qquad \mathrm{Var}\,x_t = \frac{b^2(1+a\rho)\,\sigma_u^2}{(1-a^2)(1-a\rho)}.$$

代入 $\mathrm{Var}\,D_t = \mathrm{Var}\,u_t - 2\,\mathrm{Cov}(u_t, x_t) + \mathrm{Var}\,x_t$ 并化简，分子恰好合并为 $2(1-\rho)$：

$$\frac{\mathrm{Var}\,D_t}{\sigma_u^2} = \frac{2(1-\rho)}{(2-b)\,(1-(1-b)\rho)} \approx \frac{1-\rho}{(1-\rho)+b} \quad (b\ \text{小}). \tag{3.9}$$

含义很直接：状态的记忆长度约 $1/(1-\rho)$ 局，评分的记忆长度约 $1/b$ 局。比评分记忆短的状态留在胜率里；更长的被评分吸收（状态差时分数跟着掉、对手跟着变弱）。$b = 0.029$ 时 $1/b \approx 35$ 局：$\rho = 0.9$ 的状态保留 81%，$\rho = 0.98$ 保留 42%，$\rho = 0.99$ 保留 26%（图 3.7(a)）。此外，评分对随机胜负的反应带来负自相关（第 3.3 节），与状态的正自相关相互抵消：$K = 20$ 时 AR(0.9, 60) 的 ρ_1 只剩 +0.006，从滞后约 5 局起转负（完整自协方差见附录 A.4.4）。1v1 人群模拟（$K = 32$）中，AR(0.9, 60) 的连串性也几乎正好被均值回归抵消，5 连胜后的净超额只有 +0.3 个百分点【本项目】。

这也解释了 Rosenthal 的发现：用双方当时的等级分算出期望后，中村光（Hikaru）的“实际减期望”超额得分几乎没有自相关，而原始得分在滞后 1–5 上的自相关接近 0.1，作者认为每局更新的等级分吸收了相当一部分依赖[76]【文献】。零自相关只说明给定当时评分后各局近似独立，不等于没有状态起伏。

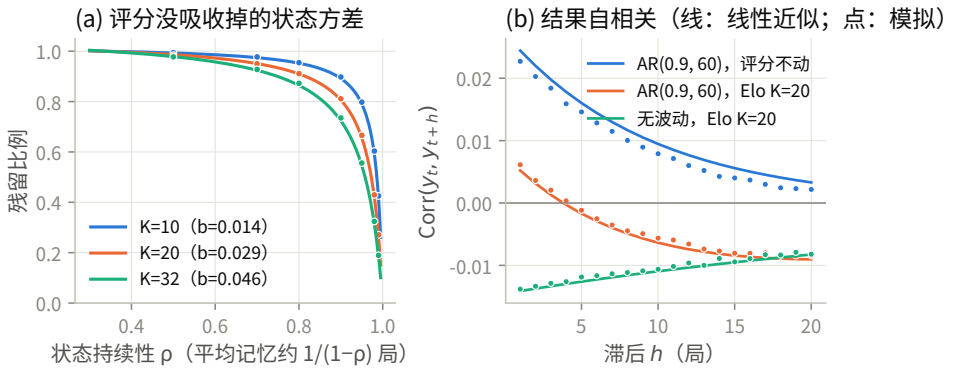


图 3.7： 评分对 AR(1) 状态的吸收。(a) 胜率中残留的状态方差比例，线为式(3.9)，点为模拟（$\sigma_u = 60$，单人校准池，4000 名玩家 × 3000 局，残留比例按 $[\mathrm{Var}(u - R) - \sigma_\varepsilon^2]/\mathrm{Var}\, u$ 计算）。(b) AR(0.9, 60) 下结果的自相关：评分不动时为正且缓慢衰减；Elo $K = 20$ 时被评分的负反馈抵消，几局后转负。线为线性近似（斜率取实力差分布上 F' 的平均），点为模拟（2×10^4 名玩家 × 1000 局）。

3.4.3　(c) 两状态隐马尔可夫：状态好与状态差

另一种直觉是“今天手感不对”：玩家在“正常”与“状态差”之间切换，转移矩阵

$$P = \begin{pmatrix} 1-\alpha & \alpha \\ \beta & 1-\beta \end{pmatrix}, \qquad \pi_{\text{差}} = \frac{\alpha}{\alpha + \beta}.$$

两种状态的平均持续时间为 $1/\alpha$ 和 $1/\beta$ 局，状态的自相关为 $(1-\alpha-\beta)^h$，u_t 的方差为 $\delta^2 \pi_{\text{差}}(1-\pi_{\text{差}})$。所以在二阶矩上它与 $\rho = 1-\alpha-\beta$ 的 AR(1) 完全相同，式(3.8)和(3.9)照样适用；区别在高阶结构：“差”是成块出现的。本节取值下差状态占 1/6 的时间、平均持续 10 局，单局胜率降到 33.7%。评分不动时，记 $D_q = \mathrm{diag}(1 - p_z)$，条件胜率可精确算出：

$$\mathbb{P}(\text{胜} \mid \text{最近} k \text{ 局全负}) = \frac{\pi^\top (D_q P)^k \boldsymbol{p}}{\pi^\top (D_q P)^k \mathbf{1}}, \tag{3.10}$$

其中 $\boldsymbol{p} = (p_{\text{正常}}, p_{\text{差}})^\top$。连败越久，处于差状态的后验概率越高：连败 3 局后胜率低 1.9 个百分点，6 局后低 3.8 个百分点；千局内 ≥ 10 连败的概率为 68%，同均值（47.3%）的独立序列只有 54%【本项目】。在 Elo（$K = 20$）下，平均实力下降（−20 分）被评分完全吸收，波动部分约 84% 留在胜率里，却与诚实回归的负反馈相互抵消，长连败与基线相当（表 3.5）。

3.4.4　(d) 上头：连败触发的自激

“上头”（tilt）指输了之后情绪化、打法变形。扑克数据显示，有经验的玩家输掉大底池后会打得更松，符合“回本”假说，而且更亏钱[175]【文献】[2]；英雄联盟顶级玩家的 59.8 万场对局中，连败与随后表现下降有“显著但很小”的相关[59]【文献】[3]。最

[2]待核对：本次未读到原文全文，仅依据摘要。
[3]待核对：本次未读到原文全文，仅依据摘要。

简单的形式化是

$$u_t = -\theta \, \min(L_{t-1}, m), \tag{3.11}$$

L_{t-1} 为第 t 局前的当前连败局数，赢一局（或下线休息）后归零。它是自激的：输得越多越容易再输。

连败长度上的马尔可夫链。　评分不动时，L 本身是马尔可夫链：在状态 L 输的概率为 $q_L = 1 - \mathbb{E}_\eta F(-\theta \min(L, m) - \eta)$，输则 $L \to L+1$，赢则 $L \to 0$。于是平稳分布 $\pi_L \propto \prod_{j<L} q_j$；一段连败开始后长度 $\geq r$ 的概率为 $\prod_{j=1}^{r-1} q_j$，平均长度 $1+q_1+q_1q_2/(1-q_3)$ $(m=3)$；连败 k 局后的胜率为 $\sum_{L\geq k} \pi_L p_L / \sum_{L\geq k} \pi_L$，连胜后恒为 p_0。本节取值下 $q_0 = 0.50$，$q_1 = 0.542$，$q_2 = 0.584$，$q_3 = 0.624$：连胜时输一局的概率是一半，一旦输了，继续输的概率升到 54%、58%、62%。一段连败 ≥ 5 局的概率从 6.3%（独立 50%）升到 12.3%，平均长度从 2 局升到 2.39 局（图 3.8(a)）【本项目】。

“连胜后连败”从哪里来。　上头不需要系统出手：连胜被一场普通的随机失败打断，上头把这一次失败放大成一串，恰好产生玩家描述的“连胜后连败”。“≥ 4 连胜紧接 ≥ 4 连败”比打乱基线多 49%（评分不动）到 55%（Elo），“≥ 5 接 ≥ 5”多 86%–97%；Elo 下千局 ≥ 10 连败的概率从 39% 升到 64%（表 3.5），与 1v1 人群模拟（$K = 32$：“4 接 4” +53%、“5 接 5” +93%，千局 ≥ 10 连败 40% → 63%，表 3.6）几乎相同【本项目】。慢状态虽然拉长连败，却几乎不增加“连胜紧接连败”，因为它们很少在一局之内由好变坏。

两个副产品。　上头玩家“连胜后”的胜率看起来**高于**自身平均（评分不动时 +4.4 个百分点），因为平均值被上头期间的败局拉低了，这不是“热手”。Elo 下上头期间评分下跌、对手变弱，所以连败 3 局后胜率最低（−6.6 个百分点），之后回升（图 3.10(c)）。

休息是天然的刹车。　每局后以 1/8 概率下线、休息后上头清零时，“≥ 5 接 ≥ 5”的增幅从 86% 降到 70%（图 3.8(b)）。社区数据方向一致：黄金段位 2 连败后**立即**再排的玩家胜率最低，短暂休息的人高于该组平均，休息 3–4 小时回到该组平均[174]【社区】；英雄联盟顶级玩家连败后会休息更久，这在输局后略微改善了表现[59]【文献】。

3.4.5　(e) 局内疲劳与休息

Sapienza 等分析了 16,665 名英雄联盟玩家约 24.2 万场单排，把间隔不超过 15 分钟的对局算作同一次游玩（session）：胜率和 KDA 在一次游玩中逐渐下降，三局及以上的游玩中首局到末局分别下降 10% 和 8% 以上，经验多的玩家下降较少；打乱对局顺序后下降消失[60]【文献】。对应的模型是 $u_t = -\phi(j_t - 1)$，j_t 为本次游玩中的局序号。

评分不动时，第 1 局胜率 50%，第 8 局约 44%；Elo 下评分跟踪平均水平，所以每次游玩开头胜率高于五成（第 1 局 55.8%），后段低于五成（第 11 局 47.0%）（图 3.9(a)）。

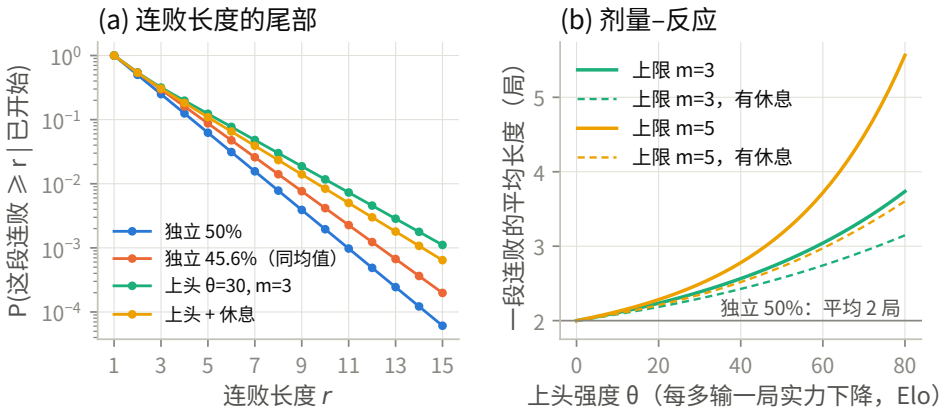


图 3.8: 上头如何把一次失败变成一串（评分不动，精确马尔可夫链，$\sigma_q = 50$）。(a) 一段连败开始后长度 $\geq r$ 的概率：上头（$\theta = 30$，$m = 3$）的尾部明显比独立 50% 和“同均值”的独立 45.6% 都厚；“上头 + 休息”为每局后以 1/8 概率休息并清零上头，尾部变薄。(b) 一段连败的平均长度随上头强度 θ 的变化，实线无休息，虚线有休息。

疲劳几乎不影响“连胜后连败”和条件胜率（表 3.5），它的特征是胜率随局序号下降，只有知道游玩划分才能看到。

检验疲劳时有一个陷阱：停止规则。设结果完全独立，但赢后以 s_W、输后以 $s_L > s_W$ 的概率下线。给定一次游玩恰好 n 局，前 $n-1$ 局是“没下线”的局，最后一局是“下线”的局：

$$\mathbb{P}(y_i = 1 \mid \text{本次共} n \text{ 局}) = \begin{cases} \dfrac{p(1-s_W)}{p(1-s_W) + q(1-s_L)}, & i < n, \\ \dfrac{p\,s_W}{p\,s_W + q\,s_L}, & i = n. \end{cases} \tag{3.12}$$

$p = 0.5$、$s_W = 0.1$、$s_L = 0.2$ 时，前面各局胜率 52.9%，最后一局只有 33.3%，按游玩长度分组的曲线呈现“局内下滑”，打乱顺序后消失（图 3.9(b)）。所以打乱对照不能单独排除停止规则；Sapienza 等也报告，上一局结果是预测是否下线的重要特征[60]【文献】。检验疲劳时应去掉每次游玩的最后一局，或把下线决策一起建模（本项目推论）。

3.4.6　五种形式的比较

图 3.10 和表 3.5 把各模型放在一起：

1. **只有有记忆的波动会制造连串**。逐局独立噪声与纯随机无法区分。
2. **评分不动时，所有有记忆的模型都会拉长连败**，并让“连败后胜率”低于平均。但只有上头会显著增加“连胜紧接连败”，因为只有它在一局之内由好变坏。
3. **评分会更新时，慢变化被吸收**。$K = 20$ 下，AR、两状态和疲劳的长连败回到基线附近，条件胜率甚至翻转为诚实 Elo 式的负回归；上头几乎不受影响，因为它发生在评分来不及反应的几局之内。

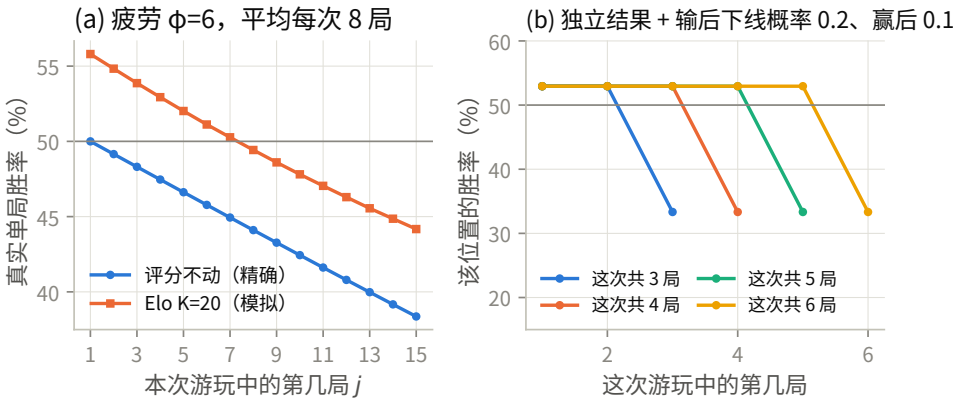


图 3.9: (a) 疲劳模型（$\phi = 6$，每局后以 1/8 概率休息）按局序号的真实胜率：评分不动为精确值，Elo $K = 20$ 为模拟（2×10^4 名玩家 $\times$ 1000 局）。(b) 结果完全独立（$p = 0.5$），但赢后以 0.1、输后以 0.2 的概率下线时，按游玩长度分组的各位置胜率（式(3.12)）：最后一局的“下滑”完全来自停止规则。

4. **真实数据中“连胜后胜率约五成”不能说明“没有状态”**：慢状态和诚实回归方向相反，可以互相抵消。

表 3.5: 各实力波动模型的统计痕迹（单人校准池，$\sigma_q = 50$，2×10^4 名玩家 $\times$ 1000 局）。$\bar{p}$：平均真实胜率；ρ_1：滞后 1 自相关；L_3/W_3：连败/连胜 3 局后下一局胜率的超额（百分点）；$\mathbb{P}(\geq 10)$：1000 局内出现 ≥ 10 连败的概率（实际/玩家内打乱）；“4 接 4”“5 接 5”：“$\geq k$ 连胜紧接 $\geq k$ 连败”的次数相对打乱基线的变化。

模型	评分	$\bar{p}$	ρ_1	L_3	W_3	$\mathbb{P}(\geq 10)$	4 接 4	5 接 5
无波动 / (a)	不动	0.500	0.000	0.0	0.0	0.386 / 0.378	0%	−1%
(b) AR(1)	不动	0.500	+0.023	−3.1	+3.1	0.589 / 0.381	−1%	+3%
(c) 两状态	不动	0.473	+0.012	−1.9	+1.4	0.681 / 0.537	+1%	+4%
(d) 上头	不动	0.456	+0.079	−8.0	+4.4	0.933 / 0.644	+49%	+86%
(d') 上头 + 休息	不动	0.465	+0.063	−6.3	+3.4	0.862 / 0.592	+39%	+70%
(e) 疲劳	不动	0.442	+0.011	−1.6	+1.3	0.827 / 0.726	0%	+1%
无波动 / (a)	$K = 20$	0.500	−0.012	+2.1	−2.1	0.256 / 0.380	+4%	+6%
(b) AR(1)	$K = 20$	0.500	+0.007	−0.6	+0.6	0.413 / 0.380	+4%	+10%
(c) 两状态	$K = 20$	0.500	−0.002	+0.4	−0.7	0.366 / 0.382	+4%	+7%
(d) 上头	$K = 20$	0.500	+0.063	−6.6	+1.8	0.644 / 0.391	+55%	+97%
(d') 上头 + 休息	$K = 20$	0.500	+0.048	−4.6	+1.1	0.554 / 0.375	+45%	+73%
(e) 疲劳	$K = 20$	0.500	−0.002	+0.4	−0.7	0.361 / 0.377	+4%	+6%

3.4.7　一个玩家要打多少局才能看出来

这一问为后续分析用户本人的战绩做准备（`docs/ROADMAP.md` 第 2 项）。每个模型用“对口”的检验：上头用结果对当前连败长度（截断到 3）回归的斜率；AR 与两状态用非重叠 10 局分块胜场的方差与二项方差之比；疲劳用结果对局序号的回归斜率；

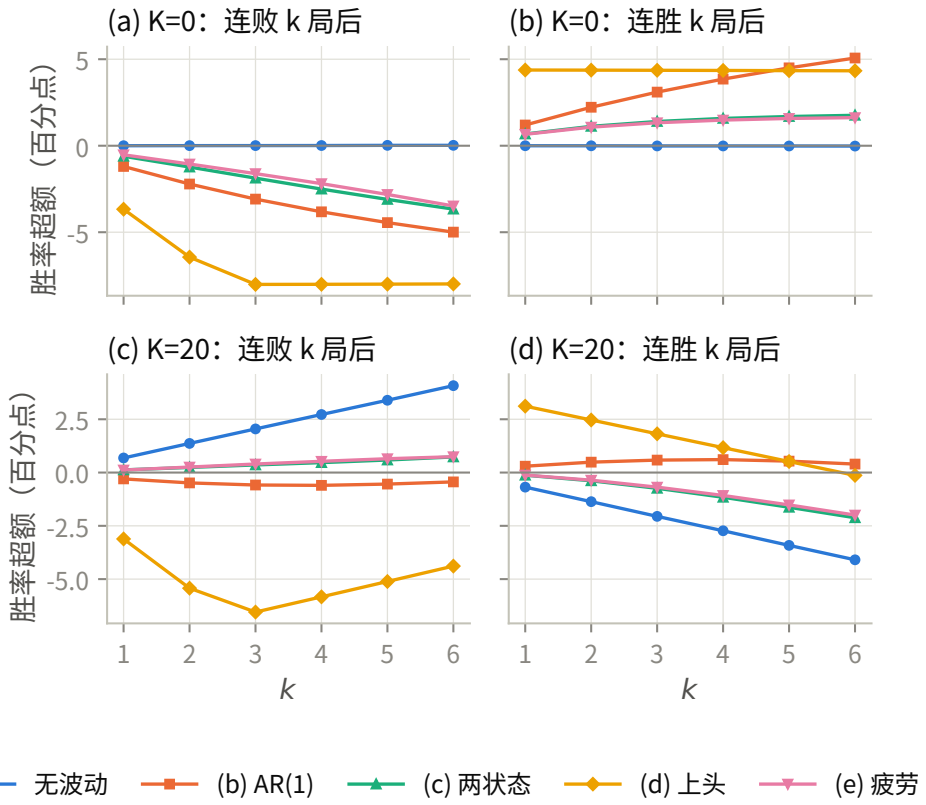


图 3.10: 连败（左）/连胜（右）k 局后下一局真实胜率相对该玩家自身平均的超额。上排评分不动，下排 Elo $K = 20$。单人校准池模拟，2×10^4 名玩家 $\times$ 1000 局（评分不动时与精确链一致到 0.05 个百分点以内）。参数见表 3.4。

诚实 Elo 用滞后 1 自相关。零分布由无波动模型模拟（8000 名玩家），双侧 5%，有限样本偏差自动扣除。每个模型模拟 3000 名玩家 × 4000 局（图 3.11）。

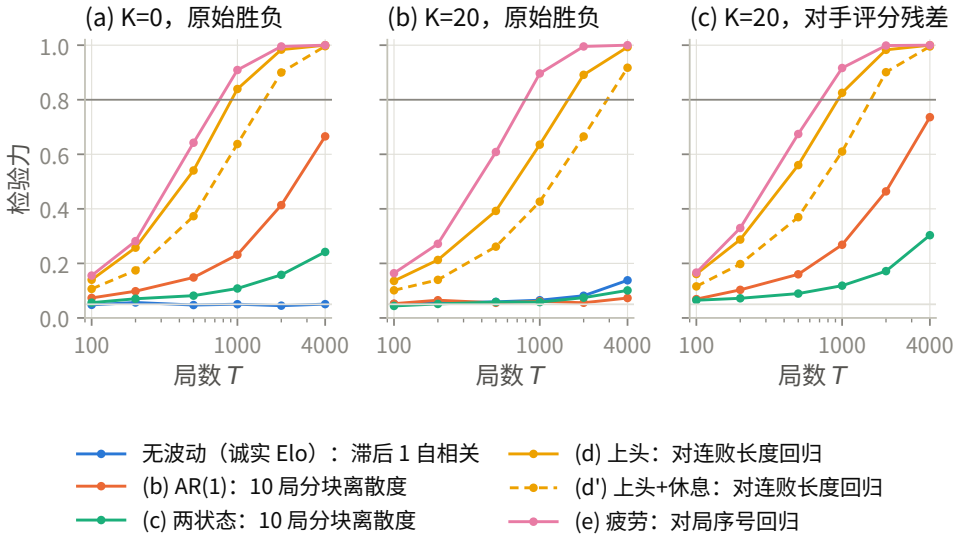


图 3.11：单个玩家从自己战绩中检出各模型的检验力（双侧 5%）。(a) 评分不动，原始胜负；(b) Elo $K = 20$，原始胜负；(c) Elo $K = 20$，以对手评分为协变量、自身实力取常数（最大似然）后的残差 $y_t - F(\hat{s} - R_t^{\text{opp}})$。水平线为 80% 和 5%。参数见表 3.4；单人校准池，$\sigma_q = 50$。

示意参数下，达到 80% 检验力所需局数如下：

- **疲劳和上头：几百到三千局。**有游玩划分时疲劳约 750–800 局，不受评分更新影响；上头约 900 局（评分不动）到 1500 局（Elo），有休息时约 1500–2900 局。
- **慢状态：原始胜负里几乎检不出。**评分不动时，4000 局的检验力 AR(0.9, 60) 为 67%、两状态 24%；Elo 下都不超过 10%。
- **加入对手评分后，慢状态重新可检。**若有每局对手（或敌队）的评分，把自身实力取常数 $\hat{s}$、计算残差 $y_t - F(\hat{s} - R_t^{\text{opp}})$，评分对状态的追踪就被协变量显式扣掉：Elo 下 4000 局时 AR 的检验力从 7% 回升到 74%，两状态从 10% 升到 30%，上头约 900 局可检出（图 3.11(c)）【本项目】。自身实力必须取常数；若像 Rosenthal 那样用每局更新后的评分算期望[76]，状态又会被吸收掉。

3.4.8　怎样用一个玩家的历史拟合这些模型

这里只给出方法，不做拟合；数据字段见 `data/README.md`。共同的基础是逐局似然

$$\mathbb{P}(y_t = 1) = F\big(s + u_t - R_t^{\text{opp}}\big),$$

其中 R_t^{opp} 是对手评分（团队游戏用敌我均分差，名次游戏改用 Plackett–Luce 似然，见第 2.5.2 节与式 (4.6)）。没有对手评分时只能检出上头和疲劳这类快速效应。

独立基线、上头和疲劳都是带偏移量的逻辑回归，后两者加入协变量 $\min(L_{t-1}, m)$（与“同一次游玩”交互）或局序号 j_t（去掉每次游玩的最后一局，或对下线决策一起

建模，见式(3.12))，$\theta = 0$、$\phi = 0$ 可用似然比检验。两状态模型是隐马尔可夫模型，前向算法给出似然，EM 或数值优化估计 (δ, α, β)；$\delta = 0$ 在边界上，检验要用参数自助法，比较模型可用 AIC/BIC。AR(1) 是非高斯状态空间模型，可用拉普拉斯近似、粒子滤波或贝叶斯方法（与 TrueSkill Through Time 同一思路）估计；$\rho \to 1$ 时描述的是长期进步或退步。条件胜率类统计量要用置换或参数自助法得到零分布；几百到几千局的数据只能可靠识别效应较大的快速波动。

3.5　认知偏差：为什么正常的随机看起来像被安排

前面几节说明，长连败和“连胜后连败”在诚实系统里本来就常见。心理学研究解释了为什么人们仍然觉得它们“不随机”[4]。

对随机的直觉偏向“交替过多”。　人们生成的“随机”序列交替得比真随机多，也认为交替过多的序列“最随机”[176]【文献】，真随机序列里的连串因此显得像被安排。“小数定律”让人把小样本当作与总体高度相似，认为短序列也应该“平均”[177]【文献】；“连胜五把了，该输了”和“系统要把我拉回五成”是同一种直觉。

热手之争。　经典研究在投篮记录中没有找到相邻投篮的正相关，并把“热手”信念归因于对随机序列的误解[178]【文献】；Miller 与 Sanjurjo 指出它所用的统计量有第 3.2.5 节的偏差，修正后结论反转[173]【文献】。所以自查战绩得到的“连胜后胜率偏低”很可能只是统计偏差，而真实的状态效应可能存在、只是难以看出。国际象棋数据支持后者：Lichess 约 1.2 亿局中，热连串和冷连串都比玩家内打乱的基线更常见，冷连串更长，初学者的热连串更长；连串与对手评分优势的相关（Spearman 约 0.28）只能部分解释它[22]【文献】。

坏事比好事更显眼。　负面事件、反馈和信息比同等的正面对应物影响更大、被加工得更充分[179]【文献】。连败更容易被记住和讲述，最惨的经历也最常被发到论坛上（本项目推论）。

输了是队友的错。　把成功归于自己、失败归于外部的自利归因普遍存在，一项涵盖 266 项研究的元分析给出平均效应量 $d = 0.96$[180]【文献】。团队游戏给它提供了“真实”的支点：5v5 人群模拟中（按评分分房间、随机分队），输局里全场最弱者是你队友的概率为 45.4%，赢局里 34.6%，无条件基线 40%；输局中你方真实平均实力更弱的概率为 60%【本项目】。“这把输在坑队友”在近一半输局里确实成立，只比基线高约 5 个百分点，而玩家记住的恰好是输局。

[4]待核对：本次未读到原文全文：本节引用的 Falk 与 Konold（1997）、Tversky 与 Kahneman（1971）、Gilovich 等（1985）、Baumeister 等（2001）、Mezulis 等（2004）只读到摘要或二手转述。

玩家如何应对连串。　对英雄联盟玩家讨论的质性分析发现，连胜和连败都会降低游戏体验，“暂时脱离”是主要应对方式，作者把连串看作玩家理解复杂系统的一种社会建构[58] 【文献】[5]。这与上头模型一致：休息是最有效的刹车。

3.6　操纵会留下什么指纹

把 H1、H2 写成具体规则，放进与第 3.3 节相同的人群模拟（1v1 $K = 32$、$\sigma_q = 100$；5v5 $\sigma_q = 250$）：

- **M1 对称“控五成”**：当前连胜 ≥ 3 时，匹配键加 100 分（配更高分的对手）；连败 ≥ 3 时减 100 分。
- **M2 非对称连胜惩罚**：只对连胜 ≥ 3 加 100 分，不对连败“放水”。
- **M3 5v5 “loser queue”**：房间按诚实评分组成，但分队时把连胜 ≥ 3 者的评分当作 +300、连败 ≥ 3 者当作 −300 再按蛇形（ABBAABBAAB）“平衡”，于是连胜者被分到较弱的队友那边。

以参与度为目标的匹配（engagement optimized matchmaking, EOMM）是这类规则的一般化：它按每名玩家的状态（含最近 10 局胜负）预测流失，再选总流失最小的配对[51] 【文献】（第 1.3.4 节）。只要流失预测依赖近期胜负，它的指纹就应与 M1–M3 同向（本项目推论）；公开证据只说明这类方案被研究、申请过专利并在未具名游戏中部署过，是否用于主流排位仍然未知（第 1.11 节）。

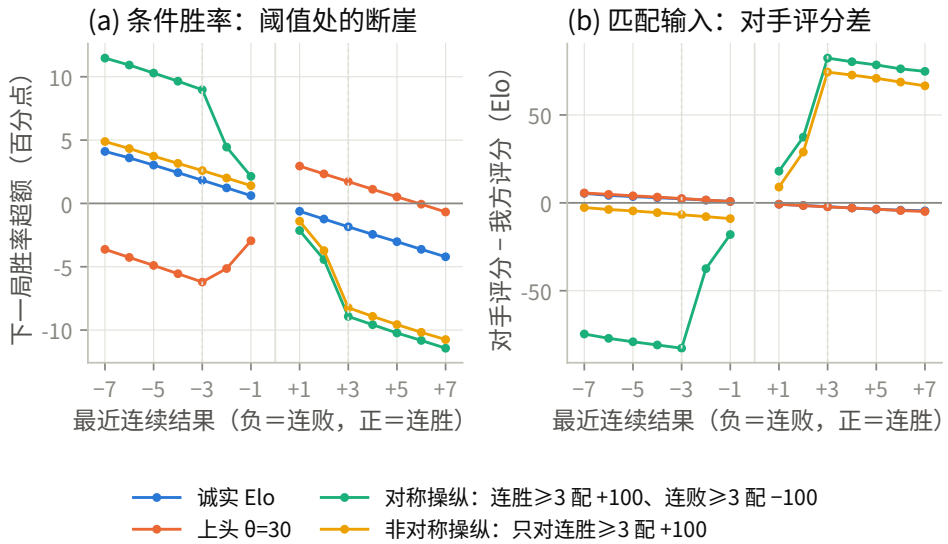


图 3.12: 操纵的指纹（人群模拟，1v1，$K = 32$，$\sigma_q = 100$，$N = 10{,}000$，记录 2000 局/人）。(a) 连败/连胜 k 局后下一局真实胜率的玩家内部超额；(b) 对手评分减我方评分的玩家内部超额。虚线标出操纵的触发阈值 ±3。诚实 Elo 与上头的曲线平滑，操纵在阈值处断崖式跳变，且对手评分差显著为正。

[5] 待核对：本次未读到原文全文，仅依据摘要。

表 3.6: 诚实 Elo、上头与三种操纵规则的指纹（人群模拟，参数同图 3.12；5v5 为每 10 人一房间、$\sigma_q = 250$）。“系统预测”：系统自己用评分算出的期望胜率在 5 连胜后的玩家内部超额（百分点）；“对手评分差”：5 连胜后对手评分减我方评分的玩家内部超额，5v5 中为敌队均分减我队均分。

场景	W_2	W_3	W_5	对手评分差	系统预测	ρ_1	$\mathbb{P}(\geq 10)$ 实际/打乱	5 接 5
诚实 Elo	−1.2	−1.9	−3.0	−3.7	+0.5	−0.012	0.293 / 0.405	+1%
上头 $\theta = 30$	+2.3	+1.7	+0.5	−3.6	+0.5	+0.060	0.628 / 0.402	+93%
M1 对称	−4.4	−8.9	−10.2	+78.5	−9.8	−0.043	0.120 / 0.405	−43%
M2 非对称	−3.7	−8.2	−9.6	+70.9	−8.9	−0.028	0.277 / 0.408	−22%
5v5 诚实	−0.2	−0.3	−0.5	−4.3	+0.6	−0.002	0.385 / 0.401	+2%
M3 5v5 loser queue	−1.0	−2.0	−2.1	+34.5	−4.7	−0.010	0.310 / 0.382	−11%

图 3.12 与表 3.6 给出四条指纹【本项目】。

1. **匹配输入**。诚实系统里连胜后对手**评分**接近零或略低（−3.7 分），对手**真实**实力更强（+23 分），那是你的评分虚高；M1、M2 下对手评分本身高出 71–79 分。5v5 要看敌我均分差（诚实 −4.3，M3 +34.5）；“连胜后队友分比我低”不是好指标，诚实系统中 5 连胜后它也有 −21 分（M3 为 −31）。
2. **系统自己的预测**。诚实系统对连胜者的预测胜率仍约五成（+0.5 个百分点）；操纵下系统明知对手更强，预测胜率下降（M1 −9.8，M3 −4.7 个百分点）。
3. **阈值处的断崖**。诚实回归随 k 线性变化（每局约 −0.6 个百分点）；操纵在触发长度处跳变（M1：$W_2 = -4.4$，$W_3 = -8.9$）。
4. **长连败的方向**。对称“控五成”**减少**长连败（千局 ≥ 10 连败 12% 对基线 41%）和“连胜后连败”（−43%）：放水让连败更快结束，惩罚让长连胜本身更少；只惩罚连胜的 M2 同样减少长连败。所以“我经常 8–10 连跪”更像随机或上头；要用操纵解释它，就得假设系统在你连败时继续加码，这与“控五成”的说法矛盾。

为什么只看胜负分不清弱操纵和诚实 Elo。　两者都产生负自相关，幅度取决于 K、窗口、人数和操纵强度：5v5 loser queue（M3）的 $\rho_1 = -0.010$，与诚实 1v1 $K = 32$ 的 −0.012 几乎相同，单人检出也要约 8 万局；上头还会与之部分抵消。只用胜负，最多能说“没有发现强操纵”。社区里的定量检验也是这一类：一份 Reddit 统计帖用约 10 万局大师段位对局（1000 名玩家各 100 局）比较连胜连败长度与独立对局的期望，没有发现异常，只是输后再输的比例约高 2%，作者倾向于用轻微上头解释，并说明无法检验队友和对手是否也在连败[169]【社区】；这 2% 也可能部分来自跨玩家合并的构成效应（第 3.2.6 节）。

推荐的检验。　以每局“对手评分 − 我方评分”（团队游戏用敌我均分差）为因变量，对近期连胜、连败指示变量 $\mathbb{1}\{W_t \geq k\}$、$\mathbb{1}\{L_t \geq k\}$（$k = 1, \ldots, 5$）回归，控制自身评分、排队时间、时段和组队人数，加玩家固定效应。诚实系统中系数约为零，操纵下

显著为正并在触发长度处跳变；其次检验系统预测胜率是否随连胜状态偏离五成；用实际胜负做条件胜率检验时，要在玩家内部进行并修正 Miller–Sanjurjo 偏差。外部研究者通常拿不到隐藏评分，本次没有找到用真实评分数据做这种检验的同行评审研究。后续的阴谋论研究（`docs/ROADMAP.md` 第 1 项）会把收集到的说法写成同样的“触发条件 + 对匹配键或分队的改动”，放进 `code/ch3/population.py` 的操纵接口，得到表 3.6式的指纹。

3.7　8 人名次游戏：酒馆战棋里的“Elo 感”

酒馆战棋按名次计分，匹配只用不可见的内部评分，尽量把内部评分最接近的 8 人放进同一局[105]【官方】（评分规则见第 1.7.3 节）。同分大厅里各名次概率都是 1/8，前面的结论可以直接平移：

- **前四是一枚公平硬币**。100 局里 81% 的人会遇到 ≥ 5 局连续后四（第 3.2 节）。
- **“久不夺冠”是常态**。夺冠率 1/8 时，打 100 局至少出现一段 ≥ 10 局无冠的概率为 99.8%，≥ 20 局为 60.3%，≥ 30 局为 17.2%，最长无冠段的期望为 22.8 局（式(3.2)给出 22.7）；打 500 局，≥ 30 局无冠的概率为 69%（图 3.13）【本项目】。
- **诚实回归和上头同样存在**。连续高名次后内部评分过冲、下一局大厅略强；上头把一次失利变成一串低名次。可见分的“地板”和追赶倍率只影响显示，不影响匹配[105]【官方】。

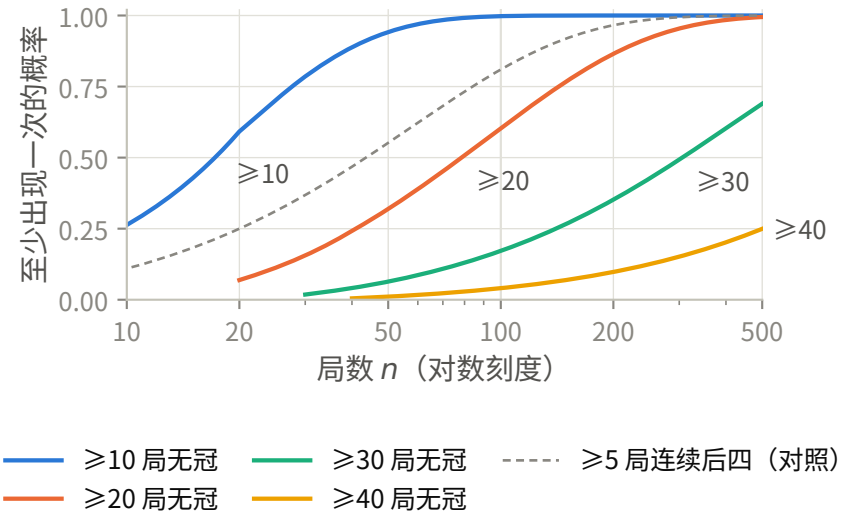


图 3.13: 8 人名次游戏中，n 局里至少出现一段 $\geq d$ 局没拿第一的概率（同分大厅，夺冠率 1/8，独立，精确计算）；虚线为“≥ 5 局连续后四”。

3.8　小结

本章要点

1. 玩家说的“Elo”多指被怀疑的操纵（强制五成、连胜惩罚、Elo 地狱），各有可检验的预测。
2. 纯随机下长连败和“连胜后连败”都很常见：最长连败 $\approx \log_{1/q}(np)+\gamma/\ln(1/q)-\frac{1}{2}$，“$\geq k$ 连胜紧接 $\geq k$ 连败”的期望次数为 $(n-2k+1)(pq)^k$。
3. 诚实 Elo 只带来小幅线性回归 $\Delta_k \approx -\kappa c K k/(16n)$，让长连败变少，单人要几万到上百万局才能察觉。
4. 只有快速、由失败触发的上头能在诚实系统里显著增加长连败和“连胜后连败”；慢状态和疲劳大多被评分吸收。
5. 统计陷阱和认知偏差把正常频率读成“被安排”；操纵的指纹在匹配输入和系统预测上。外部数据只能得出“无需操纵即可解释”。

第四章　研究四：训练视角——目标是胜率还是实力

直接回答

一句话：**训练标签是胜负，模型输出是胜率，被学到的潜参数才是实力；只有在自博弈里，胜率本身才是优化目标**。Elo 的更新式正好是“以胜负为标签、以评分差的 logistic 函数为预测”的对数损失上的一步随机梯度下降，K 就是学习率；TrueSkill 是学习率随不确定度自动变化的贝叶斯版本。实力只能确定到一个加性常数，所以评分系统只能在“数据空间”评估：看预测胜率与实际胜负是否吻合。模型稳定后胜负数据照样产生、照样推动评分，只是在负责匹配的那个模型看来每局都接近抛硬币；而恰恰是五五开的对局，对实力差的信息量最大。可以直接用胜负说明问题，但要把冻结的收敛模型当作零假设，检验“实际减预测”的残差；朴素的“连败后胜率”检验在完全诚实的 Elo 下也会误报。自博弈中和自己的副本对局永远五五开，进步只能用固定参照来量。对酒馆战棋 AI：用名次似然训练，用冻结的参照池评估。

4.1　同一个“胜率”在训练里有三种角色

用户的问题“target 究竟是胜率还是实力”之所以难答，是因为“胜率”一词在不同训练场景里扮演不同角色。下文的“按分匹配”指 skill-based matchmaking (SBMM)：按评分把水平相近的玩家配到一起。表 4.1 把常见场景放在一起。

在评分系统里，损失函数比较的是“预测胜率”与“实际胜负”的吻合程度；胜负是**标签**，胜率是模型的**输出**，实力是让二者吻合的**潜参数**。既不直接优化“胜率”，也无法直接观测“实力”。自博弈强化学习则相反：奖励就是胜负，最大化期望回报就是最大化对给定对手分布的胜率，Elo 或 TrueSkill 退居为事后测量工具。AlphaGo Zero 的价值网络介于两者之间：它的损失 $l = (z - v)^2 - \boldsymbol{\pi}^\top \log \boldsymbol{p} + c\|\theta\|^2$ 中的第一项，就是让输出 v 去预测自博弈终局的胜负 $z \in \{-1, +1\}$[181] 【文献】。所以在同一个系统里，胜率可以同时是目标（策略）、输出（价值）和课程变量（对手选择，见第 4.6 节）。

这也给“实力”一个可操作的定义：**实力是对一个固定参照池的期望胜率**（或其 logit）。参照池一变，同一个数字的含义就变；这是第 4.3 节与第 4.6 节反复出现的主

表 4.1: 不同训练场景里，胜负、胜率与实力分别扮演什么角色

场景	训练标签	模型输出	被学到或被优化的量	收敛后的胜负
评分系统（Elo、Glicko、TrueSkill）	每局胜负 y	预测胜率 E	实力 R_i：潜参数，只有相对意义	按分匹配后接近抛硬币
赛前胜负预测（电竞、体育）	每局胜负	预测胜率	特征权重；可预测性来自匹配没平衡掉的因素	取决于特征，见第 4.5 节
自博弈强化学习	胜负作奖励	策略（和价值）	**胜率本身**：对某个对手分布的期望得分	对自身副本恒为五成
价值网络（AlphaGo Zero 的 v）	自博弈终局胜负 z	当前局面的期望结果	局面价值；本身是一个胜率预测器	势均力敌的局面接近 0
RLHF 奖励模型、Chatbot Arena	两两偏好	偏好概率	奖励分或 BT 分：潜参数，只有相对意义	质量相当的两个回答约五五开
8 人名次模型（酒馆战棋）	每局名次	名次分布	实力：潜参数	同分大厅每个名次各 1/8

题。

4.2　Elo 就是在线逻辑回归

4.2.1　一次 Elo 更新是一步随机梯度下降

Elo 更新 = 对数损失上的一步 SGD

记 $p = F(R_A - R_B) = \sigma(c(R_A - R_B))$，$\sigma(x) = 1/(1+e^{-x})$，$c = \ln 10/400 \approx 0.005756$。以实际得分 $y \in \{0, \frac{1}{2}, 1\}$ 为标签，单局交叉熵为

$$\ell = -\big[y \ln p + (1-y)\ln(1-p)\big].$$

这是逻辑回归的标准对数损失（log-loss）。由 $\sigma' = \sigma(1-\sigma)$ 得 $\partial\ell/\partial R_A = -c\,(y-p)$，$\partial\ell/\partial R_B = +c\,(y-p)$。以学习率 η 做一步随机梯度下降（stochastic gradient descent, SGD）：

$$R_A \leftarrow R_A + \eta c\,(y-p), \qquad R_B \leftarrow R_B - \eta c\,(y-p). \tag{4.1}$$

令 $K = \eta c$，这正是 Elo 公式[12] $R_A \leftarrow R_A + K(y-E)$。数值梯度与解析式 $-c(y-p)$ 的差在 10^{-13} 量级【本项目】（`code/ch4/derivations_check.py`）。

这个对应关系在文献中有多种表述：Szczecinski 与 Djebbi 把 Elo 写成对评分做最大似然估计的随机梯度算法[13]【文献】；Balduzzi 等写出同一个对数损失上的在线梯度

下降，并指出取 $\eta = 16$ 或 32 就回到 Elo 的原始更新[31]【文献】；Tang 等把 Elo 看作在线凸优化中的在线梯度下降，在模型设定错误、实力随时间变化的情形下仍有次线性遗憾保证[15]【文献】；Olesker-Taylor 与 Zanetti 用马尔可夫链方法证明，在 Bradley–Terry–Luce 模型下 Elo 学习参数的速率可与当前最好的方法相比[14]【文献】；Szczecinski 的新作说明“从业者的反馈规则”与“统计学家的在线极大似然”两种视角在二元结果下完全重合，当且仅当期望得分取 logistic 函数[16]【文献】。所以 Elo 的**训练标签是胜负，模型输出是胜率 E，被学习的参数是评分，K 是学习率**。

4.2.2　TrueSkill：学习率随不确定度自动变化

TrueSkill 把每名玩家的实力看成高斯信念 $\mathcal{N}(m_i, \varsigma_i^2)$，每局之后把后验近似为高斯、作为下一局的先验，作者称之为“高斯密度滤波”（Gaussian density filtering，即假设密度滤波）[1]【文献】。两人、无平局时，胜者 A 的更新可以写成（推导见附录 A.5.3）：

$$m_A \leftarrow m_A + \frac{\varsigma_A^2}{\tilde{c}}\, v\!\left(\frac{m_A - m_B}{\tilde{c}}\right), \qquad \varsigma_A^2 \leftarrow \varsigma_A^2\left[1 - \frac{\varsigma_A^2}{\tilde{c}^2}\, w\!\left(\frac{m_A - m_B}{\tilde{c}}\right)\right], \tag{4.2}$$

其中 $\tilde{c}^2 = 2\beta^2 + \varsigma_A^2 + \varsigma_B^2$，$v(t) = \phi(t)/\Phi(t)$，$w(t) = v(t)\,[v(t) + t] \in (0, 1)$。$v/\tilde{c}$ 恰是 probit 对数似然 $\log \Phi((m_A - m_B)/\tilde{c})$ 对 m_A 的梯度，所以均值更新仍是一步梯度上升，只是**学习率等于当前方差** ς_A^2；方差按“观测到的信息量” $w/\tilde{c}^2$ 收缩，于是学习率大约按 $1/n$ 递减，这是随机逼近的经典步长。TrueSkill 还在每局前给方差加上一个动态项，相当于假设实力每局随机游走 σ_w，使学习率不会降到零。作者在 Halo 2 数据上的对比写道，TrueSkill“自动选择正确的学习率，而 Elo 只能缓慢收敛到目标实力”；对照用的 Elo 取 $\alpha = 0.07$，相当于 Elo 刻度上 $K = 24$[1]【文献】。TrueSkill 2 把同一个生成模型分成两种近似：只向前传播的在线模式，和对全部历史联合推断的批量模式（即 TrueSkill Through Time），推断都用期望传播（expectation propagation）实现；作者指出在线更新只是对后验的快速实时近似，最准确的评分来自批量处理[25]【文献】。这与下文“在线 Elo 对批量 Bradley–Terry”的关系相同。

用 Xbox Live 的公开参数（$m_0 = 25$，$\varsigma_0 = 25/3$，$\beta = \varsigma_0/2$，动态标准差 $\varsigma_0/100$）[1]【文献】，按“差值为 0 处斜率相等”把 1 个 TrueSkill 单位折合约 47 Elo，可以算出【本项目】：新玩家第一局势均力敌地赢一局，均值上升约 198 Elo（相当于 $K \approx 400$）；进入稳态后，赛前标准差约 0.79 单位（约 37 Elo），势均力敌地赢一局只涨约 3.9 Elo，相当于 $K \approx 7.8$。这个稳态值恰好等于下一小节推出的“已知漂移 σ_w 时的最优固定步长 $K^* \approx 2\sigma_w$”（此处 $\sigma_w \approx 3.9$ Elo/局）：卡尔曼式滤波的稳态增益，就是固定步长 SGD 的最优学习率。

4.2.3　固定 K 的代价：噪声球与跟踪滞后

固定学习率的 SGD 不会停在最优点，而是在其附近的“噪声球”里游走，并且越近的样本权重越大。设评分误差 $e_t = R_t - s_t$，按分匹配下 $p \approx \frac{1}{2}$，线性化后（附

录 A.5.2）

$$e_{t+1} = (1-a)\,e_t + K\xi_t - w_t, \quad a = Kcp(1-p), \quad \mathrm{Var}(e) = \frac{K^2 p(1-p) + \sigma_w^2}{2a - a^2} \approx \frac{K}{2c} + \frac{2\sigma_w^2}{Kc}, \tag{4.3}$$

其中 $\xi_t = y_t - p_t$ 是结果噪声，$w_t \sim \mathcal{N}(0, \sigma_w^2)$ 是实力每局的随机游走。第一项是**方差**（K 越大抖得越厉害），第二项是**跟踪滞后**（K 越小越跟不上实力变化），最优 $K^* \approx 2\sigma_w$，最小误差约 $\sqrt{2\sigma_w/c}$。实力恒定时，$K = 16$ 的稳态误差约 37 Elo，$K = 32$ 约 53 Elo，后者相当于胜率 $50\% \pm 7.5$ 个百分点【本项目】；Szczecinski 引用 Zanco 等对循环赛的分析给出同一近似 $v \approx sK/2$（$s = 1/c$）[16]【文献】。误差衰减的时间常数是 $1/a = 4/(Kc)$：$K = 32$ 约 22 局，$K = 8$ 约 87 局。这是每局都恰好五五开时的理想值；在随机匹配或带窗口的按分匹配下要更长，$K = 16$ 约 55–65 局、$K = 32$ 约 30–34 局（第 2.4.2 节）。图 4.1 用模拟验证了这一权衡。

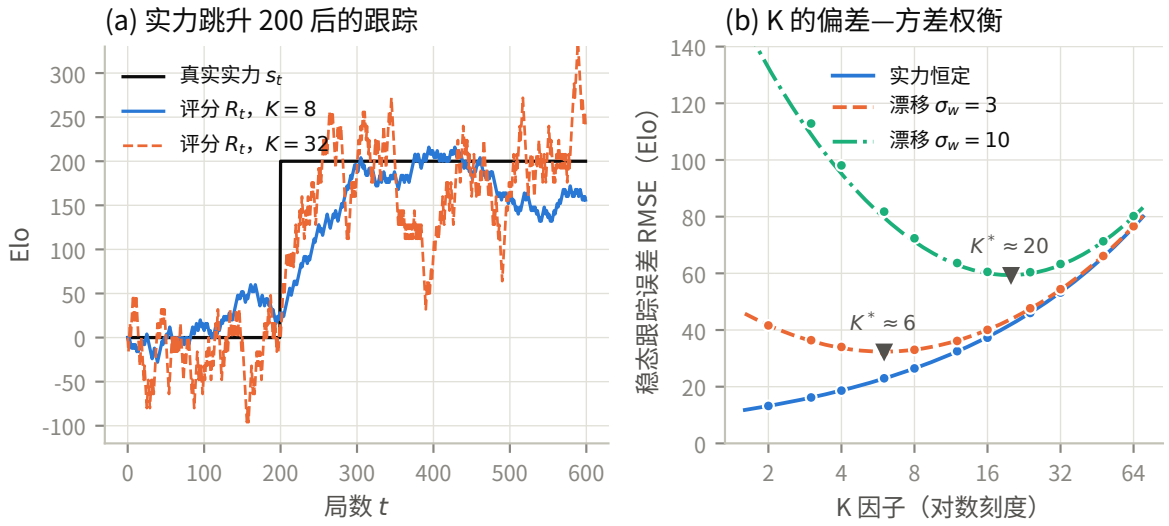


图 4.1： K 是学习率。(a) 实力在第 200 局跳升 200 Elo：$K = 8$ 抖动小但约百局才追上，$K = 32$ 追得快但一直在真实值附近大幅抖动。(b) 稳态均方根误差：实力恒定时误差随 K 单调上升（$\sqrt{K/2c}$）；实力每局随机游走 σ_w 时出现最优 $K^* \approx 2\sigma_w$。点为模拟，线为式 (4.3)。模型：一名玩家按分匹配，对手评分等于玩家当前评分且准确；(b) 每个点 200 次重复、每次 24000 局、丢弃前 4000 局。【本项目】

这一视角也解释了 Chatbot Arena 为什么在 2023 年 12 月放弃在线 Elo、改用批量 Bradley–Terry 拟合（第 4.7 节）：大模型多为静态，实力不变时最优步长是 $1/n$ 递减的批量估计，只有实力在变时才需要固定步长去跟踪。“Elo Uncovered” 也发现，大模型评测中的 Elo 要对 100 种以上的对局顺序取平均才稳定，水平接近的模型更适合较小的 K[182]【文献】。

4.3　实力不可辨识，所以只能在数据空间评估

预测只依赖评分差，给所有人同时加一个常数，似然完全不变。TrueSkill 2 的作者写明了两种不可辨识：把所有实力连同 β 一起放大，名次分布不变，所以要固定 $\beta = 1$；两人对局中给所有实力都加 2，结果分布也不变，所以先验均值无关紧要[25]【文献】。Chatbot Arena 的论文同样直接令第一个模型的系数为 0，“因为模型对 ξ 的平移不变”[183]【文献】。由此，一个 1500 分在两款游戏之间、在同一游戏的不同年份之间都不可直接比较；评分只相对于实际遇到的对手池有意义。

既然没有实力的真值，“这个人的实力分对不对”就无法直接回答。TrueSkill 2 提出的原则是：**指标应当位于数据空间，或者更一般地，位于模型的外部接口，而不是参数空间**[25]【文献】。他们的做法有两层。第一层是按时间顺序“先预测、后更新”的预测准确率：在 Halo 5 上用 2300 万局训练、其后 300 万局测试，只让模型预测获胜队伍（或平局），所以选项数是队数加一。第二层是分组校准（calibration）：比较“模型认为某类队伍会赢的频率”和“它们实际赢的频率”。例如按车队人数分组，经典 TrueSkill 对 4 人车队预期 52%、实际 57%，对 10 人以上车队预期 67%、实际 89%，说明“队伍实力等于成员之和”的假设不对[25]【文献】（图 1.3）。

评分本身的噪声也会在数据空间留下痕迹。固定 K 的评分围绕实力抖动，用原始评分差去预测会**过于自信**：被看好的一方实际赢得比预测少（图 4.2a）。拟合 $y \sim \mathrm{Bernoulli}\big(F(\hat{\gamma}\,(R_i - R_j))\big)$，在随机匹配、$\tau = 200$ 的群体里，$K = 16, 32, 64$ 分别得到 $\hat{\gamma} = 0.95, 0.87, 0.77$；$K = 32$ 时对数损失从 0.522 降到重标定后的 0.520，用真实实力的预测为 0.505【本项目】。附录 A.5.4给出近似式 $\hat{\gamma} \approx \lambda/\sqrt{1 + \pi c^2 \sigma_e^2 \lambda/4}\,(\lambda = \tau^2/(\tau^2+\sigma_e^2))$，它分别给出 0.95、0.90、0.80。Szczecinski 把这一现象总结为“排名用的模型与预测用的模型必须解耦”：估计噪声越大，预测时的有效刻度越要放宽[16]【文献】。

图 4.2b 回答了“能不能直接把胜率当训练目标”。按分匹配下，实力最低和最高的 10% 玩家长期胜率分别只有 48.2% 和 51.8%，中间 80% 玩家的胜率几乎全在 48.7%–51.3% 之间，比千局二项噪声（约 ± 1.6 个百分点）还窄【本项目】。原因是 Elo 的反馈：n 局的累计残差 $\sum(y - E) = \Delta R/K$ 被评分变化量锁住。一个以“玩家胜率”为目标训练的模型，在这种环境里会学到“人人约 50%”，它的输出几乎不含实力大小的信息；实力住在评分里，也就是住在“系统让你和谁打成五五开”里。

4.4　收敛之后：胜负照样产生，只是像抛硬币

4.4.1　完美模型在五五开对局上的三个下限

若一局的真实胜率为 p，模型完全校准，则期望准确率为 $\max(p, 1-p)$，期望对数损失为二元熵 $H(p) = -p\ln p - (1-p)\ln(1-p)$，期望 Brier 分数为 $p(1-p)$。在 $p = \frac{1}{2}$ 时三者分别为 50%、$\ln 2 \approx 0.693$ 和 0.25（图 4.3），这是任何模型都无法突破的下限【本项目】。所以“收敛后胜负像抛硬币”不是模型失败，而是匹配目标达成的直

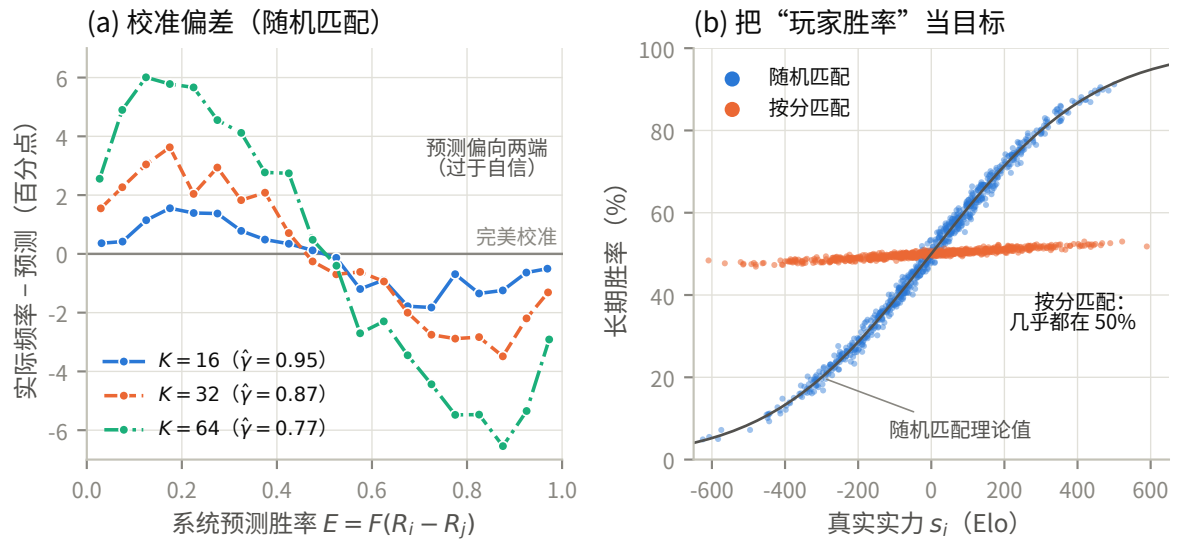


图 4.2: 在数据空间评估。(a) 校准偏差（实际胜出频率减系统预测）：评分噪声使预测偏向两端，K 越大越明显；括号内为拟合的刻度收缩系数 $\hat{\gamma}$。(b) 把“玩家长期胜率”当预测目标：随机匹配下它随实力从约 17% 变到 83%，按分匹配下几乎全挤在 50% 附近，而同一群体的评分与实力的相关系数为 0.988。参数：2000 人，实力 $\sim\mathcal{N}(0,200^2)$，每轮每人一局；(a) 随机匹配，收敛 300 轮后评估 300 轮（每个 K 30 万局）；(b) $K=16$，收敛 500 轮后统计 1000 轮，按分匹配噪声 $\sigma_q=25$。【本项目】

接结果。TrueSkill 的作者在 Halo 2 实验中提醒，由于排名与匹配相互作用，“取决于所有玩家（未知的）真实实力，可达到的最小预测错误率可能高达 50%”；为此他们让两个系统互相把自认为最胶着的对局交给对方预测，在这些对局上 TrueSkill 的错误率为 29.94%–37.17%，Elo 为 38.30%–44.12%[1]【文献】（表 1.1）。

4.4.2　最难预测的对局，恰恰最有信息

单局结果对评分差 d 的 Fisher 信息（Fisher information，衡量一次观测能把参数估计得多准）为

$$I(d)=c^2\,p(1-p),\qquad p=F(d),\tag{4.4}$$

在 $p=\frac{1}{2}$ 时取最大值 $c^2/4$（图 4.4a）【本项目】。实力悬殊的对局几乎总是强者赢，赢了也不告诉系统多少新东西；五五开的对局结果最“意外”，因而最能区分“A 略强”还是“B 略强”。“最难预测”说的是对结果 y 的预测，“最有信息”说的是对参数 d 的估计，二者是同一件事的两面。TrueSkill 官方 FAQ 的原话是：“每一局结果无法事先预测的匹配对局，都保证了这局是有信息量的”；它同时提醒，因为强者并不总赢，每局可能损失多达 75% 的信息，并把系统的首要目的定为“最小化识别玩家实力所需的对局数”[117]【官方】。同一设计原则出现在完全不同的地方：Chatbot Arena 有意把投票集中在表现相近的模型对上，“因为不确定度更高”[183]【文献】；OpenAI Five 的评估只和胜率在 15%–85% 之间的参考对手对局，“以获得最大限度有用的信息”[184]【文献】

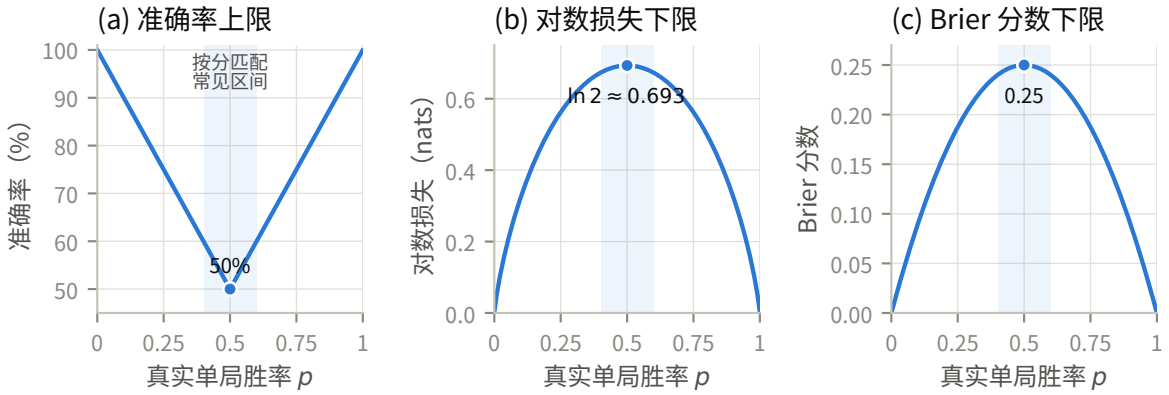


图 4.3: 完美校准的模型在真实胜率为 p 的对局上能达到的最好指标。阴影为 $|R_i - R_j| \le 70$ Elo 对应的胜率区间（约 40%–60%），按分匹配后的大多数对局落在这里。解析式。【本项目】

。

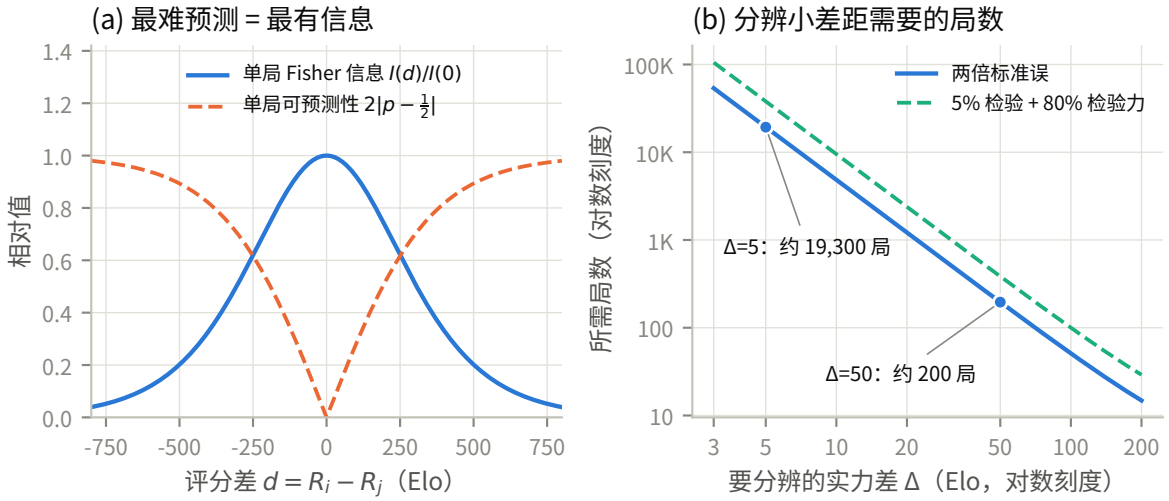


图 4.4: (a) 单局 Fisher 信息 $c^2p(1-p)$（相对其最大值）与单局可预测性 $2|p-\frac{1}{2}|$ 随评分差此消彼长。(b) 在 $p \approx \frac{1}{2}$ 附近分辨实力差 Δ 所需局数：两倍标准误 $N = (F(\Delta) - \frac{1}{2})^{-2}$，以及 5% 双侧检验、80% 检验力。解析式。【本项目】

信息量大不等于看得清。$p \approx \frac{1}{2}$ 附近 1 Elo 约等于 0.144 个百分点胜率；要以两倍标准误分辨 50 Elo 的差距约需 196 局，分辨 5 Elo 约需 19,300 局（5% 检验、80% 检验力时分别约 380 局和 37,900 局，图 4.4b）【本项目】。与此同时，评分并不会停下：$p = \frac{1}{2}$ 时每局恰好 $\pm K/2$，期望为零但从不为零，这就是式 （4.3）的噪声球。

4.4.3　能不能直接用胜负说明问题：把收敛模型当零假设

能，但要换一个问法。不该问“胜负序列像不像随机”，而该问“胜负序列与一个冻结的、已收敛的模型给出的逐局概率是否一致”。零假设是：给定第 t 局之前的全部信息，$y_t \sim \text{Bernoulli}(\hat{p}_t)$，$\hat{p}_t = F(\hat{S} - R_t^{\text{opp}})$，其中 $\hat{S}$ 是收敛阶段的平均评分。此时残

差 $r_t = y_t - \hat{p}_t$ 是鞅差（martingale difference）：只要分组变量 $g_t \in \{0,1\}$ 由赛前信息决定（上一局是否输、当前连败长度、时段、英雄），就有 $\mathbb{E}[\sum_t g_t r_t] = 0$，并且

$$z_g = \frac{\sum_t g_t r_t}{\sqrt{\sum_t g_t \hat{p}_t(1-\hat{p}_t)}} \xrightarrow{d} \mathcal{N}(0,1). \tag{4.5}$$

常用的三种检验都是它的特例：全局校准（$g_t \equiv 1$）、分组校准（按预测胜率或玩家类别分箱）、以及“触发组与其余对局”的残差差异检验 $z = (\theta_1 - \theta_0)/\sqrt{1/B_1 + 1/B_0}$，其中 $\theta_k = \sum_{g_t=k} r_t / B_k$，$B_k = \sum_{g_t=k} \hat{p}_t(1-\hat{p}_t)$（附录 A.5.5）。差异检验对 $\hat{S}$ 的小误差一阶不敏感。按触发条件**汇总**残差，期望恰好为零；先在每名玩家的序列内算“连败后胜率”再平均，才会出现 Miller–Sanjurjo 偏差[173]【文献】，这一点与第 3.2.5 节相衔接。

游程检验需要特别小心。若把 $\hat{p}_t$ 当作固定常数来算期望游程数，就忽略了匹配本身对过去结果的反应：诚实 Elo 下输一局后评分下降，下一局对手变弱，胜负更容易交替。正确的“鞅修正”版本用 $\mathbb{E}[\mathbb{1}(y_t \neq y_{t-1}) \mid \text{赛前}] = y_{t-1}(1-\hat{p}_t) + (1-y_{t-1})\hat{p}_t$，化简后正好是 $\sum_t (1-2y_{t-1})\, r_t$，即“输后残差减赢后残差”，与上面的差异检验等价（附录 A.5.5）。

图 4.5用一个模拟比较这些检验。设定：玩家基础实力为 0，系统用 $K = 16$ 的 Elo 更新评分，对手评分 $= R_t + \mathcal{N}(0, 50^2)$ 且准确；先打 2000 局收敛，取最后 1000 局的平均评分作为冻结模型的 $\hat{S}$；每个场景 2000 次重复【本项目】。两种偏离零假设的机制是：

- **上头**（tilt，即式 (3.11) 取 $m = 1$、$\theta = \delta$ 的最简形式）：上一局输了，本局实力下降 δ；
- **连败保护**（一种操纵）：前两局都输了，匹配器把对手评分压低 100。

结果有三点【本项目】。第一，上头 $\delta = 50$ 时，输后胜率为 47.1%、赢后为 52.9%；残差差异检验在 1000 局时检出率 61%，2000 局时 88%；$\delta = 25$ 要 5000 局才达到 70%，$\delta = 100$ 在 500 局时已达 89%。第二，在完全诚实、没有上头的系统里，输后胜率也略高于赢后（50.6% 对 49.4%），这是评分下调后对手变弱的均值回归，所以“输后胜率 vs 赢后胜率”的朴素检验在一万局时误报率升到约 20%，把 p_t 当固定值的游程检验更升到约 62%；冻结模型的残差检验和鞅修正游程检验则一直在 5% 左右。第三，连败保护在两连败后把胜率从 49.8% 抬到 64.6%，但对冻结模型的残差毫无影响，因为模型已经把对手变弱算进了预测；它的指纹在**输入**里：两连败后的对手评分系统性低 100，100 局就能以接近 100% 的概率检出。

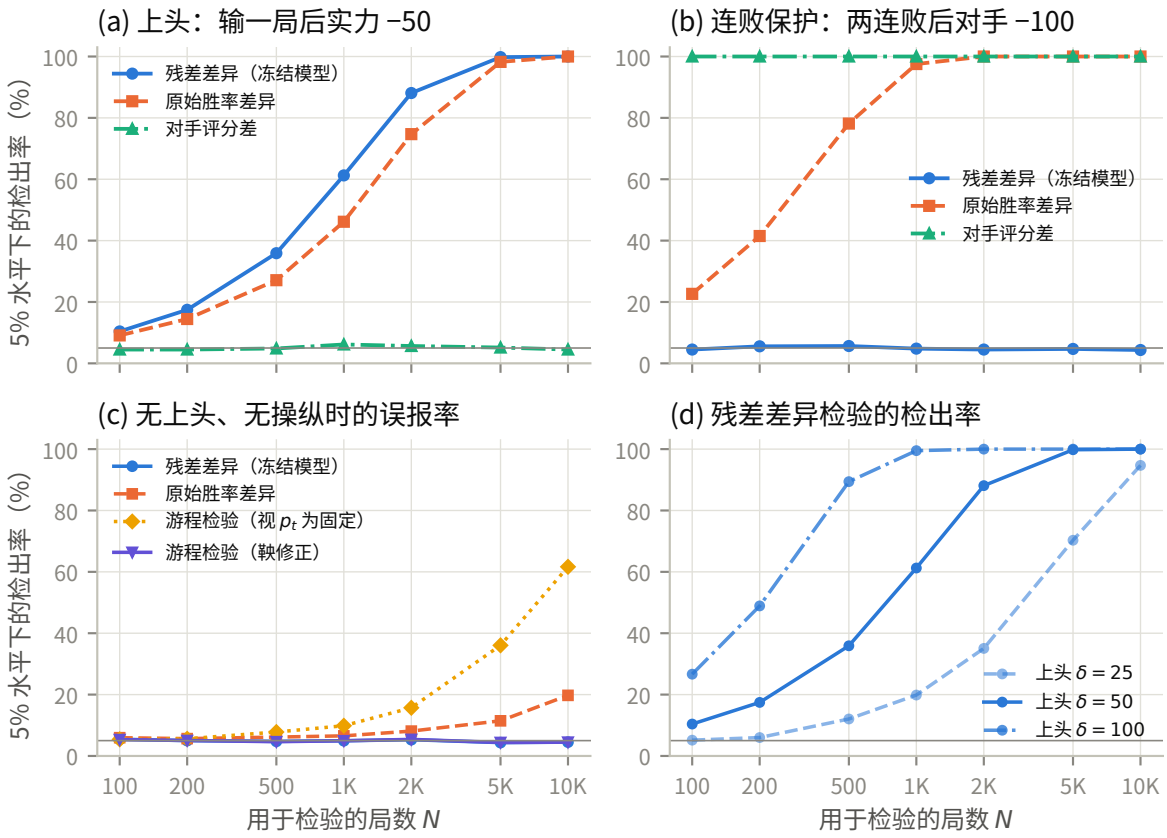


图 4.5： 把冻结的收敛模型当零假设。(a) 上头 $\delta = 50$：残差差异检验和原始胜率检验都能检出，对手评分差检验检不出。(b) 连败保护：残差检验检不出（模型已把更弱的对手算进 $\hat{p}_t$），原始胜率和对手评分差都能检出，后者 100 局即可。(c) 既无上头也无操纵时：冻结模型的残差检验和鞅修正游程检验误报率保持 5%，原始胜率检验（诚实 Elo 的均值回归）和把 p_t 当固定值的游程检验随局数增加而误报。(d) 残差差异检验对不同上头强度的检出率。纵轴为 5% 双侧水平下的拒绝比例，参数见正文，每点 2000 次重复。【本项目】

“用胜负说明问题”的指纹表

机制	残差差异（冻结模型）	原始胜率差异	对手评分差
诚实 Elo（无上头、无操纵）	不显著	长序列中轻微显著（均值回归）	不显著
上头（实力波动）	显著	显著	不显著
连败保护（按评分挑对手）	不显著	显著	显著

所以只看胜负序列本身，分不清“上头”与“连败保护”；要么需要冻结模型的逐局预测，要么需要对手的评分。简言之，上头的指纹在残差里，按评分挑对手的操纵的指纹在匹配输入里；这一区分与第 3.6 节的人群模拟结论一致，也是第 3.4.7 节中单人检验的基础。

4.5　匹配让胜负难预测，但外部模型仍能预测

“每局都接近抛硬币”只对**负责匹配的那个模型**成立。匹配器只能平衡它自己建模的东西；它漏掉的因素，外部模型可以从同一批对局里挖出来。表 4.2汇总了几项赛前预测研究。

表 4.2: 赛前胜负预测的公开结果（各研究数据集与基准不同，数字之间不宜直接比较）

游戏	研究	赛前信息与数据	结果
Halo 5	Minka 等[25]	只用队伍组成与车队信息预测获胜队或平局（选项数 = 队数 + 1）；训练 2300 万局、测试 300 万局；经典 TrueSkill	准确率 52%
		同上，TrueSkill 2（实力估计额外利用经验、车队、击杀、退出倾向、其他模式实力）	68%
Dota 2	Yang 等[69]	78,362 场；逻辑回归：仅英雄 / 仅玩家 / 玩家 × 英雄 / 全部	60.07% / 55.77% / 69.90% / 71.49%
Dota 2	Yashkov 等[185]	选人阶段阵容；阵容在极高分段至少解释约 6% 的信息（香农），普通分段约 10%	AUC 0.66–0.70
英雄联盟	Do 等[66]	5000 场排位；每名玩家对所选英雄的熟练度；所有人选完英雄、开局之前	75.1%±1.2%（DNN）

其中 Dota 2 选人阶段的 AUC 取自 Yashkov 等对其团队工作（Semenov 等）的报告幻灯片[1]。这些数字的共同解释是【文献】：匹配器用评分 R 把双方配到预测胜率约

[1]待核对：本次未读到原文全文（对应论文[68] 在付费墙后，此处依据作者报告幻灯片）。

50%，所以只用 R 的模型只能接近 50%（Halo 5 的 52%）；可预测性来自匹配没有平衡的因素。Do 等的结论直接写道：“即使经过按实力匹配，开局前两队实力仍存在很大差异”，英雄熟练度是关键[66]【文献】。Yang 等发现单项最有用的是“玩家 × 英雄”特征（69.90%），并指出先前超过 70% 的报告来自平均时长偏短（23–30 分钟）的数据集[69]【文献】。TrueSkill 2 的车队表说明经典模型低估了大车队；而 TrueSkill 系列刻意不把“与高手对位者多半也是高手”之类的统计相关性写进模型，理由是激励应当是“把游戏打好，而不是挑时段排队或挑队友”[25]【文献】。

对本研究的含义是：外部模型能显著高于 50% 地预测胜负，说明匹配**没有**把所有影响胜负的因素平衡掉，而不是说明匹配在操纵结果；反之，预测率接近 50% 是平衡匹配的正常表现。

4.6　自博弈：胜率是目标，进步要对固定参照来量

4.6.1　和自己打永远五五开

在对称零和博弈中，策略对它自己的完全副本，期望得分由对称性恰为 $\frac{1}{2}$（只受先后手或阵营不对称影响），无论它是新手还是世界冠军。这与天梯中“收敛后人人约 50%”是同一个数学事实：50% 只说明“对手与你同水平”。各大项目因此都另设了不随训练移动的参照系。

- **AlphaGo Zero**：每个新检查点要与当前最佳网络打 400 局，胜率超过 55% 才取而代之，作者说门槛是为了“避免仅凭噪声选择”[181]【文献】。按二项分布，真实胜率 50% 时误通过的概率约 2.0%，真实 55% 时只有约 48% 能通过，60% 时约 98%【本项目】。Elo 用 BayesElo 做贝叶斯逻辑回归（$c_{\text{elo}} = 1/400$），并把 Fan Hui、李世石的人机对局也纳入，以“把刻度落到人类参照上”，否则“AlphaGo 的 Elo 会因自博弈偏差而高得不现实”；最终评分为 Zero 5,185、Master 4,858、Lee 3,739、Fan 3,144，不搜索的原始网络 3,055；对 Master 的百局对抗为 89 比 11[181]【文献】。AlphaZero 后来取消了这道门槛，改为持续更新单一网络[186]【文献】。
- **OpenAI Five**：评估用 83 个固定参考智能体的 TrueSkill，从随机策略的 0 到击败世界冠军版本的 254；初始不确定度 25/3、表现噪声取其一半、不设动态项；手写脚本智能体约 105；约 8.3 TrueSkill 的差对应 80% 胜率；只和相差 10 分以内（胜率 15%–85%）的参考对手对局，参考对手的评分视为常数，每个版本报告 750 局后记录[184]【文献】。作者也承认，游戏版本更新会让在新版本上训练的新智能体出现“指标通胀”。训练时 80% 的对局打当前参数、20% 打历史版本，以避免“策略坍塌”；历史对手按质量分 q_i 的 softmax 抽样（被抽中的概率记为 π_i），当前智能体赢了对手 i 就令 $q_i \leftarrow q_i - \eta/(N\pi_i)$，$\eta = 0.01$，输了则不变[184]【文献】。这是一种按对局结果在线调整对手抽样权重的重要性加权更新：越容易被打败的历史版本，被抽到的概率越低。

- **AlphaStar**：对人类天梯的强度不是读 Battle.net 显示的 MMR，而是在暴雪的概率模型 $\mathbb{P}(o_i = 1) = \Phi\big((r - r_i)/(400\sqrt{2 + u^2 + u_i^2})\big) \approx \Phi\big((r - r_i)/568\big)$ 下，用对局结果做极大似然估计；作者用职业选手 TLO 最近 200 场验证，估计 6334，Battle.net 显示 6336。最终三族 MMR 为 6,275、6,048、5,835，高于欧服约 9 万名定级玩家的 99.8%[78]【文献】。这是“在数据空间、对外部固定参照估计潜在实力”的标准做法。
- **Leela Chess Zero**：项目 FAQ 承认官方 Elo 曲线“看起来通胀”：它把第一个网络定为 0，不与任何通用榜单校准，不同训练批次之间不可比；各点由自博弈对局算出，“自博弈往往夸大 Elo 增长”。FAQ 还写道，“自博弈 Elo”不是网络强度的真实指标，只是训练是否健康的一般参数；某个网络可能打其他引擎更差，却在直接对局中赢下所有其他网络[187]【官方】。

图 4.6用一个玩具博弈说明通胀从何而来：若每一代恰好学会克制上一代（循环维度前进一步），对上一代的胜率就稳定高于一半，累计“自博弈 Elo”线性上升；但对一个固定参照池，纯循环博弈的胜率始终是 50%，真实进步为零。只要再加一点传递性进步，固定参照池会如实反映它，而自博弈 Elo 仍把它夸大一个数量级以上。

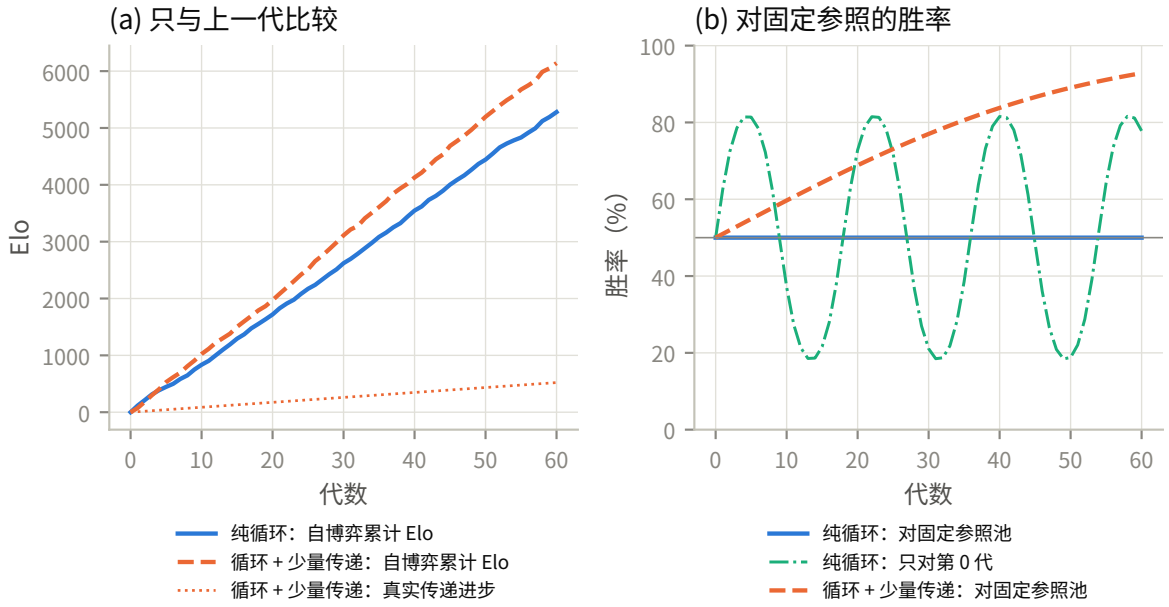


图 4.6: 只和上一代比较会让自博弈 Elo 通胀。玩具博弈 $\mathbb{P}(i \text{ 胜} j) = \sigma\big(1.5\sin(\theta_i - \theta_j) + (h_i - h_j)\big)$，每代 θ 前进 0.35。纯循环（h 不变）：每代对上一代胜率 62.6%，60 代累计自博弈 Elo 约 5,280，对 16 个均匀分布的固定参照智能体的胜率始终为 50%，只对第 0 代的胜率在 18%–82% 之间振荡。循环加少量传递（每代 h 增 0.05）：自博弈 Elo 约 6,140，真实传递进步只有约 520 Elo，对参照池的胜率从 50% 升到 92.8%。自博弈 Elo 每代用 400 局估计。【本项目】

4.6.2　AlphaStar 的联赛：把胜率当成课程的控制变量

AlphaStar 的优先虚拟自博弈（prioritized fictitious self-play, PFSP）按“学习者 A 战胜冻结对手 B 的概率”给对手加权：$\mathbb{P}(\text{选}B) \propto f(\mathbb{P}[A \text{ 胜} B])$[78]【文献】。默认权重 $f_{\text{hard}}(x) = (1-x)^p$ 聚焦打不过的对手，作者称之为“max-min 优化的平滑近似”，以区别于均匀虚拟自博弈的“max-avg”，因为在高度非传递的星际争霸里追求平均胜率会留下容易被利用的弱点；另一种权重 $f_{\text{var}}(x) = x(1-x)$ 让智能体优先与水平相当的对手对局，用于主剥削者和陷入困境的主智能体。主智能体的对局构成是 35% 自博弈、50% 对全体历史玩家的 PFSP、15% 对已被遗忘的主玩家和历史主剥削者的 PFSP；主剥削者在对当前主智能体胜率低于 20% 时，有一半对局改用 f_{var} 权重[78]【文献】。

f_{var} 的形状正是伯努利方差，也就是式（4.4）中的 Fisher 信息（图 4.7）：“和水平相当的对手打”与“按分匹配”、与“Chatbot Arena 把票集中在相近模型上”是同一个信息论选择。联赛的收益在非传递性很强时尤其明显：AlphaStar 的论文报告，在至少 70% 胜率才算克制的标准下，全联赛约有 300 万个涉及至少一个剥削者的石头剪刀布式循环，只涉及主智能体的约 200 个；朴素自博弈在消融实验中 Elo 很高，但“更健忘”[78]【文献】。

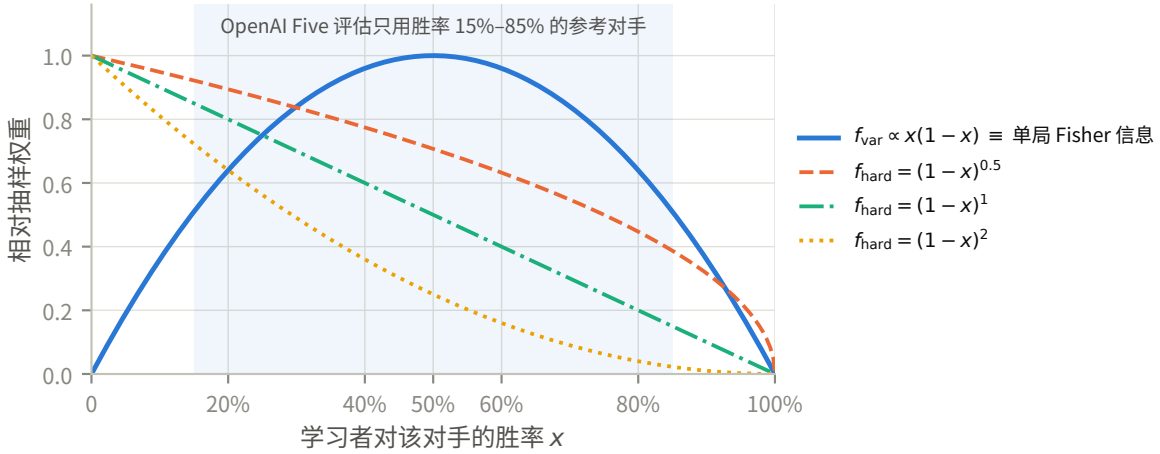


图 4.7： AlphaStar 的 PFSP 对手权重。$f_{\text{var}} \propto x(1-x)$ 与单局 Fisher 信息 $c^2x(1-x)$ 归一化后完全重合；$f_{\text{hard}} = (1-x)^p$ 偏向打不过的对手，p 越大越集中。阴影为 OpenAI Five 评估时使用的胜率窗口。解析式。

4.6.3　非传递性：一个标量 Elo 不够用

当 A 克 B、B 克 C、C 克 A 时，没有任何一维评分能同时把三对胜率预测对。Balduzzi 等证明：存在一组 Elo 评分能生成胜率矩阵 P，当且仅当 logit P 的“旋度”为零；任意胜率矩阵都可以分解为传递分量与循环分量之和，Elo 本质上是 logit 空间里的均匀平均，它的预测失败全部来自被忽略的循环分量；石头剪刀布三者 Elo 相同、预测全为 $\frac{1}{2}$，“没有任何预测力”[31]【文献】。他们的多维 Elo（mElo）给每名玩家加一

个低维向量 $\boldsymbol{c}_i$，预测 $\hat{p}_{ij}=\sigma(r_i-r_j+\boldsymbol{c}_i^{\top}\Omega\,\boldsymbol{c}_j)$；在 8 个围棋程序上，Elo 的预测误差 $\|P-\hat{P}\|_F=0.85$、对数损失 1.41，mElo 为 0.35 和 1.27。他们还指出，只要复制许多个被某智能体打败的对手，就能抬高它的 Elo，因此提出对冗余智能体不敏感的 Nash 平均[31]【文献】。在非传递博弈中，“我们希望智能体变强，但相对于谁变强并不清楚”，单纯自博弈可能原地打转[188]【文献】；Czarnecki 等则认为真实博弈的策略空间像陀螺，纵轴是传递强度，横向是同一强度上的循环数，中等水平处循环最多，所以训练需要策略种群[32]【文献】。

4.7　同一结构在大模型训练里再次出现

Chatbot Arena。模型是“玩家”，一次人类投票是“一局”。论文把 Bradley–Terry 系数定义为最小化二元交叉熵的解，并说明从先前显示的 Elo 分改为 BT 系数，“因为 BT 系数更适合统计估计”；置信区间用对模型设定错误稳健的“三明治”方差[183]【文献】。LMSYS 2023 年 12 月的博文给出了更具体的理由：标准 Elo 假设选手表现随时间变化，因而需要让近期对局权重更大的在线算法；而平台掌握全部历史对局，模型又大多是静态的，所以改用“在固定但未知的两两胜率假设下的极大似然”，评分“显著更稳定、置信区间更精确”；为满足“模型静态”的假设，还把不同版本的 GPT-4 分开计分（0314 与 0613 版分别为 1201 和 1152）[189]【官方】。

RLHF 奖励模型。Christiano 等把人类对两段轨迹 σ^1,σ^2 的偏好建模为

$$\hat{P}[\sigma^1\succ\sigma^2]=\frac{\exp\sum\hat{r}(\sigma^1)}{\exp\sum\hat{r}(\sigma^1)+\exp\sum\hat{r}(\sigma^2)},$$

用交叉熵拟合，并明说这“遵循 Bradley–Terry 模型……类似于国际象棋的 Elo 等级分”，奖励 $\hat{r}$ 是“解释人类判断的潜在因子”[190]【文献】。他们还假设人类有 10% 的概率随机作答，因为“评分者犯错的概率不会随奖励差增大而降到零”，并优先询问集成模型分歧最大的片段对，这是“挑不确定的对局”的另一种说法[190]【文献】。InstructGPT 的损失 $-\binom{K}{2}^{-1}\mathbb{E}\big[\log\sigma\big(r_\theta(x,y_w)-r_\theta(x,y_l)\big)\big]$ 把每次 4–9 个回答的排序拆成两两比较[191]【文献】，这正是第 4.2 节中 Elo 所用的对数损失。它的“抛硬币下限”来自标注噪声：训练标注者彼此一致率为 72.6%±1.5%，奖励模型对训练组标注者偏好的预测准确率为 72.4%±0.4%，对留出组为 69.6%±0.9%[191]【文献】。奖励只确定到一个常数，所以实践中要做归一化，Christiano 等对集成中的每个预测器分别归一化后再平均[190]【文献】。

GAN 的五成均衡（类比）。判别器的训练目标可以看作对 $\mathbb{P}(Y=y\mid x)$ 的对数似然最大化，即一个逻辑分类问题；生成分布等于数据分布时，最优判别器处处输出 $\frac{1}{2}$，目标值为 $-\log 4$，其相反数恰是两个 $p=\frac{1}{2}$ 的二元熵之和，即真假样本上的交叉熵都停在 $\ln 2$[192]【文献】。这与“完美匹配后胜负五五开”同构：50% 是双方都无法单方面改进的标志，而不是判别器无用。类比的限度在于 GAN 双方都在动，实践中常振荡，更像第 4.6 节的非传递循环，而不像天梯里对缓慢变化的人类实力的估计。

4.8　当目标换成留存：胜负数据混入系统意图

在上面的所有场景里，匹配或采样都服务于“看清实力”。一旦优化目标换成留存或参与度，胜负数据就不再只是“实力加噪声”的观测，而混入了系统的意图。EA 的 EOMM 就是这样的设计：以每对玩家配对后的预测流失之和为边权、求最小权完美匹配，流失预测的输入包括最近 10 局的胜负（式 （1.11））；其数据中最近三局“负负负”的玩家 7 天流失率为 5.1%，“胜胜胜”为 3.7%，部分其他组合低至 2.6%[51]【文献】。作者证明“同等实力配对”只是其框架的特例：当 $c(\text{胜})+c(\text{负})>2c(\text{平})$ 时二者等价，反之同等实力配对反而最差；而 EOMM 的输入之一正是实力模型给出的胜负概率[51]【文献】。它的模拟效应量、EA 动态难度调整的 A/B 结果和相应专利分别见第 1.3.4 节与 1.3.5 节与第 1.9 节；厂商是否在主流排位中部署这类机制仍然未知（第 1.11 节）。“无需操纵即可解释”不等于“已证明没有操纵”。

第 4.4.3 节的模拟给出了一个可检验的区分，但需要说清“相对于哪个模型”。若系统只通过**可观测的评分**挑对手（像 EOMM 那样以实力模型的胜率为输入），那么相对于系统自己的正确预测 p_t，残差仍是鞅差，残差检验检不出任何东西；变化体现在 p_t 本身（对手强度）随连败状态或流失风险而变，以及原始胜负随之而变（图 4.5b）。在公平匹配下，对手评分与连败状态无关，原始胜负只有很小的均值回归（第 4.4.3 节的模拟中输后胜率 50.6%、赢后 49.4%）。若系统通过评分以外的渠道干预（例如队友安排或隐藏的强度修正），那么相对于基于评分的 p_t，残差本身就会与连败状态或流失风险相关。两种情形都要求数据中有对手（及队友）的评分；只有胜负序列时，上头与操纵无法区分。

4.9　对酒馆战棋 AI 的含义

暴雪公开了什么。酒馆战棋的评分规则只见于两篇开发者文章（逐条转述见第 1.7.3 节）。与训练和评估直接相关的有四点[104-105]【官方】：评分之外还有一个不显示的“方差”，即系统对评分的把握；每局要计算每名玩家对其余 7 人的胜率，“一共 56 次”；匹配只按内部评分挑选最接近的 8 人，内部评分不重置、不设地板、不加进度分；外显评分则有赛季重置、2000–6000 之间每 500 分一道地板、6500 分以下的进度分，以及低于内部评分时的追赶倍率。2019 年的文章还写道，“如果你已在正确的评分上，足够多局之后会上下波动，但总体停在同一评分”[104]【官方】，这正是第 4.2.3 节的“噪声球”。“56”正好是 8 人两两有序配对数，与 TrueSkill 论文对多人对局用的“对决启发式”（每名玩家与其余每人逐一比较后平均更新）同构[1]【文献】。

名次似然。把名次当标签时，Plackett–Luce 模型[11]是 Bradley–Terry 的自然推广，Weng 与 Lin 的在线排名方法就包含它的版本[24]【文献】。

Plackett–Luce 的梯度是“实际减期望”

设 θ_k 为玩家 k 的 log 强度，$\pi(i)$ 为第 i 名，$N=8$。似然与对 θ_k 的梯度为

$$\mathbb{P}(\pi)=\prod_{i=1}^{N}\frac{e^{\theta_{\pi(i)}}}{\sum_{j\ge i}e^{\theta_{\pi(j)}}},\qquad \frac{\partial\log\mathbb{P}(\pi)}{\partial\theta_k}=1-\sum_{i=1}^{r_k}P_i(k),\quad P_i(k)=\frac{e^{\theta_k}}{\sum_{j\ge i}e^{\theta_{\pi(j)}}},\tag{4.6}$$

r_k 为 k 的名次。$\sum_{i\le r_k}P_i(k)$ 是“在 k 被选出之前的每一步，模型认为该轮选中 k 的概率”之和，其期望为 1，所以梯度的期望为零：第一名得到正梯度 $1-P_1(k)$，最后一名得到负梯度。对它做 SGD 就是“名次版 Elo”。8 人等强时，单局名次对 θ_k 的 Fisher 信息为 $1-H_8/8\approx0.660$（H_8 为调和数），是 1v1 的 0.25 的 2.64 倍（附录 A.5.6）【本项目】。

一局完整名次至多携带 $\log_2 8!\approx15.3$ 比特，1v1 至多 1 比特；TrueSkill FAQ 给出的“识别实力所需的最少局数”中，8 人混战约 3 局、2 人对局约 12 局，并提醒实际可能高到三倍[117]【官方】。收敛态同样成立：8 人等强的大厅里每个名次的概率都是 1/8，期望名次 4.5，前四率 50%，名次的多分类对数损失为 $\ln 8\approx2.08$（3 比特），这是完美模型的下限【本项目】。图 4.8a 显示，在“名次对实力的敏感度与 1v1 Elo 曲线相同”的假设下，比同桌强 100 Elo 时平均名次 3.52、前四率 69%，强 200 Elo 时 2.68、85%；真实酒馆战棋运气成分更大，同样的实力差带来的名次变化会更小。

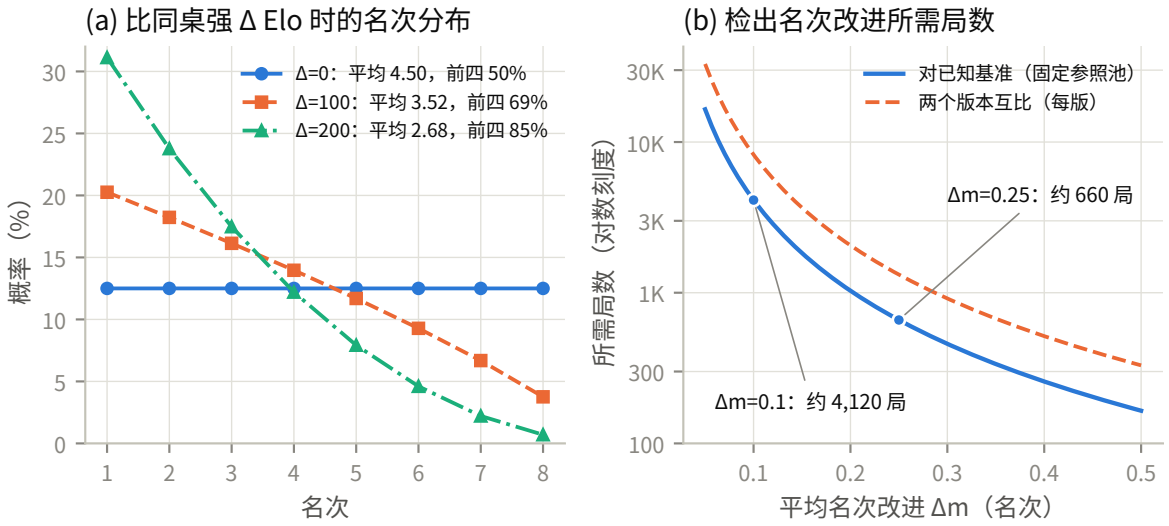


图 4.8: 8 人名次游戏。(a) Plackett–Luce 模型下，一名玩家比其余 7 名等强对手强 Δ Elo 时的名次分布（log 强度 $=c\cdot s$，即假设名次对实力的敏感度与 1v1 Elo 曲线相同）。(b) 以 5% 双侧检验、80% 检验力检出平均名次改进 Δm 所需局数；名次标准差取等强时的 $\sqrt{63/12}\approx2.29$。解析式。【本项目】

酒馆战棋 AI 的训练与评估建议（本项目推论）

1. **标签用名次，不用“胜率”或“前四率”这类聚合量**。评分或对局预测模型用 Plackett–Luce 或两两分解的似然（式 (4.6)）；评估用名次对数损失和分组校准，而不是“预测第一名的准确率”。
2. **进步对冻结参照池来量**。冻结若干历史版本与启发式机器人组成参照池，新版本进参照池组成的大厅对局，报告名次分布、平均名次、前四率，以及对参照池锚定的 Plackett–Luce 强度；参照池固定不变，并记录游戏版本，避免 OpenAI Five 提到的版本更新通胀。不要用“只和上一版比”的自博弈 Elo 衡量进步（图 4.6）。
3. **天梯数据只在同条件下比较**。按内部评分匹配会把长期前四率推回约 50%，所以“天梯前四率”本身不衡量强弱；能用的是同一赛季内追赶结束后外显评分的平台高度（6500 分以上没有进度分，地板只到 6000），以及同一分段内两个版本的名次对比。不要跨赛季比较外显分。
4. **样本量**。对已知基准（参照池中的 4.5 或 50%），前四率提高 2 个百分点约需 4,900 局，平均名次改进 0.1 约需 4,100 局，改进 0.25 约需 660 局；两个版本互比时每个版本约需两倍（9,800 局和 8,200 局）。
5. **非传递性**。英雄与流派之间可能存在很强的克制循环，单一标量强度对单局名次的解释力有限；按英雄或流派分层报告，必要时参考 mElo 或 Nash 平均的思路。
6. **用残差做体检**。把冻结模型当零假设，检查 AI 的天梯日志在连败、版本更新、时段等分组上的残差（式 (4.5)），可以发现环境变化或评估流程中的偏差。

4.10　小结

1. 评分系统的标签是胜负，输出是胜率，实力是潜参数。Elo 是对数损失上的在线 SGD，K 是学习率，在稳态误差（$\sqrt{K/2c}$，$K = 32$ 时约 53 Elo）与跟踪滞后之间权衡，实力每局漂移 σ_w 时最优 $K^* \approx 2\sigma_w$；TrueSkill 用不确定度当学习率，其稳态步长恰为这个最优值。
2. 实力只确定到常数，只能在数据空间用对数损失、Brier 分数和分组校准评估；评分噪声使原始预测过于自信。把“玩家胜率”当目标，在按分匹配下学到的是“人人约 50%”。
3. 收敛后胜负仍在产生、仍在推动评分；对负责匹配的模型而言每局接近抛硬币，而五五开的对局 Fisher 信息最大。分辨 50 Elo 约需 196 局，5 Elo 约需 19,300 局。外部模型仍能预测，说明匹配没有平衡所有因素，而不是操纵。
4. 用胜负说明问题，要把冻结的收敛模型当零假设、检验残差；朴素的“输后胜率”与把 p_t 当常数的游程检验在诚实 Elo 下也会误报。上头留在残差里，按评分挑对

手的操纵留在对手评分里。

5. 自博弈中胜率是目标，但与自身副本对局恒为五成；进步要对固定参照池、外部天梯或锚定的评分来量，只与上一代比较会通胀。PFSP 的 $x(1-x)$ 权重、按分匹配与 Chatbot Arena 的主动采样，都是“在五五开处采样”的同一选择。
6. 对酒馆战棋 AI：用名次似然训练，用冻结参照池评估，按每个版本 4,000–5,000 局（对已知基准）的量级规划样本。

结论与展望

一条主线：匹配器只看得到评分

四项研究讲的是同一件事的四个侧面：**胜率不是实力，评分是实力的带噪估计，而匹配器只看得到评分**。

研究一说明，评分与匹配是两层不同的机制。评分一层的统计理论已经成熟，厂商也普遍承认“隐藏分负责匹配、可见段位另算”；争议集中在匹配一层，而这一层恰恰没有任何厂商公开可复核的日志（第 1.12 节）。研究二说明，匹配器拉平的是估计实力，所以“每局五五开”是预测胜率五五开，真实胜率围绕 50% 分布（第 2.2 节）；在固定 K 的 Elo 下，恒等式式 (2.6) 把实力优势兑换成更高的评分，长期胜率因此趋于 50%，这不需要任何“拉回五成”的干预。研究三说明，纯随机已经能以玩家实际感受到的频率产生长连败和“连胜后连败”，诚实 Elo 的均值回归很小，真正能在诚实系统里放大连败的是玩家自己的“上头”（第 3.8 节）。研究四从训练的角度重述了这一切：胜负是标签，胜率是输出，实力是潜参数；收敛后的胜负像抛硬币，却正是信息量最大的样本（第 4.10 节）。

四者合起来，给出一个可以执行的判别原则：**操纵若存在，指纹在匹配的输入里，而不在胜负序列里**。在诚实的按分匹配中，控制自身评分之后，近期的连胜或连败不应再能预测对手和队友的评分；只看胜负，最多能说“没有发现强操纵”（第 3.6 节与第 4.4.3 节）。这也是本文的结论为什么始终是“无需操纵即可解释”，而不是“已证明没有操纵”。

局限

- **模型是理想化的**。一维实力、逻辑斯蒂胜率曲线、正态群体、固定 K 的 Elo、“评分加噪声排序”的匹配器；没有组排、位置、延迟、版本更新和流失。真实系统的数字会不同，可靠的是依赖关系和机制之间的相对大小。
- **波动模型的参数是示意值**。“上头”每多输一局降 30 分、AR(1) 状态的标准差 60 分等都不是从真实数据估计的；它们决定了“上头使‘5 接 5’约翻倍”之类结论的量级。
- **来源不完整**。约 40 条来源只读到摘要或转述（`docs/TO_VERIFY.md`）；中文学位

论文和中国专利未能检索全文；厂商的说法都是自述，只有 EA 的否认经过了诉讼程序的间接检验。

- **没有真实对局数据**。本文没有任何一款游戏的隐藏分、对手评分或匹配日志，所有关于“诚实系统会产生什么”的结论都还没有在真实数据上对照。

下一步一：把社交平台上的“控胜率”说法变成可检验的模型

第三章把三种流行说法（强制五成、连胜惩罚、5v5“输家队列”）写成了匹配规则，并找到了它们的指纹（表 3.6）。下一步是系统地收集更多说法：

1. **收集**：知乎、B 站、NGA、百度贴吧、小红书、微博、抖音评论区，以及 Reddit（r/leagueoflegends、r/Overwatch、r/CODWarzone、r/hearthstone）和 Steam 社区；记录原文、链接、日期、游戏和点赞数。
2. **归类**：如“连胜后配坑队友”“连败后放水”“新号或回流保护”“氪金影响匹配”“隐藏分低于段位时被压分”“组排惩罚单排”“深夜匹配更差”。
3. **形式化**：每一类写成“触发条件 + 对匹配键或分队的改动”，放进第三章人群模拟代码的操纵接口（`code/ch3/population.py`）。
4. **模拟与指纹**：与诚实 Elo 和上头模型比较条件胜率、对手评分差、系统预测和长连败分布，得到表 3.6那样的指纹表。
5. **检验**：说明每种说法在数据上能否证伪、需要哪些字段（对手和队友的评分、排队时间、组队人数），以及单个玩家或全服数据各需要多少局。

有些说法会被证明与“控五成”自相矛盾（例如对称的控五成反而减少长连败，第 3.6 节），有些则只能在拿到匹配输入后检验；把这个区分讲清楚，本身就是对玩家有用的结论。

下一步二：用用户本人的对局数据估计实力与波动范围

数据格式见仓库的 `data/README.md` 与 `data/template_matches.csv`：一行一局，按时间排序，必填游戏、模式、开始时间、胜负（名次制游戏填名次）和每局人数；若能导出赛前赛后评分、己方与对方平均评分、组队人数、排队时长和游玩会话编号，可检验的问题会多得多。原始导出放在 `data/private/`，默认不入库。分析分四步：

1. **基线**：独立二项（或名次多项）模型下的胜率、平均名次与 Wilson 区间（第 2.7 节）；有对手评分时，用式 （2.6）把胜率分解为“对手强弱”和“评分变化”两部分。
2. **实力轨迹与波动范围**：把 s_t 写成随机游走或 AR(1) 的状态空间模型，用卡尔曼滤波与平滑、或 TrueSkill Through Time 的思路估计实力曲线、置信带和波动标准差（第 3.4.8 节）。

3. **状态与上头**：两状态隐马尔可夫模型（前向算法求似然）和“连败长度”协变量的逻辑回归，与独立基线做似然比或 AIC 比较；疲劳要去掉每次游玩的最后一局，以免把停止规则误当成下滑（式 (3.12)）。按第 3.4.7 节的检验力估计，示意强度的上头要约 900—1500 局才能以 80% 的把握检出，在评分会更新的系统里，慢变化的状态则要借助对手评分才看得出。
4. **残差体检**：以收敛阶段的模型为零假设，检验连败、时段、组队等分组上的残差（式 (4.5)），并用 Miller–Sanjurjo 修正的方式读“连胜后胜率”（第 3.2.5 节）。

输出是个人实力随时间的曲线、波动幅度、上头效应的估计及其不确定性，以及“连败几局后该休息”这类可执行的建议；若数据里有对手评分，还能对本人的对局做一次第 3.6 节式的操纵检验。

对酒馆战棋 AI 的含义

酒馆战棋是 8 人名次游戏，前面的结论都要换成名次的语言（第 2.5.2 节与第 3.7 节与 4.9 节）：

- **“公平”的基准是名次而不是胜率**：同分大厅里平均名次 4.5、前四率 50%、第一名 12.5%。按内部评分匹配会把长期前四率推回约 50%，所以天梯前四率本身不衡量强弱。
- **训练用名次似然**：Plackett–Luce 的梯度就是“实际减期望”，一局完整名次的 Fisher 信息约为 1v1 胜负的 2.64 倍（式 (4.6)）；不要把名次压缩成“是否前四”。
- **评估用冻结参照池**：把若干历史版本与启发式机器人冻结成参照池，新版本进参照池大厅对局，报告名次分布和锚定的强度；不用“只和上一版比”的自博弈 Elo（图 4.6）。前四率提高 2 个百分点约需 4,900 局，平均名次改进 0.1 约需 4,100 局。
- **天梯分只在同条件下比较**：外显评分有地板、进度分和追赶倍率（第 1.7.3 节），跨赛季比较外显分会有偏。
- **别被“久不夺冠”吓到**：夺冠率 1/8 时，100 局里出现一段 ≥ 20 局无冠的概率约 60%（第 3.7 节）；判断版本好坏要看足够多局的名次分布，而不是最近一段的体感。

参考文献

[1] Herbrich R, Minka T, Graepel T. TrueSkill™: A Bayesian Skill Rating System [C/OL]//Advances in Neural Information Processing Systems 19 (NIPS 2006). MIT Press, 2007: 569-576 [2026-10-18]. https://proceedings.neurips.cc/paper_files/paper/2006/hash/f44ee263952e65b3610b8ba51229d1f9-Abstract.html.

[2] Glickman M E. A Comprehensive Guide to Chess Ratings[J/OL]. American Chess Journal, 1995, 3: 59-102 [2026-10-18]. https://www.glicko.net/research/acjpaper.pdf.

[3] Glickman M E. Example of the Glicko-2 System[EB/OL]. (2022-03-22) [2026-10-18]. https://www.glicko.net/glicko/glicko2.pdf.

[4] Stern H. Are All Linear Paired Comparison Models Empirically Equivalent?[J]. Mathematical Social Sciences, 1992, 23(1): 103-117. DOI: 10.1016/0165-4896(92)90040-C.

[5] International Chess Federation (FIDE). FIDE Rating Regulations Effective from 1 March 2024[EB/OL]. FIDE Handbook B.02. 2024 [2026-10-18]. https://handbook.fide.com/chapter/B022024.

[6] Thurstone L L. A Law of Comparative Judgment[J]. Psychological Review, 1927, 34(4): 273-286. DOI: 10.1037/h0070288.

[7] Mosteller F. Remarks on the Method of Paired Comparisons: I. The Least Squares Solution Assuming Equal Standard Deviations and Equal Correlations[J]. Psychometrika, 1951, 16(1): 3-9. DOI: 10.1007/BF02313422.

[8] Zermelo E. Die Berechnung der Turnier-Ergebnisse als ein Maximumproblem der Wahrscheinlichkeitsrechnung[J]. Mathematische Zeitschrift, 1929, 29(1): 436-460. DOI: 10.1007/BF01180541.

[9] Bradley R A, Terry M E. Rank Analysis of Incomplete Block Designs: I. The Method of Paired Comparisons[J]. Biometrika, 1952, 39(3/4): 324-345. DOI: 10.2307/2334029.

[10] Luce R D. Individual Choice Behavior: A Theoretical Analysis[M]. New York: Wiley, 1959.

[11] Plackett R L. The Analysis of Permutations[J]. Journal of the Royal Statistical Society: Series C (Applied Statistics), 1975, 24(2): 193-202. DOI: 10.2307/2346567.

[12] Elo A E. The Rating of Chessplayers, Past and Present[M]. 2nd ed. New York: Arco Publishing, 1986.

[13] Szczecinski L, Djebbi A. Understanding and Pushing the Limits of the Elo Rating Algorithm[EB/OL]. 2019 [2026-10-18]. https://arxiv.org/abs/1910.06081. arXiv: 1910.06081.

[14] Olesker-Taylor S, Zanetti L. An Analysis of Elo Rating Systems via Markov Chains[C]//Advances in Neural Information Processing Systems 37 (NeurIPS 2024). 2024: 138289-138323. arXiv: 2406.05869. DOI: 10.52202/079017-4389.

[15] Tang S, Wang Y, Jin C. Is Elo Rating Reliable? A Study Under Model Misspecification[EB/OL]. 2025 [2026-10-18]. https://arxiv.org/abs/2502.10985. arXiv: 2502.10985.

[16] Szczecinski L. New Insights into Elo Algorithm for Practitioners and Statisticians [EB/OL]. 2026 [2026-10-18]. https://arxiv.org/abs/2604.03840. arXiv: 2604.03840.

[17] International Chess Federation (FIDE). FIDE Seeks Public Discussion about Proposed Rating Changes[EB/OL]. (2023-07-22) [2026-10-18]. https://www.fide.com/news/2538.

[18] Regan K W, Haworth G M. Intrinsic Chess Ratings[C]//Proceedings of the AAAI Conference on Artificial Intelligence: vol. 25: 1. 2011: 834-839. DOI: 10.1609/aaai.v25i1.7951.

[19] Glickman M E. The Glicko System[EB/OL]. 2016 [2026-10-18]. https://www.glicko.net/glicko/glicko.pdf.

[20] Glickman M E. Parameter Estimation in Large Dynamic Paired Comparison Experiments[J]. Journal of the Royal Statistical Society: Series C (Applied Statistics), 1999, 48(3): 377-394. DOI: 10.1111/1467-9876.00159.

[21] Glickman M E. Dynamic Paired Comparison Models with Stochastic Variances [J]. Journal of Applied Statistics, 2001, 28(6): 673-689. DOI: 10.1080/02664760120059219.

[22] Chowdhary S, Iacopini I, Battiston F. Quantifying Human Performance in Chess [J]. Scientific Reports, 2023, 13: 2113. DOI: 10.1038/s41598-023-27735-9.

[23] Bober-Irizar M, Dua N, McGuinness M. Skill Issues: An Analysis of CS:GO Skill Rating Systems[EB/OL]. 2024 [2026-10-18]. https://arxiv.org/abs/2410.02831. arXiv: 2410.02831.

[24] Weng R C, Lin C J. A Bayesian Approximation Method for Online Ranking [J/OL]. Journal of Machine Learning Research, 2011, 12: 267-300 [2026-10-18]. https://www.jmlr.org/papers/v12/weng11a.html.

[25] Minka T, Cleven R, Zaykov Y. TrueSkill 2: An Improved Bayesian Skill Rating System[R/OL]. Microsoft Research. 2018 [2026-10-18]. https://www.microsoft.com/en-us/research/wp-content/uploads/2018/03/trueskill2.pdf.

[26] Dangauthier P, Herbrich R, Minka T, et al. TrueSkill Through Time: Revisiting the History of Chess[C/OL]//Advances in Neural Information Processing Systems 20 (NIPS 2007). 2008: 931-938 [2026-10-18]. https://papers.nips.cc/paper_files/paper/2007/file/9f53d83ec0691550f7d2507d57f4f5a2-Paper.pdf.

[27] Landfried G, Mocskos E. TrueSkill Through Time: Reliable Initial Skill Estimates and Historical Comparability with Julia, Python, and R[J]. Journal of Statistical Software, 2025, 112(6): 1-41. DOI: 10.18637/jss.v112.i06.

[28] Coulom R. Whole-History Rating: A Bayesian Rating System for Players of Time-Varying Strength[C]//Lecture Notes in Computer Science: Computers and Games (CG 2008): vol. 5131. Springer, 2008: 113-124. DOI: 10.1007/978-3-540-87608-3_11.

[29] Joshy V. OpenSkill: A Faster Asymmetric Multi-Team, Multiplayer Rating System[J]. Journal of Open Source Software, 2024, 9(93): 5901. DOI: 10.21105/joss.05901.

[30] Ebtekar A, Liu P. Elo-MMR: A Rating System for Massive Multiplayer Competitions[C]//Proceedings of the Web Conference 2021 (WWW '21). ACM, 2021: 1772-1784. DOI: 10.1145/3442381.3450091.

[31] Balduzzi D, Tuyls K, Pérolat J, et al. Re-evaluating Evaluation[C/OL]// Advances in Neural Information Processing Systems 31 (NeurIPS 2018). 2018: 3268-3279. arXiv: 1806.02643 [2026-10-18]. https://arxiv.org/abs/1806.02643.

[32] Czarnecki W M, Gidel G, Tracey B, et al. Real World Games Look Like Spinning Tops[C/OL]//Advances in Neural Information Processing Systems 33 (NeurIPS 2020). 2020. arXiv: 2004.09468 [2026-10-18]. https://arxiv.org/abs/2004.09468.

[33] Bertrand Q, Czarnecki W M, Gidel G. On the Limitations of the Elo, Real-World Games Are Transitive, Not Additive[C/OL]//Proceedings of Machine Learning Research: Proceedings of the 26th International Conference on Artificial Intelligence and Statistics (AISTATS 2023): vol. 206. 2023: 2905-2921 [2026-10-18]. https://proceedings.mlr.press/v206/bertrand23a.html.

[34] Aldous D. Elo Ratings and the Sports Model: A Neglected Topic in Applied Probability?[J]. Statistical Science, 2017, 32(4): 616-629. DOI: 10.1214/17-STS628.

[35] Jabin P E, Junca S. A Continuous Model for Ratings[J]. SIAM Journal on Applied Mathematics, 2015, 75(2): 420-442. DOI: 10.1137/140969324.

[36] Düring B, Torregrossa M, Wolfram M T. Boltzmann and Fokker–Planck Equations Modelling the Elo Rating System with Learning Effects[J]. Journal of Nonlinear Science, 2019, 29(3): 1095-1128. DOI: 10.1007/s00332-018-9512-8.

[37] Düring B, Fischer M, Wolfram M T. An Elo-Type Rating Model for Players and Teams of Variable Strength[J]. Philosophical Transactions of the Royal Society A, 2022, 380(2224), 20210155. DOI: 10.1098/rsta.2021.0155.

[38] Cortez R, Tossounian H. Convergence and Stationary Distribution of Elo Rating Systems[EB/OL]. 2024 [2026-10-18]. https://arxiv.org/abs/2410.09180. arXiv: 2410.09180.

[39] Zhou T, Fu Z, Yang T. Accelerating Skill Assessment in Chess: A Drift-Diffusion-Enhanced Elo Rating System[EB/OL]. 2026 [2026-10-18]. https://arxiv.org/abs/2606.26267. arXiv: 2606.26267.

[40] Yuksel C. Skill-Based Matchmaking for Competitive Two-Player Games[J]. Proceedings of the ACM on Computer Graphics and Interactive Techniques, 2024, 7(1). DOI: 10.1145/3651303.

[41] Emek Y, Kutten S, Wattenhofer R. Online Matching: Haste Makes Waste![C]//Proceedings of the 48th Annual ACM Symposium on Theory of Computing (STOC 2016). ACM, 2016: 333-344. DOI: 10.1145/2897518.2897557.

[42] Liu X, Pan Z, Wang Y, et al. Online Matching with Convex Delay Costs[EB/OL]. 2022 [2026-10-18]. https://arxiv.org/abs/2203.03335. arXiv: 2203.03335.

[43] Liu J, Zhang H, Zhang J. When to Match: A Cost-Balancing Principle for Dynamic Markets[EB/OL]. 2026 [2026-10-18]. https://arxiv.org/abs/2601.21858. arXiv: 2601.21858.

[44] Wang K, Liu H, Hu Z, et al. EnMatch: Matchmaking for Better Player Engagement via Neural Combinatorial Optimization[C]//Proceedings of the AAAI

Conference on Artificial Intelligence: vol. 38: 8. 2024: 9098-9106. DOI: 10.1609/aaai.v38i8.28760.

[45] Alman J, McKay D. Theoretical Foundations of Team Matchmaking[C/OL]// Proceedings of the 16th Conference on Autonomous Agents and MultiAgent Systems (AAMAS 2017). 2017: 1073-1081 [2026-10-18]. https://www.ifaamas.org/Proceedings/aamas2017/pdfs/p1073.pdf.

[46] Gong L, Feng X, Ye D, et al. OptMatch: Optimized Matchmaking via Modeling the High-Order Interactions on the Arena[C]//Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (KDD '20). 2020: 2300-2310. DOI: 10.1145/3394486.3403279.

[47] Deng Q, Li H, Wang K, et al. Globally Optimized Matchmaking in Online Games [C]//Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining (KDD '21). 2021: 2753-2763. DOI: 10.1145/3447548.3467074.

[48] Zhang C, Wang K, Chen H, et al. QuickSkill: Novice Skill Estimation in Online Multiplayer Games[C]//Proceedings of the 31st ACM International Conference on Information & Knowledge Management (CIKM '22). 2022: 3644-3653. DOI: 10.1145/3511808.3557070.

[49] Fan G, Zhang C, Wang K, et al. CUPID: Improving Battle Fairness and Position Satisfaction in Online MOBA Games with a Re-matchmaking System[J]. Proceedings of the ACM on Human-Computer Interaction, 2024, 8(CSCW2): 1-39. DOI: 10.1145/3686978.

[50] Delalleau O, Contal E, Thibodeau-Laufer E, et al. Beyond Skill Rating: Advanced Matchmaking in Ghost Recon Online[J]. IEEE Transactions on Computational Intelligence and AI in Games, 2012, 4(3): 167-177. DOI: 10.1109/TCIAIG.2012.2188833.

[51] Chen Z, Xue S, Kolen J, et al. EOMM: An Engagement Optimized Matchmaking Framework[C]//Proceedings of the 26th International Conference on World Wide Web (WWW '17). 2017: 1143-1150. DOI: 10.1145/3038912.3052559.

[52] Chen M, Elmachtoub A N, Lei X. Matchmaking Strategies for Maximizing Player Engagement in Video Games[J]. Management Science, 2026, 72(10): 8770-8788. DOI: 10.1287/mnsc.2023.02957.

[53] INFORMS. Smarter Matchmaking, Not Just Equal Skill, Could Keep Millions More Gamers Playing, Study Finds[EB/OL]. (2026-06-01) [2026-10-18]. https://www.informs.org/News-Room/INFORMS-Releases/News-Releases/Smarter-

Matchmaking-Not-Just-Equal-Skill-Could-Keep-Millions-More-Gamers-Playing-Study-Finds.

[54] Xue S, Wu M, Kolen J, et al. Dynamic Difficulty Adjustment for Maximized Engagement in Digital Games[C]//Proceedings of the 26th International Conference on World Wide Web Companion (WWW '17 Companion). 2017: 465-471. DOI: 10.1145/3041021.3054170.

[55] Hunicke R, Chapman V. AI for Dynamic Difficulty Adjustment in Games[C]// Challenges in Game Artificial Intelligence: Papers from the 2004 AAAI Workshop (19th National Conference on Artificial Intelligence). AAAI Press, 2004: 91-96.

[56] Hunicke R. The Case for Dynamic Difficulty Adjustment in Games[C]// Proceedings of the 2005 ACM SIGCHI International Conference on Advances in Computer Entertainment Technology (ACE '05). 2005: 429-433. DOI: 10.1145/1178477.1178573.

[57] Kang H, Suh C, Kim H K. Match Experiences Affect Interest: Impacts of Matchmaking and Performance on Churn in a Competitive Game[J]. Heliyon, 2024, 10(3): e24891. DOI: 10.1016/j.heliyon.2024.e24891.

[58] Kou Y, Li Y, Gui X, et al. Playing with Streakiness in Online Games: How Players Perceive and React to Winning and Losing Streaks in League of Legends [C]//Proceedings of the 2018 CHI Conference on Human Factors in Computing Systems (CHI '18). ACM, 2018: 1-14. DOI: 10.1145/3173574.3174152.

[59] Deng D, Trepanowski R, Li M, et al. Streaks and Coping: Decoding Player Performance in League of Legends Using Big Data from Top Players' Matches[C] //Companion Proceedings of the 2024 Annual Symposium on Computer-Human Interaction in Play (CHI PLAY Companion '24). ACM, 2024: 50-55. DOI: 10.1145/3665463.3678787.

[60] Sapienza A, Zeng Y, Bessi A, et al. Individual Performance in Team-Based Online Games[J]. Royal Society Open Science, 2018, 5(6): 180329. DOI: 10.1098/rsos.180329.

[61] Huang J, Zimmermann T, Nagappan N, et al. Mastering the Art of War: How Patterns of Gameplay Influence Skill in Halo[C]//Proceedings of the SIGCHI Conference on Human Factors in Computing Systems (CHI '13). ACM, 2013: 695-704. DOI: 10.1145/2470654.2470753.

[62] Dehpanah A, Ghori M F, Gemmell J, et al. The Evaluation of Rating Systems in Online Free-for-All Games[C/OL]//16th International Conference on Data Science (ICDATA '20). 2020 [2026-10-18]. https://arxiv.org/abs/2008.06787.

[63] Dehpanah A, Ghori M F, Gemmell J, et al. The Evaluation of Rating Systems in Team-Based Battle Royale Games[C/OL]//23rd International Conference on Artificial Intelligence (ICAI '21). 2021 [2026-10-18]. https://arxiv.org/abs/2105.14069.

[64] Dehpanah A, Ghori M F, Gemmell J, et al. Evaluating Team Skill Aggregation in Online Competitive Games[C/OL]//2021 IEEE Conference on Games (CoG). 2021 [2026-10-18]. https://arxiv.org/abs/2106.11397.

[65] Dehpanah A, Ghori M F, Gemmell J, et al. Player Modeling Using Behavioral Signals in Competitive Online Games[C/OL]//2021 International Conference on Computational Science and Computational Intelligence (CSCI). 2021 [2026-10-18]. https://arxiv.org/abs/2112.04379.

[66] Do T D, Wang S I, Yu D S, et al. Using Machine Learning to Predict Game Outcomes Based on Player-Champion Experience in League of Legends[C]// Proceedings of the 16th International Conference on the Foundations of Digital Games (FDG '21). ACM, 2021. DOI: 10.1145/3472538.3472579.

[67] Véron M, Marin O, Monnet S. Matchmaking in Multi-Player On-Line Games: Studying User Traces to Improve the User Experience[C]//Proceedings of the Network and Operating System Support on Digital Audio and Video Workshop (NOSSDAV '14). ACM, 2014: 7-12. DOI: 10.1145/2578260.2578265.

[68] Semenov A, Romov P, Korolev S, et al. Performance of Machine Learning Algorithms in Predicting Game Outcome from Drafts in Dota 2[C]//Communications in Computer and Information Science: Analysis of Images, Social Networks and Texts (AIST 2016): vol. 661. Springer, 2017: 26-37. DOI: 10.1007/978-3-319-52920-2_3.

[69] Yang Y, Qin T, Lei Y H. Real-time eSports Match Result Prediction[EB/OL]. 2017 [2026-10-18]. https://arxiv.org/abs/1701.03162. arXiv: 1701.03162.

[70] Hodge V, Devlin S, Sephton N, et al. Win Prediction in Esports: Mixed-Rank Match Prediction in Multi-player Online Battle Arena Games[EB/OL]. 2017 [2026-10-18]. https://arxiv.org/abs/1711.06498. arXiv: 1711.06498.

[71] Lee H, Hwang D, Kim H, et al. DraftRec: Personalized Draft Recommendation for Winning in Multi-Player Online Battle Arena Games[C]//Proceedings of the ACM Web Conference 2022 (WWW '22). 2022. DOI: 10.1145/3485447.3512278.

[72] De Bois M, Parmentier F, Puget R, et al. PandaSkill – Player Performance and Skill Rating in Esports: Application to League of Legends[EB/OL]. 2025 [2026-10-18]. https://arxiv.org/abs/2501.10049. arXiv: 2501.10049.

[73] Caplar N, Suznjevic M, Matijasevic M. Analysis of Player's In-Game Performance vs Rating: Case Study of Heroes of Newerth[C/OL]//Proceedings of the 8th International Conference on the Foundations of Digital Games (FDG 2013). 2013 [2026-10-18]. https://arxiv.org/abs/1305.5189.

[74] Cheng Z, Yang Y, Tan C, et al. What Makes a Good Team? A Large-Scale Study on the Effect of Team Composition in Honor of Kings[C]//The World Wide Web Conference (WWW '19). 2019: 2666-2672. DOI: 10.1145/3308558.3313530.

[75] Sismanis Y. How I Won the "Chess Ratings – Elo vs the Rest of the World" Competition[EB/OL]. 2010 [2026-10-18]. https://arxiv.org/abs/1012.4571. arXiv: 1012.4571.

[76] Rosenthal J S. An Investigation Into Probabilities of Streaks in Online Chess[J]. Harvard Data Science Review, 2025, 7(2). DOI: 10.1162/99608f92.6939122d.

[77] Thompson J J, Blair M R, Chen L, et al. Video Game Telemetry as a Critical Tool in the Study of Complex Skill Learning[J]. PLoS ONE, 2013, 8(9): e75129. DOI: 10.1371/journal.pone.0075129.

[78] Vinyals O, Babuschkin I, Czarnecki W M, et al. Grandmaster Level in StarCraft II Using Multi-Agent Reinforcement Learning[J]. Nature, 2019, 575(7782): 350-354. DOI: 10.1038/s41586-019-1724-z.

[79] Dockhorn A, Mostaghim S. Introducing the Hearthstone-AI Competition [EB/OL]. 2019 [2026-10-18]. https://arxiv.org/abs/1906.04238. arXiv: 1906.04238.

[80] Zhang Y, Fontaine M C, Hoover A K, et al. Deep Surrogate Assisted MAP-Elites for Automated Hearthstone Deckbuilding[C]//Proceedings of the Genetic and Evolutionary Computation Conference (GECCO '22). ACM, 2022. DOI: 10.1145/3512290.3528718.

[81] 王瑞. 竞技游戏中的 ELO 算法与匹配算法研究[D]. 导师吴建国. 安徽大学, 2019.

[82] 陈韦成. 评估玩家及团队影响力来平衡线上游戏的自动配对系统[D/OL]. 台湾交通大学资讯学院资讯学程. 2012 [2026-10-18]. https://ir.lib.nycu.edu.tw/handle/11536/71640.

[83] 黄志宏. 以团体评估探讨线上游戏团队对抗之配对平衡[D/OL]. 台湾交通大学. 2010 [2026-10-18]. https://ir.lib.nycu.edu.tw/handle/11536/48455.

[84] Riot Games. /dev: Matchmaking Real Talk[EB/OL]. (2018-02-26) [2026-10-18]. https://www.leagueoflegends.com/en-us/news/dev/dev-matchmaking-real-talk/.

[85] Riot Games. /dev: Making Matchmaking Better[EB/OL]. (2018-03-14) [2026-10-18]. https://www.leagueoflegends.com/en-us/news/dev/dev-making-matchmaking-better/.

[86] Riot Games. /dev: Making Sense of Matchmaking[EB/OL]. (2021-10-22) [2026-10-18]. https://wildrift.leagueoflegends.com/en-gb/news/dev/dev-making-sense-of-matchmaking/.

[87] Ahn S. “Losers Queue Doesn’t Exist” — Devs Explain Why You Keep Failing [EB/OL]. EarlyGame. (2024-02-12) [2026-10-18]. https://earlygame.com/news/lol/losers-queue-doesnt-exist.

[88] GGScore. Riot Games Denies Existence of Losers’ Queue: “We Only Match You on Your MMR”[EB/OL]. 2025 [2026-10-18]. https://ggscore.com/en/lol/news/70213.

[89] Riot Games. /dev: Ranked Update Season One 2025[EB/OL]. (2024-11-25) [2026-10-18]. https://www.leagueoflegends.com/en-gb/news/dev/dev-ranked-update-season-one-2025/.

[90] Riot Games. /dev: Ranked 2026[EB/OL]. (2025-12-01) [2026-10-18]. https://www.leagueoflegends.com/en-us/news/dev/dev-ranked-2026/.

[91] Riot Games. Ask VALORANT – Rank Rating Edition[EB/OL]. (2021-03-18) [2026-10-18]. https://playvalorant.com/en-us/news/dev/ask-valorant-rank-rating-edition/.

[92] Koh W. Valorant Dev Shuts Down Shroud’s Loser’s Queue Theory: ‘We Do Not Manipulate the Queue’[EB/OL]. ONE Esports. (2022-07-26) [2026-10-18]. https://www.oneesports.gg/valorant/losers-queue-valorant-ranked-shroud/.

[93] ONE Esports. Valorant Dev Explains Why You Might Feel Hard Stuck in Ranked [EB/OL]. (2024-10-03) [2026-10-18]. https://www.oneesports.gg/valorant/ranked-mmr-hard-stuck-valorant-dev/.

[94] PCGamesN. Dota 2 Is Set for Ranked Matchmaking[EB/OL]. (2013-12-07) [2026-10-18]. https://www.pcgamesn.com/dota/dota-2-set-ranked-matchmaking.

[95] Valve. Matchmaking Update[EB/OL]. (2017-04-20) [2026-10-18]. https://steamstore-a.akamaihd.net/news/externalpost/steam_community_announcements/1858141774304931332.

[96] Valve. Welcoming New Players[EB/OL]. (2017-07-29) [2026-10-18]. https://steamstore-a.akamaihd.net/news/externalpost/steam_community_announcements/2093463643457413488.

[97] Valve. Continuing Matchmaking Updates[EB/OL]. (2019-10-10) [2026-10-18]. https://steamstore-a.akamaihd.net/news/externalpost/steam_community_announcements/3051677487676270896.

[98] Valve. Gameplay Patch 7.35d and Matchmaking Features[EB/OL]. (2024-03-21) [2026-10-18]. https://steamstore-a.akamaihd.net/news/externalpost/steam_community_announcements/5686430301719384803.

[99] PC Gamer. CS:GO Ranks and How They Work[EB/OL]. (2021-01-13) [2026-10-18]. https://www.pcgamer.com/csgo-ranks-explained/.

[100] Valve. Your Time Is Now[EB/OL]. (2023-08-31) [2026-10-18]. https://steamstore-a.akamaihd.net/news/externalpost/steam_community_announcements/5141476355659151610.

[101] Valve. Release Notes for 10/10/2023[EB/OL]. (2023-10-11) [2026-10-18]. https://steamstore-a.akamaihd.net/news/externalpost/steam_community_announcements/5246188851832412936.

[102] Blizzard Entertainment. Overwatch 2 Developer Blog: Matchmaker and Competitive Deep Dive, Part 1[EB/OL]. Overwatch 官方网站. (2022-12-20) [2026-10-18]. https://overwatch.blizzard.com/en-us/news/23896785/.

[103] Blizzard Entertainment. Overwatch 2 Developer Blog: Explaining Matchmaker Goals and Plans, Part 2[EB/OL]. Overwatch 官方网站. (2023-01-30) [2026-10-18]. https://overwatch.blizzard.com/en-us/news/23910161/.

[104] Blizzard Entertainment. Developer Insights: Personal Rating in Hearthstone Battlegrounds[EB/OL]. Hearthstone 官方网站. (2019-11-27) [2026-10-18]. https://hearthstone.blizzard.com/en-us/news/23239989.

[105] Blizzard Entertainment. Developer Insights: Hearthstone Battlegrounds Rating System Update[EB/OL]. Hearthstone 官方网站. (2020-09-28) [2026-10-18]. https://hearthstone.blizzard.com/en-us/news/23523064.

[106] Hearthstone Wiki. Ranked[EB/OL]. [2026-10-18]. https://hearthstone.wiki.gg/wiki/Ranked.

[107] Blizzard Entertainment. StarCraft II Ladder Update – April 27, 2015[EB/OL]. (2015-04-27) [2026-10-18]. https://news.blizzard.com/en-us/article/18792768/starcraft-ii-ladder-update-april-27-2015.

[108] Activision Publishing. Call of Duty Update: An Inside Look at Matchmaking [EB/OL]. (2024-01-28) [2026-10-18]. https://www.callofduty.com/blog/2024/01/call-of-duty-update-an-Inside-look-at-matchmaking.

[109] Activision Publishing. Matchmaking Series: Ping[R/OL]. Activision Research. (2024-04-04) [2026-10-18]. https://research.activision.com/content/dam/atvi/activision/atvi-touchui/research/publications/docs/Call-of-Duty-Matchmaking-Series-PING.pdf.

[110] Activision Publishing. Matchmaking Series: The Role of Skill in Matchmaking [R/OL]. Activision Research. (2024-07-26) [2026-10-18]. https://www.activision.com/cdn/research/CallofDuty_Matchmaking_Series_2.pdf.

[111] Activision Publishing. Matchmaking Series: Matchmaking for MP Ranked Play [R/OL]. Activision Research. (2024-12-23) [2026-10-18]. https://activision.com/content/dam/atvi/activision/atvi-touchui/research/publications/docs/Ranked-Play-Matchmaking-Whitepaper-12-23-24.pdf.

[112] Treyarch. Call of Duty: Black Ops 7 Beta Patch Notes[EB/OL]. (2025-10-09) [2026-10-18]. https://www.callofduty.com/patchnotes/2025/10/call-of-duty-black-ops-7-beta-patch-notes.

[113] Respawn Entertainment. Apex Legends Matchmaking Update[EB/OL]. (2023-01-17) [2026-10-18]. https://www.ea.com/games/apex-legends/apex-legends/news/matchmaking-2023.

[114] PC Gamer. Fortnite Is Getting Skill-Based Matchmaking and Bots[EB/OL]. (2019-09-23) [2026-10-18]. https://www.pcgamer.com/fortnite-is-getting-skill-based-matchmaking-and-bots/.

[115] KRAFTON. Dev Letter: Matchmaking for Normal Match[EB/OL]. (2024-04-16) [2026-10-18]. https://pubg.com/en/news/7174.

[116] TechRadar. Yes, Arc Raiders Does Matchmake You Based on How Friendly or Aggressive You Are[EB/OL]. (2026-01-05) [2026-10-18]. https://www.techradar.com/gaming/yes-arc-raiders-does-matchmake-you-based-on-how-friendly-or-aggressive-you-are.

[117] Microsoft Research. TrueSkill™ Ranking System[EB/OL]. 2005 [2026-10-18]. https://www.microsoft.com/en-us/research/project/trueskill-ranking-system/.

[118] 343 Industries. Closer Look: Halo Infinite's Ranked Experience[EB/OL]. (2022-03-11) [2026-10-18]. https://www.halowaypoint.com/news/closer-look-halo-infinites-ranked-experience.

[119] Lichess. Chess Rating Systems[EB/OL]. [2026-10-18]. https://lichess.org/page/rating-systems.

[120] Chess.com. How Do Ratings Work on Chess.com?[EB/OL]. (2026-02-10) [2026-10-18]. https://support.chess.com/en/articles/8566476-how-do-ratings-work-on-chess-com.

[121] 张梓桐. 律师起诉腾讯要求公开《王者荣耀》匹配机制[EB/OL]. 每日经济新闻. (2025-08-16) [2026-10-18]. https://www.huxiu.com/article/4697662.html.

[122] IT 之家. 玩家起诉《王者荣耀》案审理终结：原告诉讼请求不成立，匹配算法不在行政监管强制公示及备案之列[EB/OL]. (2026-04-07) [2026-10-18]. https://www.ithome.com/0/936/723.htm.

[123] IT 之家. 腾讯《王者荣耀》S42 新赛季官宣 1 月 8 日上线，将以段位为主要依据进行匹配[EB/OL]. (2026-01-05) [2026-10-18]. https://www.ithome.com/0/910/430.htm.

[124] 17173. 等了 8 年！《王者荣耀》匹配机制终于重做，段位匹配真来了[EB/OL]. (2025-11-11) [2026-10-18]. https://news.17173.com/content/11112025/231259235.shtml.

[125] 快科技. 《王者荣耀》排位匹配机制大优化 新增负面信誉维度 正常玩家不再连续匹配问题队友[EB/OL]. (2026-08-12) [2026-10-18]. https://news.17173.com/content/08132026/020132459.shtml.

[126] Insider Gaming. Marvel Rivals Doesn't Use Controversial EOMM System, Says NetEase Games[EB/OL]. (2025-08-12) [2026-10-18]. https://insider-gaming.com/marvel-rivals-does-not-use-eomm-says-netease-games/.

[127] Sportskeeda. Marvel Rivals Dev Addresses EOMM and Explains Matchmaking [EB/OL]. (2025-08-23) [2026-10-18]. https://www.sportskeeda.com/esports/marvel-rivals-dev-addresses-eomm-explains-matchmaking.

[128] Marr M D, Kaplan K S, Lewis N T. System and Method for Driving Microtransactions in Multiplayer Video Games: US9789406B2[P/OL]. Activision Publishing, Inc. 申请 14/712,566，2015-05-14 提交；临时申请 2014-07-03. 2017-10-17 [2026-10-18]. https://image-ppubs.uspto.gov/dirsearch-public/print/downloadPdf/9789406.

[129] Gwaltney J. Activision Patent Encourages Microtransaction Spending Through Matchmaking (Update: Activision Responds)[EB/OL]. Game Informer. (2017-10-17) [2026-10-18]. https://www.gameinformer.com/b/news/archive/2017/10/17/activision-patent-encourages-microtransaction-spending-through-matchmaking.aspx.

[130] Marr M D, Kaplan K S, Lewis N T. Matchmaking System and Method for Multiplayer Video Games: US10322351B2[P/OL]. Activision Publishing, Inc. 申请

14/712,514，2015-05-14 提交. 2019-06-18 [2026-10-18]. https://image-ppubs.uspto.gov/dirsearch-public/print/downloadPdf/10322351.

[131] Marr M D, Kaplan K S, Lewis N T. Group Composition Matchmaking System and Method for Multiplayer Video Games: US10376792B2[P/OL]. Activision Publishing, Inc. 申请 14/712,608，2015-05-14 提交. 2019-08-13 [2026-10-18]. https://image-ppubs.uspto.gov/dirsearch-public/print/downloadPdf/10376792.

[132] Aghdaie N, Kolen J, Mattar M M, et al. Multiplayer Video Game Matchmaking Optimization: US9993735B2[P/OL]. Electronic Arts Inc. 申请 15/064,115，2016-03-08 提交. 2018-06-12 [2026-10-18]. https://image-ppubs.uspto.gov/dirsearch-public/print/downloadPdf/9993735.

[133] Aghdaie N, Kolen J, Mattar M M, et al. Multiplayer Video Game Matchmaking Optimization: US10610786B2[P/OL]. Electronic Arts Inc. US9993735 的续案. 2020-04-07 [2026-10-18]. https://image-ppubs.uspto.gov/dirsearch-public/print/downloadPdf/10610786.

[134] Aghdaie N, Kolen J, Mattar M M, et al. Multiplayer Video Game Matchmaking Optimization: US11141663B2[P/OL]. Electronic Arts Inc. US10610786 的续案. 2021-10-12 [2026-10-18]. https://image-ppubs.uspto.gov/dirsearch-public/print/downloadPdf/11141663.

[135] Xue S, Zaman K A U, Aghdaie N, et al. Multiplayer Video Game Matchmaking System and Methods: US10286327B2[P/OL]. Electronic Arts Inc. 申请 15/416,961，2017-01-26 提交；临时申请 2016-10-21. 2019-05-14 [2026-10-18]. https://image-ppubs.uspto.gov/dirsearch-public/print/downloadPdf/10286327.

[136] Xue S, Zaman K A U, Aghdaie N, et al. Multiplayer Video Game Matchmaking System and Methods: US10751629B2[P/OL]. Electronic Arts Inc. US10286327 的续案. 2020-08-25 [2026-10-18]. https://image-ppubs.uspto.gov/dirsearch-public/print/downloadPdf/10751629.

[137] Xue S, Zaman K A U, Aghdaie N, et al. Multiplayer Video Game Matchmaking System and Methods: US11344814B2[P/OL]. Electronic Arts Inc. US10751629 的续案. 2022-05-31 [2026-10-18]. https://image-ppubs.uspto.gov/dirsearch-public/print/downloadPdf/11344814.

[138] Karlsen G A, Trakhtenberg Y, et al. Game Quality-Centric Matchmaking for Online Gaming: US11071909B2[P/OL]. Electronic Arts Inc. 申请 15/925,224，2018-03-19 提交. 2021-07-27 [2026-10-18]. https://image-ppubs.uspto.gov/dirsearch-public/print/downloadPdf/11071909.

[139] Karlsen G A, Waller M R, et al. Game Quality-Centric Matchmaking for Online Gaming: US11845005B2[P/OL]. Electronic Arts Inc. US11071909 的续案. 2023-12-19 [2026-10-18]. https://image-ppubs.uspto.gov/dirsearch-public/print/downloadPdf/11845005.

[140] Wu M, Yu Q, Chaput H H, et al. User-Controllable Model-Driven Matchmaking: US11478715B1[P/OL]. Electronic Arts Inc. 申请 2020-06-22 提交；临时申请 2020-02-12. 2022-10-25 [2026-10-18]. https://image-ppubs.uspto.gov/dirsearch-public/print/downloadPdf/11478715.

[141] Aghdaie N, Kolen J, Mattar M M, et al. Dynamic Difficulty Adjustment: US9919217B2[P/OL]. Electronic Arts Inc. 申请 15/064,082，2016-03-08 提交；公开号 US2017/0259177A1. 2018-03-20 [2026-10-18]. https://image-ppubs.uspto.gov/dirsearch-public/print/downloadPdf/9919217.

[142] Aghdaie N, Kolen J, Mattar M M, et al. Dynamic Difficulty Adjustment: US10286323B2[P/OL]. Electronic Arts Inc. US9919217 的续案. 2019-05-14 [2026-10-18]. https://image-ppubs.uspto.gov/dirsearch-public/print/downloadPdf/10286323.

[143] Aghdaie N, Kolen J, Mattar M M, et al. Dynamic Difficulty Adjustment: US10807004B2[P/OL]. Electronic Arts Inc. US10286323 的续案. 2020-10-20 [2026-10-18]. https://image-ppubs.uspto.gov/dirsearch-public/print/downloadPdf/10807004.

[144] Graepel T K H, Herbrich R. Bayesian Scoring: US7050868B1[P/OL]. Microsoft Corporation. 申请 11/041,752，2005-01-24 提交. 2006-05-23 [2026-10-18]. https://image-ppubs.uspto.gov/dirsearch-public/print/downloadPdf/7050868.

[145] Graepel T K H, Herbrich R. Bayesian Scoring: US7376474B2[P/OL]. Microsoft Corporation. US7050868 的续案. 2008-05-20 [2026-10-18]. https://image-ppubs.uspto.gov/dirsearch-public/print/downloadPdf/7376474.

[146] Minka T, Graepel T K H, Herbrich R. Determining Relative Skills of Players: US8538910B2[P/OL]. Microsoft Corporation. PCT 2007-01-16 提交；公开号 US2009/0227313A1. 2013-09-17 [2026-10-18]. https://image-ppubs.uspto.gov/dirsearch-public/print/downloadPdf/8538910.

[147] Graepel T, Herbrich R, Shaw D. Adaptive Matchmaking for Games: US8672764B2[P/OL]. Microsoft Corporation. 申请 11/693,635，2007-03-29 提交；公开号 US2008/0242420A1. 2014-03-18 [2026-10-18]. https://image-ppubs.uspto.gov/dirsearch-public/print/downloadPdf/8672764.

[148] Lin J, Sottosanti P. Systems and Methods that Enable Player Matching for Multi-Player Online Games: US9795887B2[P/OL]. Riot Games, Inc. 申请 13/551,338, 2012-07-17 提交. 2017-10-24 [2026-10-18]. https://image-ppubs.uspto.gov/dirsearch-public/print/downloadPdf/9795887.

[149] Lin J, Sottosanti P. Systems and Methods that Enable Player Matching for Multi-Player Online Games: US11065547B2[P/OL]. Riot Games, Inc. US9795887 的续案, 申请 15/706,551, 2017-09-15 提交. 2021-07-20 [2026-10-18]. https://image-ppubs.uspto.gov/dirsearch-public/print/downloadPdf/11065547.

[150] Tripathi R, Moormann J B, Mozolewski T, et al. Activity-Factored Team Formation in Multiplayer Online Gaming: US11484801B2[P/OL]. Riot Games, Inc. 申请 17/210,312, 2021-03-23 提交. 2022-11-01 [2026-10-18]. https://image-ppubs.uspto.gov/dirsearch-public/print/downloadPdf/11484801.

[151] Hao S, Qi G, Chen J. Method and Apparatus for Game Matching, Storage Medium, and Electronic Device: US12533594B2[P/OL]. Beijing Bytedance Network Technology Co., Ltd. 申请 18/323,707, 2023-05-25 提交; 中国优先权 202210583584.4 (2022-05-25). 2026-01-27 [2026-10-18]. https://image-ppubs.uspto.gov/dirsearch-public/print/downloadPdf/12533594.

[152] He K, Mao Z, Luo R, et al. Method and Server for PVP Team Matching in Computer Games: US9149725B2[P/OL]. Tencent Technology (Shenzhen) Company Limited. PCT/CN2014/072145 的续案; 中国优先权 2013-06-03. 2015-10-06 [2026-10-18]. https://image-ppubs.uspto.gov/dirsearch-public/print/downloadPdf/9149725.

[153] Zajonc, Jason and Williams, Danyael and Lozano, Pranko. Class Action Complaint, *Zajonc v. Electronic Arts Inc.*, No. 3:20-cv-07871[EB/OL]. (2020-11-09) [2026-10-18]. https://storage.courtlistener.com/recap/gov.uscourts.cand.368570/gov.uscourts.cand.368570.1.0_2.pdf.

[154] CourtListener. Docket for *Zajonc v. Electronic Arts Inc.*, 3:20-cv-07871 (N.D. Cal.)[EB/OL]. (2021-02-11) [2026-10-18]. https://www.courtlistener.com/docket/18618247/zajonc-v-electronic-arts-inc/.

[155] Electronic Arts. Fair Play & Dynamic Difficulty Adjustment[EB/OL]. (2021-03-03) [2026-10-18]. https://www.ea.com/news/fair-play-and-dynamic-difficulty-adjustment.

[156] 张冰晶. 紫牛头条 | “王者”女律师起诉王者荣耀公开匹配机制：不为输赢期待推动行业改变[EB/OL]. 扬子晚报 / 紫牛新闻. (2026-02-02) [2026-10-18]. https://www.yzwb.net/news/zntt/202602/t20260202_317953.html.

[157] 范佳来, 刘天颖. 律师起诉腾讯要求公布《王者荣耀》匹配机制, 算法到底属于公共利益还是商业机密? [EB/OL]. 澎湃新闻. (2025-08-15) [2026-10-18]. https://m.thepaper.cn/newsDetail_forward_31398420.

[158] 张冰晶. “律师诉王者荣耀匹配算法案”一审宣判：驳回原告全部诉讼请求[EB/OL]. 扬子晚报 / 紫牛新闻. (2026-04-08) [2026-10-18]. https://www.yzwb.net/news/sh/202604/t20260408_339832.html.

[159] 同花顺财经. 律师要求公开《王者荣耀》匹配算法，法院一审宣判：驳回原告全部诉讼请求，匹配算法属于商业秘密[EB/OL]. (2026-04-08) [2026-10-18]. https://stock.10jqka.com.cn/20260408/c675834352.shtml.

[160] TapTap 用户帖.《王者荣耀》匹配算法诉讼原告全部诉求被驳回[EB/OL]. (2026-04-09) [2026-10-18]. https://www.taptap.cn/moment/791333970015946916.

[161] 国家互联网信息办公室, 工业和信息化部, 公安部, 等. 互联网信息服务算法推荐管理规定[EB/OL]. (2021-12-31) [2026-10-18]. https://www.gov.cn/zhengce/zhengceku/2022-01/04/content_5666429.htm.

[162] 蔡荣伟. 速评丨国家新闻出版署《网络游戏管理办法（草案征求意见稿）》[EB/OL]. 中伦律师事务所. (2023-12-25) [2026-10-18]. https://www.zhonglun.com/research/articles/15986.html.

[163] Bowling S R, Khasawneh M T, Kaewkuekool S, et al. A Logistic Approximation to the Cumulative Normal Distribution[J]. Journal of Industrial Engineering and Management, 2009, 2(1): 114-127. DOI: 10.3926/jiem.2009.v2n1.p114-127.

[164] Wilson E B. Probable Inference, the Law of Succession, and Statistical Inference [J]. Journal of the American Statistical Association, 1927, 22(158): 209-212. DOI: 10.1080/01621459.1927.10502953.

[165] Brown L D, Cai T T, DasGupta A. Interval Estimation for a Binomial Proportion [J]. Statistical Science, 2001, 16(2): 101-133. DOI: 10.1214/ss/1009213286.

[166] 忻映侃娱乐. elo 机制让我明白，有时候不是你不强，是系统真的在控制你的胜率[EB/OL]. 搜狐. (2026-06-11) [2026-10-18]. https://www.sohu.com/a/1035070363_122724367.

[167] 爱妃说笑了. 连胜之后必定连跪，王者 ELO 机制控制胜率，玩家究竟该如何自救[EB/OL]. 小米游戏中心. (2022-05-30) [2026-10-18]. https://game.xiaomi.com/viewpoint/1428140399_1653915752077_16.

[168] 会飞的鱼. 王者荣耀 elo 机制是什么? 王者荣耀 elo 机制官方解释[EB/OL]. 光环助手. (2022-11-11) [2026-10-18]. https://www.ghzs.com/wzry/54.

[169] U/renecotyfanboy. [2023] Existence of Loser Queue? A Statistical Analysis [EB/OL]. Reddit r/leagueoflegends（devtrackers.gg 转载）. 2023 [2026-10-18]. https://devtrackers.gg/leagueoflegends/p/1e570d00-existence-of-loser-queue-a-statistical-analysis.

[170] Gordon L, Schilling M F, Waterman M S. An Extreme Value Theory for Long Head Runs[J]. Probability Theory and Related Fields, 1986, 72(2): 279-287. DOI: 10.1007/BF00699107.

[171] Schilling M F. The Longest Run of Heads[J]. The College Mathematics Journal, 1990, 21(3): 196-207. DOI: 10.1080/07468342.1990.11973306.

[172] Schilling M F. Long Run Predictions[J/OL]. Math Horizons, 1994, 1(2): 10-12 [2026-10-18]. https://www.jstor.org/stable/25677964.

[173] Miller J B, Sanjurjo A. Surprised by the Hot Hand Fallacy? A Truth in the Law of Small Numbers[J]. Econometrica, 2018, 86(6): 2019-2047. DOI: 10.3982/ECTA14943.

[174] ITero. LoL: Analyzing "Tilt" to Win More Games[EB/OL]. (2020-05-28) [2026-10-18]. https://www.itero.gg/articles/lol-tilt.

[175] Smith G, Levere M, Kurtzman R. Poker Player Behavior After Big Wins and Big Losses[J]. Management Science, 2009, 55(9): 1547-1555. DOI: 10.1287/mnsc.1090.1044.

[176] Falk R, Konold C. Making Sense of Randomness: Implicit Encoding as a Basis for Judgment[J]. Psychological Review, 1997, 104(2): 301-318. DOI: 10.1037/0033-295X.104.2.301.

[177] Tversky A, Kahneman D. Belief in the Law of Small Numbers[J]. Psychological Bulletin, 1971, 76(2): 105-110. DOI: 10.1037/h0031322.

[178] Gilovich T, Vallone R, Tversky A. The Hot Hand in Basketball: On the Misperception of Random Sequences[J]. Cognitive Psychology, 1985, 17(3): 295-314. DOI: 10.1016/0010-0285(85)90010-6.

[179] Baumeister R F, Bratslavsky E, Finkenauer C, et al. Bad Is Stronger than Good [J]. Review of General Psychology, 2001, 5(4): 323-370. DOI: 10.1037/1089-2680.5.4.323.

[180] Mezulis A H, Abramson L Y, Hyde J S, et al. Is There a Universal Positivity Bias in Attributions? A Meta-Analytic Review of Individual, Developmental, and Cultural Differences in the Self-Serving Attributional Bias[J]. Psychological Bulletin, 2004, 130(5): 711-747. DOI: 10.1037/0033-2909.130.5.711.

[181] Silver D, Schrittwieser J, Simonyan K, et al. Mastering the Game of Go without Human Knowledge[J]. Nature, 2017, 550(7676): 354-359. DOI: 10.1038/nature24270.

[182] Boubdir M, Kim E, Ermis B, et al. Elo Uncovered: Robustness and Best Practices in Language Model Evaluation[C/OL]//Proceedings of the Third Workshop on Natural Language Generation, Evaluation, and Metrics (GEM). Association for Computational Linguistics, 2023: 339-352 [2026-10-18]. https://aclanthology.org/2023.gem-1.28/.

[183] Chiang W L, Zheng L, Sheng Y, et al. Chatbot Arena: An Open Platform for Evaluating LLMs by Human Preference[C/OL]//Proceedings of the 41st International Conference on Machine Learning (ICML). 2024. arXiv: 2403.04132 [2026-10-18]. https://arxiv.org/abs/2403.04132.

[184] Berner C, Brockman G, Chan B, et al. Dota 2 with Large Scale Deep Reinforcement Learning[EB/OL]. 2019 [2026-10-18]. https://arxiv.org/abs/1912.06680. arXiv: 1912.06680.

[185] Yashkov D, Romov P, Neklyudov K, et al. Applications of Machine Learning in DOTA2: Literature Review and Practical Knowledge Sharing[EB/OL]. 2016 [2026-10-18]. https://dtai.cs.kuleuven.be/events/MLSA16/slides/05_Daniil_Yashkov.pdf.

[186] Silver D, Hubert T, Schrittwieser J, et al. Mastering Chess and Shogi by Self-Play with a General Reinforcement Learning Algorithm[EB/OL]. 2017 [2026-10-18]. https://arxiv.org/abs/1712.01815. arXiv: 1712.01815.

[187] Leela Chess Zero. FAQ – Leela Chess Zero（开发者维基）[EB/OL]. 2019 [2026-10-18]. https://lczero.org/dev/wiki/faq/.

[188] Balduzzi D, Garnelo M, Bachrach Y, et al. Open-ended Learning in Symmetric Zero-sum Games[C/OL]//PMLR: Proceedings of the 36th International Conference on Machine Learning (ICML): vol. 97. 2019: 434-443. arXiv: 1901.08106 [2026-10-18]. https://arxiv.org/abs/1901.08106.

[189] Chiang W L, Li T, Gonzalez J E, et al. Chatbot Arena: New Models & Elo System Update[EB/OL]. LMSYS Org. (2023-12-07) [2026-10-18]. https://lmsys.org/blog/2023-12-07-leaderboard/.

[190] Christiano P, Leike J, Brown T B, et al. Deep Reinforcement Learning from Human Preferences[C/OL]//Advances in Neural Information Processing Systems 30 (NIPS 2017). 2017. arXiv: 1706.03741 [2026-10-18]. https://arxiv.org/abs/1706.03741.

[191] Ouyang L, Wu J, Jiang X, et al. Training Language Models to Follow Instructions with Human Feedback[C/OL]//Advances in Neural Information Processing Systems 35 (NeurIPS 2022). 2022. arXiv: 2203.02155 [2026-10-18]. https://arxiv.org/abs/2203.02155.

[192] Goodfellow I J, Pouget-Abadie J, Mirza M, et al. Generative Adversarial Nets [C/OL]//Advances in Neural Information Processing Systems 27 (NIPS 2014). 2014. arXiv: 1406.2661 [2026-10-18]. https://arxiv.org/abs/1406.2661.

附录 A　推导与模拟细节

A.1　第一章学术部分的推导与公式

A.1.1　正态曲线与 Elo 逻辑斯蒂曲线的刻度换算

Elo 曲线式 (1.3) 在分差 0 处的斜率为 $F'(0)=c/4=\ln 10/1600\approx 1.439\times 10^{-3}$（每分）。正态曲线 $\Phi\big(x/(\sigma\sqrt{2})\big)$ 在 0 处的斜率为 $1/(\sigma\sqrt{2}\sqrt{2\pi})$。令两者相等，得

$$\sigma=\frac{1600}{\ln 10\cdot\sqrt{2}\cdot\sqrt{2\pi}}\approx 196,$$

即“400 分刻度的逻辑斯蒂曲线”在中心附近等价于“每人单局表现标准差约 196 分”的正态曲线，与 Elo 原书取的 200 几乎相同【本项目】。用 FIDE 现行条例 8.1.1 表（$p=0.51,\dots,0.99$ 共 49 格）做最小二乘拟合，得到的单人标准差为 202.6；表中分差与 $\sigma=200$ 的正态曲线最大相差 19 分（$p=0.99$ 处），与 Elo 逻辑斯蒂曲线最大相差 121 分（同一处）【本项目】。两种曲线在中段几乎重合，差别只在 $p>0.9$ 的尾部：逻辑斯蒂曲线给弱者留的胜率更大。脚本见 `code/ch1/fig_1a_curves.py`。

A.1.2　Glicko 与 Glicko-2 的完整公式

Glicko。　按 Glickman 公开的计算步骤[19]：每个评分周期开始时，未定级玩家取 $r=1500$、RD$=350$，其他玩家 RD $\leftarrow\min\big(\sqrt{\mathrm{RD}^2+c^2},\,350\big)$。若希望一个 RD$=50$ 的常客在 30 个周期不下棋后回到 350，则 $c=\sqrt{(350^2-50^2)/30}\approx 63.2$。周期结束时，设对手 $j=1,\dots,m$ 的评分与偏差为 r_j,RD_j，得分 $s_j\in\{0,\tfrac12,1\}$，

$$q=\frac{\ln 10}{400},\qquad g(\mathrm{RD})=\frac{1}{\sqrt{1+3q^2\mathrm{RD}^2/\pi^2}},\qquad E_j=\frac{1}{1+10^{-g(\mathrm{RD}_j)(r-r_j)/400}},$$

$$d^2=\Big[q^2\sum_j g(\mathrm{RD}_j)^2E_j(1-E_j)\Big]^{-1},$$

$$r'=r+\frac{q}{1/\mathrm{RD}^2+1/d^2}\sum_j g(\mathrm{RD}_j)(s_j-E_j),\qquad \mathrm{RD}'=\Big(\frac{1}{\mathrm{RD}^2}+\frac{1}{d^2}\Big)^{-1/2}.$$

预测两名玩家 i、j 的对局时，用 $E=\big[1+10^{-g(\sqrt{\mathrm{RD}_i^2+\mathrm{RD}_j^2})(r_i-r_j)/400}\big]^{-1}$，图 1.1(a) 的点划线即双方 RD$=350$ 时的这一曲线。

Glicko-2。　按 Glickman 的算例文档[3]：先换到内部刻度 $\mu=(r-1500)/173.7178$、$\phi=\mathrm{RD}/173.7178$；令 $g(\phi)=(1+3\phi^2/\pi^2)^{-1/2}$，$E_j=\big[1+e^{-g(\phi_j)(\mu-\mu_j)}\big]^{-1}$，

$$v=\Big[\sum_j g(\phi_j)^2E_j(1-E_j)\Big]^{-1},\qquad \Delta=v\sum_j g(\phi_j)(s_j-E_j).$$

新的波动率 σ' 由方程 $f(x)=\dfrac{e^x(\Delta^2-\phi^2-v-e^x)}{2(\phi^2+v+e^x)^2}-\dfrac{x-\ln\sigma^2}{\tau^2}=0$ 的根 $x=\ln\sigma'^2$ 给出，用 Illinois 试位法求解（2012 年修订版）。然后

$$\phi^*=\sqrt{\phi^2+\sigma'^2},\qquad \phi'=\Big(\frac{1}{\phi^{*2}}+\frac{1}{v}\Big)^{-1/2},\qquad \mu'=\mu+\phi'^2\sum_j g(\phi_j)(s_j-E_j),$$

再换回 $r'=173.7178\mu'+1500$、$\mathrm{RD}'=173.7178\phi'$。一个周期不比赛时只做 $\phi'=\phi^*$ 这一步。

A.1.3　TrueSkill 两人更新式

设胜方、负方实力的先验为 $s_\mathrm{w}\sim\mathcal{N}(\mu_\mathrm{w},\sigma_\mathrm{w}^2)$、$s_\mathrm{l}\sim\mathcal{N}(\mu_\mathrm{l},\sigma_\mathrm{l}^2)$，表现 $p=s+\mathcal{N}(0,\beta^2)$。表现差 $d=p_\mathrm{w}-p_\mathrm{l}\sim\mathcal{N}(m,c^2)$，其中 $m=\mu_\mathrm{w}-\mu_\mathrm{l}$，$c^2=\sigma_\mathrm{w}^2+\sigma_\mathrm{l}^2+2\beta^2$。观测到“胜方获胜且不是平局”即 $d>\varepsilon$。

截断正态的矩。　记 $d=m+cZ$，Z 为标准正态，$t=m/c$，$a=\varepsilon/c$，$u=t-a$，则 $d>\varepsilon\Leftrightarrow Z>-u$，且

$$\begin{aligned}\mathbb{E}[Z\mid Z>-u]&=\frac{\varphi(u)}{\Phi(u)}=:v(t,a),\\ \mathrm{Var}[Z\mid Z>-u]&=1-v(t,a)\big(v(t,a)+u\big)=:1-w(t,a).\end{aligned}$$

传回实力。　(s_w,d) 联合正态，$\mathrm{Cov}(s_\mathrm{w},d)=\sigma_\mathrm{w}^2$，故 $\mathbb{E}[s_\mathrm{w}\mid d]=\mu_\mathrm{w}+(\sigma_\mathrm{w}^2/c^2)(d-m)$，$\mathrm{Var}[s_\mathrm{w}\mid d]=\sigma_\mathrm{w}^2(1-\sigma_\mathrm{w}^2/c^2)$。对条件 $d>\varepsilon$ 用全期望与全方差公式：

$$\begin{aligned}\mathbb{E}[s_\mathrm{w}\mid d>\varepsilon]&=\mu_\mathrm{w}+\frac{\sigma_\mathrm{w}^2}{c}\,v(t,a),\\ \mathrm{Var}[s_\mathrm{w}\mid d>\varepsilon]&=\sigma_\mathrm{w}^2\Big(1-\frac{\sigma_\mathrm{w}^2}{c^2}\Big)+\frac{\sigma_\mathrm{w}^4}{c^4}\,c^2\big(1-w(t,a)\big)=\sigma_\mathrm{w}^2\Big(1-\frac{\sigma_\mathrm{w}^2}{c^2}\,w(t,a)\Big).\end{aligned}$$

负方的 $\mathrm{Cov}(s_\mathrm{l},d)=-\sigma_\mathrm{l}^2$，均值更新取负号，方差更新形式相同。TrueSkill 把后验近似为具有这两个矩的高斯（期望传播中的矩匹配），即得式 (1.7)。若有动态方差 γ^2（TrueSkill 论文的记号），赛前先令 $\sigma^2\leftarrow\sigma^2+\gamma^2$。爆冷时 $t\ll0$，$v\approx a-t$ 很大，均值更新幅度近似与“爆冷程度”成正比；$t\gg0$（强者赢弱者）时 $v\to0$，几乎不更新【本项目】。

A.1.4　TrueSkill 匹配质量即相对平局概率

平局边际 ε 很小时，$\mathbb{P}(|d| \le \varepsilon) \approx 2\varepsilon \cdot \frac{1}{c\sqrt{2\pi}} \exp\!\big(-\frac{m^2}{2c^2}\big)$。它的最大可能值出现在 $m=0$ 且双方实力完全确定（$\sigma_i=\sigma_j=0$，$c^2=2\beta^2$）时，为 $2\varepsilon/\big(\sqrt{2\beta^2}\sqrt{2\pi}\big)$。两者之比与 ε 无关：

$$q_{\text{draw}} = \sqrt{\frac{2\beta^2}{c^2}}\exp\!\Big(-\frac{m^2}{2c^2}\Big), \qquad c^2 = 2\beta^2+\sigma_i^2+\sigma_j^2,$$

即式 (1.8)。它同时惩罚均值差（指数项）和不确定性（根号项）：两个新号即使均值相同，质量也低于两个均值相同的老玩家【本项目】。

A.1.5　Weng–Lin 的 Bradley–Terry 全配对更新

按 Weng 与 Lin 的算法 1[24]：队伍 i 的实力均值与方差取成员之和 $\mu_i=\sum_j \mu_{ij}$、$\sigma_i^2=\sum_j \sigma_{ij}^2$；对每支对手队 $q\neq i$，

$$c_{iq}=\sqrt{\sigma_i^2+\sigma_q^2+2\beta^2}, \qquad \hat{p}_{iq}=\frac{e^{\mu_i/c_{iq}}}{e^{\mu_i/c_{iq}}+e^{\mu_q/c_{iq}}},$$
$$\delta_q=\frac{\sigma_i^2}{c_{iq}}\big(s_{iq}-\hat{p}_{iq}\big), \qquad \eta_q=\gamma_q\frac{\sigma_i^2}{c_{iq}^2}\hat{p}_{iq}\hat{p}_{qi},$$

其中 s_{iq} 为 1（i 名次在前）、1/2（并列）或 0，γ_q 为可选的缩放因子。令 $\Omega_i=\sum_{q\neq i}\delta_q$、$\Delta_i=\sum_{q\neq i}\eta_q$，成员更新为

$$\mu_{ij}\leftarrow\mu_{ij}+\frac{\sigma_{ij}^2}{\sigma_i^2}\,\Omega_i, \qquad \sigma_{ij}^2\leftarrow\sigma_{ij}^2\max\!\Big(1-\frac{\sigma_{ij}^2}{\sigma_i^2}\Delta_i,\ \kappa\Big),$$

$\kappa>0$ 防止方差变为非正。与 Elo 的式 (1.6) 相比，“实际减预测”的结构相同，步长则正比于各自的方差。

A.1.6　EOMM 的三种特例

设玩家流失只取决于本局结果，记 $c(\mathrm{W})$、$c(\mathrm{L})$、$c(\mathrm{D})$ 为胜、负、平后的流失概率，$P_{ij}(\cdot)$ 为 i 对 j 的结果分布。一对玩家的流失之和为

$$\begin{aligned}&P_{ij}(\mathrm{W})\big[c(\mathrm{W})+c(\mathrm{L})\big]+P_{ij}(\mathrm{L})\big[c(\mathrm{L})+c(\mathrm{W})\big]+P_{ij}(\mathrm{D})\cdot 2c(\mathrm{D})\\ &\quad=\big[c(\mathrm{W})+c(\mathrm{L})\big]-P_{ij}(\mathrm{D})\big[c(\mathrm{W})+c(\mathrm{L})-2c(\mathrm{D})\big].\end{aligned}$$

对所有配对求和后，最小化总流失等价于：若 $c(\mathrm{W})+c(\mathrm{L})>2c(\mathrm{D})$，最大化总平局概率；若不等号反向，最小化总平局概率。平局在实力相近时最可能发生，所以前一种情形下按分匹配最优，后一种情形下按分匹配最差。若流失与本局结果无关（只取决于赛前状态），总流失与配对无关，任何匹配（包括随机匹配）都一样。这就是 Chen 等[51] 第 4 节的结论。

由此还可以推出一点【本项目】：在没有平局的输赢游戏中，若流失只取决于本局结果，则每对玩家的流失之和恒为 $c(\mathrm{W})+c(\mathrm{L})$，匹配对总流失毫无影响。参与度优化匹配要有效果，流失必须依赖于玩家的状态（例如最近几局的胜负、技能、在线时长），而且这种依赖要因人而异。EOMM 的输入正是“最近 10 局的胜负平”等状态变量，这也是它与“按连胜连败安排对手”在机制上相通的原因。

A.1.7　Yuksel 目标胜率公式

设玩家最近 n 局赢了 w 局，希望包含接下来 $n+1$ 局在内、长 $2n+1$ 的窗口的期望胜率为 λ。若接下来每局对手都使其胜率为 p，窗口期望胜局数为 $w+(n+1)p$，令其等于 $\lambda(2n+1)$ 即得式 (1.12)。两人游戏取 $\lambda=1/2$、论文实验取 $n=5$ 时，$w=0,1,\ldots,5$ 对应的目标胜率依次为 $11/12,\ 9/12,\ 7/12,\ 5/12,\ 3/12,\ 1/12$（约 92%、75%、58%、42%、25%、8%）【本项目】。论文在评分 $f^{-1}(p\pm\Delta p)$ 范围内找对手，实验取 $\Delta p=1/(2n+2)=1/12$；作者指出取严格小于该值才能保证 $p\pm\Delta p$ 落在 $(0,1)$ 内[40]。换言之，这一匹配器对近期战绩的反应相当强：连赢 5 局后，下一局几乎一定会遇到明显更强的对手。

A.2　厂商披露与专利部分的检索方法与核算

A.2.1　来源与读取方式

第 1.7 节至第 1.11 节的材料于 2026 年 10 月 18—19 日读取，分三类：

- **官方网页与白皮书**：直接下载原页面或 PDF 并通读。Riot、Blizzard、Respawn、343、KRAFTON、微软研究院、Lichess、Chess.com 的页面，以及 Activision 的博客和三份白皮书 PDF，均读到原文；Valve 的 Dota 2 与 CS2 公告经 Steam 新闻接口读取原文。以下只读到二手转述，正文已加脚注：Valve 2013 年 Dota 2 天梯博客（原页已下线，依据 PCGamesN 引文）、Epic 2019 年公告（依据 PC Gamer 引文）、Riot 2025 年 15.14 版本推文、Valve 员工 2015 年 Reddit 回复、《王者荣耀》2018 年《狄仁杰答疑》原文、2026 年 8 月“对局环境优化专栏”原文、《漫威争锋》说明视频、ARC Raiders 访谈。
- **专利**：Google Patents、Justia 等在本研究网络环境中拒绝自动访问，因此改用美国专利商标局的全文图像 PDF（`image-ppubs.uspto.gov`），用 Tesseract 5.3 对首页和最后五页做光学字符识别，读取著录项（专利号、权利人、发明人、申请号、提交日、授权日、优先权、续案关系）和全部独立权利要求，必要时读从属权利要求。OCR 文本偶有断词和双栏串行，正文只转述可以确认的内容。专利的法律状态（是否维持、是否到期）未核对。中国国家知识产权局检索系统同样不可访问，中国专利只能通过搜索引擎查找，未能核对权利要求。

- **诉讼与法规**：Zajonc 诉 EA 的起诉状与撤诉通知取自 CourtListener 收录的联邦法院电子案卷（PACER/RECAP）；王者荣耀案的判决书未公开，依据扬子晚报、澎湃新闻、每日经济新闻、IT 之家、同花顺财经等多家报道交叉核对；《算法推荐管理规定》取自中国政府网全文。

A.2.2　公平对局中的连败概率

正文两处厂商说法涉及“完全公平时会出现多少连败”。设每局胜率恰为 1/2、各局独立，令 $q_k(n)$ 为 n 局中至少出现一次长度不小于 k 的连败的概率。用“当前连败长度” $j \in \{0,\dots,k-1\}$ 作状态做动态规划：每局以 1/2 的概率 $j \to j+1$（若达到 k 则记为命中并吸收），以 1/2 的概率 $j \to 0$。数值结果【本项目】：

- 连续 5 局全负的概率 $= 2^{-5} = 3.1\%$，与 Activision 白皮书“约 3% 的玩家会经历五连败”一致[110]；
- 100 局中至少一次 10 连败：$q_{10}(100) \approx 4.4\%$；至少一次 10 连胜或 10 连败：约 8.7%。《英雄联盟手游》说明称“100 局里 10 连败的概率接近 10%”[86]，与后一个数相符；
- 100 局中至少一次 5 连败：$q_5(100) \approx 81\%$。

更一般的连串分布及其在评分系统中的变化见第 3.2 节与 3.3 节。

A.3　第二章的推导与模拟参数

本节给出研究二（第二章）中较长的推导和全部模拟设定。记号同正文：$F(x) = 1/(1+10^{-x/400})$，$c = \ln 10/400$，$F'(x) = c\,F(x)\big(1-F(x)\big)$，$F'(0) = c/4$；$\sigma_d = 1.702/c \approx 295.7$。

A.3.1　模拟设定

所有模拟由 `code/ch2/model.py` 完成（numpy 向量化，固定随机种子），结果缓存在 `code/ch2/cache/`。共同设定：

- 玩家实力 $s \sim \mathcal{N}(1500, \tau^2)$，默认 $\tau = 200$；初始评分全部为 1500（刻度拉伸实验取初始评分等于实力）。
- 每轮每人恰好一局。标准实验 10,000 人、3,000 轮，前 1,000 轮预热，统计第 1,001–3,000 局（每人 2,000 局，个人胜率的二项标准误约 1.1 个百分点）。
- 1v1：$p = F(s_i - s_j)$，评分 $R_i \leftarrow R_i + K(y - E)$，$E = F(R_i - R_j)$。
- 5v5：加和模型 $p = F\big((\sum s_A - \sum s_B)/\sqrt{5}\big)$，均值模型 $p = F(\bar{s}_A - \bar{s}_B)$；每名队员按团队的 $K(y-E)$ 更新，E 用与结果模型相同的形式。
- 8 人自由混战：表现 $= s+\mathrm{Gumbel}$（尺度 $400/\ln 10$），评分按两两比较更新，$\Delta R_i = \frac{K}{7}\sum_{j\neq i}\big(S_{ij} - F(R_i - R_j)\big)$，$S_{ij} = 1$ 表示 i 名次在 j 之前。

- 匹配：随机匹配为每轮全体随机打乱后依次成组；按分匹配为按 $R+\mathcal{N}(0,\sigma_q^2)$ 排序后相邻成组，团队在 10 人组内蛇形分队（按评分排序后 ABBAABBAAB）。不使用任何隐藏变量。

表 A.1: 第二章的模拟实验（标准实验均为 10,000 人、3,000 轮、统计第 1,001–3,000 局）。

实验	设定	用于
1v1 随机匹配	$K=16,32$；另有 $\tau=100,300$；单局噪声 $\sigma_x=150$；AR(1) 状态 $\sigma_u=100$、$\phi=0.99$	图 2.1、2.3、2.2、2.10
1v1 按分匹配	$\sigma_q=20,50,100,200$，$K=16,32$；另有 $\sigma_q=100$ 加单局噪声或 AR(1) 状态	图 2.1、2.5、2.4、2.10
5v5	随机分队（加和、均值）；按分匹配 $\sigma_q=100$（加和、均值）、$\sigma_q=200$（加和）；$K=16$	图 2.2、2.8
8 人自由混战	随机组局、按分匹配 $\sigma_q=100$；$K=16$	第 2.5.2 节
K 扫描	4,000 人，2,500 轮，$K=8$–64，随机匹配与 $\sigma_q=100,200$	图 2.4(a)
重置实验	运行 1,000 轮后从实力前 10% 中重置 500 人为 1500，跟踪 400 局	图 2.6
刻度拉伸	2,000 人，初始评分 = 实力，$K=16$，10,000 轮，$\sigma_q=20,50,100,200$	图 2.7
进步实验	运行 1,000 轮后随机抽 2%（对照：10%）玩家每局进步 $v=0.25,0.5,1$，共 +300，再观察 200 局；$\sigma_q=100$	图 2.11

A.3.2　随机匹配与团队胜率

高斯恒等式。设 Z,Z' 独立标准正态。$\mathbb{E}[\Phi(a+bZ)]=\mathbb{E}[\mathbb{P}(Z'\le a+bZ\mid Z)]=\mathbb{P}(Z'-bZ\le a)=\Phi(a/\sqrt{1+b^2})$。取 $Z=(t-\mu)/\tau$、$a=(s-\mu)/\sigma_d$、$b=-\tau/\sigma_d$，即得式 (2.4)。数值表（表 2.1、2.3）不用正态近似，而是用 80 点 Gauss–Hermite 求积直接计算 $\mathbb{E}[F(X)]$；“前 10% 平均”对第 90–100 百分位的 20,001 个等距百分位点求平均。

团队。焦点玩家实力 $\mu+d$，$n-1$ 名队友与 n 名对手独立取自 $\mathcal{N}(\mu,\tau^2)$。加和模型下 $\sum s_A-\sum s_B=d+\sum_{i=1}^{n-1}(t_i-\mu)-\sum_{j=1}^{n}(o_j-\mu)$，均值为 d、方差 $(2n-1)\tau^2$，除以 $\sqrt{n}$ 得 $X\sim\mathcal{N}(d/\sqrt{n},(2n-1)\tau^2/n)$；均值模型除以 n。再套用高斯恒等式得式 (2.11)。$d=0$ 处的斜率：加和模型 $\phi(0)/\big(\sqrt{n}\sqrt{\sigma_d^2+(2n-1)\tau^2/n}\big)$，$n$ 大时 $\approx\phi(0)/\big(\sqrt{n}\sqrt{\sigma_d^2+2\tau^2}\big)$；均值模型 $\phi(0)/\big(n\sqrt{\sigma_d^2+(2n-1)\tau^2/n^2}\big)\approx\phi(0)/(n\sigma_d)$。

A.3.3　“五五开”对局的真实胜率

设 $s\sim\mathcal{N}(\mu,\tau^2)$，$R=s+e$，$e\sim\mathcal{N}(0,\sigma_e^2)$ 独立。由正态共轭，$s\mid R\sim\mathcal{N}\big(\mu+\frac{\tau^2}{\tau^2+\sigma_e^2}(R-\mu),\,v\big)$，$v=\tau^2\sigma_e^2/(\tau^2+\sigma_e^2)$。两名评分同为 r 的玩家，实力条件独立且均值相同，故 $\Delta s=s_A-s_B\sim\mathcal{N}(0,2v)$，与 r 无关。令 $p=F(\Delta s)$，$x=F^{-1}(p)$，$\mathrm{d}p/\mathrm{d}x=c\,p(1-p)$，换元得

$$f_p(p)=\frac{1}{\sigma_\Delta}\phi\Big(\frac{F^{-1}(p)}{\sigma_\Delta}\Big)\cdot\frac{1}{c\,p(1-p)},\qquad \sigma_\Delta=\sqrt{2v}.$$

p 的分位数为 $F(z_q\sigma_\Delta)$。团队加和模型下，给定两队评分和相等，$(\sum s_A-\sum s_B)/\sqrt{n}$ 的方差为 $2nv/n=2v$，只是 v 中的 σ_e 换成团队游戏的个人评分误差。

A.3.4　恒等式与评分误差的线性化

恒等式：$R_T-R_0=\sum_t\Delta R_t=K\sum_t(y_t-E_t)$，除以 KT 即得式 (2.6)；不需要任何模型假设，只要求每局更新恰为 $K(y_t-E_t)$。

稳态误差。按分匹配下对手评分 $R'\approx R$。令 $e=R-s$、$e'=R'-s'$，则 $y-E=\big[F(s-s')-F(R-R')\big]+\eta$，$\eta=y-F(s-s')$ 满足 $\mathbb{E}\eta=0$、$\mathrm{Var}\,\eta=p(1-p)\approx\frac14$。线性化 $F(s-s')-F(R-R')\approx-\frac{c}{4}(e-e')$，记 $k=Kc/4$：

$$e_{t+1}=(1-k)e_t+k\,e'_t+K\eta_t.$$

设 e,e',η 两两独立、$\mathrm{Var}\,e=\mathrm{Var}\,e'=V$，平稳时 $V=(1-k)^2V+k^2V+K^2/4$，解得

$$V=\frac{K^2}{8k(1-k)}=\frac{K}{2c\,(1-Kc/4)}.$$

略去对手误差（$e'\equiv0$）则为 $V=K^2/\big(4(2k-k^2)\big)\approx K/(2c)$，即表 2.2的第二列。评分刻度为 λ 时，实力差 $=(R-R'-e+e')/\lambda$，回复系数变为 $k_\lambda=Kc/(4\lambda)$，于是 $V=K\lambda/\big(2c(1-Kc/(4\lambda))\big)$，这就是按分匹配下误差略大的原因。

时间常数。理想情况下误差每局衰减 $1-k$，时间常数 $1/k=4/(Kc)\approx695/K$。一般情形需要两处修正。其一，线性化斜率应取 F' 在实际实力差上的平均，即 $c\,\mathbb{E}[P(1-P)]=\frac{c}{4}\cdot4\mathbb{E}[P(1-P)]$。其二，在附录 A.3.5的窗口模型下，玩家的期望评分变化为

$$\mathbb{E}[\Delta R]\approx K\tfrac{c}{4}\big[(s-\mu)-(1-g+bg)(R-\mu)\big],\qquad b=\frac{\lambda\tau^2}{\sigma_R^2},$$

其中 bg 来自“配到的对手评分向均值回归，其实力又按 b 回归”。把 $R-\mu=\lambda(s-\mu)+e$ 代入，e 的系数为 $-K\frac{c}{4}\big(1-g(1-b)\big)=-K\frac{c}{4}\cdot\frac{\lambda\tau^2+\sigma_q^2}{\sigma_R^2+\sigma_q^2}$。合并两处得 $\tau_R=4/(Kc\kappa)$，$\kappa=4\mathbb{E}[P(1-P)]\cdot(\lambda\tau^2+\sigma_q^2)/(\sigma_R^2+\sigma_q^2)$。随机匹配时 $\sigma_q\to\infty$，$\kappa\to4\mathbb{E}[P(1-P)]$，但 $\mathbb{E}[P(1-P)]$ 因人而异（实力越极端越小），群体的误差自相关是各人指数衰减的平均，图 2.4(b) 的随机匹配虚线即按此计算。

A.3.5　匹配窗口的边缘效应

设评分在群体中近似正态，均值 μ、方差 $\sigma_R^2 = \lambda^2\tau^2 + \sigma_e^2$。排序键 $k = R + \xi$，$\xi \sim \mathcal{N}(0, \sigma_q^2)$；人口足够多时，相邻者的键几乎相等。由正态共轭，$R' \mid k \sim \mathcal{N}\big(\mu + g(k-\mu),\, g\sigma_q^2\big)$，$g = \sigma_R^2/(\sigma_R^2 + \sigma_q^2)$。给定自己的 R，$k = R + \xi$，于是 $R' \mid R \sim \mathcal{N}\big(\mu + g(R-\mu),\, g^2\sigma_q^2 + g\sigma_q^2\big)$，即

$$R - R' \sim \mathcal{N}\big((1-g)(R-\mu),\; g(1+g)\sigma_q^2\big).$$

平稳时 $\Delta R/(KT) \to 0$，长期胜率等于平均预测胜率 $\bar{E} = \mathbb{E}[F(R - R')]$，用 $F \approx \Phi(\cdot/\sigma_d)$ 和高斯恒等式得式 (2.9)。计算时 λ 取平稳值 λ^*（附录 A.3.6），σ_e 取 $\sigma_e(K, \lambda^*)$；十分位平均对评分标准化位置 $z \in$ 最高 10% 求平均。配对两人评分差的方差为 $2g\sigma_q^2$（两人的 ξ 在给定相同键时各有条件方差 $g\sigma_q^2$，条件均值相同）。

A.3.6　刻度拉伸

精确结论。若一局双方评分相等，则 $E = \frac{1}{2}$，赛后两人评分为 $R \pm K/2$，两人评分平方和增加 $K^2/2$，平均每人 $K^2/4$；均值不变，所以群体评分方差每局增加 $K^2/4$。更一般地，只要给定自己的评分时对手实力与自己的实力可交换，就有 $\mathbb{E}[y - E \mid R] = 0$，进而 $\mathrm{Cov}(R, y - E) = 0$，于是 $\mathrm{Var}(R_{t+1}) = \mathrm{Var}(R_t) + K^2\,\mathrm{Var}(y - E)$，方差只增不减。真实实力分布不变，排序又近乎正确，增加的方差只能表现为斜率 λ 变大：$\lambda^2\tau^2 \approx \lambda_0^2\tau^2 + K^2 t/4$。

平均场方程。沿用附录 A.3.4的期望评分变化，把它投影到 s 上：

$$\frac{\mathrm{d}\lambda}{\mathrm{d}t} = \frac{\mathrm{Cov}(\mathbb{E}[\Delta R], s)}{\tau^2} = K\tfrac{c}{4}\big[1 - (1 - g + bg)\lambda\big].$$

代入 g、b 化简：$1 - (1 - g(1-b))\lambda = \big[\sigma_R^2 + \sigma_q^2 - \lambda\sigma_q^2 - \lambda^2\tau^2\big]/(\sigma_R^2 + \sigma_q^2) = \big[\sigma_e^2 + \sigma_q^2(1-\lambda)\big]/(\lambda^2\tau^2 + \sigma_e^2 + \sigma_q^2)$，即式 (2.10)。令分子为零得 $\lambda^* = 1 + \sigma_e^2(\lambda^*)/\sigma_q^2$；由于 $\sigma_e^2(\lambda) \approx \lambda\,\sigma_e^2(1)$，解得 $\lambda^* = 1/\big(1 - \sigma_e^2(1)/\sigma_q^2\big)$，仅当 $\sigma_q > \sigma_e(1)$ 时为正。$\sigma_q \to 0$ 时方程化为 $\mathrm{d}\lambda/\mathrm{d}t \approx K\frac{c}{4}\sigma_e^2/(\lambda^2\tau^2) = K^2/(8\lambda\tau^2)$，与精确结论一致。图 2.7 的虚线用步长 1 局的欧拉法积分这一方程，σ_e^2 取 $K\lambda/\big(2c(1 - Kc/(4\lambda))\big)$。

A.3.7　团队与自由混战的评分误差、Plackett–Luce 名次

Gumbel 表现与 Plackett–Luce。设表现 $X_i = s_i + bG_i$，G_i 独立标准 Gumbel，$b = 400/\ln 10$。标准 Gumbel 满足 $e^{-G} \sim$ 指数分布 (率 1)，所以 $Y_i = e^{-X_i/b} = e^{-s_i/b}e^{-G_i}$ 服从率为 $w_i = e^{s_i/b} = 10^{s_i/400}$ 的指数分布，且“表现最高”等价于“Y 最小”。独立指数变量中 Y_i 最小的概率为 $w_i/\sum_j w_j$；由无记忆性，最小值的大小与“谁最小”独立，去掉第一名后其余人仍是同样的结构，所以完整名次是依次按 worth 比例抽取的 Plackett–Luce 模型。$N = 2$ 时 $w_i/(w_i + w_j) = F(s_i - s_j)$，即两两边际恰为 Elo 曲线。焦点玩家 worth 为 w、其余 $N-1$ 人为 1 时，第 $j+1$ 次抽取 ($j = 0, \ldots, k-1$) 没有抽中焦点玩家的条件概率为 $(N - 1 - j)/(w + N - 1 - j)$，连乘取补即得式 (2.12)。

自由混战的评分误差。同水平的 N 人一局，名次均匀分布，$\sum_j S_{ij} = N-$名次 的方差为 $(N^2-1)/12$；步长 $K/(N-1)$ 使单局评分变化方差为 $K^2(N^2-1)/\big(12(N-1)^2\big) = K^2(N+1)/\big(12(N-1)\big)$。每局的回复力为 $\frac{K}{N-1}\sum_j F'(0) = K\frac{c}{4}$，与 1v1 相同，故方差之比为 $\frac{(N+1)/(12(N-1))}{1/4} = \frac{N+1}{3(N-1)}$，$N=8$ 时为 0.43，标准差之比 0.65。

团队中的个人评分误差（粗略）。加和模型下个人评分误差 e 对团队评分差的贡献为 $e/\sqrt{n}$，回复系数变为 $Kc/(4\sqrt{n})$；忽略其余 9 人的误差相关，套用附录 A.3.4得 $V \approx K\sqrt{n}/\big(2c(1-\sqrt{n}Kc/4)\big)$，$n=5$、$K=16$ 时标准差 57.2，模拟 57.7。均值模型的回复系数为 $Kc/(4n)$，误差更大。

A.3.8　状态起伏与窗口胜率的方差

评分对状态的吸收。在实力单位下把评分写成 $\hat{s}_t = (1-\alpha)\hat{s}_{t-1} + \alpha(s+u_t)+$ 噪声，$\alpha = 1/\tau_R$。状态部分 $x_t = \sum_{i\ge 0}\alpha(1-\alpha)^i u_{t-i}$。$u$ 为 AR(1)，$\mathrm{Cov}(u_{t-i},u_t) = \sigma_u^2\phi^i$，故

$$\mathrm{Cov}(x_t,u_t) = \alpha\sigma_u^2\sum_i\big[(1-\alpha)\phi\big]^i = \frac{\alpha\sigma_u^2}{1-(1-\alpha)\phi},$$

即式 (2.13)。记 $a_0 = 1-\alpha$，x 的自协方差可以递推得到：$\gamma_x(0) = \alpha^2\sigma_u^2(1+a_0\phi)/\big((1-a_0^2)(1-a_0\phi)\big)$，$k\ge 1$ 时

$$\gamma_x(k) = a_0^k\gamma_x(0) + \frac{\alpha^2\sigma_u^2}{1-a_0\phi}\cdot\frac{\phi\,(\phi^k - a_0^k)}{\phi - a_0}.$$

按分匹配下的窗口方差。由式 (2.6)，n 局窗口胜率 $W_n = \bar{E}_n + (R_{t+n}-R_t)/(Kn)$。第一项的局间波动来自窗口内对手评分的随机性，方差约 $\mathrm{Var}(E_t)/n$，其中 $\mathrm{Var}(E_t) = \mathrm{Var}\big(F(R-R')\big)$ 按附录 A.3.5的 $R-R'$ 分布计算 ($\sigma_q=100$、$K=16$ 时约 0.026)。第二项的方差为 $2[\Gamma(0)-\Gamma(n)]/(K^2n^2)$，评分（评分单位）的自协方差取 $\Gamma(k) = \lambda^2\gamma_x(k) + \sigma_e^2(1-\alpha)^k$，前者是对状态的跟踪，后者是评分噪声。除以二项方差 $p(1-p)/n \approx 1/(4n)$ 即得式 (2.14)。模拟中的方差比是“每人 $m = 2000/n$ 个连续窗口的样本方差”，期望值为 $\frac{m}{m-1}\big[D(n) - D(mn)/m^2\big]$，$D(h) = 2[\Gamma(0)-\Gamma(h)]$；图 2.10(b) 的曲线已含此修正，图 2.12(a) 取 $m\to\infty$。α 用修正后的时间常数，λ、σ_e 用平稳值 λ^*、$\sigma_e(K,\lambda^*)$，均不由模拟拟合。实力固定 ($\sigma_u = 0$) 且 $n \gg \tau_R$ 时，$\mathrm{Var}(R_{t+n}-R_t)\to 2\sigma_e^2$，$\mathrm{sd}(W_n)\approx\sqrt{2}\sigma_e/(Kn)$。

随机匹配下的窗口方差。此时胜负与评分无关，单局胜率 $p_t \approx p(s) + \beta(s)u_t$，$\beta(s)$ 为随机匹配胜率曲线在 s 处的斜率（对手的状态并入对手实力的离散，$\tau\to\sqrt{\tau^2+\sigma_u^2}$）。$n$ 局状态均值的方差为

$$V_n = \frac{\sigma_u^2}{n}\Big[\frac{1+\phi}{1-\phi} - \frac{2\phi(1-\phi^n)}{n(1-\phi)^2}\Big],$$

方差比约为 $1 + n\beta^2V_n/\big(p(1-p)\big)$，再对实力分布取平均，并作同样的样本方差修正。

A.3.9　进步时的胜率与滞后

实力以 v 每局上升，评分折算的实力 $\hat{s}=\mu+(R-a)/\lambda$ 的差距 $g=s-\hat{s}$ 满足 $\mathrm{d}g/\mathrm{d}t=v-\frac{1}{\lambda}\frac{\mathrm{d}R}{\mathrm{d}t}$，而 $\frac{\mathrm{d}R}{\mathrm{d}t}\approx K\frac{c}{4}g$。于是 g 以时间常数 $4\lambda/(Kc)$ 趋于 $g^{*}=4\lambda v/(Kc)$；稳态时 $\hat{s}$ 与 s 同速，$\mathrm{d}R/\mathrm{d}t=\lambda v$，由式 （2.6）得 $W-\bar{E}=\lambda v/K$。这里忽略了窗口回归（会使滞后略大）和零和池中其他玩家的下沉。

A.3.10　样本量与 8 人局指标

式 （2.16）是比例检验的正态近似。Wilson 区间为

$$\Big[\hat{p}+\frac{z^{2}}{2n}\pm z\sqrt{\frac{\hat{p}(1-\hat{p})}{n}+\frac{z^{2}}{4n^{2}}}\Big]\Big/\Big(1+\frac{z^{2}}{n}\Big).$$

8 人局同水平时名次均匀，平均名次的方差为 $(N^{2}-1)/12=5.25$；检验平均名次时用 $n=\big((z_{1-\alpha/2}\sigma_{0}+z_{1-\beta}\sigma_{1})/\delta\big)^{2}$，$\sigma_{0}=2.29$，$\sigma_{1}$ 与 δ 由 Plackett–Luce 名次分布算出。前四率 52% 对应 $d=10.9$ 分，此时第一名率 13.2%、平均名次 4.39、$\sigma_{1}=2.27$。若改用正态表现（Thurstone，$\beta=\sigma_{d}/\sqrt{2}$），所需局数为 3,472，与 Plackett–Luce 的 3,413 相近【本项目】。

A.4　第三章的推导与模拟参数

本节给出研究三（第三章）中较长的推导和全部模拟参数。代码在 `code/ch3/`：`model.py`（精确计算、单人模拟、统计量），`population.py`（人群模拟），`experiments.py`（单人实验与检验力），`ch3_numbers.py`（打印正文引用的全部数字），`fig_*.py`（各图）。

A.4.1　游程的精确计算

最长连败。　设各局独立，赢的概率为 p、输的概率为 q。记 $a_{n}=\mathbb{P}(L_{n}<r)$。若 $n<r$，必然 $L_{n}<r$，故 $a_{n}=1$。若 $n\ge r$，考虑第一场胜利的位置：前 j 局全输（$0\le j\le r-1$，否则已出现 r 连败）、第 $j+1$ 局赢，此后 $n-j-1$ 局中不能出现 r 连败，得到式 （3.1）。另一种做法是马尔可夫链：状态 $\ell=0,\dots,r-1$ 为当前尾部连败长度，转移 $\ell\to 0$（概率 p）、$\ell\to\ell+1$（概率 q），$\ell+1=r$ 时吸收。两种方法在所有检查点上一致到 10^{-5}，并与 Monte Carlo（10^{5} 条序列）一致到抽样误差以内。$\mathbb{E}L_{n}=\sum_{r\ge1}\mathbb{P}(L_{n}\ge r)$，$\mathbb{E}L_{n}^{2}=\sum_{r\ge1}(2r-1)\mathbb{P}(L_{n}\ge r)$。

连败段的期望个数。　一段 $\ge r$ 连败从第 1 局开始的概率为 q^{r}，从第 $i\ge2$ 局开始的概率为 pq^{r}（第 $i-1$ 局赢），可能的起点有 $n-r$ 个，故 $\mathbb{E}N_{r}=q^{r}[1+(n-r)p]$。

$\mathrm{W}^k\mathrm{L}^k$ 的精确性与变体。　子串 $\mathrm{W}^k\mathrm{L}^k$ 的任何真前缀都不是它的真后缀（前缀以 W 开头，后缀以 L 结尾），所以两次出现不重叠，每次出现与一个“左侧连胜 $\geq k$、右侧连败 $\geq k$ 的胜负交界”一一对应，期望由线性性直接得到式 (3.3)。“恰好 k 胜接恰好 k 负”要求两端再各有一个相反结果（或序列边界），内部位置的概率为 $p^{k+1}q^{k+1}$，$n = 1000$、$k = 4$、$p = 0.5$ 时期望为 0.97。“至少出现一次”用 KMP 自动机：状态 $0, \ldots, 2k-1$ 为已匹配的前缀长度，W/L 两种转移由失配函数给出，到达 $2k$ 即吸收；对 n 步做前向动态规划。

滑动窗口。　“存在某个 w 局窗口只赢 $\leq x$ 局”：以最近 $w-1$ 局的胜负（2^{w-1} 个状态）为状态做前向动态规划，每步把“加上本局后窗口胜场 $\leq x$”的概率质量移入吸收态。$w = 20$ 时状态数约 52 万，100 局约需数秒。$w = 50$ 无法精确计算，用 Monte Carlo（5×10^4 条序列）。

A.4.2　Miller–Sanjurjo 估计量的精确动态规划

估计量 $\hat{P}_k = \#\{t:\ y_{t-k} = \cdots = y_{t-1} = 1,\ y_t = 1\} / \#\{t:\ y_{t-k} = \cdots = y_{t-1} = 1\}$，只在分母大于 0 时有定义。前向动态规划的状态为 (s, c, w)：$s = \min(\text{当前连胜}, k)$，c 为至今合格局数（前面已有 k 连胜的局），w 为其中的胜局数。每一步：若 $s < k$，本局不是合格局，赢则 $s \to \min(s+1, k)$、输则 $s \to 0$；若 $s = k$，本局是合格局，$c \to c+1$，赢则 $w \to w+1$、s 保持为 k，输则 $s \to 0$。n 步后，$\mathbb{E}[\hat{P}_k \mid c > 0] = \sum_{c>0,w} \mathbb{P}(c, w)\,(w/c) / \mathbb{P}(c > 0)$。一次前向计算可以在每个中间步读出对应 n 的结果。$n = 20$ 时与 2^{20} 种序列的穷举一致；$k = 1$ 时与引理 1 的闭式（对 n_1 加权的 $(n_1 - 1)/(n-1)$）一致到机器精度。

“最近 100 局”若是更长职业生涯的一个窗口，窗口开头的连胜可能始于窗口之外；把前 k 局的状态也计入时，3 连胜后的期望为 46.2%，与 46.0% 几乎相同（计算见 `research_notes/` 中的 `verify_streaks.md`）。

A.4.3　诚实 Elo 均值回归的线性高斯推导

设定。　记 e_t 为玩家评分相对“公平评分”的误差（评分单位），n 为每队人数。按评分匹配时，系统预测胜率 $E_t = F(\text{双方评分差}) \approx \frac{1}{2}$。真实胜率对自己评分误差的线性敏感度写成 $g = \kappa c/(4n)$：$c/4$ 是 F 在 0 处的斜率，$1/n$ 来自团队平均，κ 是“评分误差传到真实胜率的比例”。单人对校准对手池时，对手的真实实力就是对手评分 $= R_t + \eta_t$，于是 $p_t = F(-e_t - \eta_t)$，$\kappa = 1$（对 η 平均后实际斜率略小，$\sigma_q = 50$ 时约 0.98）。闭合人群中，评分刻度相对实力拉伸了 λ 倍并带有误差，我的评分升高 Δ 时，同评分对手的期望实力升高 $\Delta \cdot \beta_{s|R}$，其中 $\beta_{s|R} = \mathrm{Cov}(s, R)/\operatorname{Var} R = \rho_{Rs}^2/\lambda$ 是实力对评分的回归斜率，于是 $\kappa \approx \beta_{s|R}$。匹配窗口远宽于人群的评分离散时，同评分的对手不再跟随我的评分（向人群中部回归），κ 进一步减小，随机匹配时 $\kappa \to 0$；这时式(3.5)高估效应（表 3.3中 $\sigma_q \geq 200$ 的行）。

稳态。　$y_t = p_t + \xi_t$，$\mathbb{E}\xi_t = 0$，$\operatorname{Var}\xi_t = p_t(1-p_t) \approx \frac{1}{4}$。Elo 更新 $e_{t+1} = e_t + K(y_t - E_t)$。代入 $p_t - E_t \approx -g\,e_t + \zeta_t$（$\zeta_t$ 汇集对手误差和排队噪声，与 e_t 独立，对均值无贡献），得 $e_{t+1} = (1-b)e_t + K\xi_t + K\zeta_t$，$b = gK$。忽略 ζ 的方差贡献（它的量级为 $(Kc/4)^2\sigma_\zeta^2$，在本章参数下不到 $K^2/4$ 的 3%），

$$\sigma_e^2 = \frac{K^2/4}{1-(1-b)^2} = \frac{K^2}{4b(2-b)}.$$

$n = \kappa = 1$ 时，$\sigma_e^2 = K/[c(2-b)] \approx (200/\ln 10)\,K/(1-cK/8)$，即 $\sigma_e \approx 9.3\sqrt{K}$。

条件期望。　事件 $A_k = \{y_{t-k} = \cdots = y_{t-1} = 1\}$ 等价于“第 t 局开始时连胜 $\geq k$”。在 A_k 上，评分每局增加 $K(1-E) \approx K/2$，故 $e_t = e_{t-k} + kK/2$（忽略 η 带来的二阶修正）。e_{t-k} 的先验为 $\mathcal{N}(0, \sigma_e^2)$。给定 e_{t-k}，k 场胜利的似然为 $\prod_{m=0}^{k-1}\left(\frac{1}{2} - g\,e_{t-k+m} + \dots\right)$；一阶近似下 $\log(\frac{1}{2} - ge) \approx -\ln 2 - 2ge$，而 $e_{t-k+m} - e_{t-k}$ 在 A_k 上是确定的（$mK/2$），所以似然对 e_{t-k} 的依赖为 $\exp(-2gk\,e_{t-k})$。高斯先验乘以指数倾斜仍是高斯，均值平移 $-2gk\sigma_e^2$，方差不变。于是

$$\mathbb{E}[e_t \mid A_k] = \frac{kK}{2} - 2gk\,\frac{K^2}{4b(2-b)} = \frac{kK}{2} - \frac{kK}{2(2-b)} = \frac{kK(1-b)}{2(2-b)},$$

超额胜率 $\Delta_k = -g\,\mathbb{E}[e_t \mid A_k]$，即式 (3.5)。图 3.4 的理论曲线还用到：连胜开始前，平稳高斯 AR(1) 在时间反演下的回归系数仍为 $(1-b)^j$，故 $\mathbb{E}[e_{t-k-j} \mid A_k] \approx (1-b)^j\,\mathbb{E}[e_{t-k} \mid A_k]$；连胜结束后未来不受条件约束，$\mathbb{E}[e_{t+h} \mid A_k] = (1-b)^h\mathbb{E}[e_t \mid A_k]$。

滞后 1 自相关。　$\operatorname{Cov}(y_t, y_{t+1}) = g^2\operatorname{Cov}(e_t, e_{t+1}) - g\operatorname{Cov}(\xi_t, e_{t+1}) = g^2(1-b)\sigma_e^2 - gK/4 = -\frac{gK}{4}\cdot\frac{1}{2-b}$，除以 $\operatorname{Var} y \approx \frac{1}{4}$ 得 $\rho_1 \approx -gK/(2-b) = -\kappa cK/[4n(2-b)]$。单人检出所需局数取 $n^* = (z_{0.975} + z_{0.8})^2/\rho_1^2$。模拟中 ρ_1 用“按玩家去均值后合并”的估计量，它在独立序列下的期望为 $-1/T$，表中的 ρ_1 和 n^* 已用玩家内打乱的序列扣除这一偏差。

A.4.4　AR(1) 吸收与结果自相关

线性化系统为

$$u_t = \rho u_{t-1} + \varepsilon_t, \qquad x_{t+1} = (1-b)x_t + b\,u_t + K\xi_t, \qquad y_t = \tfrac{1}{2} + g(u_t - x_t) + \xi_t,$$

$\operatorname{Var}\varepsilon = \sigma_u^2(1-\rho^2)$，$\operatorname{Var}\xi = \frac{1}{4}$，$x_t = R_t - s$。记 $D_t = u_t - x_t = \sum_{m\geq 0}\psi_m\varepsilon_{t-m} + \sum_{m\geq 1}\phi_m\xi_{t-m}$，其中 $\phi_m = -K(1-b)^{m-1}$，$\psi_m = \rho^m - b\sum_{i=0}^{m-1}(1-b)^i\rho^{m-1-i}$（$m \geq 1$），$\psi_0 = 1$。于是对 $h \geq 1$，

$$\operatorname{Cov}(y_t, y_{t+h}) = g^2\Big[\sigma_\varepsilon^2\sum_m \psi_m\psi_{m+h} + \tfrac{1}{4}\sum_m \phi_m\phi_{m+h}\Big] + \tfrac{1}{4}\,g\,\phi_h,$$

除以 $\frac{1}{4}$ 即得自相关；数值上把无穷和截断到 4000 项（`model.linear_outcome_acf`）。$K = 0$ 时 $\phi \equiv 0$、$\psi_m = \rho^m$，退化为式 (3.8)；$\sigma_u = 0$ 时退化为诚实 Elo 的 $\rho_h =$

$-\frac{gK}{2-b}(1-b)^{h-1}$。只保留 ε 部分并取 $h=0$，即得式 (3.9) 的方差比。F 偏离 0 后变平，线性近似会高估自相关；图 3.7(b) 用 $\kappa_F=\mathbb{E}[F'(X)]/F'(0)$ 代替 κ，$X\sim\mathcal{N}(0,\operatorname{Var}D+\sigma_q^2)$，修正后与模拟的差距在 0.002 以内（其中约 0.001 是估计量的 $-1/T$ 偏差）。

A.4.5　马尔可夫调制的伯努利序列

评分不动($K=0$)时，两状态、上头、疲劳模型都可以写成：隐藏状态 $z\in\{1,\dots,Z\}$ 决定单局胜率 p_z，下一状态的分布可依赖本局胜负。定义两个 $Z\times Z$ 矩阵

$$T_W[z,z']=\mathbb{P}(\text{胜},\,z_{t+1}=z'\mid z_t=z),\qquad T_L[z,z']=\mathbb{P}(\text{负},\,z_{t+1}=z'\mid z_t=z),$$

$M=T_W+T_L$。则（行向量 π 为 M 的平稳分布，$\boldsymbol{p}$ 为 p_z 组成的列向量）：

- 长期胜率 $\bar{p}=\pi\boldsymbol{p}$；
- $\mathbb{P}(\text{胜}\mid\text{最近}k\text{ 局全负})=\pi T_L^k\boldsymbol{p}/\pi T_L^k\mathbf{1}$，连胜同理；
- $\mathbb{P}(y_t=1,y_{t+h}=1)=\pi T_W M^{h-1}\boldsymbol{p}$，由此得自相关；
- 最长连败 $<r$ 的概率：在增广状态 (z,ℓ)（$\ell<r$ 为当前连败）上做前向计算，胜：$(z,\ell)\to(z',0)$ 用 T_W，负：$(z,\ell)\to(z',\ell+1)$ 用 T_L，$\ell+1=r$ 时吸收；
- 模式计数：在 $(z,$自动机状态$)$ 上做前向计算，每次到达 $2k$ 时把概率质量计入期望次数并回到 0；
- 一段连败开始后长度 $\geq r$ 的概率：$v_1=\pi T_W T_L$，$v_r=v_{r-1}T_L$，$\mathbb{P}=v_r\mathbf{1}/v_1\mathbf{1}$。

三种模型的 T_W,T_L：两状态模型 $T_W=\operatorname{diag}(\boldsymbol{p})P$、$T_L=\operatorname{diag}(\mathbf{1}-\boldsymbol{p})P$；上头模型的状态为截断到 m 的连败 L，胜则到 0，负则到 $\min(L+1,m)$，有休息时负后以休息概率回到 0；疲劳模型的状态为局序号 j（截断到 80），每局后以休息概率回到 1、否则 $j+1$，转移与胜负无关。各模型的 $p_z=\mathbb{E}_\eta F(u_z-\eta)$，$\eta\sim\mathcal{N}(0,50^2)$，用 41 点高斯–埃尔米特求积计算。精确值与单人模拟一致到抽样误差（如上头模型 $\mathbb{P}(L_{1000}\geq10)$：精确 0.935，模拟 0.933）。

A.4.6　模拟参数

图与脚本的对应（图 3.1 至图 3.13，按出现顺序）：`fig_longest_run`、`fig_pattern_window`、`fig_ms_bias`、`fig_elo_event`、`fig_elo_reversion`、`fig_models_traj`、`fig_ar_absorb`、`fig_tilt_chain`、`fig_fatigue_session`、`fig_models_conditional`、`fig_models_longest`、`fig_power`、`fig_manip`、`fig_bg_drought`，均为 `code/ch3/` 下的 `.py` 脚本。

模型的局限需要如实说明：人群模拟假设正态实力、模型设定正确、固定 K、封闭人群、人人每轮都打、无组排和流失；窄窗口与按评分蛇形分队时评分刻度在统计期内仍在拉伸，相应数字只是快照。真实游戏多用 Glicko、TrueSkill 一类变步长系统，本章的固定 K 结果只给出效应量的量级和区间。所有实力波动参数都是示意值。

表 A.2: 第三章的模拟设定。所有随机种子固定，脚本可独立重现；重模拟结果缓存在 `code/ch3/cache/`。

项目	设定
人群模拟（第 3.3 节、第 3.6 节，`population.py`）	$N = 10{,}000$；实力 $s \sim \mathcal{N}(0, 200^2)$；评分从 0 起步；每轮所有人各打一局；预热 1500 轮后记录 2000 局/人。匹配键 = 评分 + $\mathcal{N}(0, \sigma_q^2)$（+ 操纵偏移），1v1 排序后相邻配对（默认 $\sigma_q = 100$），5v5 每 10 人一房间（$\sigma_q = 250$），随机分队或按评分蛇形分队。团队强度 = 5 人有效实力均值。Elo：$R \leftarrow R + K(y - F(\Delta R))$，团队成员同增减。上头：有效实力 $s - \theta \min(L, m)$，$\theta = 30$、$m = 3$。操纵：M1 匹配键 ± 100（连胜/连败 ≥ 3），M2 只 $+100$，M3 分队时评分按 ± 300 计。“超额”均为玩家内部：$\mathbb{E}$[量 | 状态] 减该玩家自身平均。连败统计取两个 1000 局半段，与玩家内打乱的序列对比。种子 3101–3143。
单人模拟（第 3.3 节、第 3.4 节，`experiments.py`）	一名平均实力为 0 的玩家对校准对手池：对手实力 = 对手评分 = 我的评分 + $\mathcal{N}(0, 50^2)$。评分不动（$K = 0$）或 Elo $K = 20$（波动模型）、$K = 10/32$（图 3.4、图 3.5(a)）。预热 400 局；标准模型 2×10^4 名玩家 × 1000 局；事件研究 $4 \times 10^4 \times 400$；AR 吸收 4000×3000。休息：每局后以 1/8 概率结束本次游玩（疲劳与带休息的上头）。波动参数见表 3.4。
检验力（第 3.4.7 节）	每个模型 3000 名玩家 × 4000 局，取前 $T \in \{100, 200, 500, 1000, 2000, 4000\}$ 局。零分布：无波动模型 8000 名玩家（(a)(b) 为 $K = 0$ 的独立序列，(c) 为诚实 Elo $K = 20$ 的残差）。检验：滞后 1 自相关；y_t（或残差）对 $\min(L_{t-1}, 3)$ 的斜率；非重叠 10 局分块胜场方差 / 二项方差（残差版为分块残差平方和 / $\sum F(1-F)$）；对 $\min(j_t, 15)$ 的斜率。双侧 5%。残差版先对每名玩家用牛顿法求常数实力 $\hat{s}$ 的最大似然。
精确计算	最长连败、模式、滑动窗口（$w \leq 20$）、Miller–Sanjurjo、马尔可夫调制链：见上文；8 人游戏的“无冠”即 $q = 7/8$ 的最长连败。

A.5　第四章的推导

本节的解析数字都可以用 `python code/ch4/derivations_check.py` 独立复算；图的参数见附录 A.5.7。

A.5.1　Elo 更新与随机梯度下降

正文式 (4.1) 对 $y \in \{0, \frac{1}{2}, 1\}$ 都成立：平局时标签取 $\frac{1}{2}$，交叉熵 $-[y\ln p + (1-y)\ln(1-p)]$ 仍有梯度 $-c(y-p)$，所以 Elo 对平局的处理等价于“软标签”。若队伍强度取成员评分之和，$p = \sigma\big(c(\sum_{i\in A} R_i - \sum_{j\in B} R_j)\big)$，则每名成员的梯度都是 $-c(y-p)$，一步 SGD 给全队每人相同的 $K(y-p)$；TrueSkill 论文里 Elo 对团队局与多人局用的“对决启发式”则是对每名玩家与其余每人逐一比较后取平均更新[1]。批量版本（对全部历史对局一次性最大化似然）就是 Bradley–Terry 极大似然[9]，即 Chatbot Arena 现在的做法。

A.5.2　固定 K 的稳态误差与最优 K

设第 t 局对手评分为 R_t^{opp} 且准确，系统预测 $E_t = F(R_t - R_t^{\text{opp}})$，真实胜率 $p_t = F(s_t - R_t^{\text{opp}})$，误差 $e_t = R_t - s_t$。则

$$y_t - E_t = (y_t - p_t) + (p_t - E_t) \approx \xi_t - c\,p_t(1-p_t)\,e_t, \qquad \xi_t = y_t - p_t,\ \mathrm{Var}(\xi_t) = p_t(1-p_t).$$

实力每局随机游走 $s_{t+1} = s_t + w_t$，$w_t \sim \mathcal{N}(0, \sigma_w^2)$，于是 $e_{t+1} = (1-a)e_t + K\xi_t - w_t$，$a = Kc\,p(1-p)$。三项互相独立，稳态方差满足 $V = (1-a)^2 V + K^2 p(1-p) + \sigma_w^2$，即正文式 (4.3)。取 $p(1-p) = \frac{1}{4}$：

$$V(K) \approx \frac{K}{2c} + \frac{2\sigma_w^2}{Kc}, \qquad V'(K) = 0 \Rightarrow K^* = 2\sigma_w, \qquad V(K^*) = \frac{2\sigma_w}{c}.$$

数值最优（保留 a^2 项）与近似几乎一致：$\sigma_w = 2, 4, 10$ 时 $K^* = 3.99, 7.95, 19.7$，最小均方根误差 26.4、37.4、59.4 Elo。误差的确定性部分按 $(1-a)^t$ 衰减，时间常数 $1/a = 4/(Kc)$，$K = 8, 16, 32$ 时分别约 87、43、22 局。按分匹配有噪声 σ_q 时 $\mathbb{E}[p(1-p)]$ 略小于 $\frac{1}{4}$（$\sigma_q = 50$ 时约 0.248），结论不变。

A.5.3　TrueSkill 两人更新、学习率与稳态

两人无平局时，表现 $\pi_A \sim \mathcal{N}(s_A, \beta^2)$、$\pi_B \sim \mathcal{N}(s_B, \beta^2)$，$A$ 胜当且仅当 $d = \pi_A - \pi_B > 0$。在信念 $s_A \sim \mathcal{N}(m_A, \varsigma_A^2)$、$s_B \sim \mathcal{N}(m_B, \varsigma_B^2)$ 下，$d \sim \mathcal{N}(m_A - m_B, \tilde{c}^2)$，$\tilde{c}^2 = 2\beta^2 + \varsigma_A^2 + \varsigma_B^2$，$\mathbb{P}(A \text{ 胜}) = \Phi(t)$，$t = (m_A - m_B)/\tilde{c}$。截断高斯的矩为 $\mathbb{E}[d \mid d>0] = (m_A - m_B) + \tilde{c}\,v(t)$、$\mathrm{Var}(d \mid d>0) = \tilde{c}^2[1 - w(t)]$，其中 $v = \phi/\Phi$，$w = v(v+t)$。s_A 与 d 联合高斯、协方

差为 ς_A^2，故

$$\mathbb{E}[s_A \mid d>0] = m_A + \frac{\varsigma_A^2}{\tilde{c}} v(t),$$
$$\operatorname{Var}(s_A \mid d>0) = \varsigma_A^2 - \frac{\varsigma_A^4}{\tilde{c}^2} + \frac{\varsigma_A^4}{\tilde{c}^4}\operatorname{Var}(d \mid d>0) = \varsigma_A^2\Big[1 - \frac{\varsigma_A^2}{\tilde{c}^2} w(t)\Big].$$

把后验按矩匹配近似为高斯，就是正文式 (4.2)；败者把 $+v$ 换成 $-v$。用数值积分对新玩家情形做矩匹配，均值增量与闭式一致到小数点后四位【本项目】。

学习率解释。把 $\tilde{c}$ 视为常数，有

$$\frac{\partial \log \Phi(t)}{\partial m_A} = \frac{v(t)}{\tilde{c}}, \qquad \Delta m_A = \varsigma_A^2 \cdot \frac{\partial \log \Phi(t)}{\partial m_A},$$

即均值更新是学习率为 ς_A^2 的一步梯度上升。精度的变化为 $1/\varsigma_A'^2 \approx 1/\varsigma_A^2 + w(t)/\tilde{c}^2$，而 $w(t) = -\partial^2 \log \Phi(t)/\partial t^2$ 正是 probit 似然的观测信息，所以 n 局后 $\varsigma_A^2 \approx 1/(1/\varsigma_0^2 + \sum w/\tilde{c}^2)$，学习率约按 $1/n$ 递减。

稳态。TrueSkill 在每局前给方差加上 σ_w^2（Xbox Live 取 $\sigma_w = \varsigma_0/100$）[1]。设赛前方差为 $S^2 = \varsigma^2 + \sigma_w^2$，对手处于同样的稳态、对局势均力敌（$t=0$），不动点条件为

$$S^2 - \sigma_w^2 = S^2\Big[1 - \frac{S^2 w(0)}{2\beta^2 + 2S^2}\Big] \iff \sigma_w^2 = \frac{S^4\, w(0)}{2\beta^2 + 2S^2}, \qquad w(0) = 2/\pi.$$

取 $\varsigma_0 = 25/3$、$\beta = \varsigma_0/2$、$\sigma_w = \varsigma_0/100$，解得 $S \approx 0.791$，势均力敌赢一局 $\Delta m = S^2 v(0)/\tilde{c} \approx 0.0833$ 单位。刻度换算：令 probit 胜率 $\Phi\big(\Delta/(\sqrt{2}\beta)\big)$ 与 Elo 曲线在 0 处斜率相等，β 对应 $4\phi(0)/(\sqrt{2}c) \approx 196$ Elo，1 单位约 47.0 Elo。于是稳态等效 $K = 2\Delta m \approx 7.8$ Elo，而 $\sigma_w \approx 3.92$ Elo/局，$K^* = 2\sigma_w \approx 7.8$：在线性高斯近似下，卡尔曼滤波的稳态增益就是均方误差最小的固定增益。新玩家第一局（双方 ς_0）势均力敌地赢，$\Delta m \approx 4.21$ 单位，约 198 Elo。

A.5.4　评分噪声为什么让预测过于自信

设真实实力差 $d \sim \mathcal{N}(0, 2\tau^2)$，评分差 $\hat{d} = d + \varepsilon$，$\varepsilon \sim \mathcal{N}(0, 2\sigma_e^2)$ 与 d 独立。则 $d \mid \hat{d} \sim \mathcal{N}(\lambda \hat{d},\, 2\sigma_e^2\lambda)$，$\lambda = \tau^2/(\tau^2 + \sigma_e^2)$。用 logistic 的 probit 近似 $\mathbb{E}[\sigma(X)] \approx \sigma\big(\mathbb{E}X/\sqrt{1 + \pi \operatorname{Var} X/8}\big)$：

$$\mathbb{P}(y=1 \mid \hat{d}) = \mathbb{E}[\sigma(cd) \mid \hat{d}] \approx \sigma\left(\frac{c\lambda \hat{d}}{\sqrt{1 + \pi c^2 \sigma_e^2 \lambda/4}}\right) \Rightarrow \hat{\gamma} \approx \frac{\lambda}{\sqrt{1 + \pi c^2 \sigma_e^2 \lambda/4}}.$$

两个因子分别是“向均值收缩”（评分差偏大的配对，有一部分是评分误差）和“模糊”（同一评分差对应一个实力差的分布）。代入图 4.2模拟中测得的评分误差（$K = 16, 32, 64$ 时 37.9、54.3、80.8 Elo），得 $\hat{\gamma} \approx 0.95, 0.90, 0.80$，模拟拟合值为 0.95、0.87、0.77；差距来自近似忽略了评分误差与实力、与对手之间的相关。Szczecinski 给出了考虑这两项的更一般的刻度修正[16]。

A.5.5　零假设下的残差检验与游程检验

记 $\mathcal{F}_{t-1}$ 为第 t 局开始前的全部信息（含对手评分），零假设 H_0：$\mathbb{P}(y_t=1\mid\mathcal{F}_{t-1})=\hat{p}_t$。则 $r_t=y_t-\hat{p}_t$ 满足 $\mathbb{E}[r_t\mid\mathcal{F}_{t-1}]=0$、$\mathrm{Var}(r_t\mid\mathcal{F}_{t-1})=\hat{p}_t(1-\hat{p}_t)$。对任何由 $\mathcal{F}_{t-1}$ 决定的 g_t，$M_n=\sum_{t\le n}g_tr_t$ 是有界增量鞅，其可预测二次变差为 $\sum g_t\hat{p}_t(1-\hat{p}_t)$，由鞅中心极限定理得正文式 (4.5)。关键在于“可预测”：分组只能用赛前信息，不能用本局结果。

差异检验。对两组 $k\in\{0,1\}$，$\theta_k=\sum_{g_t=k}r_t/B_k$，$B_k=\sum_{g_t=k}\hat{p}_t(1-\hat{p}_t)$，$z=(\theta_1-\theta_0)/\sqrt{1/B_1+1/B_0}$。若冻结模型的 $\hat{S}$ 偏了 ϵ，则 r_t 约平移 $-c\hat{p}_t(1-\hat{p}_t)\epsilon$，两组的 θ_k 都平移 $-c\epsilon$，在差中抵消。

朴素游程检验为什么失效。记 $I_t=\mathbb{1}(y_t\neq y_{t-1})$，游程数为 $1+\sum_{t\ge2}I_t$。若把 $\hat{p}_t$ 当作与过去结果无关的常数，$\mathbb{E}I_t=\hat{p}_t(1-\hat{p}_{t-1})+\hat{p}_{t-1}(1-\hat{p}_t)$，方差还要加上相邻项的协方差 $\mathbb{E}[I_tI_{t+1}]-\mathbb{E}I_t\,\mathbb{E}I_{t+1}$，其中 $\mathbb{E}[I_tI_{t+1}]=\hat{p}_{t-1}(1-\hat{p}_t)\hat{p}_{t+1}+(1-\hat{p}_{t-1})\hat{p}_t(1-\hat{p}_{t+1})$。但按分匹配下 $\hat{p}_t$ 依赖 y_{t-1}：输一局后评分下降、下一局对手变弱、$\hat{p}_t$ 变大，胜负更容易交替，游程数系统性偏多。图 4.5c 中这一检验在诚实 Elo 下一万局的误报率约 62%。

鞅修正。用条件期望 $\mathbb{E}[I_t\mid\mathcal{F}_{t-1}]=y_{t-1}(1-\hat{p}_t)+(1-y_{t-1})\hat{p}_t$。分 $y_{t-1}=0$ 与 $y_{t-1}=1$ 两种情况验证可得

$$I_t-\mathbb{E}[I_t\mid\mathcal{F}_{t-1}]=(1-2y_{t-1})\,(y_t-\hat{p}_t),\qquad z_{\mathrm{runs}}=\frac{\sum_t(1-2y_{t-1})\,r_t}{\sqrt{\sum_t\hat{p}_t(1-\hat{p}_t)}},$$

即“输后残差之和减赢后残差之和”，与差异检验等价。

与 Miller–Sanjurjo 偏差的关系。在一条有限的独立序列里，先算“连胜（败）之后的成功比例”再在序列间平均，期望会偏离真实概率[173]；这里把所有触发局的残差**汇总**后再标准化，$\mathbb{E}[\sum g_tr_t]=0$ 精确成立，不受此偏差影响。

对手评分差检验。$G_t=R_t^{\mathrm{opp}}-R_t$，比较触发组与其余对局的均值（合并方差的两样本 t 检验）。它不需要任何胜率模型，只需要对手评分。

A.5.6　Plackett–Luce 的梯度、Fisher 信息与样本量

对式 (4.6) 取对数，$\log\mathbb{P}(\pi)=\sum_{i=1}^{N}\big[\theta_{\pi(i)}-\log\sum_{j\ge i}e^{\theta_{\pi(j)}}\big]$。$\theta_k$ 只在 $\pi(i)=k$ 的那一项出现一次（贡献 1），并在 k 仍在场的每一步 $i\le r_k$ 的归一化项中出现（贡献 $-P_i(k)$），于是梯度为 $1-\sum_{i\le r_k}P_i(k)$。把“第 i 步是否选中 k”看作伯努利增量，$\sum_{i\le r_k}[\mathbb{1}(\pi(i)=k)-P_i(k)]$ 是一个鞅在停时 r_k 处的值，故期望为 0、方差为 $\mathbb{E}\sum_{i\le r_k}P_i(k)[1-P_i(k)]$，即 Fisher 信息。等强时第 i 步还剩 $m=N-i+1$ 人，$P_i(k)=1/m$，k 仍在场的概率为 m/N：

$$I_N=\sum_{m=1}^{N}\frac{m}{N}\cdot\frac{1}{m}\Big(1-\frac{1}{m}\Big)=1-\frac{H_N}{N},\qquad I_2=0.25,\quad I_8=1-\frac{2.718}{8}\approx0.660.$$

蒙特卡洛（20000 局）得梯度方差 0.656。$N=2$ 时回到 Bradley–Terry 的 $\frac{1}{4}$。

样本量。对已知基准做 5% 双侧检验、80% 检验力，$n = \left[(z_{0.975} + z_{0.8})\,\sigma/\delta\right]^2$。前四率 $\sigma = 0.5$、$\delta = 0.02$ 得 4,906 局；平均名次在等强时 $\sigma = \sqrt{(N^2-1)/12} = 2.291$，$\delta = 0.1$ 得 4,121 局，$\delta = 0.25$ 得 659 局。两个版本互比时差值的方差加倍，每个版本需 $2n$（9,811 局与 8,241 局）。若参照池强于或弱于被测版本，名次分布不再均匀，σ 略小，所需局数略少。

AlphaGo Zero 的评估门槛。400 局中胜率需超过 55%，即至少 221 胜。真实胜率为 50%、52%、55%、60% 时，通过概率分别为 0.020、0.105、0.481、0.976（二项分布精确值）。

A.5.7　模拟参数与脚本

表 A.3: 第四章各图的脚本与参数（脚本均可在仓库根目录用 `python code/ch4/`加脚本名独立运行，固定随机种子）

图与脚本	模型与参数
图 4.1 `fig_k_tradeoff.py`	一名玩家按分匹配，对手评分 $= R_t$ 且准确；(a) 600 局，第 200 局实力 $+200$；(b) $K \in \{2,\dots,64\}$，$\sigma_w \in \{0,3,10\}$，200 次重复 $\times$ 24000 局，丢弃前 4000 局；缓存 `cache/k_tradeoff.npz`
图 4.2 `fig_calibration.py`	2000 人，实力 $\mathcal{N}(0,200^2)$，评分初值 0，每轮每人一局；(a) 随机匹配，$K = 16, 32, 64$，前 300 轮收敛、后 300 轮评估，预测按 0.05 分箱（每箱至少 200 局）；(b) $K = 16$，随机匹配与按分匹配（$\sigma_q = 25$，按评分加噪声排序后相邻配对），前 500 轮收敛、后 1000 轮统计
图 4.3 `fig_coinflip.py`	解析式
图 4.4 `fig_fisher.py`	
图 4.5 `fig_residual_tests.py`	$K = 16$，对手评分 $= R_t + m_t + \mathcal{N}(0,50^2)$ 且准确；先 2000 局收敛，冻结 $\hat{S}$ 为最后 1000 局平均评分；检验用随后 $N \in \{100,\dots,10^4\}$ 局；上头 $\delta \in \{0,25,50,100\}$（上一局输则本局实力 $-\delta$）；连败保护：前两局皆输则 $m_t = -100$；每场景 2000 次重复
图 4.7 `fig_pfsp.py`	解析式
图 4.6 `fig_selfplay_inflation.py`	$\mathbb{P}(i \text{ 胜} j) = \sigma\big(1.5\sin(\theta_i - \theta_j) + (h_i - h_j)\big)$，每代 $\Delta\theta = 0.35$，$\Delta h \in \{0, 0.05\}$，60 代，每代对上一代 400 局；参照池为 16 个 θ 均匀分布、$h = 0$ 的智能体
图 4.8 `fig_bg_placement.py`	Plackett–Luce，log 强度 $= c \cdot s$，一名玩家强 $\Delta \in \{0, 100, 200\}$，其余 7 人等强；样本量公式见上